

Sprint 6: Datos listos para modelar

Una introducción práctica al ecosistema de datos en Python: desde la comprensión del rol del Data Scientist hasta la exploración visual de conjuntos de datos reales. En este sprint aprenderás a cargar, inspeccionar y visualizar datos con las herramientas más utilizadas en la industria.

S6.1 · DATOS, PANDAS Y VISUALIZACIÓN EXPLORATORIA

¿Qué hace un Data Scientist?

El Data Scientist actúa como puente entre los datos brutos y las decisiones de negocio. Sus responsabilidades abarcan todo el ciclo de vida del dato, desde la recolección hasta la comunicación de resultados.



Explorar y limpiar

Identificar problemas en los datos: valores nulos, outliers, inconsistencias y formatos incorrectos antes de cualquier análisis.



Modelar y predecir

Aplicar algoritmos de machine learning y estadística para construir modelos que respondan preguntas concretas del negocio.



Comunicar resultados

Traducir hallazgos técnicos a un lenguaje comprensible para equipos no técnicos, usando visualizaciones y narrativa clara.



Diseñar pipelines

Construir flujos de trabajo reproducibles y escalables para que los análisis puedan ejecutarse de forma continua y automatizada.

Comparativa de Tipos de Dato

Cada tipo de dato tiene características propias que condicionan las técnicas de análisis y los modelos aplicables. Esta tabla resume las diferencias clave.

Característica	Estructurado	No estructurado	Series temporales
Formato	Tablas, CSV, SQL	Texto, imagen, audio	Tabla indexada por tiempo
Herramientas	pandas, SQL	NLP, CNN, OCR	pandas, statsmodels
Volumen típico	Medio	Alto	Medio-alto
Ejemplo	Tabla de clientes	Reseñas de productos	Precio de acciones

Primeros Pasos con pandas

Cargar e inspeccionar un dataset son las primeras acciones en cualquier proyecto de datos. pandas ofrece funciones específicas para cada etapa del proceso de exploración inicial.

Carga de datos

```
import pandas as pd

# Cargar desde CSV
df = pd.read_csv("datos.csv")

# Cargar desde Excel
df = pd.read_excel("datos.xlsx")

# Cargar desde JSON
df = pd.read_json("datos.json")
```

Inspección básica

```
# Primeras filas del DataFrame
df.head()

# Dimensiones (filas, columnas)
df.shape

# Tipos de columnas y nulos
df.info()

# Estadísticas descriptivas
df.describe()
```

Una buena inspección inicial te ahorrará horas de depuración más adelante. Siempre ejecuta `df.info()` y `df.describe()` antes de cualquier análisis.

Comparativa de Librerías de Visualización

Criterio	matplotlib	seaborn	plotly
Curva de aprendizaje	Alta	Media	Media
Interactividad	No	No	Sí
Gráficos estadísticos	Básico	Excelente	Bueno
Personalización	Total	Alta	Alta
Uso recomendado	Publicaciones	EDA estadístico	Dashboards

¿Con cuál empezar?

Para exploración del día a día, **seaborn** es la opción más productiva: gráficos elegantes con poco código. Aprende **matplotlib** para personalizaciones avanzadas y **plotly** cuando necesites interactividad o presentaciones para clientes.

> Las tres librerías son complementarias. En un proyecto real se usan las tres en distintas etapas.

Guía Rápida: Tipo de Pregunta → Gráfico



¿Cómo se distribuye una variable?

Usa un **histograma** para ver frecuencias, un **boxplot** para detectar outliers o un **violinplot** para ver la distribución completa con densidad.



¿Cómo se comparan categorías?

Un **gráfico de barras** es la opción más clara. Si tienes muchas categorías, considera un gráfico de barras horizontal para mejorar la legibilidad.



¿Existe relación entre dos variables?

El **scatter plot** muestra correlaciones directamente. Complementa con una línea de tendencia o usa un **heatmap** para múltiples variables a la vez.



¿Cómo evoluciona algo en el tiempo?

El **gráfico de líneas** es el estándar para series temporales. El **gráfico de área** añade énfasis en el volumen acumulado a lo largo del tiempo.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S06_01_pandas_eda — 45 min

pandas, EDA y primer chequeo de calidad

sprints/S06/notebooks/S06_01_pandas_eda.ipynb

RETO

Reto del sprint — 30 min

Arrancar el inventario de defectos del fichero sucio (pasos 1–2)

sprints/S06/guia/Reto_Sprint_06.md