SPRINT 6 · DATOS LISTOS PARA MODELAR · S06.1

Datos, pandas y exploración (EDA)

El cliente nos ha pasado su histórico de reservas y quiere «meter IA». Antes de modelar hay que conocer los datos.

Qué hace un Data Scientist y qué datos maneja

Qué hace

Explora, limpia, modela y **comunica**: traduce datos en decisiones para el negocio.

Tipos de dato

Estructurados (tablas, CSV, SQL), no estructurados (texto, imagen, audio) y series temporales.

Dónde estamos

Tabla estructurada: `reservas_turisdata.csv`, 6.000 reservas, una fila por reserva y `cancelada` como objetivo.

Regla de oro: **primero mide, luego decide**. Los pasos del sprint: explorar → limpiar → preparar → medir.

Cargar e inspeccionar (Ejercicio 1)

```
import pandas as pd
df = pd.read_csv(dato("reservas_turisdata.csv"))

df.shape              # ¿cuántas filas y columnas?
df.info()             # tipo de cada columna y nulos
df.head()             # primeras filas
df.describe()         # resumen de las numéricas
```

Lo primero siempre: ¿cuántas filas y columnas? ¿de qué tipo es cada una? ¿hay nulos?

Filtrar y agrupar (Ejercicio 2)

```
df[df["canal"] == "directo"]                          # filtro booleano
df[(df["noches"] > 7) & (df["tarifa"] == "flexible")]

tasa_por_deposito = df.groupby("deposito")["cancelada"].mean()
```

- La **media de una columna 0/1** es una **tasa**: `cancelada.mean()` = proporción de canceladas.
- `groupby` + media responde a «¿cancela más un grupo que otro?».

Unir tablas con `merge` (Ejercicio 3)

```
df = df.merge(temporadas, on="mes_llegada", how="left")   # left: no perdemos reservas
```

- A menudo la información está repartida en varias tablas.
- `how="left"` conserva todas las reservas aunque falte la fila en la otra tabla.
- Comprueba siempre las filas antes y después: si cambian, la unión duplicó o perdió datos.

El gráfico según el dato (Ejercicio 4)

Quiero ver…	Gráfico	Ejemplo con TurisData
Una variable numérica	Histograma	`precio_noche`
Numérica por categorías	Diagrama de cajas	`precio_noche` por `tipo_habitacion`
Dos numéricas	Dispersión	`antelacion_dias` frente a `precio_noche`
Una categórica	Barras	reservas por `canal`

```
mediana_por_tipo = df.groupby("tipo_habitacion")["precio_noche"].median()
```

Relaciones entre variables y calidad del dato

```
corr = df.select_dtypes("number").corr()              # Ejercicio 5
var_mas_ligada = corr["cancelada"].drop("cancelada").abs().idxmax()

filas_duplicadas = df.duplicated().sum()              # Ejercicio 6
pct_nulos_pais = df["pais_origen"].isna().mean() * 100
```

- Correlación mide relación **lineal**; no prueba causalidad (lo vimos en el Sprint 5).
- Primer chequeo de calidad: duplicados, nulos, rangos imposibles.

Mini-reto: tres hallazgos para el cliente

Con lo que has explorado, escribe **tres hallazgos** que un gerente entendería sin saber Python.

- Cada hallazgo = **una cifra + una frase** («los clientes sin depósito cancelan X veces más»).
- Apóyate en `tasa_por_deposito`, `mediana_por_tipo` y la matriz `corr`.
- Los mismos pasos 1–2 del reto de este sprint: inventario de defectos del fichero sucio.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S06_01_pandas_eda — 45 min

pandas, EDA y primer chequeo de calidad

sprints/S06/notebooks/S06_01_pandas_eda.ipynb

RETO

Reto del sprint — 30 min

Arrancar el inventario de defectos del fichero sucio (pasos 1–2)

sprints/S06/guia/Reto_Sprint_06.md