IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 6 DE 17

# Sprint 6 · Datos listos para modelar

*¿están los datos en condiciones de entrenar algo fiable?*

**FECHAS**
4–5 de noviembre

**HORAS**
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

**Reto de este sprint: «Datos sucios, cliente impaciente». Ver el reto completo, explicado paso a paso** · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

## Material del sprint

- **Guía del sprint (PDF):** `Guia_Sprint_06.pdf` · versión ecofriendly para imprimir
- **Reto completo, paso a paso:** `Reto_Sprint_06.md`
- **S06.1 · Datos pandas y visualizacion exploratoria:** `S06.1_Datos_pandas_y_visualizacion_exploratoria.pdf`
- **S06.2 · Limpieza y preprocesado:** `S06.2_Limpieza_y_preprocesado.pdf`
- **S06.3 · scikit learn metricas y validacion:** `S06.3_scikit_learn_metricas_y_validacion.pdf`

**Contenidos:** M2 (rol del Data Scientist, pandas, visualización, limpieza y preprocesado) y M3 UD 3.1–3.2 (flujo con scikit-learn, pipelines, métricas y validación).

**En esta carpeta:** `guia/` PDF de la guía (normal y para imprimir) y el reto explicado paso a paso · `presentaciones/` diapositivas de cada sesión · `notebooks/` prácticas para abrir en Colab · `plantillas/` plantillas para el reto

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Teoría = diapositivas · Práctica = cuaderno de Colab o actividad · Reto = trabajo en equipo · Ceremonia = momento de Scrum

**Miércoles 4/11**

1. **Ceremonia**: Planning del reto «Datos sucios, cliente impaciente» y reparto de roles · *15 min*
2. **Teoría**: Datos, pandas y visualización exploratoria · *40 min*
3. **Práctica**: pandas, EDA y primer chequeo de calidad · *45 min*
4. **Reto**: Arrancar el inventario de defectos del fichero sucio (pasos 1–2) · *50 min*
5. **Teoría**: Limpieza y preprocesado · *45 min*
6. **Práctica**: Limpieza: duplicados, tipos, fechas, categorías, imposibles y nulos · *55 min*

**Jueves 5/11**

7. **Práctica**: Escalado, codificación, `ColumnTransformer` y `Pipeline` · *40 min*
8. **Reto**: Función de limpieza, partición train/test, *pipeline* y *baseline* (pasos 3–4) · *1 h*
9. **Teoría**: scikit-learn: métricas y validación · *45 min*
10. **Práctica**: *Baseline*, métricas, validación cruzada y fuga de datos · *45 min*
11. **Reto**: Informe, README y ensayo (paso 5) · *25 min*
12. **Ceremonia**: Entrega en `sprint-06/`, autoevaluación y coevaluación, review y retrospectiva · *35 min*

## Qué aprenderás

- Explorar una tabla con pandas y encontrar sus defectos (nulos, duplicados, *outliers*, fechas y categorías mal formadas).
- Construir un **pipeline** reproducible ( `ColumnTransformer` + `Pipeline` ) sin fuga de datos.

- Medir un modelo con honestidad: *baseline*, métricas y validación cruzada.
- Hace falta haber visto los Sprints 4 y 5 (Python, NumPy y pandas básicos).

## Prácticas

| Notebook | Tema | Tiempo | Colab |
|---|---|---|---|
| `S06_01_pandas_eda` | pandas, EDA y visualización exploratoria; primer chequeo de calidad | 55 min | Abrir en Colab |
| `S06_02_limpieza` | Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos | 65 min | Abrir en Colab |
| `S06_03_preprocesado_pipeline` | Escalado, codificación, `ColumnTransformer` y `Pipeline` | 50 min | Abrir en Colab |
| `S06_04_metricas_validacion` | Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal | 60 min | Abrir en Colab |

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Los datos se descargan solos.

### RETO Reto · «Datos sucios, cliente impaciente»

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData Canarias nos envía `reservas_sucio.csv`, exportado a mano desde varios sistemas. Quieren un primer modelo de cancelaciones, pero el gerente no se fía de los datos. Pide un informe corto de qué está mal y por qué, y un proceso que deje los datos listos cada vez.

**Entregáis** (carpeta `sprint-06/` del repositorio del equipo):

- `informe_calidad.md` (1–2 páginas): defectos, causa probable, tratamiento y preguntas al cliente. Plantilla: `informe_calidad_plantilla.md`.
- `reto_S06.ipynb`: EDA, función de limpieza, *pipeline* y *baseline* con validación cruzada.
- `README.md` con las instrucciones y versiones para reproducirlo.

**Reglas:**

- Unas 3 h 45 min en equipo; solo librerías del curso. Nada de editar el CSV a mano: toda corrección va en código.
- Lo aprendido de los datos (medianas, categorías…) se ajusta **solo con train**. No se descarta ninguna fila sin justificarla.
- Nunca claves ni datos personales. Review: 5 min por equipo (3 defectos graves y *pipeline* en marcha).

**Se valora:** corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿y si el país de origen se imputa mal?).

### Definition of Done · antes de cerrar el sprint

- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] El informe recoge cada defecto con causa probable y tratamiento
- [ ] Hay *baseline* (`DummyClassifier`) y un modelo, comparados con validación cruzada
- [ ] Entregable subido a la carpeta `sprint-06/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas