IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 6 DE 17

Sprint 6 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

Reto de este sprint: «Datos sucios, cliente impaciente». Ver el reto completo, explicado paso a paso · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

Qué aprenderás

- Explorar una tabla con pandas y encontrar sus defectos (nulos, duplicados, *outliers*, fechas y categorías mal formadas).
- Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) sin fuga de datos.
- Medir un modelo con honestidad: *baseline*, métricas y validación cruzada.
- Hace falta haber visto los Sprints 4 y 5 (Python, NumPy y pandas básicos).

Prácticas

Notebook	Tema	Tiempo	Colab
`S06_01_pandas_eda`	pandas, EDA y visualización exploratoria; primer chequeo de calidad	45 min	Abrir en Colab
`S06_02_limpieza`	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	55 min	Abrir en Colab
`S06_03_preprocesado_pipeline`	Escalado, codificación, `ColumnTransformer` y `Pipeline`	40 min	Abrir en Colab
`S06_04_metricas_validacion`	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	45 min	Abrir en Colab

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Los datos se descargan solos.