README Sprint S06 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. Explorar una tabla con pandas y elegir el gráfico adecuado para cada tipo de dato.
2. Encontrar defectos en un dataset (nulos, duplicados, *outliers*, tipos y fechas mal formados, categorías inconsistentes) y **razonar de dónde vienen**.
3. Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) que impute, escale y codifique sin fuga de datos.
4. Medir un modelo con honestidad: *baseline*, métricas, validación cruzada, partición temporal.
5. Reconocer y evitar la **fuga de datos** (*data leakage*).

Requisitos previos

- Sprint 4 y 5: Python básico, NumPy y algo de estadística con pandas.
- Cuenta de Google (para Colab) o el entorno local del curso (Python 3.11).
- Datos: `datos/reservas_turisdata.csv` (limpio) y `datos/reservas_sucio.csv` (el del reto). Los notebooks los descargan solos si no los encuentran.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Infografías del reto	2 láminas ilustradas del reto	—	Reto
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S06.1_Datos_pandas_y_visualizacion_exploratoria.pdf`	Datos, pandas y visualización exploratoria	30 min	Teoría · miércoles 4/11
`S06.2_Limpieza_y_preprocesado.pdf`	Limpieza y preprocesado	30 min	Teoría · miércoles 4/11
`S06.3_scikit_learn_metricas_y_validacion.pdf`	scikit-learn: métricas y validación	25 min	Teoría · jueves 5/11

Material de las actividades

Notebook	Tema	Tiempo
`S06_01_pandas_eda`	pandas, EDA y visualización exploratoria; primer chequeo de calidad	45 min

Notebook	Tema	Tiempo
`S06_02_limpieza`	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	55 min
`S06_03_preprocesado_pipeline`	Escalado, codificación, `ColumnTransformer` y `Pipeline`	40 min
`S06_04_metricas_validacion`	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	45 min

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Los datos se descargan solos.

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Miércoles 4/11

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Datos sucios, cliente impaciente» y reparto de roles	10 min
2	Teoría	Datos, pandas y visualización exploratoria	30 min
3	Práctica	pandas, EDA y primer chequeo de calidad	45 min
4	Reto	Arrancar el inventario de defectos del fichero sucio (pasos 1–2)	30 min
5	Teoría	Limpieza y preprocesado	30 min
6	Práctica	Limpieza: duplicados, tipos, fechas, categorías, imposibles y nulos	55 min

Jueves 5/11

Nº	Tipo	Qué se hace	Tiempo
7	Práctica	Escalado, codificación, `ColumnTransformer` y `Pipeline`	40 min
8	Reto	Función de limpieza, partición train/test, *pipeline* y *baseline* (pasos 3–4)	35 min
9	Teoría	scikit-learn: métricas y validación	25 min
10	Práctica	*Baseline*, métricas, validación cruzada y fuga de datos	45 min
11	Reto	Informe, README y ensayo (paso 5)	20 min
12	Ceremonia	Entrega en `sprint-06/`, autoevaluación y coevaluación, review y retrospectiva	35 min

RETO Reto · «Datos sucios, cliente impaciente»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias nos envía `reservas_sucio.csv`, exportado a mano desde varios sistemas. Quieren un primer modelo de cancelaciones, pero el gerente no se fía de los datos. Pide un informe corto de qué está mal y por qué, y un proceso que deje los datos listos cada vez.

Entregáis (carpeta `sprint-06/` del repositorio del equipo):

- `informe_calidad.md` (1–2 páginas): defectos, causa probable, tratamiento y preguntas al cliente. Plantilla: `informe_calidad_plantilla.md`.
- `reto_S06.ipynb`: EDA, función de limpieza, *pipeline* y *baseline* con validación cruzada.
- `README.md` con las instrucciones y versiones para reproducirlo.

Reglas:

- Unas 3 h 45 min en equipo; solo librerías del curso. Nada de editar el CSV a mano: toda corrección va en código.
- Lo aprendido de los datos (medianas, categorías…) se ajusta **solo con train**. No se descarta ninguna fila sin justificarla.
- Nunca claves ni datos personales. Review: 5 min por equipo (3 defectos graves y *pipeline* en marcha).

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿y si el país de origen se imputa mal?).

Definition of Done · antes de cerrar el sprint

- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] El informe recoge cada defecto con causa probable y tratamiento
- [ ] Hay *baseline* (`DummyClassifier`) y un modelo, comparados con validación cruzada
- [ ] Entregable subido a la carpeta `sprint-06/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas