Sprint 6 · Datos listos para modelar

¿están los datos en condiciones de entrenar algo fiable?

FECHAS
4–5 de noviembre

HORAS
12 h (4 h teoría · 4 h práctica guiada · 4 h PBL)

Reto de este sprint: «Datos sucios, cliente impaciente». Ver el reto completo, explicado paso a paso · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

Material del sprint

- **Guía del sprint (PDF):** `Guia_Sprint_06.pdf` · versión ecofriendly para imprimir
- **Reto completo, paso a paso:** `Reto_Sprint_06.md`
- **S06.1 · Datos pandas y visualizacion exploratoria:** `S06.1_Datos_pandas_y_visualizacion_exploratoria.pdf`
- **S06.2 · Limpieza y preprocesado:** `S06.2_Limpieza_y_preprocesado.pdf`
- **S06.3 · scikit learn metricas y validacion:** `S06.3_scikit_learn_metricas_y_validacion.pdf`

Contenidos: M2 (rol del Data Scientist, pandas, visualización, limpieza y preprocesado) y M3 UD 3.1–3.2 (flujo con scikit-learn, pipelines, métricas y validación).

En esta carpeta: `guia/` PDF de la guía (normal y para imprimir) y el reto explicado paso a paso · `presentaciones/` diapositivas de cada sesión · `notebooks/` prácticas para abrir en Colab · `plantillas/` plantillas para el reto

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Teoría = diapositivas · Práctica = cuaderno de Colab o actividad · Reto = trabajo en equipo · Ceremonia = momento de Scrum

Miércoles 4/11

1. **Ceremonia**: Planning del reto «Datos sucios, cliente impaciente» y reparto de roles · *25 min*
2. **Teoría**: Datos, pandas y visualización exploratoria · *55 min*
3. **Práctica**: pandas, EDA y primer chequeo de calidad · *55 min*
4. **Reto**: Arrancar el inventario de defectos del fichero sucio (pasos 1–2) · *1 h*
5. **Teoría**: Limpieza y preprocesado · *1 h*
6. **Práctica**: Limpieza: duplicados, tipos, fechas, categorías, imposibles y nulos · *1 h 5 min*

Jueves 5/11

7. **Práctica**: Escalado, codificación, `ColumnTransformer` y `Pipeline` · *50 min*
8. **Reto**: Función de limpieza, partición train/test, *pipeline* y *baseline* (pasos 3–4) · *1 h 20 min*
9. **Teoría**: scikit-learn: métricas y validación · *1 h 10 min*
10. **Práctica**: *Baseline*, métricas, validación cruzada y fuga de datos · *1 h*
11. **Reto**: Informe, README y ensayo (paso 5) · *25 min*
12. **Ceremonia**: Entrega en `sprint-06/`, autoevaluación y coevaluación, review y retrospectiva · *35 min*

Qué aprenderás

- Explorar una tabla con pandas y encontrar sus defectos (nulos, duplicados, *outliers*, fechas y categorías mal formadas).
- Construir un **pipeline** reproducible (`ColumnTransformer` + `Pipeline`) sin fuga de datos.
- Medir un modelo con honestidad: *baseline*, métricas y validación cruzada.
- Hace falta haber visto los Sprints 4 y 5 (Python, NumPy y pandas básicos).

Prácticas

Notebook	Tema	Tiempo
`S06_01_pandas_eda`	pandas, EDA y visualización exploratoria; primer chequeo de calidad	55 min
`S06_02_limpieza`	Limpieza: duplicados, tipos, fechas, categorías, imposibles, nulos	65 min
`S06_03_preprocesado_pipeline`	Escalado, codificación, `ColumnTransformer` y `Pipeline`	50 min

Notebook	Tema	Tiempo
`S06_04_metricas_validacion`	Baseline, métricas, sobreajuste, validación cruzada, fuga y partición temporal	60 min

Cada notebook tiene ejercicios con `assert`: si la celda de comprobación no da error, vas bien. Los datos se descargan solos.

RETO Reto · «Datos sucios, cliente impaciente»

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias nos envía `reservas_sucio.csv`, exportado a mano desde varios sistemas. Quieren un primer modelo de cancelaciones, pero el gerente no se fía de los datos. Pide un informe corto de qué está mal y por qué, y un proceso que deje los datos listos cada vez.

Entregáis (carpeta `sprint-06/` del repositorio del equipo):

- `informe_calidad.md` (1–2 páginas): defectos, causa probable, tratamiento y preguntas al cliente. Plantilla: `informe_calidad_plantilla.md`.
- `reto_S06.ipynb`: EDA, función de limpieza, *pipeline* y *baseline* con validación cruzada.
- `README.md` con las instrucciones y versiones para reproducirlo.

Reglas:

- Unas 3 h 45 min en equipo; solo librerías del curso. Nada de editar el CSV a mano: toda corrección va en código.
- Lo aprendido de los datos (medianas, categorías…) se ajusta **solo con train**. No se descarta ninguna fila sin justificarla.
- Nunca claves ni datos personales. Review: 5 min por equipo (3 defectos graves y *pipeline* en marcha).

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿y si el país de origen se imputa mal?).

Definition of Done · antes de cerrar el sprint

- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] El informe recoge cada defecto con causa probable y tratamiento
- [ ] Hay *baseline* (`DummyClassifier`) y un modelo, comparados con validación cruzada
- [ ] Entregable subido a la carpeta `sprint-06/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas