IFCD107 · SPRINT 6 · EL RETO PASO A PASO

Datos sucios, cliente impaciente

Vais a aprender a desconfiar de los datos, a limpiar de forma reproducible y a evitar la fuga de información del test al entrenamiento.

EN BREVE

Qué os piden

EL ENCARGO

TurisData os envía por correo un fichero de reservas exportado a mano desde varios sistemas (reservas_sucio.csv). El gerente quiere un primer modelo de cancelaciones «para ayer», pero no se fía de los datos (con razón). Os pide dos cosas: informe corto; proceso automático.

LO QUE HACÉIS

Hacer un inventario · Explicar la causa probable · Escribir una función de limpieza · Montar un pipeline · Entrenar un modelo de referencia (baseline) · Escribir el informe y el README

LO QUE ENTREGÁIS

un repositorio o carpeta con informe_calidad.md, reto_S06.ipynb y README.md.

CÓMO SE HACE

Los pasos, uno a uno

Día 1 — 60 min de reto

1

Planning y reparto de roles

20 min

- Elegid Scrum Master y responsable técnico de este sprint (no pueden repetir quienes lo fueron en el anterior).
- Pasad al tablero las tareas: inventario de defectos, función de limpieza, pipeline, baseline, informe, README.
- Decidid quién empieza cada una, sabiendo que todo el equipo debe entender todo.

2

Inventario de defectos

40 min

- Cargad reservas_sucio.csv y ejecutad la función resumen_calidad de las prácticas.
- Haced gráficos (histogramas, conteo por categoría).
- Por cada defecto, rellenad una fila en la tabla del informe (informe_calidad_plantilla.md)

MATERIAL

- **reservas_sucio.csv** datos/reservas_sucio.csv
- **informe_calidad_plantilla.md** sprints/S06/Reto_S06/informe_calidad_plantilla.md

Día 2 — 80 min de reto

3

Función de limpieza y separación train/test

30 min

- Escribid limpiar_reservas(df): una función que recibe la tabla sucia y devuelve la tabla limpia aplicando todos vuestros…
- Comprobad antes y después (nulos, duplicados, rangos).
- Separad train y test ANTES de calcular medianas, medias o categorías frecuentes.
- No descartéis ninguna fila sin justificarlo en el informe.

4

Pipeline y baseline

30 min

- Construid un Pipeline de scikit-learn con tres pasos: imputar huecos, escalar números y codificar categorías.
- Añadid un modelo de referencia (por ejemplo, regresión logística).
- Evaluadlo con validación cruzada y comparadlo con un DummyClassifier.
- Pensad en la métrica: si solo se cancela el 20 %, un modelo que dice «nunca cancelan» acierta el 80 %.

5

Informe, README y ensayo

20 min

- Completad el informe (1–2 páginas): tabla de defectos, tratamientos justificados y preguntas al cliente.
- En README.md: cómo ejecutar el cuaderno, qué versiones de librerías usáis y en qué orden.
- Comprobad que «Reiniciar y ejecutar todo» funciona sin errores.
- Ensayad la review (5 minutos) y preparad la retro.

✓

Antes de entregar

- Repasad la lista «Antes de entregar» de la ficha y la Definition of Done.
- Cada persona rellena y sube su hoja de autoevaluación y coevaluación.

MATERIAL

- **Autoevaluación y coevaluación** sprints/S06/Reto_S06/autoevaluacion_y_coevaluacion.md
- **Cómo entregar en GitHub** material/5. Como_entregar_en_GitHub.md
- **Cómo se trabaja un reto** material/4. Como_se_trabaja_un_reto.md

PARA EVITAR

Errores frecuentes

ERROR 1

Calcular la mediana con todos los datos antes de partir

Partid primero; ajustad imputación y escalado solo con train (dentro del Pipeline)

ERROR 2

Borrar filas «raras» sin avisar

Cada fila eliminada se cuenta y se justifica

ERROR 3

Informe que dice «hay nulos» sin más

Para cada defecto: dónde, cuántas filas, causa, tratamiento y razón

ERROR 4

Un modelo que «acierta el 80 %» y se celebra

Comparadlo con DummyClassifier

CON IA

Para qué sirve y qué hay que comprobar

USO DE LA IA

Entender una función de pandas

Comprobad que probáis cada ejemplo y lo entendéis

USO DE LA IA

Depurar un error

Comprobad que arreglas la causa, no solo el síntoma

USO DE LA IA

Revisar la fuga

Comprobad que entendéis por qué hay o no fuga

SI EL TIEMPO APRIETA

Núcleo y extra

NÚCLEO · LO OBLIGATORIO

inventario de defectos, función de limpieza y baseline con su pipeline.

EXTRA · SI SOBRA TIEMPO

informe más detallado y comparativa de variantes de limpieza.

Si la IA os hace un cálculo o un texto, comprobadlo y escribid dónde la habéis usado.

Ficha completa: sprints/S06/Reto_S06/Reto_Sprint_06.md