IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Modelos que predicen un recorrido

Dónde estamos dentro de la IA · qué modelo responde a qué pregunta · cómo saber si funciona

Sprint 7 · recorrido global de los cuadernos S07_02 a S07_05

DÓNDE ESTAMOS

Un mapa de la inteligencia artificial

Inteligencia artificial

Máquinas que hacen tareas que parecen propias de personas.

Aprendizaje automático

La máquina **aprende de ejemplos**, no de reglas escritas a mano.

Aprendizaje supervisado

Los ejemplos **traen la respuesta**: el precio real, si la reserva canceló o no.

Regresión

Predice un **número**: cuánto cobrar.

Clasificación

Predice una **categoría**: ¿cancela, sí o no?

Sin respuestas

Agrupar y descubrir (Sprint 9)

Redes neuronales

Imágenes y texto (Sprint 10 en adelante)

Todo el Sprint 7 vive en el recuadro «Aprendizaje supervisado»: **modelos que aprenden de ejemplos con la respuesta conocida**.

DOS TIPOS DE PREGUNTA

¿Cuánto? ¿O sí o no?

Un número

¿Cuánto cobrar por esta noche?

La respuesta es un **número**: 84 €, 150 €…

Se llama **regresión**.

Otros ejemplos: la demanda de mañana, el gasto de un cliente.

Sí o no

¿Esta reserva se cancelará?

La respuesta es una **categoría**: sí o no.

Se llama **clasificación**.

Otros ejemplos: ¿es spam? ¿es fraude? ¿se va a dar de baja?

TurisData necesita las dos: una tarifa de referencia (regresión) y un aviso de cancelación (clasificación).

La regresión lineal del cuaderno 1 fue la primera: una tabla de precios en la que cada variable suma o resta euros.

LOS MODELOS DE HOY

Cinco ideas, cinco modelos

Modelo	Responde a…	La idea en una frase	Cuaderno
Ridge y Lasso	un número	Regresión con **límite** para que no memorice	S07_02
Regresión logística	sí o no	Calcula una **probabilidad** y tú decides dónde cortar	S07_03
k-NN	sí o no	Mira a las reservas **más parecidas** y vota	S07_05
Naive Bayes	sí o no	Suma **pistas** como un médico	S07_05

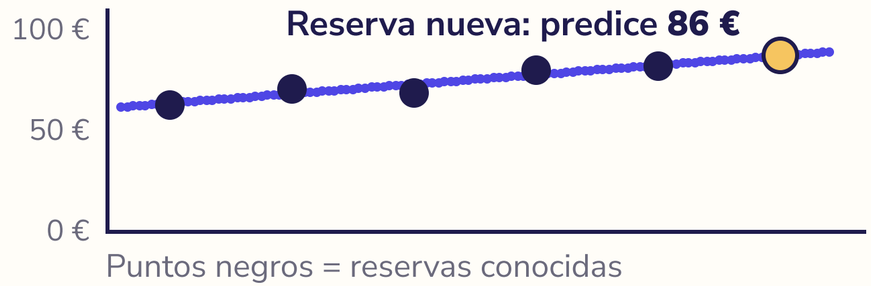
¿Y cómo sabemos si un modelo vale? Con las medidas de acierto (ROC, precisión–recall y coste): cuaderno S07_04.

Recorrido de hoy: 1 · Cuando memoriza → 2 · Sí o no → 3 · ¿Vale de verdad? → 4 · Dos modelos más.

El problema: aprenderse el examen de memoria

Modelo sencillo

una recta que sigue la tendencia



Puntos negros = reservas conocidas

Modelo que memoriza

una curva que pasa por los 5 puntos



Puntos negros = reservas conocidas

Cómo se lee

Punto dorado = la reserva nueva, la que importa.

La **recta** sigue la tendencia: predice 86 €.

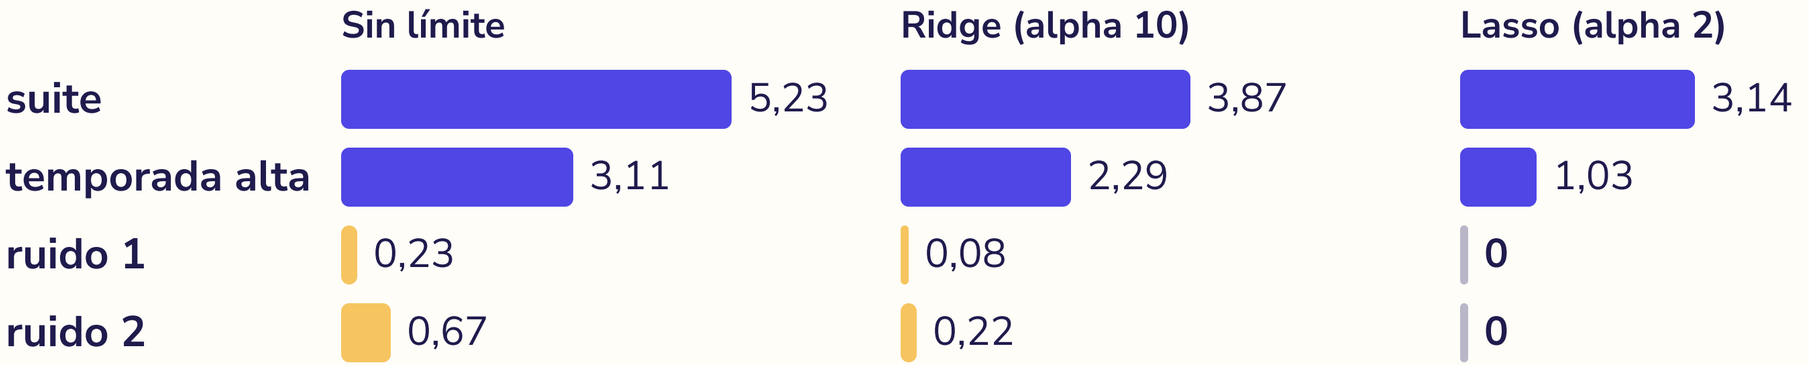
La **curva** acierta los 5 puntos… y para la nueva predice **7 €**.

En tu cuaderno

Con 120 reservas y 665 columnas: R^2 **1,000** en entrenamiento y **0,716** en prueba.

Acertar lo ya visto **no es aprender**.

El remedio: ponerle un límite al modelo



Poner un límite = castigar los pesos grandes (regularizar). Cada barra: cuánto «pesa» la variable. Amarillo = puro ruido.

Ridge: baja el volumen

Reduce **todos** los pesos. Ninguno llega a cero.

Bueno si **muchas** variables aportan un poco.

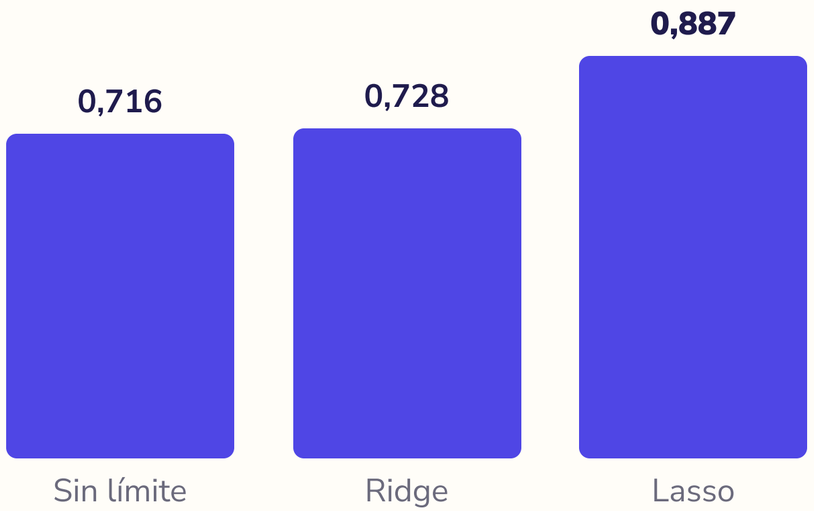
Lasso: apaga lo que sobra

Lleva a **cero** las variables que no sirven.

Bueno si **pocas** lo explican casi todo.

1 · CUANDO EL MODELO MEMORIZA

¿Cuánto límite? Se elige sin mirar el examen



Cómo se elige

El límite se llama **alpha**: pequeño = casi no limita; grande = limita demasiado.

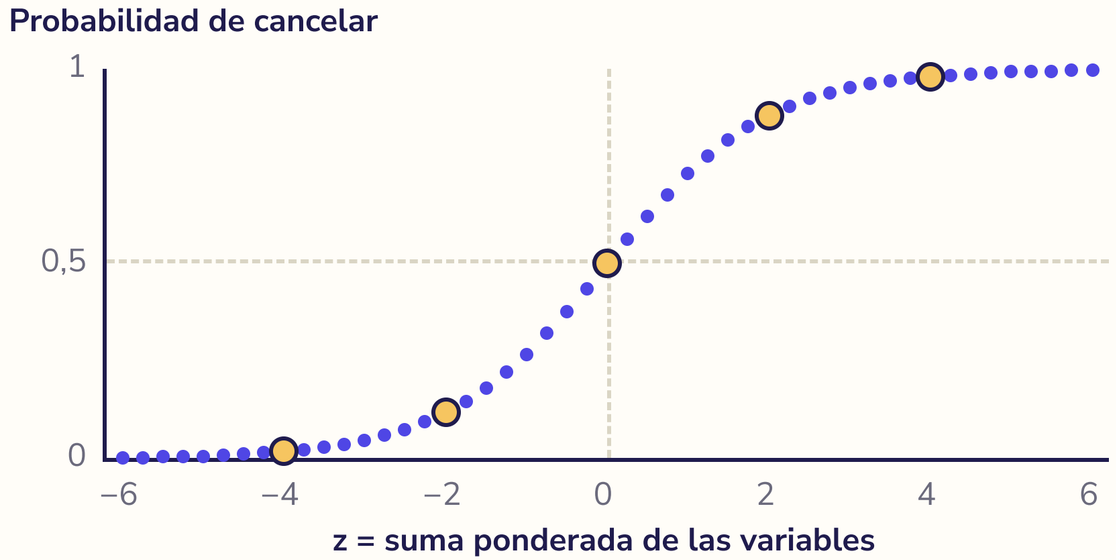
Se prueban varios con **trozos del entrenamiento** (validación cruzada) y se queda el mejor.

La regla de oro

El **test es el examen final**: se mira **una sola vez**, al terminar. Si eliges **alpha** mirándolo, haces trampa.

¿Con cuál nos quedamos? Con Lasso (0,887): mejor nota en prueba y solo usa 27 de 665 columnas, así que también es el más fácil de explicar.

De una suma a una probabilidad



De dónde sale la probabilidad

Para cada reserva el modelo **suma** el efecto de sus datos (antelación, depósito, tarifa, canal…).

La curva en «S» convierte esa suma en un número **entre 0 y 1**: la probabilidad de cancelar (**predict_proba**).

En tu cuaderno

1200 reservas de prueba, con probabilidades de **0,03 a 0,99**.

La media (0,466) casi coincide con la tasa real de cancelación (0,459).

El hilo: probabilidad → variables → **umbral** → errores → contarlos → coste.

¿Qué sube o baja el riesgo?



La línea negra es «×1»: no cambia nada. Cada barra mide cuánto se multiplican las «apuestas» de que la reserva cancele.

De dónde salen

Las **aprende el modelo** con las 4.800 reservas de entrenamiento: cada variable recibe un peso (coeficiente).

Odds ratio = **exp(peso)**. En números como la antelación: por cada **desviación típica** más (están escaladas).

Cómo se lee

×2 = las «apuestas» de cancelar se **duplican**; **×0,5** = se reducen a la **mitad**.

Tarifa no reembolsable y depósito total: cancelar sale caro, el riesgo baja a menos de la mitad.

El umbral: la nota de corte



Cada punto es una reserva, colocada según la probabilidad que le da el modelo (de 0 a 1).

Cómo se lee

El modelo **no dice sí o no**: dice una probabilidad (0,64 = 64 %).

El **umbral** es la nota de corte: si la probabilidad **llega** a ese valor, avisamos.

Mover la línea

Umbral **0,5**: avisamos de 4 reservas. Umbral **0,3**: de 6.

Lo **decidimos nosotros**, como el 5 de un examen.

Mover el umbral cambia aciertos y errores

Probabilidad del modelo	0,92	0,81	0,64	0,55	0,42	0,36	0,28	0,19	0,12	0,07
Qué pasó de verdad	canceló	canceló	se quedó	canceló	canceló	se quedó	canceló	se quedó	se quedó	se quedó
Avisamos si la probabilidad es ≥ 0,5	acierta	acierta	falsa alarma	acierta	se escapa	—	se escapa	—	—	—
Avisamos si la probabilidad es ≥ 0,3	acierta	acierta	falsa alarma	acierta	acierta	falsa alarma	se escapa	—	—	—

Cómo se lee

Avisamos si la probabilidad llega al **umbral**.

Con **0,5**: 3 de 5 cancelaciones y 1 falsa alarma.

Con **0,3**: 4 de 5, pero 2 falsas alarmas.

En tu cuaderno

Con 0,5 detectabas el **61,5 %** de las cancelaciones.

Con 0,3, el **87,5 %**; la precisión baja del 66 % al 56 %.

Cuatro resultados posibles

	El modelo dice: se queda	El modelo dice: cancela
En realidad: se queda	**Acierto tranquilo** **472** no cancela y no avisamos	**Falsa alarma** **177** llamada de más a un cliente que se quedaba
En realidad: cancela	**Se escapa** **212** cancelación sin detectar: habitación vacía	**Detectada** **339** cancelación avisada a tiempo

Precisión

De los avisos que doy, **¿cuántos aciertan?**

339 de 516 = **0,66**

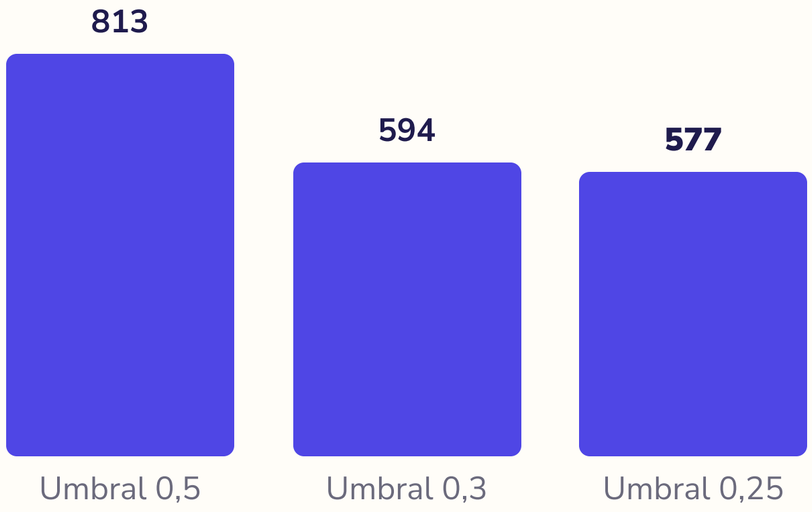
Recall (sensibilidad)

De las cancelaciones reales, **¿cuántas pillo?**

339 de 551 = **0,62**

Con umbral 0,5 en el cuaderno. Una **falsa alarma** cuesta una llamada; una cancelación que **se escapa** cuesta una habitación vacía.

No todos los errores cuestan igual



Cómo se lee

Una cancelación que **se escapa** cuesta **3**; una falsa alarma cuesta **1** (decisión del negocio).

Coste total = 3 × escapes + 1 × falsas alarmas. Gana el umbral de **menor coste**.

En tu cuaderno

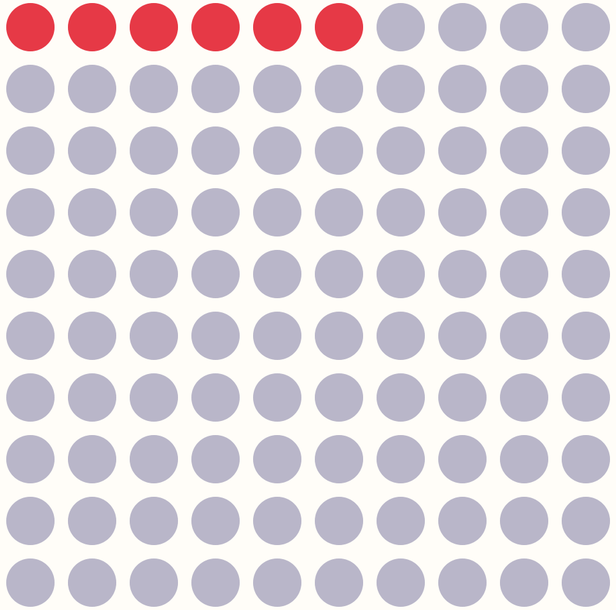
El mejor umbral fue **0,25**.

Coste **577** frente a **813** con el 0,5 de siempre: un **29 % menos**.

El umbral no lo decide el modelo: lo decide **lo que cuesta equivocarse**.

3 · ¿VALE DE VERDAD?

Cuando lo que buscas es raro, acertar mucho engaña



Cómo se lee

Cada punto es una reserva. Solo **6 de 100** cancelan (rojo).

Un modelo que dice siempre «no cancela» **acierta 94**…

…y **no detecta ninguna** cancelación.

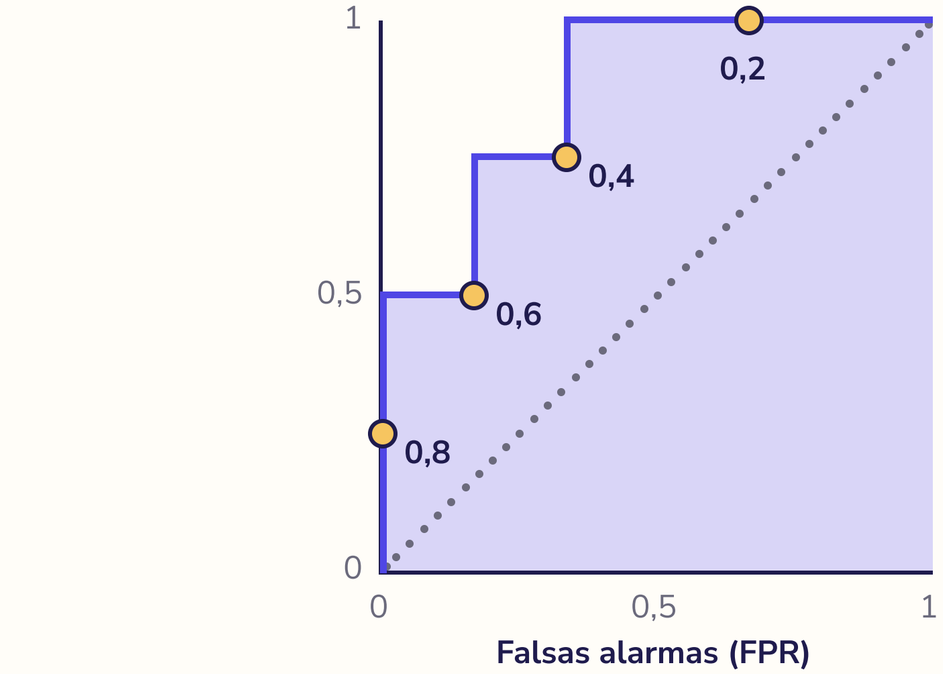
En tu cuaderno

El modelo «inútil» acertó el **94,0 %**.

Su recall: **0 %**.

Con clases raras, mira recall y precisión, no solo cuántas aciertas en total.

ROC: una foto por cada umbral



TPR y FPR

TPR = de las que **cancelan**, ¿cuántas detecto? (es el recall).

FPR = de las que **no cancelan**, ¿a cuántas aviso por error? (falsas alarmas).

Punto «0,6»: detecta 2 de 4 cancelaciones (TPR 0,5) y avisa por error a 1 de 6 (FPR 0,17).

Cómo se lee

Cada punto es un **umbral**. Mejor = arriba a la izquierda (muchas detectadas, pocas falsas alarmas).

La diagonal es el **azar**.

3 · ¿VALE DE VERDAD?

AUC: ¿ordena bien las parejas?

5 parejas: una reserva que canceló frente a una que se quedó. ¿Dio el modelo más probabilidad a la que canceló?

canceló · 0,92	>	se quedó · 0,28	✔ bien ordenada
canceló · 0,81	>	se quedó · 0,55	✔ bien ordenada
canceló · 0,64	>	se quedó · 0,12	✔ bien ordenada
canceló · 0,42	<	se quedó · 0,55	✘ mal ordenada
canceló · 0,55	>	se quedó · 0,19	✔ bien ordenada

Cómo se lee

Coge una reserva que **canceló** y otra que **no**. Si el modelo da **más probabilidad a la que canceló**, la pareja está bien ordenada.

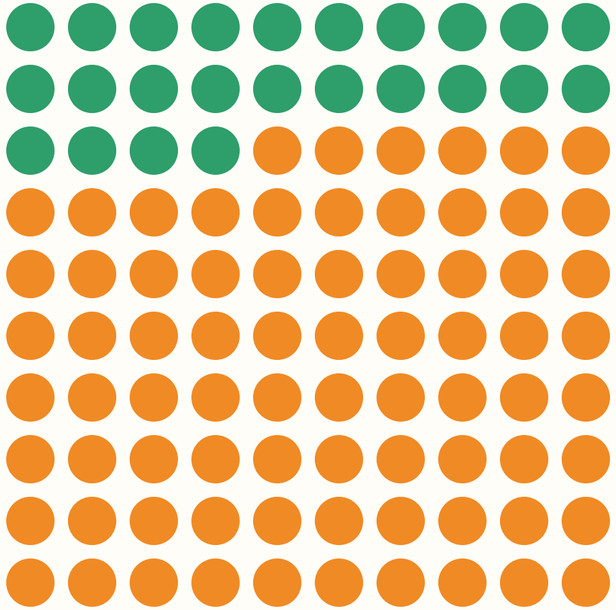
AUC = proporción de parejas bien ordenadas (aquí 4 de 5 = 0,80).

En tu cuaderno

AUC = 0,774: en 77 de cada 100 parejas la cancelada recibe más probabilidad.

0,5 = azar (cara o cruz). **1** = ordena perfecto.

Precisión: de mis avisos, ¿cuántos aciertan?



Cómo se lee

Cada punto es un **aviso** que da el modelo.

Verde = aviso **acertado** (24). Naranja = **falsa alarma** (76).

La ROC parecía casi perfecta, pero **76 de cada 100 avisos eran falsos**.

Precisión

Precisión = avisos acertados entre todos los avisos: aquí **24 de 100 = 0,24**.

La curva PR dibuja la precisión para cada nivel de recall (cuántas cancelaciones detectas).

Con clases raras la curva PR es más **sincera** que la ROC: se fija en la clase que importa.

3 · ¿VALE DE VERDAD?

AP: la precisión media de la lista

Reservas ordenadas de más a menos probabilidad de cancelar →

1.ª	2.ª	3.ª	4.ª	5.ª	6.ª	7.ª	8.ª	9.ª	10.ª
canceló	se quedó	canceló	se quedó	se quedó	canceló	se quedó	se quedó	se quedó	se quedó
1 de 1		2 de 3			3 de 6				
1,00		0,67			0,50				

Precisión en cada cancelación detectada: 1,00 · 0,67 · 0,50 → AP = su media = 0,72

Cómo se lee

Ordenamos las reservas de **más a menos** probabilidad.

Cada vez que el modelo **acierta una cancelación** (rojo), anotamos qué parte de los avisos hasta ahí eran buenos.

AP = la media de esas precisiones. Sube si el modelo pone las cancelaciones arriba.

En tu cuaderno

AP = 0,24: de media, 24 de cada 100 avisos aciertan.

El azar daría **0,06** (6 de cada 100 reservas cancelan): el modelo es **4 veces mejor**.

3 · ¿VALE DE VERDAD?

Tres remedios para una clase rara

1 · Dar más peso a la clase rara

`class_weight="balanced"`: un error con una cancelación **pesa unas 16 veces más**.

Recall: **3 %** → **73 %**

Precisión: 14 %

2 · Tirar parte de las que sobran

Submuestreo: solo en **entrenamiento**, nunca en test.

Quedan 435 filas de 2417.

Recall: **45 %**

3 · Mover el umbral

No cambia el modelo: cambia **cuándo avisa**.

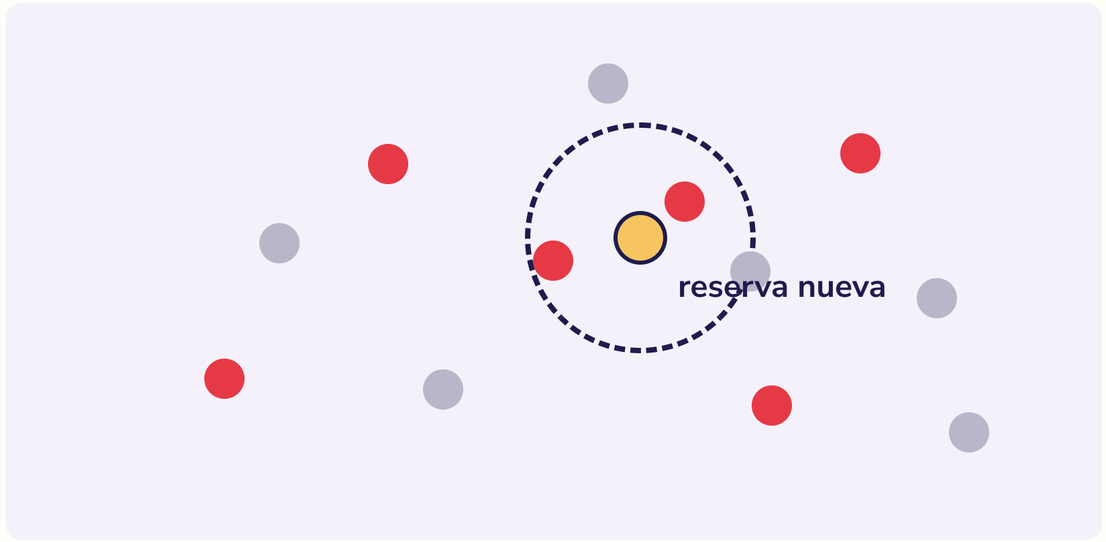
Umbral 0,048:

Recall: **82 %** · Precisión: 12 %

Los tres hacen lo mismo: más cancelaciones detectadas a cambio de más falsas alarmas. No hacen el modelo más listo; mueven dónde corta.

El AUC y el AP casi no cambian entre los tres: las probabilidades vienen a ser igual de buenas.

k-NN: dime con quién andas



canceló se quedó Círculo = las **3 más parecidas** (k = 3)

Cómo se lee

Para una reserva nueva, el modelo busca las **3 más parecidas** (k = 3).

Entre ellas, 2 cancelaron y 1 no: **gana el sí** (2 de 3 = 67 %).

No «aprende»: **guarda los datos** y busca al predecir.

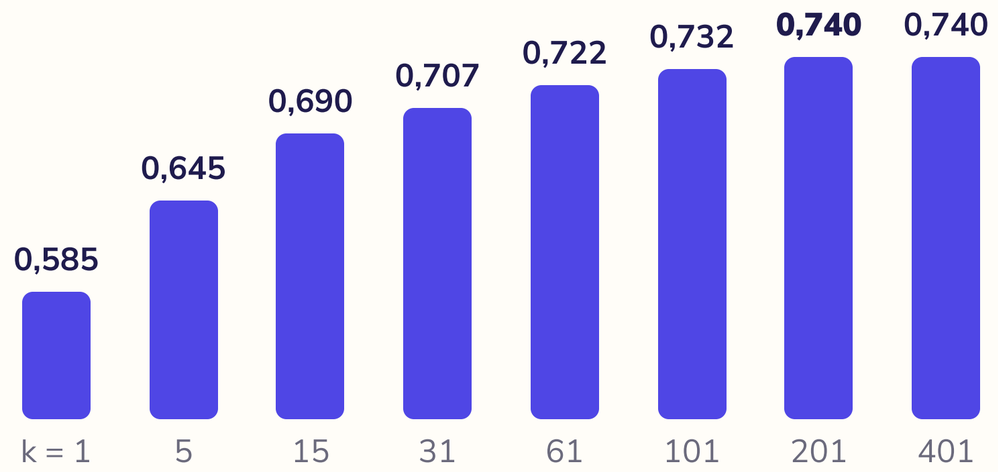
Aquí k = 3

Es solo un ejemplo pequeño: **k es cuántas vecinas consulta** el modelo antes de votar.

En el cuaderno se eligió k = 201 (siguiente diapositiva).

4 · DOS MODELOS MÁS

¿Cuántos vecinos? Qué significa «el mejor k fue 201»



Qué es k

k = cuántas reservas parecidas consulta el modelo antes de votar.

k = 1: se fía de **una sola** vecina, que puede ser un caso raro.

k = 201: promedia las **201** más parecidas (de 4.800): más estable.

Cómo se elige

Se prueban varios valores de **k** con validación cruzada y se queda el de **mayor AUC**: **201**.

Con 401 sale igual: **ya no mejora**.

Cada barra: **AUC** del modelo con ese **k** (altura medida desde 0,5, el azar).

4 · DOS MODELOS MÁS

Escalar: no mezclar kilómetros con centímetros

Sin escalar: cuánto aporta cada variable a «lo parecidas que son» dos reservas



Escaladas: todas en la misma escala



Cómo se lee

La **distancia** se mide en la unidad de cada variable: 100 días pesan muchísimo más que «repetidor sí/no» (0 o 1).

Sin escalar, k-NN solo mira antelación y precio.

La solución

Escalar antes: todas las variables en la misma escala y con el mismo peso.

Es **imprescindible** en k-NN (no tanto en la regresión logística).

4 · DOS MODELOS MÁS

Naive Bayes: sumar pistas como un médico

Reserva nueva: tarifa flexible y sin depósito. De 10 reservas pasadas, 4 cancelaron y 6 no.

Cancela	**0,40** 4 de 10 cancelaron	×	**0,75** 3 de 4 eran flexibles	×	**0,75** 3 de 4 sin depósito	=	**0,225**
No cancela	**0,60** 6 de 10 no cancelaron	×	**0,33** 2 de 6 eran flexibles	×	**0,17** 1 de 6 sin depósito	=	**0,033**

0,225 frente a 0,033 → 87 % de probabilidad de cancelar. Gana la clase con la puntuación más alta.

Cómo se lee

Cada dato aporta una **pista** y se **multiplican**.

«Ingenuo»: supone que las pistas **no se influyen**. No es cierto, pero **funciona**.

En tu cuaderno

Es rapidísimo y necesita pocos datos.

GaussianNB: AUC **0,719**. **CategoricalNB**: **0,742**.

4 · DOS MODELOS MÁS

¿Qué modelo elijo? Mira tres cosas

Modelo	Acierto (AUC)	Velocidad al predecir	¿Se puede explicar?
Regresión logística	**0,757** (el mejor)	Muy rápida	**Sí**: odds ratio de cada variable
k-NN	0,740	**La más lenta** (15–20 veces)	Solo con ejemplos parecidos
Naive Bayes	0,719 / 0,742	Muy rápida	Aporte de cada dato

En este problema, la regresión logística gana: mejor acierto, rápida y explicable al cliente.

Compara siempre **acierto + velocidad + explicabilidad**: el «mejor» modelo depende de para qué lo necesitas.

PARA LLEVARSE

Lo que tienes que poder decir

Si memoriza

Muy bien en entrenamiento y mal en prueba = **memoriza**.

Ridge **baja**, Lasso **apaga**.

Sí o no

El modelo da una **probabilidad**; el **umbral** lo decide el coste de equivocarse.

¿Vale?

Con clases raras la exactitud **engaña**: mira recall, precisión y AP.

Elegir

Acierto + velocidad + **explicabilidad**.

Los detalles, en las presentaciones S07_02 a S07_05 y en los cuadernos.