IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Predecir un precio con una recta

Teoría, práctica y, al final, material de consulta

Sprint 7 · S07_01 · teoría breve, 40 min de práctica y material de consulta

LA IDEA

Una suma de efectos que se lee en euros

Ejemplo con 8 reservas (2 por casilla; aquí, su precio medio). **Regresión** = predecir un número, el precio de la noche.

tipo_habitacion	tipo_suite	alta	precio medio
estandar	0	0	70 €
estandar	0	1	84 €
suite	1	0	150 €
suite	1	1	186 €

Lo que aprende el modelo

precio = 64,5 + 91,0 × tipo_suite + 25,0 × alta

El 64,5 es el punto de partida que mejor ajusta las 4 casillas a la vez; **no es el precio** de ninguna.

Coeficiente

Euros que cambia el precio al subir esa variable en 1, **con las demás iguales**.

Dummy: columna 0/1

Una categoría pasa a 0/1. **estandar** queda como **referencia** (todo a 0).

Se puede explicar

Por eso es el primer modelo que se prueba: cada número tiene sentido.

MEDIR EL ERROR

MAE, RMSE y R^2: tres formas de medir

real	predicho	error (valor absoluto)
80 €	75 €	5 €
95 €	100 €	5 €
120 €	110 €	10 €
70 €	72 €	2 €
150 €	160 €	10 €

6,4 €

MAE = media de los errores de estas 5 reservas: (5+5+10+2+10) / 5. Lo que te equivocas, de media, **en euros**.

7,1 €

RMSE: como el MAE, pero los errores grandes pesan más (elevar al cuadrado).

0,94

R^2: 1 = perfecto; 0 = no mejor que predecir la media; negativo = peor.

AJUSTAR Y MEDIR

Entrenar con unos datos, medir con otros

1 · Separa

Una parte para **entrenar**, otra para **probar**.

2 · Ajusta

El modelo aprende sus coeficientes **solo con la parte de entrenamiento**.

3 · Predice

Calcula el precio de reservas que **no ha visto**.

4 · Mide

Compara con el precio real: **MAE, RMSE y R^2**.

El baseline predice siempre la media. Si tu modelo no lo mejora con claridad, no aporta nada.

Medir con los mismos datos con los que aprendió es como poner en el examen las preguntas del ensayo: sale mejor de lo que es.

INTERPRETAR

Cada coeficiente es una diferencia en euros

Con las 8 reservas del ejemplo	Valor	Cómo se lee
tipo_suite	91.0	Una suite cuesta 91 € más que una estándar
alta	25.0	Reservar en temporada alta añade 25 €
intercept_	64.5	Punto de partida del ajuste (la estándar en baja real es 70 €)

Se suman

Una suite en temporada alta: 64,5 + 91,0 + 25,0 = **180,5 €** (el real es 186 €).

Una dummy no es el precio

Es la **diferencia** con la categoría de referencia, la estándar.

Por eso se prefiere este modelo cuando hay que explicar: cada número tiene un significado en euros.

RESIDUOS

¿Se equivoca de forma «sana»?

Residuo = real − predicho. Si cuesta 82 € y el modelo dice 89,5 €, el residuo es −7,5 €: se pasó.

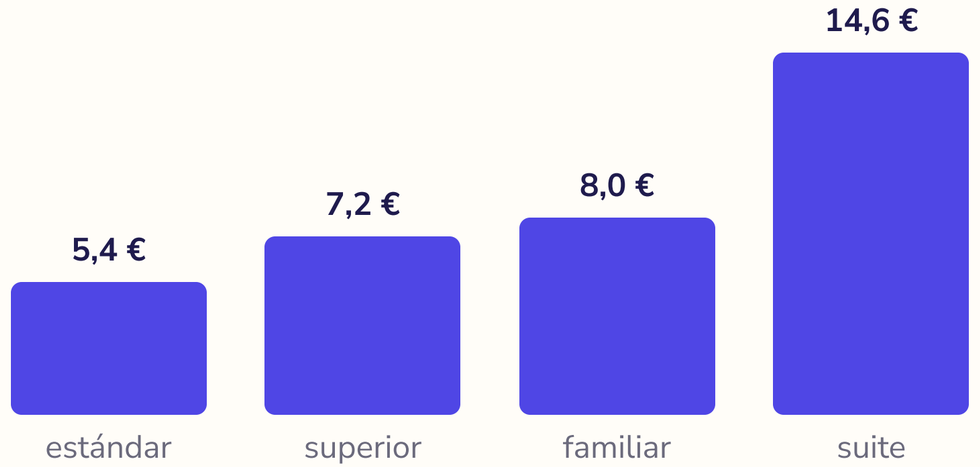
Modelo bien planteado

Residuos **sin patrón**, repartidos alrededor de 0.

Un embudo

Los errores **crecen con el precio**: al modelo le falta algo.

Error medio (MAE) por tipo de habitación, en test (mismo modelo):



El modelo suma euros fijos; los precios cambian en proporción (la temporada alta los multiplica por 1,25).

INTERACCIONES

El efecto de la temporada depende de la habitación

Precio medio	Temporada baja	Temporada alta	La temporada añade
estándar	70 €	84 €	+14 €
suite	150 €	186 €	+36 €

Sin interacción

El modelo pone el mismo **+25 €** a las dos. Suite en alta: predice 180,5 €; real, 186 €.

Con interacción

Añade una columna **tipo_suite · alta**, con coeficiente 22 (36 menos 14). Suite en alta: **186 €**.

Interacción = producto de dos variables: deja que el efecto de una dependa de la otra.

POLINOMIOS

Más columnas, más curvas

x	x^0	x^1	x^2	x^3
2	1	2	4	8
3	1	3	9	27

Grado bajo

Una recta o una curva suave: **sencillo y explicable**.

Grado alto

Imita hasta el ruido: **sobreajusta** y no se puede explicar al cliente.

Variable bien pensada

Una columna que ya contiene el patrón (*feature engineering*) rinde más que complicar el modelo.

Primero piensa la variable; añade complejidad solo si hace falta.

PRÁCTICA · CUADERNO S07_01

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación y ejemplo	Cargar **reservas_turisdata.csv** y preparar **X** e **y** con variables dummy	Clase
Ejercicio 1	Separar en train y test, ajustar **LinearRegression** y medir R^2 y MAE	Clase
Ejemplo	Comparar con el baseline (predecir siempre la media)	Clase
Ejercicio 2	Leer los coeficientes en euros: extra de una suite y efecto de la temporada alta	Clase
Ejemplo	Dibujar y leer los residuos; probar interacciones con validación cruzada	Clase
Ejercicio 3	Error de las interacciones en test y cuánto mejora	Clase
Ejercicio 4	Polinomio sobre el mes frente a la columna **temporada_alta**	Casa
Mini-reto	Función **precio_recomendado(tipo, alta)**	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 4 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Ajustar la regresión lineal	11 y 12
2	Leer los coeficientes	13 y 14
3	Interacciones	15 y 16
4 (casa)	Polinomios y variables bien pensadas	17 y 18
Mini-reto (casa)	La función precio_recomendado	19 y 20

CONSULTA · EJERCICIO 1

Entrenar, predecir y comparar (ejercicio 1)

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=SEMILLA)
modelo_lin = LinearRegression().fit(X_train, y_train)   # ajustar con train
pred = modelo_lin.predict(X_test)                       # predecir en test
r2_test = r2_score(y_test, pred)
mae_test = mean_absolute_error(y_test, pred)
```

0,915
R² en test

7,24 €
MAE en test

9,70 €
RMSE en test

Baseline = predecir siempre la media: MAE 25,56 € y R² ≈ 0. Nuestro modelo baja el error a 7,24 €.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer el ajuste de la regresión (ejercicio 1)

random_state=SEMILLA

Fija el reparto: todo el mundo obtiene **las mismas 1200 reservas de test** y los mismos números.

fit y predict

fit aprende con **X_train, y_train**; **predict** calcula precios para **X_test**, que el modelo **no ha visto**.

$R^2 = 0{,}915$

Con solo el tipo de habitación y la temporada, el modelo explica el **91,5 %** de la variación del precio.

RMSE mayor que MAE

El RMSE eleva los errores al cuadrado y **castiga más los grandes**, sobre todo en las suites.

CONSULTA · EJERCICIO 2

Leer los coeficientes en euros (ejercicio 2)

```
coefs = pd.Series(modelo_lin.coef_, index=X.columns)
extra_suite = coefs["tipo_habitacion_suite"]
efecto_temporada_alta = coefs["temporada_alta"]
```

Con las 8 reservas del ejemplo	Valor	Cómo se lee
tipo_suite	91.0	Una suite cuesta 91 € más que una estándar
alta	25.0	Reservar en temporada alta añade 25 €
intercept_	64.5	Punto de partida del ajuste (la estándar en baja real es 70 €)

En el cuaderno (6 000 reservas)

Suite **+101,2 €** · alta **+22,4 €** · ordenada **67,3 €**

Ojo con la lectura

Una dummy **no es el precio**: es la diferencia con la referencia.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer los coeficientes con nombre (ejercicio 2)

Mismo orden que X

coef_ es una lista sin nombres: **pd.Series(..., index=X.columns)** pone cada coeficiente en **su columna**.

intercept_

El precio cuando todas las columnas valen 0: una **estándar en temporada baja**, 67,3 €.

Los efectos se suman

Una familiar en temporada alta: 67,3 + 45,0 + 22,4 = **134,7 €**.

La referencia

La estándar no tiene columna (**drop_first=True**): los demás efectos se leen **respecto a ella**.

CONSULTA · EJERCICIO 3

PolynomialFeatures crea los productos (ejercicio 3)

```
con_interacciones = make_pipeline(
    PolynomialFeatures(degree=2, interaction_only=True, include_bias=False),
    LinearRegression())
con_interacciones.fit(X_train, y_train)
mae_inter_test = mean_absolute_error(y_test, con_interacciones.predict(X_test))
mejora_mae = mae_test - mae_inter_test   # positivo = mejor
```

es_suite	alta	→	es_suite	alta	producto
1	1		1	1	1
1	0		1	0	0
0	1		0	1	0
0	0		0	0	0

Resultado en el cuaderno

R^2 (CV): **0,924 → 0,933**

MAE en test: **7,24 € → 6,76 €**

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer las interacciones (ejercicio 3)

interaction_only=True

Crea solo los **productos** entre variables, como **suite × temporada_alta**, sin potencias.

make_pipeline

Encadena la creación de columnas con la regresión: se ajusta y se predice **de una vez**.

Resta con signo

mejora_mae = mae_test - mae_inter_test: **positivo = mejor**. Al revés saldría negativo.

Mejora modesta

De 7,24 € a 6,76 €: un **7 %** menos de error. Las interacciones corrigen solo una parte del embudo.

CONSULTA · EJERCICIO 4

Más complejidad no siempre gana (ejercicio 4, casa)

POTENCIAS DE X

```
PolynomialFeatures(3)
x = 2  →  1, 2, 4, 8
x = 3  →  1, 3, 9, 27
# columnas: 1, x, x², x³
```

Habitaciones estándar (CV)	R^2
Mes crudo, grado 2	0,09
Mes crudo, grado 8	0,55
Mes crudo, grado 12	0,60
temporada_alta (1 columna)	**0,65**

Pensar bien la variable (feature engineering) rinde más que añadir complejidad: una columna bate al grado 12.

Con el mes es fácil que el polinomio de grado alto **sobreajuste** y, además, no se puede explicar al cliente.

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer la comparación de polinomios (ejercicio 4, casa)

El mes no es una curva suave

Los meses caros son enero a marzo, julio, agosto y diciembre: una parábola no los imita (**R^2 0,09**).

Una columna 0/1

temporada_alta ya contiene el patrón: **R^2 0,65** con una sola columna.

Ni con 12 grados

El polinomio de grado 12 llega a ≈ 0,60: no alcanza a la variable bien pensada.

Dobles corchetes

fit espera una **tabla**: **est[["temporada_alta"]]**, no **est["temporada_alta"]**.

CONSULTA · MINI-RETO

La tarifa de referencia (mini-reto, casa)

precio_recomendado(tipo, alta) construye **una fila con las mismas columnas que X** (mismo orden) y se la pasa a **modelo_lin.predict**.

tipo, alta	tipo_familiar	tipo_suite	tipo_superior	alta
estandar, 0	0	0	0	0
suite, 1	0	1	0	1
superior, 1	0	0	1	1
familiar, 0	1	0	0	0

Qué comprobar

Una estándar en temporada baja ronda **70 €**; una suite en temporada alta pasa de **180 €**.

La estándar es la referencia

No tiene columna que activar: su fila queda con los tres tipos a 0.

CONSULTA · ACLARACIONES · MINI-RETO

Leer precio_recomendado (mini-reto, casa)

Misma fila que X

Una fila con **las mismas columnas y en el mismo orden**: el modelo aprendió un coeficiente por posición.

La estándar

No tiene columna: su fila queda **toda a 0** y el precio es la ordenada en el origen.

float(...[0])

predict devuelve una lista; el **[0]** saca el primer valor y **float** lo deja como número.

Comprobación

Estándar en baja ≈ **67 €**; suite en alta ≈ **191 €** (67,3 + 101,2 + 22,4).