IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Predecir cancelaciones con probabilidades

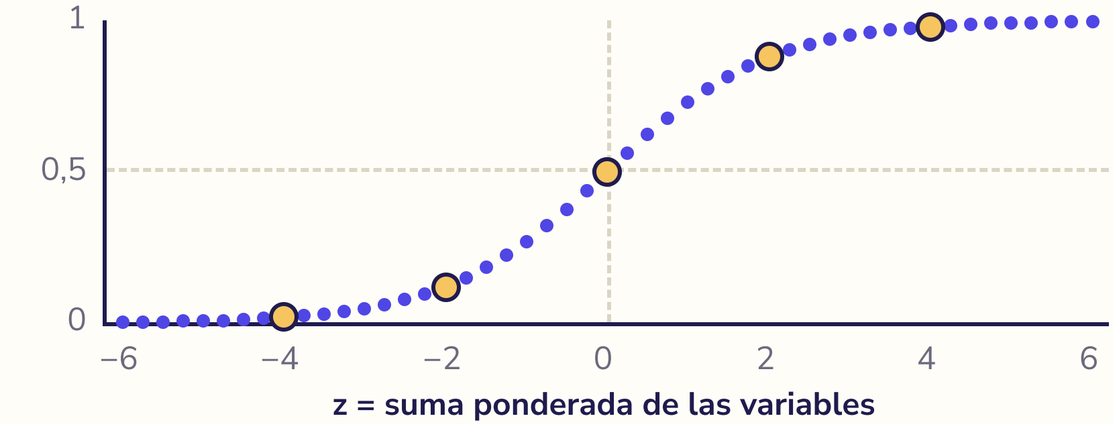
Regresión logística: sigmoide, odds ratio, umbral y matriz de confusión

Sprint 7 · S07_03 · 45 min en clase (ejercicios 1, 2 y 3)

LA IDEA · SECCIÓN 1

De una suma a una probabilidad

Clasificar es predecir una categoría: 0 = se mantiene, 1 = cancela. El modelo no da un precio, da la **probabilidad** de cancelar.



z	probabilidad
−4	0,02
−2	0,12
0	0,50
2	0,88
4	0,98

z negativa: casi 0 · z = 0: **50 %** · z positiva: casi 1

```
prob = 1 / (1 + np.exp(-z))   # con z = 2 sale 0.88
```

LA IDEA · SECCIÓN 1

Primero se suma, después se comprime

Reserva	Tarifa no reembolsable	Viene por agencia	z	Probabilidad de cancelar
A	sí (1)	no (0)	−1,7	0,15
B	no (0)	sí (1)	0,4	0,60
C	sí (1)	sí (1)	−0,8	0,31
D	no (0)	no (0)	−0,5	0,38

```
z = -0.5 - 1.2 * no_reemb + 0.9 * agencia    # la suma ponderada (coeficientes)
prob = 1 / (1 + np.exp(-z))                  # la sigmoide
```

−0,5 · intercepto

El punto de partida.

−1,2 · coeficiente

Tarifa no reembolsable: **baja** el riesgo.

+0,9 · coeficiente

Venir por agencia: lo **sube**.

ENTRENAR EL MODELO · EJERCICIO 1

Un Pipeline y dos formas de preguntar

1 · Imputar

Rellena los huecos.

2 · Escalar

Números en la misma escala.

3 · Codificar

Texto → columnas 0 y 1.

4 · Modelo

Aprende los coeficientes.

```
modelo = LogisticRegression().fit(antelacion, cancela)    # aprende
nuevas = [[15], [60], [120]]                              # días de antelación
modelo.predict_proba(nuevas)[:, 1]                        # [0.11 0.39 0.85]
modelo.predict(nuevas)                                    # [0 0 1]
```

predict_proba

Probabilidad de cada clase. **[:, 1]** = la de cancelar.

predict

La clase final, con umbral por defecto **0,5**.

INTERPRETAR · SECCIÓN 3

Odds y odds ratio: contar en apuestas

Odds = probabilidad de cancelar / probabilidad de no cancelar

p	odds	Se lee
0,20	0,25	1 contra 4
0,50	1,00	1 contra 1
0,75	3,00	3 contra 1
0,90	9,00	9 contra 1

Odds ratio = **exp(coeficiente)**: por cuánto se multiplican los odds

coeficiente	odds ratio	Se lee
−0,7	0,50	reduce a la mitad
0	1,00	no influye
0,4	1,49	casi ×1,5
1,1	3,00	triplica

Odds 0,25 (p = 0,20) × odds ratio 2 = odds 0,50, y la probabilidad pasa a 0,33.

Mayor que 1: **sube** el riesgo · Igual a 1: no influye · Menor que 1: lo **baja**.

INTERPRETAR · EJERCICIO 2

Leer los odds ratio del modelo

```
odds = np.exp(coefs).sort_values(ascending=False)
odds["cat__canal_agencia"]    # 1.20
odds.idxmax()                 # num__antelacion_dias
```

variable	odds ratio
num__antelacion_dias	1,57
num__cancelaciones_previas	1,35
cat__canal_agencia	1,20
cat__regimen_todo_incluido	0,75
cat__tipo_habitacion_suite	0,62

Numéricas: por desviación típica

Con el escalado, 1,57 es «por cada **desviación típica** más de antelación» (una medida de cuánto se separan los datos de la media).

Dos valores, una columna

Con **drop="if_binary"** una variable de dos valores deja **una sola** columna; la otra es la referencia.

Asociación, no causa

Un odds ratio menor que 1 no prueba que la variable **cause** menos cancelaciones.

EL UMBRAL · SECCIÓN 4

El modelo da probabilidades; tú decides

Reserva	1	2	3	4	5	6	7	8	9	10
Probabilidad	0,92	0,81	0,64	0,55	0,42	0,36	0,28	0,19	0,12	0,07
Real (1 = cancela)	1	1	0	1	1	0	1	0	0	0
Alarma con 0,5	1	1	1	1	0	0	0	0	0	0
Alarma con 0,3	1	1	1	1	1	1	0	0	0	0

```
alarma = (proba >= 0.3).astype(int)    # 1 si la probabilidad llega al umbral
```

Umbral alto

Pocas alarmas, casi todas ciertas, pero se escapan cancelaciones.

Umbral bajo

Más cancelaciones detectadas, pero también más clientes molestados.

MATRIZ DE CONFUSIÓN · SECCIÓN 4 · POSITIVO = CANCELA

Cuatro resultados posibles

100 reservas	Predicho: se mantiene	Predicho: cancela
Real: se mantiene	**VN** · 50 aciertos	**FP** · 10 falsas alarmas
Real: cancela	**FN** · 15 cancelaciones no previstas	**VP** · 25 detectadas

25 / 35 = 0,71

Precisión

¿De las alarmas, cuántas eran ciertas?

VP / (VP + FP)

25 / 40 = 0,625

Recall

¿De las cancelaciones reales, cuántas avisamos?

VP / (VP + FN)

```
vn, fp, fn, vp = confusion_matrix(real, pred).ravel()
```

UMBRAL 0,5 FRENTE A 0,3 · EJERCICIO 3

Bajar el umbral: más recall, menos precisión

Umbral (10 reservas)	VP	FP	FN	VN	Precisión	Recall
0,5	3	1	2	4	0,75	0,60
0,3	4	2	1	3	0,67	0,80

```
m05 = metricas_umbral(real, proba, 0.5)
m03 = metricas_umbral(real, proba, 0.3)
round(m03["recall"] - m05["recall"], 2)          # 0.2
round(m05["precision"] - m03["precision"], 2)    # 0.08
```

Sube el recall

Del 60 % al 80 %: detectas **20 puntos más** de cancelaciones.

Baja la precisión

Del 75 % al 67 %: **8 puntos menos** de alarmas ciertas.

SECCIÓN 5 · EJERCICIO 4 (CASA)

Elegir el umbral según el coste

Umbral	FN	FP	Coste = 3·FN + 1·FP
0,1	0	4	4
0,2	0	2	**2**
0,3	1	2	5
0,5	2	1	7

FN: cancelación no prevista

Habitación vacía que se podía vender: **3**.

FP: falsa alarma

Cliente molestado u overbooking: **1**.

```
costes = [coste_total(real, proba, u) for u in umbrales]
umbrales[np.argmin(costes)]    # el umbral de menor coste
```

Regla teórica: 1 / (1 + 3) = 0,25. Se elige con validación cruzada sobre train, nunca con el test.

MINI-RETO (CASA) · SECCIÓN 6

Una tabla para el gerente

umbral	recall	precision	coste
0,50	0,60	0,75	7
0,30	0,80	0,67	5
0,25	1,00	0,71	**2**

```
tabla = pd.DataFrame(filas)    # una fila por umbral
filas.append({"umbral": u, "recall": …, "coste": …})
```

Recomiendo el umbral 0,25: avisa de todas las cancelaciones del ejemplo (recall 1,00) a cambio de más falsas alarmas, porque una habitación vacía cuesta tres veces más.

Tu recomendación debe llevar **al menos una cifra** y decir por qué.

HOY HAS APRENDIDO

Probabilidad, umbral y coste

Probabilidad

Sigmoide y **predict_proba**: el modelo da riesgo, no sí o no

Odds ratio

exp(coef): mayor que 1 sube el riesgo, menor que 1 lo baja

Umbral y errores

La matriz separa FP y FN; el umbral se elige por coste, con validación

Siguiente: S07_04 · curvas ROC y PR, y clases desbalanceadas