IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Predecir cancelaciones con probabilidades

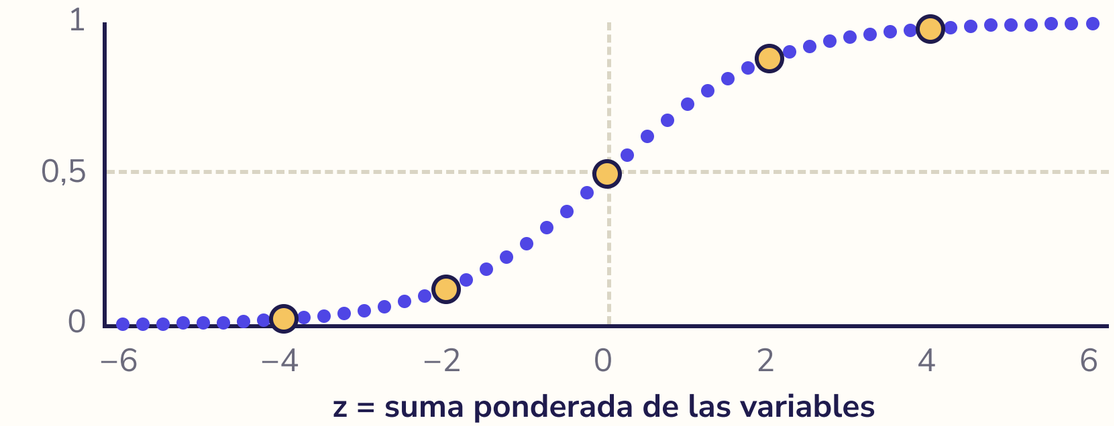
Teoría, práctica y, al final, material de consulta

Sprint 7 · S07_03 · teoría breve, 45 min de práctica y material de consulta

LA IDEA

De una suma a una probabilidad

Clasificar es predecir una categoría: 0 = se mantiene, 1 = cancela. El modelo no da un precio, da la **probabilidad** de cancelar.



z	probabilidad
−4	0,02
−2	0,12
0	0,50
2	0,88
4	0,98

z negativa: casi 0 · z = 0: **50 %** · z positiva: casi 1

probabilidad = 1 / (1 + e^(−z)): con z = 2 sale 0,88

LA IDEA

Primero se suma, después se comprime

Reserva	Tarifa no reembolsable	Viene por agencia	z	Probabilidad de cancelar
A	sí (1)	no (0)	−1,7	0,15
B	no (0)	sí (1)	0,4	0,60
C	sí (1)	sí (1)	−0,8	0,31
D	no (0)	no (0)	−0,5	0,38

z = −0,5 − 1,2 × no_reembolsable + 0,9 × agencia → sigmoide

−0,5 · intercepto

El punto de partida.

−1,2 · coeficiente

Tarifa no reembolsable: **baja** el riesgo.

+0,9 · coeficiente

Venir por agencia: lo **sube**.

ENTRENAR EL MODELO

Dos formas de preguntar al modelo

predict

Da la **clase**: 0 o 1, aplicando un umbral de 0,5.

predict_proba

Da la **probabilidad** de cada clase; la de cancelar es la columna 1.

Por qué la probabilidad

Con ella **tú eliges el umbral**; con la clase, ya viene decidido.

Todo el preprocesado va dentro de un Pipeline, como en el Sprint 6: así el test se trata igual que el train.

INTERPRETAR

Odds y odds ratio: contar en apuestas

Odds = probabilidad de cancelar / probabilidad de no cancelar

p	odds	Se lee
0,20	0,25	1 contra 4
0,50	1,00	1 contra 1
0,75	3,00	3 contra 1
0,90	9,00	9 contra 1

Odds ratio = **exp(coeficiente)**: por cuánto se multiplican los odds

coeficiente	odds ratio	Se lee
−0,7	0,50	reduce a la mitad
0	1,00	no influye
0,4	1,49	casi ×1,5
1,1	3,00	triplica

Odds 0,25 (p = 0,20) × odds ratio 2 = odds 0,50, y la probabilidad pasa a 0,33.

Mayor que 1: **sube** el riesgo · Igual a 1: no influye · Menor que 1: lo **baja**.

EL UMBRAL

El modelo da probabilidades; tú decides

Reserva	1	2	3	4	5	6	7	8	9	10
Probabilidad	0,92	0,81	0,64	0,55	0,42	0,36	0,28	0,19	0,12	0,07
Real (1 = cancela)	1	1	0	1	1	0	1	0	0	0
Alarma con 0,5	1	1	1	1	0	0	0	0	0	0
Alarma con 0,3	1	1	1	1	1	1	0	0	0	0

Alarma = 1 si la probabilidad **llega al umbral**.

Umbral alto

Pocas alarmas, casi todas ciertas, pero se escapan cancelaciones.

Umbral bajo

Más cancelaciones detectadas, pero también más clientes molestados.

MATRIZ DE CONFUSIÓN · POSITIVO = CANCELA

Cuatro resultados posibles

100 reservas	Predicho: se mantiene	Predicho: cancela
Real: se mantiene	**VN** · 50 aciertos	**FP** · 10 falsas alarmas
Real: cancela	**FN** · 15 cancelaciones no previstas	**VP** · 25 detectadas

25 / 35 = 0,71

Precisión

¿De las alarmas, cuántas eran ciertas?

VP / (VP + FP)

25 / 40 = 0,625

Recall

¿De las cancelaciones reales, cuántas avisamos?

VP / (VP + FN)

Las cuatro casillas se cuentan comparando lo **real** con lo **predicho**.

COSTES DE LOS ERRORES

No todos los errores cuestan igual

Dos errores, dos precios

Perder una cancelación (**FN**) cuesta más que una falsa alarma (**FP**).

Coste total

peso_FN · FN + peso_FP · FP. Los pesos los pone **el negocio**.

Elegir el umbral

Se prueba cada umbral y se queda el de **menor coste**.

Umbral	FN	FP	Coste = 3·FN + 1·FP
0,1	0	4	4
0,2	0	2	**2**
0,3	1	2	5

Los umbrales se comparan con validación cruzada en train; el test se usa una sola vez.

PRÁCTICA · CUADERNO S07_03

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación y ejemplo	Cargar las reservas y ver la función sigmoide	Clase
Ejercicio 1	Entrenar el **Pipeline** y obtener probabilidades	Clase
Ejemplo	Odds ratio de cada variable	Clase
Ejercicio 2	Leer dos odds ratio y la variable de más riesgo	Clase
Ejemplo	Matriz de confusión con dos umbrales	Clase
Ejercicio 3	Efecto de bajar el umbral de 0,5 a 0,3	Clase
Ejemplo	Probabilidades de CV, costes y curva del coste	Casa
Ejercicio 4	Elegir el umbral de menor coste	Casa
Mini-reto	Tabla de umbrales para el gerente	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 4 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Entrenar y obtener probabilidades	11 y 12
2	Odds ratio	13 y 14
3	Bajar el umbral	15 y 16
4 (casa)	Umbral de menor coste	17 y 18
Mini-reto (casa)	Tabla para el gerente	19 y 20

CONSULTA · EJERCICIO 1

Pipeline y dos formas de preguntar (ejercicio 1)

1 · Imputar

Rellena los huecos.

2 · Escalar

Números en la misma escala.

3 · Codificar

Texto → columnas 0 y 1.

4 · Modelo

Aprende los coeficientes.

```
modelo = LogisticRegression().fit(antelacion, cancela)    # aprende
nuevas = [[15], [60], [120]]                              # días de antelación
modelo.predict_proba(nuevas)[:, 1]                        # [0.11 0.39 0.85]
modelo.predict(nuevas)                                    # [0 0 1]
```

predict_proba

Probabilidad de cada clase. **[:, 1]** = la de cancelar.

predict

La clase final, con umbral por defecto **0,5**.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer el entrenamiento (ejercicio 1)

Pipeline

Imputa, escala, codifica **y** entrena en un solo objeto: lo aprendido en train se aplica igual a test.

drop="if_binary"

Una variable de dos valores (sí o no) deja **una sola columna** 0/1 en vez de dos.

predict_proba(X)[:, 1]

Devuelve dos columnas (no cancela y cancela); **[:, 1]** se queda con la de **cancelar**.

Probabilidad media

≈ 0,466 frente a una tasa real del 45,9 %: el modelo es **coherente** con lo que ocurre.

CONSULTA · EJERCICIO 2

Leer los odds ratio (ejercicio 2)

```
odds = np.exp(coefs).sort_values(ascending=False)
odds["cat__deposito_total"]    # 0.46
odds.idxmax()                  # num__antelacion_dias
```

variable	odds ratio
num__antelacion_dias	2,12
cat__deposito_sin_deposito	2,01
cat__canal_web_intermediaria	1,70
cat__deposito_total	0,46
cat__tarifa_no_reembolsable	0,44

Numéricas: por desviación típica

Con el escalado, 2,12 es «por cada **desviación típica** más de antelación» (una medida de cuánto se separan los datos de la media).

Dos valores, una columna

Con **drop="if_binary"** una variable de dos valores deja **una sola** columna; la otra es la referencia.

Asociación, no causa

Un odds ratio menor que 1 no prueba que la variable **cause** menos cancelaciones.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer los odds ratio (ejercicio 2)

np.exp(coefs)

El coeficiente está en escala logarítmica; **exp** lo convierte en **odds ratio**: cuántas veces se multiplican los odds.

odds.idxmax()

Devuelve el **nombre** de la variable con el mayor valor: la que más sube el riesgo, **antelacion_dias**.

Menos de 1 reduce

Tarifa no reembolsable, 0,44: los odds de cancelar se **multiplican por 0,44**, es decir, un 56 % menos.

Por desviación típica

Las numéricas están escaladas: ×2,12 es por **cada desviación típica** de antelación, no por cada día.

CONSULTA · EJERCICIO 3

Bajar el umbral: más recall, menos precisión

Umbral (10 reservas)	VP	FP	FN	VN	Precisión	Recall
0,5	3	1	2	4	0,75	0,60
0,3	4	2	1	3	0,67	0,80

```
m05 = metricas_umbral(real, proba, 0.5)
m03 = metricas_umbral(real, proba, 0.3)
round(m03["recall"] - m05["recall"], 2)          # 0.2
round(m05["precision"] - m03["precision"], 2)    # 0.08
```

Sube el recall

Del 60 % al 80 %: detectas **20 puntos más** de cancelaciones.

Baja la precisión

Del 75 % al 67 %: **8 puntos menos** de alarmas ciertas.

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer el efecto del umbral (ejercicio 3)

metricas_umbral

Para cada umbral cuenta VN, FP, FN y VP y calcula **precisión y recall**.

Restas con signo

sube_recall = m03 − m05 y **baja_precision = m05 − m03**: lo que **ganas** y lo que **pierdes**.

Recall 0,615 → 0,875

Con 0,3 se avisa del **87,5 %** de las cancelaciones (482 de 551) frente al 61,5 % (339).

Precisión 0,657 → 0,555

De cada 100 alarmas, **unas 45 son falsas** (antes, unas 34): hay que ponerles precio.

CONSULTA · EJERCICIO 4 (CASA)

Elegir el umbral según el coste

Umbral	FN	FP	Coste = 3·FN + 1·FP
0,1	0	4	4
0,2	0	2	**2**
0,3	1	2	5
0,5	2	1	7

FN: cancelación no prevista

Habitación vacía que se podía vender: **3**.

FP: falsa alarma

Cliente molestado u overbooking: **1**.

```
costes = [coste_total(real, proba, u) for u in umbrales]
umbrales[np.argmin(costes)]    # el umbral de menor coste
```

Regla teórica: 1 / (1 + 3) = 0,25. Se elige con validación cruzada sobre train, nunca con el test.

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer la elección del umbral (ejercicio 4, casa)

np.arange(0.05, 0.96, 0.05)

Los **19 umbrales** que se prueban, de 0,05 a 0,95.

np.argmin(costes)

Da la **posición** del menor coste; **umbrales[...]** la convierte en el umbral elegido.

Elegir en train, medir en test

Los costes salen de **proba_cv** (validación cruzada en train); el **test se usa una sola vez**.

Por qué 0,25

Un FN cuesta el **triple** que un FP: 1 / (1 + 3) = 0,25. Coste en test: **577** frente a 813 con 0,5.

CONSULTA · MINI-RETO (CASA)

Una tabla para el gerente

umbral	recall	precision	coste
0,50	0,60	0,75	7
0,30	0,80	0,67	5
0,25	1,00	0,71	**2**

```
tabla = pd.DataFrame(filas)    # una fila por umbral
filas.append({"umbral": u, "recall": …, "coste": …})
```

Recomiendo el umbral 0,25: avisa de todas las cancelaciones del ejemplo (recall 1,00) a cambio de más falsas alarmas, porque una habitación vacía cuesta tres veces más.

Tu recomendación debe llevar **al menos una cifra** y decir por qué.

CONSULTA · ACLARACIONES · MINI-RETO

Leer la tabla para el gerente (mini-reto, casa)

Tres umbrales

Recorre 0,5, 0,3 y **mejor_umbral**; para cada uno calcula recall, precisión y coste.

pd.DataFrame(filas)

Junta las filas en la tabla **tabla_umbrales**: **una fila por umbral**.

La recomendación

recomendacion propone un umbral y lo justifica con **al menos una cifra**.

Para el gerente

Precisión 0,533: **53 %** de las alarmas son ciertas. Se enseña recall, precisión y coste: si cambian los pesos, él decide.