IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Clases raras: cuando la exactitud engaña

Teoría, práctica y, al final, material de consulta

Sprint 7 · S07_04 · teoría breve, 15 min de práctica y material de consulta

LA PARADOJA DE LA EXACTITUD

Acierta el 95 % y no sirve para nada

200 reservas	Predicho: se mantiene	Predicho: cancela
Real: se mantiene (190)	**VN** · 190	**FP** · 0
Real: cancela (10)	**FN** · 10	**VP** · 0

Exactitud: 95 %

Acierta 190 de 200 reservas.

Recall: 0 %

No detecta **ninguna** cancelación.

Un modelo que dice siempre «se mantiene» acierta casi todo y no sirve de nada.

Con clases raras la **exactitud engaña**: mira recall, precisión, AUC y AP.

CURVA ROC

ROC: una foto por cada umbral

10 reservas de ejemplo: 4 cancelan (puntuaciones 0,90 · 0,75 · 0,55 · 0,35) y 6 se mantienen (0,65 · 0,45 · 0,30 · 0,25 · 0,15 · 0,10).

Umbral	VP	FP	TPR = VP / 4	FPR = FP / 6
0,8	1	0	0,25	0,00
0,6	2	1	0,50	0,17
0,4	3	2	0,75	0,33
0,2	4	4	1,00	0,67

TPR (= recall)

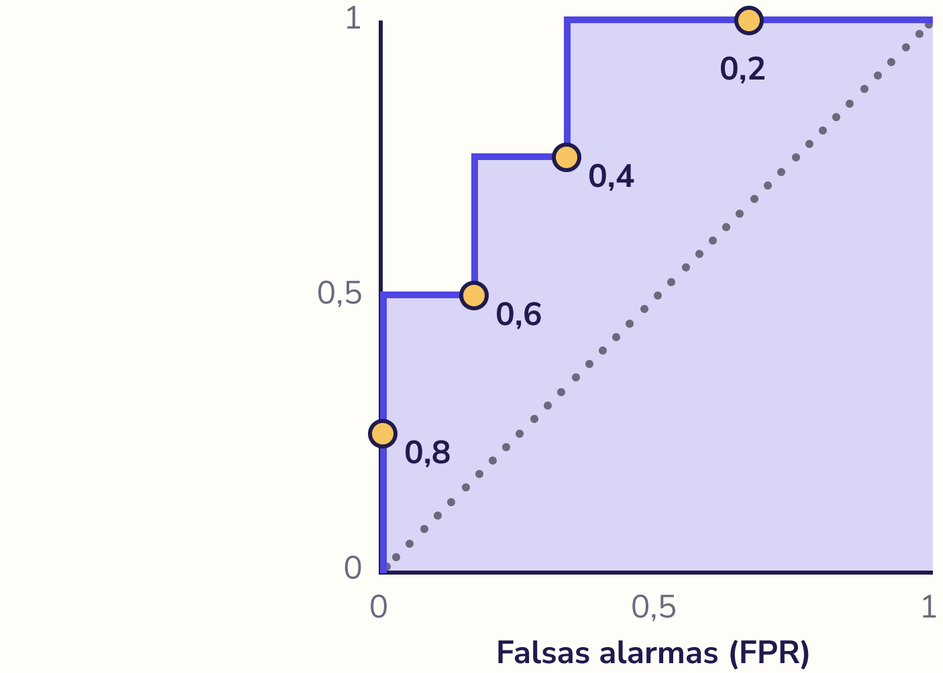
De las cancelaciones, ¿cuántas detectas?

FPR

De las que se mantienen, ¿a cuántas marcas por error?

CURVA ROC

Cada umbral es un punto de la curva



Diagonal: el azar

Un modelo inútil va por la diagonal: AUC = **0,5**.

Esquina superior izquierda

Muchas cancelaciones detectadas con pocas falsas alarmas: AUC = **1**.

Área sombreada: AUC

En este ejemplo, **0,875**. Los puntos dorados son los umbrales 0,8 · 0,6 · 0,4 · 0,2.

AUC

AUC: ganar un duelo por parejas

Cancelación (puntuación)	Supera a … de las 6 que se mantienen
0,90	6
0,75	6
0,55	5
0,35	4
Total	**21 de 24 parejas** = 0,875

AUC = probabilidad de que una cancelada puntúe *más alto* que una que se mantiene. AUC 0,875 *no* es «87,5 % de acierto».

CURVA PR

Con clases raras la ROC parece demasiado buena

1000 reservas	Predicho: se mantiene	Predicho: cancela
Real: se mantiene (970)	**VN** · 894	**FP** · 76
Real: cancela (30)	**FN** · 6	**VP** · 24

Lo que ve la ROC

TPR = 24 / 30 = **0,80**

FPR = 76 / 970 = **0,078**: casi la esquina buena.

Lo que ve la curva PR

Precisión = 24 / 100 = **0,24**

76 de cada 100 alarmas son falsas.

El FPR se divide entre muchísimos negativos y no ve el problema. El azar en PR no es la diagonal: es la prevalencia (30 / 1000 = 0,03).

AVERAGE PRECISION

AP: la precisión media de cada acierto

20 reservas, 4 cancelan. Ordenadas por puntuación, cada vez que aciertas una cancelación anotas la precisión hasta ahí.

Acierto	Puntuación	Posición en la lista	Precisión
1.º	0,90	1.ª	1 / 1 = 1,00
2.º	0,70	3.ª	2 / 3 = 0,67
3.º	0,50	6.ª	3 / 6 = 0,50
4.º	0,30	10.ª	4 / 10 = 0,40

La media de las cuatro precisiones es 0,64: 3,2 veces mejor que el azar (0,64 / 0,20).

TRES REMEDIOS

Qué hacer con una clase rara

1 · Pesos por clase

1000 reservas: 50 cancelan y 950 no. Con **"balanced"**, un error en la clase rara pesa 10 y en la otra 0,53: **19 veces más**.

2 · Submuestreo

Train: 30 cancelan y 270 no. Te quedas con las 30 y con **60** negativas elegidas al azar: 90 filas.

3 · Ajustar el umbral

No cambia el modelo: cambia la decisión de **cuándo avisar**.

El remuestreo solo se aplica a train, nunca a test.

AJUSTAR EL UMBRAL

El gerente pide recall de al menos 0,70

Umbral	Recall	Precisión	¿Recall ≥ 0,70?
0,70	0,50	0,67	no
0,50	**0,75**	**0,50**	**sí: el mayor umbral que cumple**
0,30	1,00	0,40	sí
0,25	1,00	0,36	sí

Mismas puntuaciones (AUC 0,84, AP 0,64) y distinto punto de trabajo: **pesos y submuestreo son formas indirectas de mover el umbral.**

PRÁCTICA · CUADERNO S07_04

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación	Cargar las reservas, con solo un 6 % de cancelaciones	Clase
Ejercicio 1	El modelo inútil que acierta el 94 %: exactitud y recall	Casa
Ejemplo	Entrenar el modelo base y sacar sus probabilidades	Clase
Ejercicio 2	Calcular la curva ROC y el AUC	Clase
Ejemplo	Curva de precisión y recall	Casa
Ejercicio 3	Cuánto mejora la AP al azar	Casa
Ejercicios 4 y 5	Pesos por clase y submuestreo de la clase mayoritaria	Casa
Ejercicio 6	Umbral para detectar al menos el 70 %	Casa
Mini-reto	Comparativa de las tres estrategias	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Tras intentar el ejercicio o si algo no sale. No se proyecta. Orden del cuaderno: ejercicios 1 a 6 y mini-reto.

Ejercicio	Tema	Diapositivas
1 (casa)	El modelo inútil	12 y 13
2	Curva ROC y AUC	14 y 15
3 (casa)	AP frente al azar	16 y 17
4 (casa)	Pesos por clase	18 y 19
5 (casa)	Submuestreo	20 y 21
6 (casa)	Umbral para el 70 %	22 y 23
Mini-reto (casa)	Tres estrategias	24 y 25

CONSULTA · EJERCICIO 1

El modelo inútil (ejercicio 1, casa)

```
tonto = DummyClassifier(strategy="most_frequent").fit(X_train, y_train)
pred_tonto = tonto.predict(X_test)
acc_tonto = accuracy_score(y_test, pred_tonto)     # 0.94
recall_tonto = recall_score(y_test, pred_tonto)    # 0.0
```

94,0 %

Exactitud del modelo inútil

0 %

Recall: no detecta ninguna

Con eventos raros, **un modelo sin ninguna utilidad saca un 94 %.**

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer el modelo inútil (ejercicio 1, casa)

strategy="most_frequent"

Predice siempre la clase más frecuente, «no cancela». **.fit** solo cuenta cuál es.

Por qué acierta

El **94 %** de las reservas no se cancela: diciendo siempre «no» acierta todas esas.

La exactitud engaña

94 % de exactitud con **0 %** de recall: no detecta ni una cancelación.

Qué mirar

Con eventos raros: **recall, precisión, AUC o AP**.

CONSULTA · EJERCICIO 2

Curva ROC y AUC (ejercicio 2)

```
fpr, tpr, _ = roc_curve(y_test, proba_base)    # 3 arrays: un punto por umbral
auc = roc_auc_score(y_test, proba_base)        # área bajo la curva
```

≈ 0,77

AUC del modelo base

0,5

Azar: la diagonal

La curva queda **por encima de la diagonal:** el modelo ordena mejor que el azar.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer la curva ROC (ejercicio 2)

Tres arrays

roc_curve devuelve **fpr**, **tpr** y los umbrales; con _ dices «los umbrales no me hacen falta».

Un punto por umbral

Cada punto de la curva es un **umbral distinto**: lo que detectas y lo que falsamente avisas.

AUC ≈ 0,77

Si tomas una reserva cancelada y otra no, el modelo da **más probabilidad a la cancelada en ≈ 77 %** de los casos.

Por encima de la diagonal

Ordena mejor que el azar: con un FPR ≈ 0,18 detecta **≈ 56–58 %** de las cancelaciones.

CONSULTA · EJERCICIO 3

Precisión media frente al azar (ejercicio 3, casa)

```
ap_base = average_precision_score(y_test, proba_base)    # 0.24
veces_mejor_que_azar = ap_base / prevalencia             # 4.0
```

0,24

AP del modelo base

4,0

veces mejor que el azar

El azar en PR no es la diagonal: es la prevalencia (≈ 6 %).

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer la AP (ejercicio 3, casa)

ap_base / prevalencia

Compara la AP con lo que haría el azar: acertar tanto como la **proporción de positivas**.

4 veces mejor

Las alarmas del modelo son ciertas **unas 4 veces más** que al azar: 24 % frente a 6 %.

AUC 0,77 y AP 0,24

El AUC parece bueno y la AP pobre. Las dos son **ciertas**: miran cosas distintas.

Por qué difieren

La ROC divide entre los ≈ 970 negativos de test; frente a solo 62 positivas, unas decenas de falsas alarmas **son la mayoría de las alarmas**.

CONSULTA · EJERCICIO 4

Pesos por clase (ejercicio 4, casa)

```
con_pesos = nuevo_modelo(class_weight="balanced").fit(X_train, y_train)
recall_base = recall_score(y_test, base.predict(X_test))                # 0.03
recall_pesos = recall_score(y_test, con_pesos.predict(X_test))          # 0.73
precision_pesos = precision_score(y_test, con_pesos.predict(X_test))    # 0.14
```

73 %

Recall: de 3 % a

14 %

Precisión del ponderado

Se detecta más, pero **86 de cada 100 alarmas son falsas.**

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer los pesos por clase (ejercicio 4, casa)

class_weight="balanced"

Peso **inversamente proporcional** a la frecuencia: aquí, un error en una cancelada cuenta unas **16 veces más**.

Mismo pipeline

nuevo_modelo(...) monta el mismo **Pipeline**; solo cambia el peso de las clases.

Qué se gana

El recall pasa de **3 % a 73 %**: el modelo ya avisa de casi todas las cancelaciones.

Qué se paga

La precisión es **14 %**: 86 de cada 100 alarmas son falsas. El modelo base daba solo 3 alarmas en test.

CONSULTA · EJERCICIO 5

Submuestreo (ejercicio 5, casa)

```
pos_tr = X_train[y_train == 1]
neg_tr = X_train[y_train == 0]
neg_sub = resample(neg_tr, replace=False, n_samples=2 * len(pos_tr), random_state=SEMILLA)
X_sub = pd.concat([pos_tr, neg_sub])    # 435 filas
y_sub = pd.Series([1] * len(pos_tr) + [0] * len(neg_sub), index=X_sub.index)
con_submuestreo = nuevo_modelo().fit(X_sub, y_sub)
```

145

positivas en **X_sub**

290

negativas en **X_sub**

CONSULTA · ACLARACIONES · EJERCICIO 5

Leer el submuestreo (ejercicio 5, casa)

resample(..., replace=False)

Elige negativas **al azar y sin repetir**: el doble que de positivas (290 frente a 145).

pd.concat y y_sub

Une positivas y negativas en **X_sub**; **y_sub** pone **unos** a las positivas y **ceros** a las negativas.

Recall ≈ 0,45

Menor que con pesos (0,73): aquí hay **2 negativas por cada positiva**; con **balanced**, queda 1 a 1.

Su inconveniente

Se **tira información**: de 2272 negativas solo se usan 290. Solo en train, y repetible con otras muestras.

CONSULTA · EJERCICIO 6

Umbral para detectar el 70 % (ejercicio 6, casa)

```
cv = StratifiedKFold(5, shuffle=True, random_state=SEMILLA)
proba_cv = cross_val_predict(nuevo_modelo(), X_train, y_train, cv=cv, method="predict_proba")[:, 1]
p_cv, r_cv, u_cv = precision_recall_curve(y_train, proba_cv)
umbral_70 = float(u_cv[r_cv[:-1] >= 0.70].max())    # 0.048
pred_70 = (proba_base >= umbral_70).astype(int)
```

82 %

Recall en test con 0,048

12 %

Precisión en test

CONSULTA · ACLARACIONES · EJERCICIO 6

Leer la elección del umbral (ejercicio 6, casa)

cross_val_predict

Da a cada reserva de train una probabilidad calculada por un modelo que **no la ha visto**.

r_cv[:-1]

precision y **recall** tienen **un elemento más** que **umbrales**: se recorta el último para alinearlos.

El mayor umbral

.max() entre los que cumplen recall ≥ 0,70: es el que **pierde menos precisión**.

Por qué tan bajo

Con solo un 6 % de positivas las probabilidades son pequeñas: para detectar el 70 % hay que avisar desde **≈ 5 %**.

CONSULTA · MINI-RETO

Comparar las tres estrategias (mini-reto, casa)

Estrategia	AUC	AP	Recall	Precisión
base	0,774	0,242	0,032	0,667
pesos	0,770	0,245	0,726	0,136
submuestreo	0,752	0,241	0,452	0,172

AUC y AP casi no cambian; lo que cambia es el **punto de trabajo**: recall frente a precisión.

```
comparativa = pd.DataFrame(filas).T.round(3)
ganadora_ap = comparativa["AP"].idxmax()    # 'pesos'
```

CONSULTA · ACLARACIONES · MINI-RETO

Leer la comparativa (mini-reto, casa)

Probabilidades y clases

AUC y AP se calculan con **predict_proba**; recall y precisión, con **predict** (umbral 0,5).

idxmax()

Devuelve el **nombre** de la fila con mayor AP: **pesos**, 0,245; pero la ventaja es mínima.

Por qué casi no cambian

Las tres versiones **ordenan las reservas casi igual**: AUC y AP miden el orden, no el umbral.

Qué sí cambia

El **recall** (0,03 · 0,73 · 0,45) y con él la precisión: pesos y submuestreo son formas indirectas de **bajar el umbral**.