IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Mirar a los vecinos o multiplicar probabilidades

Teoría, práctica y, al final, material de consulta

Sprint 7 · S07_05 · teoría breve, práctica en casa (40 min) y material de consulta

K-NN · LA IDEA

Dime con quién te pareces

1 · Mide la distancia a todas las reservas conocidas → 2 · Elige las k más cercanas → 3 · Vota: gana la clase más frecuente

Reserva	Antelación (días)	Distancia a la nueva (90 días)	¿Canceló?
B	95	5	sí
A	100	10	sí
C	120	30	no
D	40	50	no
E	150	60	sí

Con k = 3, B, A y C votan 1, 1 y 0: **2 de 3 = 0,67** de probabilidad de cancelar. No hay entrenamiento: el modelo **guarda los datos** y trabaja al predecir.

K-NN · ESCALAR

La variable grande se come a las pequeñas

Reserva	Antelación (días)	Repetidor (0/1)	¿Canceló?	Dist. sin escalar	Dist. escalada
A	100	0	sí	10,05	2,06
B	95	0	sí	5,10	2,05
C	120	1	no	30,00	0,83
D	40	1	no	50,00	1,38
E	150	0	sí	60,01	2,63

Reserva nueva: **90 días** de antelación y **cliente repetidor (1)**. k = 3.

Sin escalar

Vecinas **B, A, C**: 2 de 3 cancelaron → **cancela**. Ser repetidor (0 o 1) apenas pesa frente a cientos de días.

Escalando

Vecinas **C, D, B**: 2 de 3 no cancelaron → **no cancela**. Ahora la antelación y el repetidor pesan parecido.

K-NN · ELEGIR K

Elegir k: ni copiar ni promediar de más

Clase de las 9 vecinas, de la más cercana a la más lejana: **1 0 0 1 0 0 0 1 0** (1 = canceló).

k	Vecinas que cuentan	Cancelan	Predice
1	solo la 1ª	1 de 1	**cancela**
3	de la 1ª a la 3ª	1 de 3	no cancela
9	todas	3 de 9	no cancela (como el baseline)

k pequeño (1, 3)

Copia el ruido: **alta varianza**, sobreajuste.

k grande

Promedia demasiado: **alto sesgo**.

Se elige con **validación cruzada**, comparando el AUC de cada k.

NAIVE BAYES · LA IDEA

Cada dato aporta su probabilidad

Puntuación(cancela) = P(cancela) × P(tarifa | cancela) × P(depósito | cancela) × …

Teorema de Bayes

Calcula la probabilidad de cancelar **a partir de los datos** de la reserva.

La simplificación «ingenua»

Supone que los datos son **independientes entre sí** dentro de cada clase. Por eso basta **multiplicar**.

Falso, pero útil

Entrena en milisegundos, necesita pocos datos y rinde sorprendentemente bien.

Como un médico que suma pistas una a una (fiebre, tos, cansancio) sin pensar en cómo se influyen entre sí. Su pega: las probabilidades suelen salir **demasiado extremas**.

NAIVE BAYES · A MANO

Con un ejemplo de 10 reservas

10 reservas pasadas	Cancelan (4)	No cancelan (6)
Tarifa flexible	3	2
Sin depósito	3	1

Reserva nueva: tarifa **flexible** y **sin depósito**. ¿Se cancelará?

Se multiplica…	Cancela	No cancela
P(clase)	4/10 = 0,40	6/10 = 0,60
× P(flexible | clase)	3/4 = 0,75	2/6 = 0,33
× P(sin depósito | clase)	3/4 = 0,75	1/6 = 0,17
= puntuación	**0,225**	**0,033**

Se normaliza: 0,225 / (0,225 + 0,033) = 0,87 → 87 % de probabilidad de cancelar.

NAIVE BAYES · VARIABLES NUMÉRICAS

GaussianNB: una campana por clase

Antelación de las reservas pasadas	Media	Desviación
Cancelaron: 100, 120, 140, 160, 180	140	28
No cancelaron: 20, 40, 60, 80, 100	60	28

Reserva nueva con…	60 días	90 días	100 días	110 días	130 días
P(cancela)	2 %	27 %	50 %	**73 %**	95 %

Para cada clase guarda la **media y la desviación** de cada variable y supone una campana de Gauss.

NAIVE BAYES · VARIABLES CATEGÓRICAS

CategoricalNB: contar frecuencias

Antelación (días)	5	12	20	33	47	60	85	120	160	300
Tramo (0 a 4)	0	0	1	1	2	2	3	3	4	4

Cada tramo tiene el mismo nº de reservas: los bordes (5 · 16 · 40 · 72,5 · 140 · 300) salen de los **cuantiles**.

Por qué enteros

CategoricalNB solo entiende categorías **0, 1, 2…**: hay que discretizar y codificar.

Qué cuenta

En cada clase, **cuántas veces aparece** cada categoría: tramo, agencia, tarifa…

COMPARAR MODELOS

¿Qué modelo para el equipo de reservas?

Modelo	Ajustar	Predecir	¿Se puede explicar?
Regresión logística	milisegundos	milisegundos	**Sí**: odds ratio de cada variable
k-NN	casi nada: guarda los datos	**la más lenta**: compara con todas	Solo con ejemplos parecidos
GaussianNB	milisegundos	milisegundos	Aporte de cada dato a la probabilidad
CategoricalNB	milisegundos	milisegundos	Aporte de cada dato a la probabilidad

Compara siempre **AUC + coste + explicabilidad**: el «mejor» modelo depende del contexto.

PRÁCTICA · CUADERNO S07_05 (CASA)

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación	Cargar las reservas y el preprocesado	Casa
Ejemplo	Qué variable manda en la distancia	Casa
Ejercicio 1	Cuánto pesa la antelación, con y sin escalar	Casa
Ejercicio 2	Elegir k con validación cruzada	Casa
Ejercicio 3	Naive Bayes con variables numéricas (GaussianNB)	Casa
Ejercicio 4	Naive Bayes con tramos (CategoricalNB)	Casa
Mini-reto	Comparar los cuatro modelos: AUC y tiempos	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 4 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Peso de la antelación	12 y 13
2	Elegir k	14 y 15
3	GaussianNB	16 y 17
4	CategoricalNB	18 y 19
Mini-reto	Comparar los cuatro modelos	20 y 21

CONSULTA · EJERCICIO 1

Cuánto pesa la antelación (ejercicio 1)

```
pct_antelacion_sin_escalar = sin_escalar["antelacion_dias"] * 100    # 76.6
pct_antelacion_escalada = escalado["antelacion_dias"] * 100          # 11.4
```

77 %

Sin escalar: la antelación decide

11 %

Escalada: un reparto parejo

Con 9 variables, 1/9 ≈ 11,1 % a cada una: el escalado reparte el peso por igual.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer el peso de la antelación (ejercicio 1)

sin_escalar y escalado

Dos Series con la parte de la distancia² que aporta **cada variable**, en tanto por uno.

["antelacion_dias"] * 100

Toma el valor de esa variable y lo pasa a **porcentaje**.

77 % y 23 %

Sin escalar, **antelacion_dias** y **precio_noche** se reparten casi todo; las demás aportan **menos del 1 %**.

Escalada: 11 %

Cada variable pesa ≈ **1/9**. Sin escalar, una variable 0/1 como **cliente_repetidor** ni se nota.

CONSULTA · EJERCICIO 2

Elegir k con validación cruzada (ejercicio 2)

```
ks = [1, 5, 15, 31, 61, 101, 201, 401]
auc_por_k = []
for k in ks:
    modelo_k = Pipeline([("prep", prep_onehot()), ("knn", KNeighborsClassifier(n_neighbors=k))])
    auc_por_k.append(cross_val_score(modelo_k, X, y, cv=cv, scoring="roc_auc").mean())
mejor_k = ks[int(np.argmax(auc_por_k))]    # 201
```

201

mejor k (AUC ≈ 0,740)

0,585

k = 1: sobreajuste

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer la elección de k (ejercicio 2)

for k in ks

Prueba cada k con **el mismo** preprocesado y la misma validación cruzada de 5 folds.

np.argmax(auc_por_k)

Da la **posición** del mayor AUC; **ks[…]** la convierte en el k.

k = 1: AUC ≈ 0,58

Copia la clase de **un solo vecino** y el ruido lo engaña: sobreajuste, casi no mejora al azar.

Se aplana desde k ≈ 100–200

201 y 401 dan ≈ 0,740: subir más **ya no ayuda**. Vale el k más pequeño que rinde bien.

CONSULTA · EJERCICIO 3

Naive Bayes con GaussianNB (ejercicio 3)

```
nb_gauss = Pipeline([("prep", prep_onehot()), ("nb", GaussianNB())])
auc_nb_gauss = cross_val_score(nb_gauss, X, y, cv=cv, scoring="roc_auc").mean()    # 0.719
```

≈ 0,72

AUC de GaussianNB

0,740

AUC de k-NN (k = 201)

Mismo preprocesado que k-NN: así se comparan en igualdad de condiciones.

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer GaussianNB (ejercicio 3)

Pipeline con **prep_onehot()**

Imputa, escala y pasa las categóricas a **one-hot**: el mismo preprocesado que k-NN.

GaussianNB()

Guarda **media y desviación** de cada variable en cada clase y supone una campana de Gauss.

Qué es «ingenuo»

Supone las variables **independientes** entre sí dado el resultado, y por eso multiplica sus probabilidades.

Matriz densa

GaussianNB necesita matriz **densa**: el codificador lleva **sparse_output=False**. Si no, da error.

CONSULTA · EJERCICIO 4

Naive Bayes con CategoricalNB (ejercicio 4)

```
prep_cat = ColumnTransformer([
    ("num", Pipeline([("imp", SimpleImputer(strategy="median")),
                      ("bins", KBinsDiscretizer(n_bins=5, encode="ordinal", strategy="quantile"))]), columnas_num),
    ("cat", Pipeline([("imp", SimpleImputer(strategy="most_frequent")),
                      ("ord", OrdinalEncoder())]), columnas_cat)])
nb_cat = Pipeline([("prep", prep_cat), ("nb", CategoricalNB(min_categories=5))])
auc_nb_cat = cross_val_score(nb_cat, X, y, cv=cv, scoring="roc_auc").mean()    # 0.742
```

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer CategoricalNB (ejercicio 4)

KBinsDiscretizer(..., "quantile")

Parte cada numérica en **5 tramos** con el mismo nº de reservas (20 % cada uno).

OrdinalEncoder()

Pasa el texto a **enteros**; CategoricalNB solo entiende categorías 0, 1, 2…

min_categories=5

Evita errores si un tramo **no aparece** en un fold: deja sitio a los 5 tramos.

0,742 frente a 0,719

Gana a GaussianNB: al discretizar capta relaciones que **no son una campana** de Gauss.

CONSULTA · MINI-RETO

Comparar los cuatro modelos (mini-reto)

```
for nombre, m in candidatos.items():
    auc = cross_val_score(m, X, y, cv=cv, scoring="roc_auc").mean()
    t0 = time.perf_counter(); m.fit(X_train, y_train); t1 = time.perf_counter()
    m.predict_proba(X_test); t2 = time.perf_counter()
    filas[nombre] = {"auc_cv": auc, "segundos_ajuste": t1 - t0, "segundos_predecir": t2 - t1}
tabla = pd.DataFrame(filas).T.round(3)   # una fila por modelo
```

Modelo	AUC	Ajustar	Predecir
logistica	0,757	≈ 0,03 s	≈ 0,006 s
knn	0,740	≈ 0,03 s	**≈ 0,1 s**
nb_gauss	0,719	≈ 0,03 s	≈ 0,006 s
nb_cat	0,742	≈ 0,03 s	≈ 0,006 s

CONSULTA · ACLARACIONES · MINI-RETO

Leer la comparativa (mini-reto)

candidatos.items()

Recorre el diccionario de los 4 modelos: cada uno con **su AUC y sus tiempos**.

time.perf_counter()

Marca el instante antes y después de **fit** y de **predict_proba**; **restar** da los segundos.

k-NN predice más lento

≈ 0,1 s frente a ≈ 0,006 s: unas **15 veces más**. Compara cada reserva nueva con todas las guardadas.

Recomendación

Regresión logística: mejor AUC (0,757), rápida y **explicable** (odds ratio). Los otros AUC quedan entre 0,72 y 0,74.