IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Mirar a los vecinos o multiplicar probabilidades

k-NN y Naive Bayes: dos formas de razonar para predecir cancelaciones

Sprint 7 · S07_05 · 40 min en casa (cuaderno completo: ejercicios 1 a 4 y mini-reto)

Dime con quién te pareces

1 · Mide la distancia a todas las reservas conocidas → 2 · Elige las k más cercanas → 3 · Vota: gana la clase más frecuente

Reserva	Antelación (días)	Distancia a la nueva (90 días)	¿Canceló?
B	95	5	sí
A	100	10	sí
C	120	30	no
D	40	50	no
E	150	60	sí

```
X = [[95], [100], [120], [40], [150]]
y = [1, 1, 0, 0, 1]                  # 1 = canceló
m = KNeighborsClassifier(n_neighbors=3).fit(X, y)
m.predict([[90]])                    # [1] cancela
m.predict_proba([[90]]).round(2)     # [[0.33 0.67]]
```

La probabilidad es la proporción de vecinas de cada clase: B, A y C votan 1, 1 y 0 → **2 de 3 = 0,67**.

NAIVE BAYES · LA IDEA

Cada dato aporta su probabilidad

Puntuación(cancela) = P(cancela) × P(tarifa | cancela) × P(depósito | cancela) × …

Teorema de Bayes

Calcula la probabilidad de cancelar **a partir de los datos** de la reserva.

La simplificación «ingenua»

Supone que los datos son **independientes entre sí** dentro de cada clase. Por eso basta **multiplicar**.

Falso, pero útil

Entrena en milisegundos, necesita pocos datos y rinde sorprendentemente bien.

Como un médico que suma pistas una a una (fiebre, tos, cansancio) sin pensar en cómo se influyen entre sí. Su pega: las probabilidades suelen salir **demasiado extremas**.

NAIVE BAYES · A MANO

Con un ejemplo de 10 reservas

10 reservas pasadas	Cancelan (4)	No cancelan (6)
Tarifa flexible	3	2
Sin depósito	3	1

Reserva nueva: tarifa **flexible** y **sin depósito**. ¿Se cancelará?

Se multiplica…	Cancela	No cancela
P(clase)	4/10 = 0,40	6/10 = 0,60
× P(flexible | clase)	3/4 = 0,75	2/6 = 0,33
× P(sin depósito | clase)	3/4 = 0,75	1/6 = 0,17
= puntuación	**0,225**	**0,033**

Se normaliza: 0,225 / (0,225 + 0,033) = 0,87 → 87 % de probabilidad de cancelar.

La variable grande se come a las pequeñas

Reserva	Antelación (días)	Repetidor (0/1)	¿Canceló?	Dist. sin escalar	Dist. escalada
A	100	0	sí	10,05	2,06
B	95	0	sí	5,10	2,05
C	120	1	no	30,00	0,83
D	40	1	no	50,00	1,38
E	150	0	sí	60,01	2,63

Reserva nueva: **90 días** de antelación y **cliente repetidor (1)**. k = 3.

Sin escalar

Vecinas **B, A, C**: 2 de 3 cancelaron → **cancela**. Ser repetidor (0 o 1) apenas pesa frente a cientos de días.

Escalando

Vecinas **C, D, B**: 2 de 3 no cancelaron → **no cancela**. Ahora la antelación y el repetidor pesan parecido.

GUÍA PARA CASA · K-NN · EJERCICIO 1

¿Cuánto manda cada variable en la distancia?

Dos reservas: la distancia² (distancia al cuadrado) es la **suma** de las diferencias al cuadrado. Cada variable aporta su parte.

Variable	Diferencia entre las dos	Diferencia²	% de la distancia²
Antelación (días)	80	6400	**97,8 %**
Precio por noche (€)	12	144	2,2 %
Cliente repetidor (0/1)	1	1	0,0 %

Sin escalar

La antelación debe aportar **más del 60 %**: decide casi sola.

Escaladas

Cada variable aporta una parte parecida: la antelación, **menos del 25 %**.

En el cuaderno: guarda ese % para **antelacion_dias** en **pct_antelacion_sin_escalar** y **pct_antelacion_escalada**.

GUÍA PARA CASA · K-NN · EJERCICIO 2

Elegir k: ni copiar ni promediar de más

Clase de las 9 vecinas, de la más cercana a la más lejana: **1 0 0 1 0 0 0 1 0** (1 = canceló).

k	Vecinas que cuentan	Cancelan	Predice
1	solo la 1ª	1 de 1	**cancela**
3	de la 1ª a la 3ª	1 de 3	no cancela
9	todas	3 de 9	no cancela (como el baseline)

k pequeño (1, 3)

Copia el ruido: **alta varianza**, sobreajuste.

k grande

Promedia demasiado: **alto sesgo**.

```
ks, auc = [1, 5, 15], [0.58, 0.64, 0.69]   # AUC de ejemplo
ks[int(np.argmax(auc))]                    # 15, el k de mayor AUC
```

GaussianNB: una campana por clase

Antelación de las reservas pasadas	Media	Desviación
Cancelaron: 100, 120, 140, 160, 180	140	28
No cancelaron: 20, 40, 60, 80, 100	60	28

Reserva nueva con…	60 días	90 días	100 días	110 días	130 días
P(cancela)	2 %	27 %	50 %	**73 %**	95 %

Cómo se monta

Pipeline con **prep_onehot()** y **GaussianNB()**. Guarda **media y desviación** de cada variable en cada clase.

Ojo con el error típico

GaussianNB necesita matriz **densa**: el codificador lleva **sparse_output=False**.

CategoricalNB: contar frecuencias

Antelación (días)	5	12	20	33	47	60	85	120	160	300
Tramo (0 a 4)	0	0	1	1	2	2	3	3	4	4

Cada tramo tiene el mismo nº de reservas: los bordes (5 · 16 · 40 · 72,5 · 140 · 300) salen de los **cuantiles**.

```
KBinsDiscretizer(n_bins=5, encode="ordinal", strategy="quantile")   # numéricas → tramos
OrdinalEncoder()                                                    # texto → números (agencia 0, directo 1…)
CategoricalNB(min_categories=5)                                     # cuenta frecuencias
```

Por qué enteros

CategoricalNB solo entiende categorías **0, 1, 2…**: hay que discretizar y codificar.

Por qué min_categories

Con un valor **nuevo** o negativo falla. **min_categories=5** deja sitio a los tramos.

GUÍA PARA CASA · MINI-RETO

¿Qué modelo para el equipo de reservas?

Modelo	Ajustar	Predecir	¿Se puede explicar?
Regresión logística	milisegundos	milisegundos	**Sí**: odds ratio de cada variable
k-NN	casi nada: guarda los datos	**la más lenta**: compara con todas	Solo con ejemplos parecidos
GaussianNB	milisegundos	milisegundos	Aporte de cada dato a la probabilidad
CategoricalNB	milisegundos	milisegundos	Aporte de cada dato a la probabilidad

Tiempos: llama a **time.perf_counter()** antes y después de **fit** y de **predict_proba**, y resta.

Compara siempre AUC + coste + explicabilidad. Los cuatro AUC quedan cerca (entre 0,72 y 0,76): no los sobreinterpretes.

HOY HAS APRENDIDO

Vecinas o probabilidades

k-NN

Predice por **analogía**: exige escalar, k se elige con validación cruzada y es lento al predecir

Naive Bayes

Multiplica probabilidades asumiendo independencia: rápido y sencillo

Comparar

Métrica + coste + explicabilidad: el «mejor» modelo depende del contexto

Siguiente: Sprint 8 · S08_01 · árboles de decisión