Sprint 7 · Reto «Precio y cancelación»

Ficha completa del reto, para consultar. Para trabajar con ella abierta, usad el reto en una página.

- Volver al README del sprint · README del sprint en PDF · ecofriendly
- **Esta ficha en PDF:** a color · ecofriendly, para imprimir
- Si es vuestro primer reto: Cómo se trabaja un reto.

RETO Ficha del reto

1 Qué os pide el cliente

Qué os pide el cliente. El gerente de TurisData quiere **dos herramientas**. La primera es una **tarifa de referencia**: cuánto debería costar una noche según el tipo de habitación y la época (predecir un **número**: `precio_noche`). La segunda es un **aviso de riesgo de cancelación**, para decidir cuándo vender por encima de su capacidad (*overbooking*: aceptar más reservas que habitaciones, apostando a que algunas se cancelarán), que predice una **categoría**: `cancelada`, sí o no. Hay un detalle importante: **el gerente no quiere oír hablar de «AUC»**. Quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro. Vuestro trabajo es **traducir las métricas a euros**: escribir cuánto cuesta cada tipo de error, elegir el umbral que menos cuesta, comprobar qué pasa si esos costes cambian y recomendar una acción con cifras.

Cómo se trabaja. No hace falta experiencia previa: los cuadernos del sprint (`S07_01` a `S07_04`) tienen casi todo el código que necesitáis, y vuestro trabajo es **reutilizarlo en un cuaderno nuevo** y **decidir** con él. Las hipótesis de coste son vuestras: la IA no las elige por vosotros. En clase tenéis 10 minutos de planning y **25 minutos de reto el día 1** (hipótesis de coste y precio), **30 el día 2** (cancelación, sensibilidad e informe) y **15 de entrega**; lo que no quepa va a casa o a la 6.ª hora. El equipo decide hasta dónde llega: mínimo, estándar o extra.

2 · Recursos del reto

Recurso	Para qué lo usaréis	Dónde está
Google Colab (Python con `pandas`, `numpy`, `scikit-learn` y `matplotlib`, las librerías del curso)	Crear y ejecutar `reto_S07.ipynb`	colab.research.google.com → *Nuevo cuaderno*
El CSV `reservas_turisdata.csv`	6000 reservas **sintéticas**; objetivos `precio_noche` y `cancelada`	Los cuadernos lo descargan solos con la función `dato()`; también en el botón *Download raw file*
Cuadernos del sprint: `S07_01` (regresión lineal) y `S07_02` (Ridge y Lasso)	Las celdas para el modelo de **precio**	Colab; su código explicado
Cuadernos del sprint: `S07_03` (logística, umbral y coste) y `S07_04` (ROC, PR y desbalance)	Las celdas para la **cancelación**; `S07_03` trae `coste_total`, el punto de partida para el coste	Colab
Cuaderno `S07_05` (k-NN y Naive Bayes)	Solo para el segundo modelo del nivel extra	Colab
La plantilla del informe `informe_modelado_plantilla.md`	Los apartados del informe, con huecos	En GitHub: copiad el texto con el botón *Raw*

Recurso	Para qué lo usaréis	Dónde está
Matriz de confusión en sencillo	Repasar FN, FP y por qué los errores no cuestan igual	Explicación sencilla y lámina de la matriz
Cómo entregar en GitHub	Subir la carpeta `sprint-07/` desde el navegador	Guía de entrega (apartado 6: subir un cuaderno de Colab)
Autoevaluación y coevaluación	Cada persona rellena su hoja	Hoja del sprint
Un asistente de IA (opcional)	Entender errores y métricas	Con las reglas de la «Ayuda 1» del paso a paso

3 · Qué entregar

Este apartado responde a **dos preguntas distintas**, una tabla para cada una:

Tabla A · Los ficheros: qué ficheros hay, de dónde sale cada uno (ya hecho, lo modificáis, lo creáis o lo genera el programa) y **cuáles se suben y adónde**.

Tabla B · Los requisitos: qué tiene que cumplir lo que entregáis y hasta dónde llegar (mínimo, estándar, extra). **Es lo que se evalúa.**

En total, al final del sprint se suben a `sprint-07/` : 3 ficheros del equipo (`informe_modelado.md` , `reto_S07.ipynb` , `README.md`) **+ 1 autoevaluación y coevaluación por persona**, es decir, **3 + tantos ficheros como personas haya en el equipo** (un equipo de 3 sube 6). «El reto» no es un fichero aparte: son esos tres ficheros. Además, el CSV va a `data/` si aún no está. La *review* y la *retro* se hacen de palabra, el jueves 12/11 junto con las del Sprint 8: no se suben.

Tabla A · Los ficheros: de dónde sale cada uno y cuáles se suben

Todo lo que se sube va al repositorio privado del equipo (`ifcd107-equipo-…`), en la carpeta `sprint-07/` , salvo el CSV.

Fichero	Origen	Qué hacéis vosotros	¿Se sube?
`reto_S07.ipynb`	**Lo creáis.** No hay plantilla: es un cuaderno nuevo de Colab	Reutilizáis las celdas de `S07_01` a `S07_04` : un modelo de **precio** y otro de **cancelación**, cada uno con su *baseline*, validación y métricas	**Sí** · `sprint-07/`
`informe_modelado.md` (o `.pdf`)	**Lo creáis a partir de una plantilla.** Os damos `informe_modelado_plantilla.md` con huecos	Copiarla como `informe_modelado.md` y rellenarla (2–3 páginas, con euros)	**Sí** · `sprint-07/`
`README.md`	**Lo modificáis.** La carpeta `sprint-07/` ya trae un `README.md` (si no, lo creáis)	Abrirlo con el lápiz y escribir semilla, versiones, cómo ejecutar, quién hizo qué y el uso de la IA	**Sí** · `sprint-07/`
`reservas_turisdata.csv`	**Ya hecho.** Los datos reales (sintéticos)	Nada: se usa sin cambiarlo	**Sí**, sin cambios · `data/` (si aún no está)
Autoevaluación y coevaluación (`autoevaluacion_nombre.md`)	**Ya hecha, en blanco**	Cada persona copia la plantilla con su nombre y la rellena; la coevaluación va **dentro del mismo fichero**	**Sí**, **una por persona** (no una por equipo) · `sprint-07/`

Fichero	Origen	Qué hacéis vosotros	¿Se sube?
Segundo modelo de clasificación (extra)	**Lo creáis vosotros**, dentro de `reto_S07.ipynb`	Solo si el equipo llega al nivel extra	Solo si lo hacéis · dentro de `reto_S07.ipynb`
Cuadernos de práctica `S07_01` – `S07_05`	**Ya hecho.** Son vuestras copias de trabajo del sprint	Usarlos como pista y copiar las celdas que os sirvan	**No se suben**

Tabla B · Los requisitos: qué tiene que cumplir y hasta dónde llegar

Requisito	Qué se pide exactamente	Nivel	Dónde se comprueba
Sin fuga de datos	Solo variables **conocidas en el momento de reservar**. `cancelada` no se usa para predecir el precio. Lista escrita de variables usadas y excluidas	Mínimo	`reto_S07.ipynb` · `informe_modelado.md` (apartado 2)
Precio: referencia y regresión lineal	*Baseline* (predecir siempre el precio medio de entrenamiento) y regresión lineal, con MAE y RMSE **en euros** sobre datos de test	Mínimo	`reto_S07.ipynb` · informe (apartado 3)
Cancelación: referencia y logística	Partición train/test, *baseline* (siempre «no cancela») y regresión logística, con matriz de confusión	Mínimo	`reto_S07.ipynb` · informe (apartado 4)
Hipótesis de coste	`COSTE_FN` y `COSTE_FP` como variables del cuaderno, cada una con **una frase de razón**. «La IA dijo 200 €» no vale	Mínimo	`reto_S07.ipynb` · informe (apartado 5)
Umbral elegido	Un umbral elegido y justificado en una frase. En el mínimo, puede salir de una tabla corta de umbrales	Mínimo	`reto_S07.ipynb` · informe (apartado 5)
Informe	`informe_modelado.md` con resumen para el gerente (con euros), tabla de métricas de los dos modelos y las hipótesis de coste. En el mínimo, versión corta	Mínimo	`informe_modelado.md`
README y reproducibilidad	`SEMILLA = 42`, versiones de Python y `scikit-learn`, cómo ejecutar el cuaderno de arriba abajo. Cómo se usó la IA: qué pedisteis y qué revisasteis	Mínimo	`README.md`
Git	Todo subido a `sprint-07/` con mensajes de commit claros, de personas distintas, sin claves ni datos personales	Mínimo	Historial del repositorio del equipo
Mejora del precio	Una mejora (interacciones, polinomio, Ridge o Lasso) con MAE, RMSE y R^2, y una frase sobre si compensa la complejidad. Máximo 3 modelos por problema	Estándar	`reto_S07.ipynb` · informe (apartado 3)
Curvas y métricas de la cancelación	Curvas ROC y PR con AUC y AP, explicados sin jerga en el informe	Estándar	`reto_S07.ipynb` · informe (apartado 4)
Umbral que minimiza el coste	Probar muchos umbrales con **validación cruzada sobre train**, calcular `FN × COSTE_FN + FP × COSTE_FP` y elegir el menor. El test se usa **una sola vez**: coste sin modelo, con umbral 0,5 y con el umbral elegido	Estándar	`reto_S07.ipynb` · informe (apartado 5)
Análisis de sensibilidad	Tabla o gráfico con el umbral óptimo y el coste total cuando cambian `COSTE_FN` y `COSTE_FP` (por ejemplo, FN el doble o FP la mitad)	Estándar	`reto_S07.ipynb` · informe (apartado 5)
Recomendación de negocio	Acción concreta con cifras (umbral, ahorro frente a «no hacer nada») y **límites** (datos sintéticos de un solo hotel…)	Estándar	`informe_modelado.md` (apartado 6)

Requisito	Qué se pide exactamente	Nivel	Dónde se comprueba
IA responsable	Riesgos específicos en el informe: quién sufre los falsos positivos, si se penaliza a algún país o canal, qué pasa si se piden depósitos solo a ciertos clientes	Estándar	`informe_modelado.md` (apartado 7)
Revisión y autoevaluación	Alguien que **no escribió esa parte** revisa cuaderno, informe y README con la rúbrica (justo debajo de estas tablas) y anota nivel y prueba en el informe (si va en PDF, en el README); cada persona sube su hoja de autoevaluación y coevaluación	Estándar	`informe_modelado.md` (sección «Revisión con la rúbrica») y `sprint-07/`
Extras	Un segundo modelo de clasificación (por ejemplo, k-NN) comparado · remuestreo solo en train · recomendación de *overbooking* con el ahorro estimado en euros por temporada	Extra	`reto_S07.ipynb` · `informe_modelado.md`

Rúbrica del reto · cómo se puntúa y cómo se revisa

La usan **dos veces**: el equipo, para revisar su propio trabajo antes de entregar (es lo que dice la *Definition of Done*), y el docente, para puntuar. Se mira **cada criterio por separado** y se pone el nivel de la columna cuyo texto **se cumple entero**: si lo de un nivel se cumple a medias, es el nivel de abajo. **0** significa que no se ha entregado nada de ese criterio.

Orientación: lo que pide el nivel mínimo sale en un **2**, el estándar en un **3** y los extras en un **4**.

Criterio	1 · Empezado	2 · Mínimo	3 · Estándar	4 · Extra
Corrección técnica (¿funciona?)	Hay cuaderno, pero faltan los *baselines*, se usa `cancelada` para predecir el precio o no se ejecuta de arriba abajo	Precio y cancelación tienen *baseline* y modelo; MAE y RMSE en euros; matriz de confusión; sin fuga; `COSTE_FN` y `COSTE_FP` definidos y un umbral elegido	Mejora del precio con R^2; ROC/PR con AUC y AP; umbral elegido con validación cruzada sobre train minimizando el coste; test usado **una sola vez**; máximo 3 modelos por problema	Además, un segundo modelo de clasificación comparado o remuestreo hecho solo en train, sin fuga, y las cifras del informe coinciden con las del cuaderno
Reproducibilidad (¿lo puede repetir otra persona?)	Solo funciona en la sesión de quien lo hizo (faltan celdas, rutas propias)	El README dice cómo ejecutar, pero falta la semilla o las versiones	Otra persona ejecuta el cuaderno de arriba abajo y obtiene **las mismas cifras** siguiendo solo el README (`SEMILLA = 42`, versiones, orden); todo en `sprint-07/`, el CSV en `data/` y commits de personas distintas, sin claves	Además, el README indica el orden exacto de ejecución y qué cifras del informe sale de qué celda
Análisis y comunicación al cliente (¿lo entiende quien no programa?)	El informe solo da métricas técnicas (AUC, RMSE) sin pasarlas a euros	El resumen para el gerente da el error del precio en euros y una hipótesis de coste con razón para cada error, pero sin sensibilidad ni límites	Recomendación con **cifras** (umbral, coste frente a «no hacer nada»), sensibilidad y límites, sin jerga: el gerente entiende qué hacer y cuánto se juega	Además, dice con qué costes la recomendación cambiaría y qué dato del hotel haría falta para afinarla
IA responsable (¿se sabe qué hizo la IA y qué comprobasteis?)	No dice si se ha usado IA ni habla de riesgos	Dice que se ha usado IA, o nombra riesgos genéricos, sin detalle	El README dice **qué se pidió, qué se revisó y qué se cambió**; los costes y el umbral salen de vuestro cálculo; el informe nombra riesgos **específicos** (falsos positivos, país o canal, depósitos)	Además, comprueba un riesgo con los datos (por ejemplo, la tasa de falsos positivos por canal o país), propone una medida y recuerda que los datos son sintéticos

Cómo se revisa (unos 10 minutos, antes de subir; lo hace **una persona que no escribió esa parte**):

1. **Ejecutar** el cuaderno en una sesión nueva de Colab con *Entorno de ejecución → Reiniciar y ejecutar todo*, copiando solo lo que dice el README. Anotar si algo falla o si alguna cifra cambia respecto al informe.
2. **Leer el informe como si fuera el gerente:** ¿se entiende el resumen sin saber qué es el AUC? ¿La recomendación tiene euros y límites? Subrayar lo que no se entienda.
3. **Mirar el cuaderno:** ¿alguna variable no se conoce al reservar? ¿Se usa `X_test` antes de elegir el umbral? ¿Los costes están en `COSTE_FN` y `COSTE_FP`, con su razón? Que quien lo escribió explique cualquier celda que no entendáis.
4. **Poner un nivel (1 a 4) en cada criterio, con una frase de prueba.** Ejemplos: «Corrección técnica · 2: hay baselines y matriz, pero el umbral se eligió mirando el test en la celda 18»; «Reproducibilidad · 3: mismas cifras siguiendo el README, versiones indicadas»; «Análisis · 2: el resumen da el MAE en euros, pero falta decir qué pasa si el coste de FP se duplica»; «IA responsable · 3: dicen qué pidieron y qué revisaron, y hablan de depósitos por país». Sin prueba escrita, el nivel no vale.
5. **Apuntar el resultado** en la sección «Revisión con la rúbrica» del final de `informe_modelado.md` y corregir lo más fácil de arreglar. Lo demás se anota como mejora.

Cada persona, además, se puntúa a sí misma en su hoja de autoevaluación y coevaluación con **esta misma rúbrica**.

---

4 · Guía paso a paso

Son cinco pasos, de **55 minutos en total** (25 el día 1 y 30 el día 2), más 15 minutos de entrega. Cada uno dice **qué hacéis** (la lista corta), **cómo se hace** con el detalle, **qué deberíais ver** y **cuándo está hecho**. Las ayudas (IA, errores, atascos) están al final. Si el tiempo aprieta, completad el nivel mínimo y dejad lo demás para casa. Antes del paso 1 ya habéis hecho el *planning* de 10 minutos (roles del sprint y tareas en el tablero).

Paso 1 · Acordar las hipótesis de coste y abrir el cuaderno (día 1, 5 minutos)

1. Abrir un cuaderno nuevo en Colab con el nombre `reto_S07`.
2. Responder la pregunta central: ¿qué cuesta más, una cancelación no prevista o una falsa alarma?
3. Escribir una hipótesis de coste para cada error, con una frase de razón.

Cómo se hace

- **Abrir el cuaderno.** En Colab, *Nuevo cuaderno*, y ponedle `reto_S07`. En la primera celda copiad la celda «Preparación» de `S07_01` (la función `dato()` que descarga el CSV) y escribid `SEMILLA = 42`.
- **La pregunta central del informe.** Una **cancelación no prevista** es un falso negativo (FN): el modelo dice «no se cancelará», sí se cancela y la habitación queda vacía. Una **falsa alarma** es un falso positivo (FP): el modelo dice «se cancelará», no se cancela y el cliente llega y no hay sitio.
- **Hipótesis de coste.** Proponed una cifra en euros para cada error y **una frase de razón**. Ejemplos del enunciado: una cancelación no prevista cuesta **la mitad de una noche**, porque solo se revende la mitad de esas noches; una falsa alarma cuesta **una noche de compensación** (alojamiento en otro hotel y una disculpa). Para pasar «una noche» a euros, mirad el precio medio de `precio_noche` en los datos.
- **Escribidlas como variables**, con su razón en un comentario, para poder cambiarlas luego: `COSTE_FN = … # razón` y `COSTE_FP = … # razón`.

Qué deberíais ver. Una celda con `SEMILLA`, `COSTE_FN` y `COSTE_FP`, cada coste con su razón al lado, y el CSV cargado en un `DataFrame`.

Hecho cuando: el cuaderno abre y carga los datos, y las dos hipótesis de coste están escritas con su razón.

Paso 2 · Regresión del precio (día 1, 20 minutos)

1. Elegir las variables que **se conocen al reservar**; `cancelada` queda fuera.
2. Separar train y test, y medir el modelo de referencia (precio medio).
3. Ajustar la regresión lineal y comparar.
4. Probar una mejora y decidir si compensa. Contar el resultado en euros.

Cómo se hace

- **Variables sin fuga.** Haced una lista de las columnas del CSV y marcad cuáles se conocen **en el momento de reservar** (por ejemplo, tipo de habitación, mes de llegada, antelación, canal). `cancelada` **no se puede usar para predecir el precio**: es fuga, porque no se sabe hasta después. Apuntad la lista de usadas y excluidas: va en el informe.
- **Separar y medir la referencia.** Como en `S07_01`: `train_test_split` con 20 % de test y `random_state=SEMILLA`. El modelo de referencia (*baseline*) predice siempre la media del precio de entrenamiento (`DummyRegressor`). Medid MAE y RMSE sobre test.
- **Regresión lineal.** La de `S07_01` (`LinearRegression`), con las variables elegidas. Medid MAE, RMSE y R^2. ¿Mejora a la referencia?
- **Una mejora.** Interacciones o polinomio (`S07_01`) o regularización Ridge o Lasso (`S07_02`). Si apenas mejora, quedaos con el modelo sencillo y decidlo en el informe.
- **En euros.** Escribid una frase del tipo «nos equivocamos de media en X € por noche».

Qué deberíais ver. Una tabla con una fila por modelo (referencia, lineal y mejora) y las columnas MAE, RMSE y R^2. La lineal mejora a la referencia. Como orientación: en `S07_01`, con tipo de habitación y temporada, el cuaderno espera un R^2 por encima de 0,85 y un MAE de entre 5 y 15 €. Si el vuestro está muy lejos, mirad la «Ayuda 2».

Hecho cuando: la tabla de precio está en el cuaderno, sin `cancelada` entre las variables, y tenéis la frase del error medio en euros.

Paso 3 · Clasificación de la cancelación y elección del umbral (día 2, 15 minutos)

1. Separar train y test, y **no tocar el test** hasta el final.
2. Medir la referencia (siempre «no cancela») y la regresión logística; dibujar la matriz de confusión y las curvas ROC y PR.
3. Elegir el umbral que minimiza el coste con validación cruzada sobre train.
4. Usar el test **una sola vez**, al final, para dar el coste esperado.

Cómo se hace

- **Partir y modelos.** Como en `S07_03`: partición train/test y regresión logística. La referencia es un `DummyClassifier` que siempre dice «no cancela». Máximo 3 modelos por problema, referencia incluida.
- **Matriz y curvas.** Matriz de confusión en test (`S07_03`), y curvas ROC y PR con AUC y AP (`S07_04`: `roc_auc_score`, `average_precision_score`). Para el nivel mínimo basta la matriz.
- **El umbral.** El umbral es la probabilidad a partir de la cual decimos «se cancelará». Con `cross_val_predict` sobre train (como en `S07_03`) obtenéis las probabilidades; probad muchos umbrales (`np.arange(0.05, 0.96, 0.05)`) y calculad el coste de cada uno: `coste = FN × COSTE_FN + FP × COSTE_FP`. **Cuidado:** `coste_total` de `S07_03` trae por defecto FN = 3 y FP = 1; pasadle **vuestros** costes. El mejor umbral es el que **minimiza el coste**; no se lo dejéis elegir a la IA.
- **El test, una vez.** Con el umbral ya elegido, calculad el coste en test de tres formas: **sin modelo** (la referencia, que nunca avisa), con el umbral 0,5 y con el umbral elegido.

Qué deberíais ver. La matriz de confusión, una tabla o curva de coste por umbral con un mínimo claro y tres cifras de coste en test (sin modelo, umbral 0,5 y umbral elegido). El umbral elegido cuesta menos que el 0,5.

Hecho cuando: hay umbral elegido con vuestros costes, el coste en test está calculado una sola vez y nadie ha mirado el test para elegir el umbral.

Paso 4 · Análisis de sensibilidad (día 2, 5 minutos)

1. Cambiar los costes: ¿y si una noche vacía costara el doble? ¿y si la compensación costara la mitad?
2. Calcular el umbral óptimo y el coste total de cada combinación.
3. Resumir en una tabla y una frase.

Cómo se hace

- **Repetid la búsqueda del paso 3** dentro de un bucle: para cada pareja de costes, buscad el umbral de menor coste y guardad el resultado. Usad al menos tres combinaciones: la vuestra, FN el doble y FP la mitad.

- **Tabla.** Con las columnas `COSTE_FN`, `COSTE_FP`, umbral óptimo y coste total; un gráfico del umbral óptimo también vale.
- **La conclusión** es del tipo: «con estos costes recomendamos un umbral de X; si el coste de una falsa alarma sube al doble, el umbral sube a Y». Las cifras serán las de vuestro cuaderno.

Qué deberíais ver. Una tabla con al menos tres filas y cómo se mueve el umbral óptimo. Si FN se encarece, el umbral baja (se avisa más); si se encarece FP, sube.

Hecho cuando: la tabla (o el gráfico) está en el cuaderno y tenéis la frase de conclusión escrita.

Paso 5 · Informe y README (día 2, 10 minutos)

1. Copiar la plantilla como `informe_modelado.md` y rellenarla con las cifras del cuaderno.
2. Escribir el README: semilla, versiones, cómo ejecutar y uso de la IA.
3. Preparar la entrega: revisión con la rúbrica, subida y autoevaluación (los 15 minutos siguientes).

Cómo se hace

- **El informe.** Abrid `informe_modelado_plantilla.md`, pulsad *Raw*, copiad el texto y pegadlo en un archivo nuevo `informe_modelado.md`. Para el **nivel mínimo** bastan estas, en pocas líneas:

Apartado de la plantilla	Qué escribís
1 · Resumen para el gerente	Cinco líneas con euros: qué recomendáis, qué cuesta cada error y cuánto ahorráis frente a no hacer nada
3 · Regresión	La tabla de MAE, RMSE y R^2 y la frase del error medio en euros
4 · Clasificación	La tabla de métricas y la matriz de confusión con el umbral elegido
5 · De las métricas a los euros	`COSTE_FN` y `COSTE_FP` con su razón, el umbral y el coste en test

Para el **nivel estándar**, completad también el 2 (variables usadas y excluidas), la sensibilidad del 5, el 6 (recomendación con cifras y límites) y el 7 (riesgos de IA responsable).

- **El README.** Cuatro cosas: `SEMILLA = 42`; las versiones (`!python --version` y `import sklearn; print(sklearn.__version__)` en una celda); cómo ejecutar (*abrir en Colab y ejecutar de arriba abajo*); y el uso de la IA (qué pedisteis y qué revisasteis). Añadid quién hizo qué.
- **La revisión con la rúbrica (5 minutos, al empezar la entrega).** Quien revisa sigue los cinco pasos de «Cómo se revisa» (apartado 3) y rellena la sección «Revisión con la rúbrica» del final de `informe_modelado.md`: un nivel de 1 a 4 por criterio y **una frase de prueba**.
- **Subir los ficheros (la vía del curso, desde el navegador).** Seguid Cómo entregar en GitHub: (1) en Colab, *Entorno de ejecución → Reiniciar y ejecutar todo* y después *Archivo → Descargar → Descargar .ipynb*; (2) abrid el repositorio del equipo y **entrad primero en la carpeta `sprint-07`**; (3) *Add file → Upload files* y arrastrad los ficheros; (4) escribid un mensaje corto y pulsad **Commit changes**. Cada subida es un *commit* con el nombre de quien la hace. Un reparto posible: la persona A sube `reto_S07.ipynb` («Añado cuaderno del reto»), la B sube `informe_modelado.md` («Añado informe»), la C edita `README.md` («Completo README»). Los nombres de archivo, **en minúsculas y sin espacios**. El CSV va a `data/` del repositorio solo si aún no está.

Qué deberíais ver. En la carpeta `sprint-07` del repositorio, los tres ficheros del equipo y una hoja de autoevaluación por persona (**3 + N**); y en el historial (el icono del reloj), commits de personas distintas.

Hecho cuando: otra persona podría ejecutar el cuaderno siguiendo solo el README, la sección «Revisión con la rúbrica» del informe está rellena y todo está subido a `sprint-07/`.

Después, 15 minutos de entrega: cada persona rellena y sube su autoevaluación y coevaluación a `sprint-07/` (la parte de coevaluación se completa en la *review* del jueves 12/11, en el mismo fichero). En la *review* (5 minutos por equipo) enseñaréis la tabla comparativa de métricas, el umbral elegido y su coste en euros frente a «no hacer nada», y una frase de recomendación para el gerente. En la retrospectiva, pensad: ¿qué hipótesis de coste discutimos más? ¿Cómo cambia la decisión si cambia el coste? ¿Qué habríamos necesitado saber del hotel para afinar?

Ayuda 1 · Cómo usar la IA en este reto

La IA puede ahorrar tiempo, pero **da código que parece funcionar y no se entiende**, y también **cifras que parecen razonables y no lo son**. Reglas:

- **Las hipótesis de coste son vuestras.** Si la IA os da cifras, preguntaos de dónde salen y justificadlas. No sirve «la IA dijo 200 €».
- **No dejéis que la IA elija el umbral por vosotros:** debe salir del cálculo con vuestros costes.
- **Todo lo que dé, lo ejecutáis y lo entendéis.** Si el docente pregunta por una línea, tenéis que saber explicarla.
- **Declaradlo** en el README: qué pedisteis y qué revisasteis.
- **Nada de datos personales ni claves** en una IA.

Para qué	Ejemplo de petición	Qué comprobáis
Entender una métrica	«Explícame la diferencia entre MAE y RMSE con un ejemplo de precios de hotel»	Que podéis explicar cuándo conviene cada una
Entender falsos positivos y negativos	«Dame un ejemplo en un hotel de falso positivo y falso negativo de un modelo de cancelaciones»	Que los asociáis a **vuestros** costes
Depurar código	«Este código de scikit-learn da este error: *[error]*. ¿Qué lo causa?»	Que lo entendéis y lo arregláis vosotros
Revisar la recomendación	«Lee esta recomendación al gerente y dime si hay algo ambiguo o demasiado técnico»	Que no cambie las cifras

Pista de IA responsable: ¿quién sufre los falsos positivos (un cliente reubicado)? ¿Se penaliza a algún país o canal? ¿Qué pasa si el modelo se usa para pedir depósitos solo a ciertos clientes? Respondedlo en el informe.

Ayuda 2 · Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Usar `cancelada` o información posterior para predecir el precio	No se piensa en el momento de la reserva	Hacer una lista de variables y marcar cuáles se conocen **al reservar**
Elegir el umbral mirando el test	«Queda mejor»	El umbral sale de validación cruzada sobre train; el test, **una sola vez**
Costes sin justificar, o los de la IA	Parece un detalle	Cada coste lleva una frase de razón y es del equipo
Dejar los costes por defecto de `coste_total` (3 y 1)	Se copia la celda de `S07_03` sin cambiarla	Pasar `COSTE_FN` y `COSTE_FP` a la función
Informe solo con AUC	Es lo que muestra el cuaderno	Traducir a euros: «el modelo ahorra X € frente a no hacer nada»
Probar 10 modelos	«Más es mejor»	Máximo **3 modelos por problema**, referencia incluida
Olvidar el análisis de sensibilidad	Parece opcional	Es lo que da robustez a la recomendación
El cuaderno da errores de dimensiones	La variable objetivo sigue dentro de `X`, o `X` e `y` no coinciden	Comprobar `X.shape` y `y.shape` y que `precio_noche` o `cancelada` no están en `X`

Ayuda 3 · Si os atascáis

1. **No sabemos qué costes poner:** pensad en una noche de un alojamiento de TurisData, razonad con una frase y luego **variad** los costes en la sensibilidad.

2. **No entendemos el umbral:** pensad en un semáforo. Con el umbral muy bajo avisamos casi siempre (muchas falsas alarmas); muy alto, casi nunca (muchas cancelaciones sin detectar).
3. Repasad el cuaderno de esa parte (`S07_01` a `S07_04`) y su código explicado. Después preguntad al equipo y, por último, al docente.