IFCD107 · ESPECIALISTA EN IA

Sprint 7 · Resultados

Modelos de regresión y clasificación para predecir el precio y las cancelaciones de Turisdata.

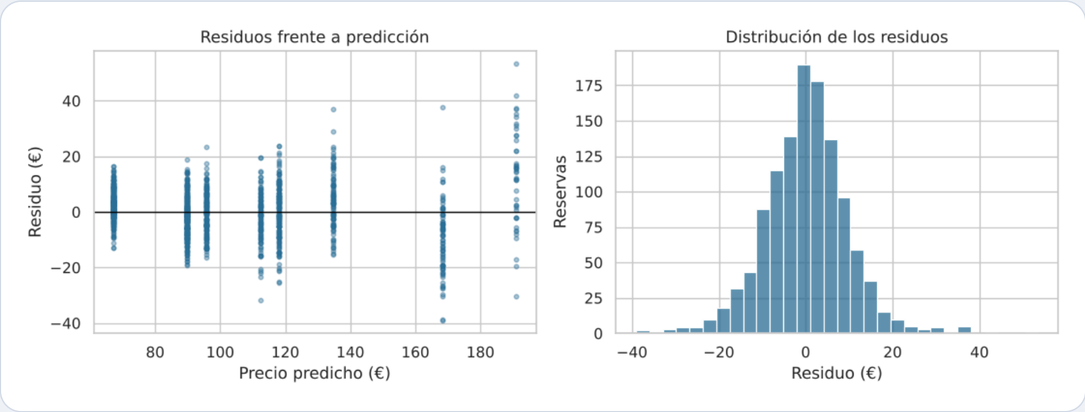
S07_01 · QUÉ PIDE Y QUÉ OBTENEMOS

S07_01 • Regresión lineal y polinómica

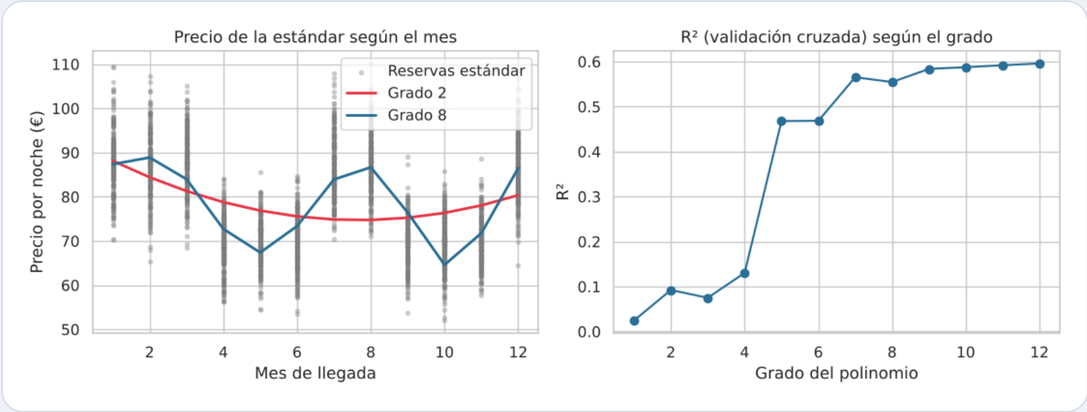
Ej.	Qué pide	Qué obtenemos
1 · clase	Separar entrenamiento y prueba, ajustar una regresión lineal del precio y medirla	R^2 **0.915** · error medio **7.24 €** en prueba: explica el 91 % de la variación del precio
2 · clase	Leer los coeficientes: cuánto sube el precio de una suite y de la temporada alta	Suite **+101.2 €** sobre la estándar · temporada alta **+22.4 €** · una estándar en temporada baja cuesta **67.3 €**
3 · clase	Añadir interacciones (tipo de habitación × temporada) y ver si mejora	Error medio **6.76 €**: mejora **0.48 €** respecto al modelo sin interacciones
4 · casa	Dos formas de usar la época del año con validación cruzada: polinomio del mes o «temporada alta»	Polinomio de grado 2 sobre el mes: R^2 **0.09** · una columna «temporada alta»: R^2 **0.65**

S07_01 · GRÁFICOS

S07_01 • Regresión lineal y polinómica



Sección 3 · Residuos: el error del modelo se reparte alrededor de 0 y tiene forma de campana (izquierda: según el precio predicho; derecha: histograma).



Sección 5 · Con grado 2 la curva (roja) apenas sigue el vaivén del año; subir el grado mejora el R² hasta unos 0.6, pero la curva se vuelve nerviosa.

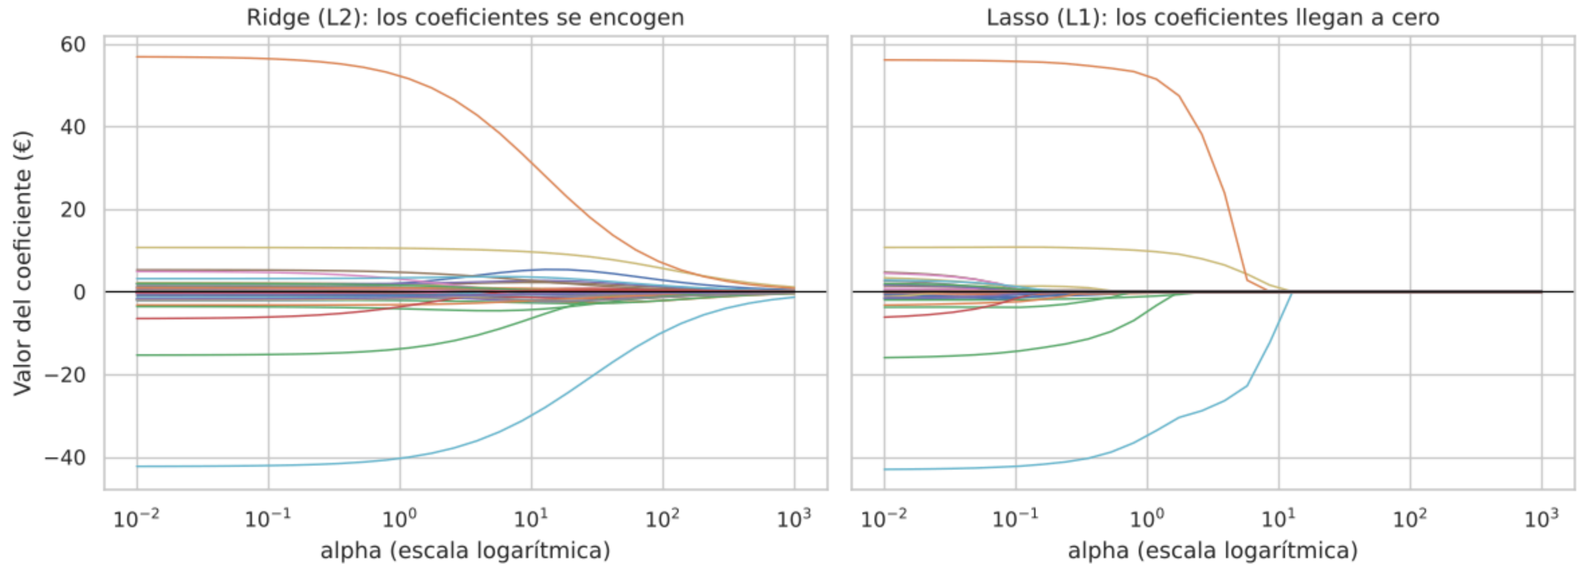
S07_02 · QUÉ PIDE Y QUÉ OBTENEMOS

S07_02 • Regularización: Ridge y Lasso

Ej.	Qué pide	Qué obtenemos
1 · clase	Comparar el R^2 en entrenamiento y en prueba del modelo sin regularizar (con 665 variables)	Entrenamiento **1.00** y brecha de **0.28** con prueba: el modelo se aprende los datos de memoria (sobreajuste)
2 · clase	Ridge: dejar que elija solo cuánto encoger los coeficientes	Elige **alpha = 25.9** y mejora el R^2 en prueba a **0.728**
3 · clase	Lasso: lo mismo, pero dejando algunos coeficientes a cero	R^2 en prueba **0.887**; se queda solo con **27 variables de 665**

S07_02 · GRÁFICOS

S07_02 • Regularización: Ridge y Lasso



Sección 2 · Al subir alpha (eje horizontal) los coeficientes se encogen: Ridge (izquierda) los acerca a 0; Lasso (derecha) los deja exactamente en 0.

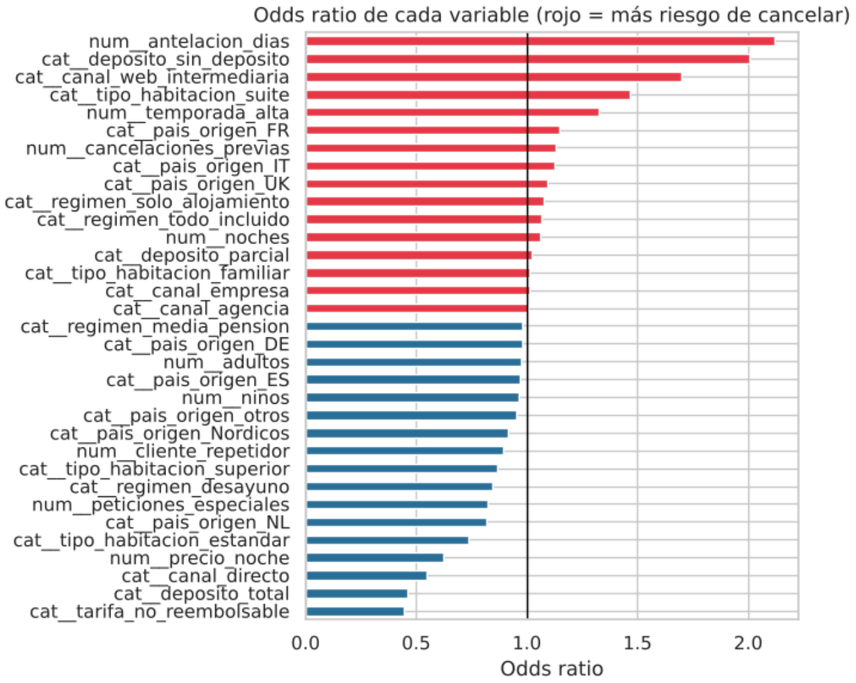
S07_03 · QUÉ PIDE Y QUÉ OBTENEMOS

S07_03 • Regresión logística

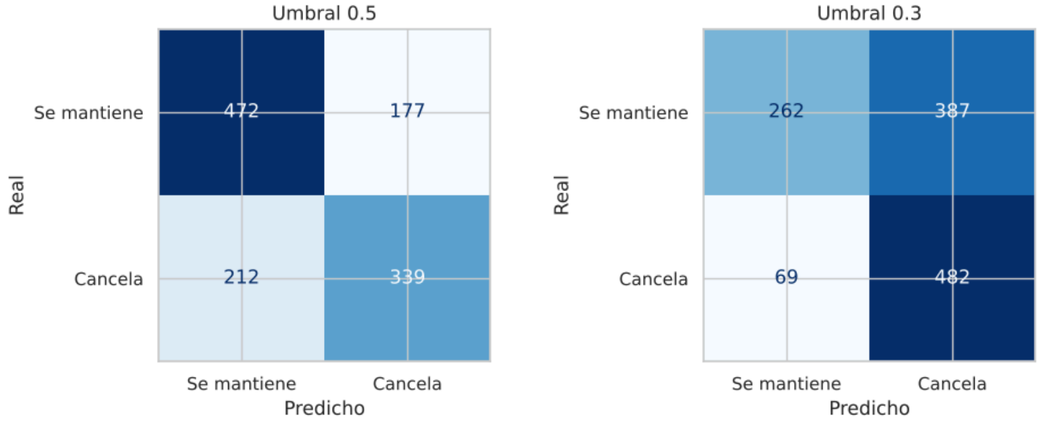
Ej.	Qué pide	Qué obtenemos
1 · clase	Entrenar la logística y obtener la probabilidad de cancelar de cada reserva de prueba	Un número entre 0 y 1 por reserva (1 200 reservas), por ejemplo 0.38, 0.61, 0.79…
2 · clase	Interpretar con odds ratios la tarifa no reembolsable y el depósito total	Tarifa no reembolsable **×0.44** y depósito total **×0.46** los odds de cancelar; lo que más aumenta el riesgo es la **antelación**
3 · clase	Cambiar el umbral de 0.5 a 0.3	Se detectan **26 puntos más** de cancelaciones, pero la precisión **baja 10 puntos**
4 · casa	Elegir el umbral que da menor coste (un falso negativo cuesta más que un falso positivo)	Mejor umbral **0.25**; coste en prueba **577**, frente a **813** con 0.5

S07_03 · GRÁFICOS

S07_03 • Regresión logística

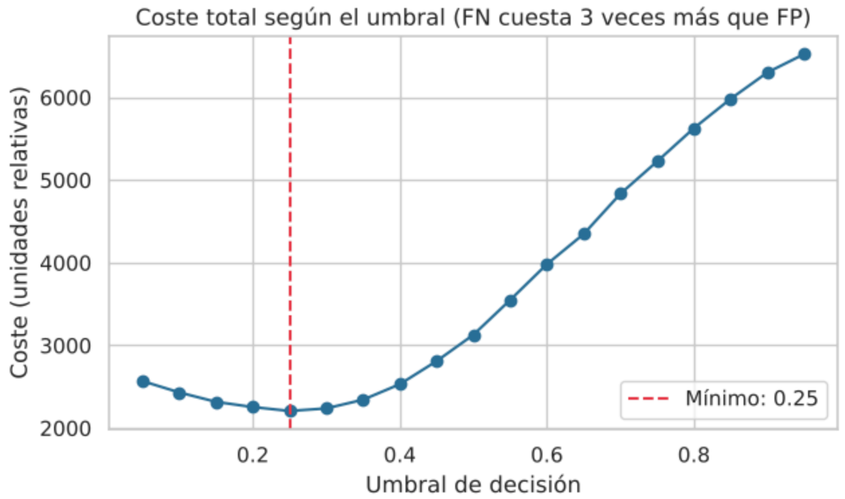


Ejercicio 2 · Odds ratios: rojo = aumenta la probabilidad de cancelar (más de 1); azul = la reduce (menos de 1). Tarifa no reembolsable y depósito total quedan abajo.



Ejercicio 3 · Matriz de confusión con umbral 0.5 (izquierda) y 0.3 (derecha): con 0.3 solo se escapan 69 cancelaciones, a costa de más falsas alarmas.

S07_03 • Regresión logística



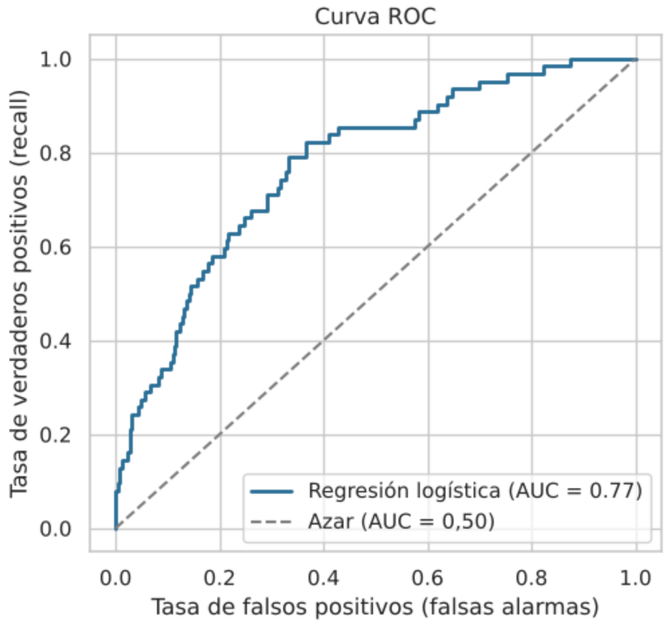
Ejercicio 4 · Coste total según el umbral: el mínimo está en 0.25 (línea roja).

S07_04 · QUÉ PIDE Y QUÉ OBTENEMOS

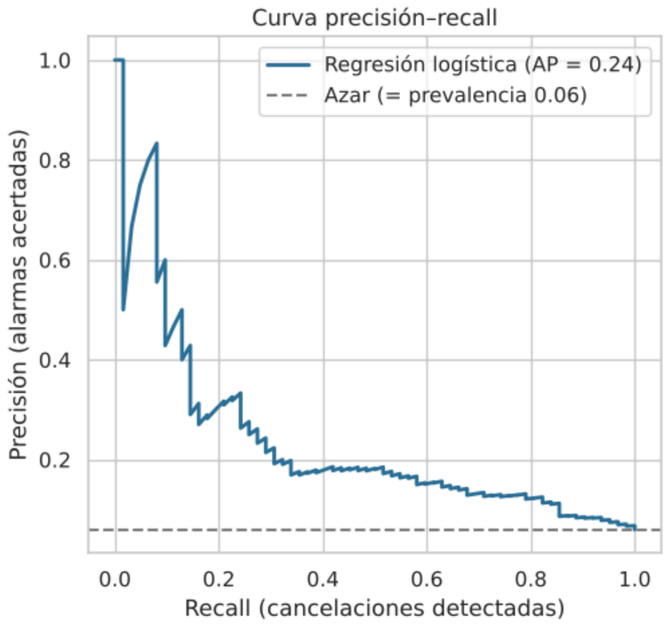
S07_04 • ROC, precisión–recall y desbalance

Ej.	Qué pide	Qué obtenemos
1 · casa	Un modelo «inútil» que siempre responde la clase mayoritaria	Exactitud **94.0 %** pero recall **0 %**: no detecta ninguna cancelación
2 · clase	Curva ROC y AUC del modelo base	AUC **0.77**: el modelo ordena bastante mejor que el azar (0.50)
3 · casa	Average precision y comparación con el azar	AP **0.24**, unas **4 veces** mejor que la prevalencia (0.06)
4 · casa	Dar más peso a la clase poco frecuente	Recall sube de **3 %** a **73 %**; la precisión del ponderado es **14 %**
5 · casa	Submuestreo: quedarse con todas las positivas y el doble de negativas (solo del entrenamiento)	Muestra equilibrada de **435 reservas** con la que se entrena el nuevo modelo
6 · casa	Detectar al menos el 70 % de las cancelaciones con la mayor precisión posible	Umbral **0.048**; en prueba recall **82 %** y precisión **12 %**

S07_04 • ROC, precisión–recall y desbalance



Ejercicio 2 · Curva ROC: cuanto más se aleja de la diagonal (azar), mejor; AUC = 0.77.



Ejercicio 3 · Curva precisión–recall: parte de 1 y cae enseguida; la línea discontinua es el azar (0.06).

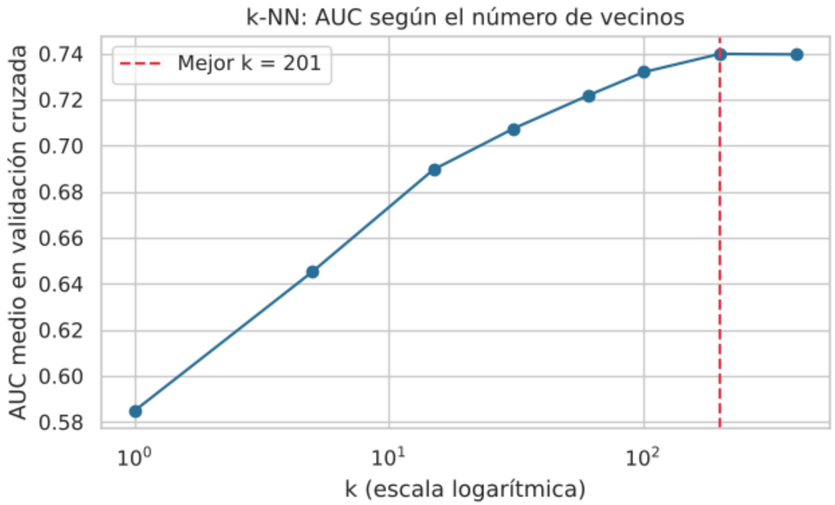
S07_05 · QUÉ PIDE Y QUÉ OBTENEMOS

S07_05 • k-NN y Naive Bayes

Ej.	Qué pide	Qué obtenemos
1 · casa	Cuánto pesa la antelación en la distancia con y sin escalar	Sin escalar decide el **77 %** de la distancia; escalada, solo el **11 %**
2 · casa	Probar distintos k de k-NN con validación cruzada	El AUC sube de **0.58** (k = 1) a **0.73** (k = 101); el mejor es **k = 201**
3 · casa	Naive Bayes gaussiano	AUC **0.719**
4 · casa	Naive Bayes categórico (variables en tramos)	AUC **0.742**: algo mejor que el gaussiano

S07_05 · GRÁFICOS

S07_05 • k-NN y Naive Bayes



Ejercicio 2 · AUC según el número de vecinos (escala logarítmica): mejora con k y se estabiliza hacia k = 200 (línea roja).

PARA LLEVARSE

La historia del sprint

0.915	Una **regresión lineal** sencilla explica el 91 % del precio; los coeficientes se leen en euros.
665 → 27	**Lasso** se queda con 27 variables de 665 y generaliza mejor (R^2 0.89).
0.25	Con costes distintos para cada error, el **umbral** bueno no es 0.5: coste 577 frente a 813.
94 % y 0 %	Exactitud engañosa: el modelo inútil acierta el 94 % y no detecta **ninguna** cancelación.