Sprint 7 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
6 y 9 de noviembre

HORAS
12 h (4 h teoría · 5 h práctica guiada · 3 h PBL)

CONTENIDOS
M3 UD 3.3 (regresión lineal, polinómica, Ridge y Lasso), UD 3.4 (regresión logística y clasificación) y UD 3.5 (k-NN y Naive Bayes).

Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

Requisitos previos

- Sprint 6: pipelines (`ColumnTransformer` + `Pipeline`), baseline, validación cruzada y fuga de datos.
- Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`). Los notebooks lo descargan solos si no lo encuentran.

Prácticas

Notebook	Tema	Tiempo
`S07_01_regresion_lineal_polinomica`	Regresión lineal, coeficientes, residuos, interacciones y polinomios	55 min
`S07_02_ridge_lasso`	Regularización: Ridge, Lasso y elección de `alpha`	45 min
`S07_03_regresion_logistica`	Regresión logística, *odds ratios*, umbral, matriz de confusión y coste	60 min
`S07_04_roc_pr_desbalance`	ROC, precisión–recall y clases desbalanceadas	50 min
`S07_05_knn_naive_bayes`	k-NN y Naive Bayes; comparativa de modelos	45 min

Los ejercicios se autocorrigen con `assert`. Si terminas antes, dedica tiempo a las preguntas de reflexión del final de cada notebook.

RETO Reto PBL · «Precio y cancelación» (unas 3 h, en equipo)

En pocas palabras (léelo primero)

Qué os pide el cliente. El gerente de TurisData quiere **dos herramientas**:

1. Una **tarifa de referencia**: cuánto debería costar una noche según el tipo de habitación y la época (predecir un **número**: `precio_noche`).
2. Un **aviso de riesgo de cancelación**, para decidir cuándo vender por encima de su capacidad (*overbooking*: aceptar más reservas que habitaciones, apostando a que algunas se cancelarán) (predecir una **categoría**: `cancelada`, sí o no).

Y hay un detalle importante: **el gerente no quiere oír hablar de «AUC»**. Quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro. Vuestro trabajo es **traducir métricas técnicas a euros**.

Qué vais a hacer, en seis pasos:

1. **Predecir el precio** (regresión): un modelo de referencia, una regresión lineal y una mejora.
2. **Predecir la cancelación** (clasificación): un modelo de referencia y una regresión logística (y, si queréis, un segundo modelo).
3. **Decidir cuánto cuesta cada tipo de error** (con hipótesis razonadas).
4. **Elegir el umbral** que minimiza el coste total.
5. **Probar qué pasa si esos costes cambian** (análisis de sensibilidad).
6. **Escribir un informe** de 2–3 páginas con una recomendación de negocio, con euros.

Qué vais a entregar: `informe_modelado.md` (o PDF), el cuaderno `reto_S07.ipynb` y un `README.md`.

Qué vais a aprender haciéndolo: a elegir métricas según el problema, a **evitar la fuga de datos**, a **traducir un modelo a dinero** y a defender una decisión con hipótesis claras.

Cuánto tiempo: unas 3 horas en equipo entre el planning, el reto y la entrega (6 y 9/11). El reto se hace sobre todo el lunes 9/11, con lo aprendido el viernes.

Palabras que van a aparecer en este reto

Palabra	Qué significa, en sencillo
Regresión	Predecir un número (el precio)
Clasificación	Predecir una categoría (cancela / no cancela)
Baseline	Modelo sencillo de referencia (por ejemplo, predecir siempre el precio medio)
MAE	Error medio en euros: «de media nos equivocamos en X €»
RMSE	Parecido al MAE, pero castiga más los errores grandes
R^2	Cuánta parte de la variación del precio explica el modelo (de 0 a 1)
Falso negativo (FN)	El modelo dice «no se cancelará» y **sí se cancela** → habitación vacía
Falso positivo (FP)	El modelo dice «se cancelará» y **no se cancela** → cliente que llega y no hay sitio
Umbral	Probabilidad a partir de la cual decimos «se cancelará»
Curva ROC / PR	Gráficos que muestran cómo cambian los aciertos y errores al mover el umbral
AUC / AP	Un solo número que resume una curva ROC / PR. Mejor cuanto más alto
Análisis de sensibilidad	Comprobar si la decisión cambia cuando cambian los costes que habíamos supuesto
Fuga de datos	Usar información que no se conocería al decidir (por ejemplo, `cancelada` para predecir el precio)
Overbooking	Vender más habitaciones de las que hay, esperando cancelaciones

Contexto del cliente. TurisData Canarias quiere dos cosas: (1) una **tarifa de referencia** que le diga cuánto debería costar una noche según el tipo de habitación y la época, y (2) un **aviso de riesgo de cancelación** para decidir cuándo vender por encima de su capacidad (*overbooking*). El gerente no quiere oír hablar de "AUC": quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro.

Qué se entrega.

1. `informe_modelado.md` (o PDF), 2–3 páginas. Plantilla: `plantillas/informe_modelado_plantilla.md`. Debe incluir la comparativa de métricas de los dos modelos y una **recomendación de negocio** (con euros).
2. `reto_S07.ipynb`: un modelo de **regresión** para `precio_noche` y otro de **clasificación** para `cancelada`, cada uno con su *baseline*, validación y métricas.
3. `README.md` para reproducirlo (semilla, versiones).

La pregunta clave del informe. *¿Qué cuesta más: una cancelación no prevista (habitación vacía) o una falsa alarma (cliente que llega y no hay sitio)?* Debéis **proponer una hipótesis de coste razonada** para cada error (por ejemplo, «solo se revende la mitad de las noches» o «una noche de compensación»), elegir el **umbral** que minimiza el coste y mostrar **qué pasa si esos costes cambian** (análisis de sensibilidad).

Restricciones.

- Solo variables **conocidas en el momento de reservar** (¡sin fuga!). `cancelada` no puede usarse para predecir el precio.
- El umbral se elige con validación cruzada sobre train; el test se usa una sola vez.
- Solo librerías del curso; semilla fija (`SEMILLA = 42`).
- Máximo 3 modelos por problema (baseline incluido).

Criterios de evaluación (0–4 cada uno; misma rúbrica de todos los retos):

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Errores que invalidan el resultado	Correcto con fallos menores	Correcto y bien justificado	Correcto, justificado y con alternativas comparadas
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda	Se ejecuta desde el README	Además incluye datos o script y versiones fijas

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Análisis y comunicación al cliente	Solo código o cifras sin interpretar	Interpretación básica	Conclusiones claras para el cliente	Recomendación accionable con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos identificados	Medidas aplicadas y evaluadas

Pista de IA responsable: ¿quién sufre los falsos positivos (un cliente reubicado)? ¿Se penaliza a algún país o canal? ¿Qué pasa si el modelo se usa para pedir depósitos solo a ciertos clientes?

Pasos sugeridos.

- **Viernes 6/11:** *planning* (20 min); las prácticas de regresión y de regresión logística preparan los modelos del reto.
- **Lunes 9/11 (2 h 15 min):** acordar las hipótesis de coste (15 min); regresión: baseline, lineal y una mejora, con métricas en euros (30 min); clasificación: baseline y logística, curva ROC/PR, elección del umbral con validación cruzada y coste total en test (45 min).
- **Cierre del lunes:** análisis de sensibilidad (15 min), informe con la recomendación y README (30 min), autoevaluación y coevaluación; **review + retrospectiva** (última hora).

Guía paso a paso para principiantes

Paso 1 · Acordar las hipótesis de coste (lunes 9/11, 15 minutos; el planning fue el viernes)

1. Roles del sprint y tareas en el tablero.
2. **La pregunta central del informe:** *¿qué cuesta más, una cancelación no prevista (habitación vacía) o una falsa alarma (un cliente llega y no hay sitio)?*
3. **Proponed una hipótesis de coste para cada error**, razonada con una frase. Ejemplos: - Una cancelación no prevista cuesta **la mitad de una noche**, porque solo se revende la mitad de esas noches. - Una falsa alarma cuesta **una noche de compensación** (alojamiento en otro hotel + disculpa).
4. Escribidlas en el cuaderno como variables (`COSTE_FN`, `COSTE_FP`) para poder cambiarlas luego.

Paso 2 · Regresión del precio (lunes 9/11, 30 minutos)

1. Elegid las variables que **se conocen al reservar** (tipo de habitación, mes, antelación, canal…). **`cancelada` no puede usarse para predecir el precio** (es fuga).
2. Modelo de referencia: predecir siempre el precio medio de entrenamiento. Medid MAE y RMSE.
3. Regresión lineal. Medid MAE, RMSE y R^2. ¿Mejora al modelo de referencia?
4. Una mejora (añadir interacciones o regularización tipo Lasso). ¿Compensa la complejidad?
5. Expresad el resultado **en euros**: «nos equivocamos de media en X € por noche».

Paso 3 · Clasificación de la cancelación (lunes 9/11, 45 minutos)

1. Partid los datos (train/test) y **no toquéis el test hasta el final**.
2. Modelo de referencia (por ejemplo, el que siempre dice «no cancela»). Regresión logística. Opcional: un segundo modelo.
3. Dibujad la **matriz de confusión** y las curvas ROC y PR. Calculad AUC y AP.
4. **Elegid el umbral con validación cruzada sobre train**: probad muchos umbrales y calculad el coste total de cada uno con vuestras hipótesis: `coste = FN × COSTE_FN + FP × COSTE_FP`. El mejor umbral es el que **minimiza el coste**.
5. **Usad el test una sola vez**, al final, para dar el coste esperado.

Paso 4 · Análisis de sensibilidad (lunes 9/11, 15 minutos)

Preguntaos: *¿y si una noche vacía costara el doble? ¿y si la compensación costara la mitad?* Variad los costes y mirad **cómo cambia el umbral óptimo** y el coste total. Mostradlo en una tabla o gráfico. La conclusión es del tipo: *«con estos costes recomendamos un umbral de 0,35; si el coste de una falsa alarma sube al doble, el umbral sube a 0,45»*.

Paso 5 · Informe y README (lunes 9/11, 30 minutos)

Seguid la plantilla `informe_modelado_plantilla.md`:

1. **Resumen para el gerente** (5 líneas, con euros).
2. Tabla comparativa de métricas de los dos modelos.
3. Umbral elegido y su coste frente a «no hacer nada».
4. Análisis de sensibilidad.
5. **Recomendación de negocio con cifras y límites.**
6. Riesgos de IA responsable.

README: semilla (`SEMILLA = 42`), versiones y cómo ejecutar.

Cómo usar la IA en este reto

Para qué	Ejemplo de petición	Qué tenéis que comprobar
Entender una métrica	«Explícame la diferencia entre MAE y RMSE con un ejemplo de precios de hotel»	Que podáis explicar cuándo conviene cada una
Entender falsos positivos y negativos	«Dame un ejemplo en un hotel de falso positivo y falso negativo de un modelo de cancelaciones»	Que los asociáis a **vuestros** costes
Depurar código	«Este código de scikit-learn da este error: *[error]*. ¿Qué lo causa?»	Que lo entendéis y lo arregláis
Revisar la recomendación	«Lee esta recomendación al gerente y dime si hay algo ambiguo o demasiado técnico»	Que no cambie las cifras

Reglas del reto:

- **Las hipótesis de coste son vuestras:** si la IA os da cifras, preguntaos de dónde salen y justificadlas. No sirve «la IA dijo 200 €».
- **No dejéis que la IA elija el umbral por vosotros:** debe salir del cálculo con vuestros costes.
- Declarad el uso de IA en el README.

Pista de IA responsable: ¿quién sufre los falsos positivos (un cliente reubicado)? ¿Se penaliza a algún país o canal? ¿Qué pasa si el modelo se usa para pedir depósitos solo a ciertos clientes? Respondedlo en el informe.

Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Usar `cancelada` o información posterior para predecir el precio	No se piensa en el momento de la reserva	Haced una lista de variables y marcad cuáles se conocen **al reservar**
Elegir el umbral mirando el test	«Queda mejor»	El umbral sale de validación sobre train; el test, **una sola vez**
Costes sin justificar	Parece un detalle	Cada coste lleva una frase de razón
Informe solo con AUC	Es lo que muestra el cuaderno	Traducid a euros: «el modelo ahorra X € frente a no hacer nada»
Probar 10 modelos	«Más es mejor»	Máximo **3 modelos por problema**, baseline incluido
Olvidar el análisis de sensibilidad	Parece opcional	Es lo que da robustez a la recomendación

Un buen resultado se parece a...

> *«Recomendamos activar el aviso de cancelación con un umbral de 0,35. Con nuestras hipótesis (noche vacía = 50 €, compensación = 100 €), el coste esperado pasa de 4.200 € a 2.900 € por temporada, es decir, ahorra unos 1.300 €. Si la compensación costara 200 €, el umbral óptimo subiría a 0,45 y el ahorro bajaría a 800 €: la recomendación se mantiene, pero conviene medir el coste real. Límites: datos sintéticos de un solo hotel.»* (Cifras de ejemplo.)

Antes de entregar: autoevaluación rápida

Pregunta	Sí / No
¿La regresión tiene baseline y métricas en euros (MAE, RMSE) y R^2?	
¿La clasificación tiene baseline, matriz de confusión, AUC/AP y umbral justificado?	
¿Los costes de FN y FP son hipótesis explícitas con análisis de sensibilidad?	
¿La recomendación tiene cifras y límites?	
¿No hay fuga de datos y el test se usó una sola vez?	
¿El cuaderno se ejecuta entero y el README tiene versiones y semilla?	
¿Está subido a Git, con autoevaluación y coevaluación?	

Si os atascáis

- **No sabemos qué costes poner:** pensad en una noche de un alojamiento de TurisData y razonad con una frase; luego **variad** los costes en la sensibilidad.

- **No entendemos el umbral:** pensad en un semáforo: si ponemos el umbral muy bajo, avisamos casi siempre (muchas falsas alarmas); muy alto, casi nunca (muchas cancelaciones sin detectar).
- **El cuaderno da errores de dimensiones:** comprobad `X.shape` y `y.shape` y que habéis eliminado la variable objetivo de X.
- Más ayuda: Cómo se trabaja un reto.

Qué se enseña en la review (5 min por equipo): la tabla comparativa de métricas, el umbral elegido y su coste en euros frente a «no hacer nada», y una frase de recomendación para el gerente.

Preguntas de la retrospectiva: ¿qué hipótesis de coste discutimos más? ¿Cómo cambia la decisión si cambia el coste? ¿Qué habríamos necesitado saber del hotel para afinar?

Definition of Done

- [ ] Modelo de regresión con baseline y métricas en euros (MAE, RMSE) y R^2.
- [ ] Modelo de clasificación con baseline, matriz de confusión, AUC/AP y umbral justificado.
- [ ] Costes de FN y FP explicitados como hipótesis y análisis de sensibilidad.
- [ ] Recomendación de negocio con cifras y límites.
- [ ] Sin fuga de datos; test usado una sola vez.
- [ ] Notebook ejecutable de principio a fin y README con versiones.
- [ ] Subido a Git; autoevaluación y coevaluación rellenadas.

Recursos

- Documentación de scikit-learn: *Linear Models* (Ridge, Lasso, regresión logística).
- Documentación de scikit-learn: *Model evaluation: quantifying the quality of predictions* (ROC, PR, matriz de confusión).
- Guía de scikit-learn: *Tuning the decision threshold for class prediction*.
- Notebook `S07_03` (umbral y coste): reutiliza `coste_total` como punto de partida.
- Tu tabla de defectos y el pipeline del reto del Sprint 6.