Sprint 7 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
5–9 de noviembre

HORAS
12 h (4 h teoría · 5 h práctica guiada · 3 h PBL)

CONTENIDOS
M3 UD 3.3 (regresión lineal, polinómica, Ridge y Lasso), UD 3.4 (regresión logística y clasificación) y UD 3.5 (k-NN y Naive Bayes).

Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

Requisitos previos

- Sprint 6: pipelines (`ColumnTransformer` + `Pipeline`), baseline, validación cruzada y fuga de datos.
- Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`). Los notebooks lo descargan solos si no lo encuentran.

Prácticas

Notebook	Tema	Tiempo
`S07_01_regresion_lineal_polinomica`	Regresión lineal, coeficientes, residuos, interacciones y polinomios	60 min
`S07_02_ridge_lasso`	Regularización: Ridge, Lasso y elección de `alpha`	50 min
`S07_03_regresion_logistica`	Regresión logística, *odds ratios*, umbral, matriz de confusión y coste	70 min
`S07_04_roc_pr_desbalance`	ROC, precisión–recall y clases desbalanceadas	60 min
`S07_05_knn_naive_bayes`	k-NN y Naive Bayes; comparativa de modelos	55 min

Los ejercicios se autocorrigen con `assert`. Si terminas antes, dedica tiempo a las preguntas de reflexión del final de cada notebook.

RETO Reto PBL · «Precio y cancelación» (3 h, en equipo)

Contexto del cliente. TurisData Canarias quiere dos cosas: (1) una **tarifa de referencia** que le diga cuánto debería costar una noche según el tipo de habitación y la época, y (2) un **aviso de riesgo de cancelación** para decidir cuándo vender por encima de su capacidad (*overbooking*). El gerente no quiere oír hablar de "AUC": quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro.

Qué se entrega.

1. `informe_modelado.md` (o PDF), 2–3 páginas. Plantilla: `guias/S07/informe_modelado_plantilla.md`. Debe incluir la comparativa de métricas de los dos modelos y una **recomendación de negocio** (con euros).
2. `reto_S07.ipynb`: un modelo de **regresión** para `precio_noche` y otro de **clasificación** para `cancelada`, cada uno con su *baseline*, validación y métricas.
3. `README.md` para reproducirlo (semilla, versiones).

La pregunta clave del informe. *¿Qué cuesta más: una cancelación no prevista (habitación vacía) o una falsa alarma (cliente que llega y no hay sitio)?* Debéis **proponer una hipótesis de coste razonada** para cada error (por ejemplo, «solo se revende la mitad de las noches» o «una noche de compensación»), elegir el **umbral** que minimiza el coste y mostrar **qué pasa si esos costes cambian** (análisis de sensibilidad).

Restricciones.

- Solo variables **conocidas en el momento de reservar** (¡sin fuga!). `cancelada` no puede usarse para predecir el precio.
- El umbral se elige con validación cruzada sobre train; el test se usa una sola vez.
- Solo librerías del curso; semilla fija (`SEMILLA = 42`).

- Máximo 3 modelos por problema (baseline incluido).

Criterios de evaluación (0–4 cada uno; misma rúbrica de todos los retos):

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Errores que invalidan el resultado	Correcto con fallos menores	Correcto y bien justificado	Correcto, justificado y con alternativas comparadas
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda	Se ejecuta desde el README	Además incluye datos o script y versiones fijas
Análisis y comunicación al cliente	Solo código o cifras sin interpretar	Interpretación básica	Conclusiones claras para el cliente	Recomendación accionable con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos identificados	Medidas aplicadas y evaluadas

Pista de IA responsable: ¿quién sufre los falsos positivos (un cliente reubicado)? ¿Se penaliza a algún país o canal? ¿Qué pasa si el modelo se usa para pedir depósitos solo a ciertos clientes?

Pasos sugeridos.

- **Día 1 (5–6/11):** *planning* (30 min); acordar las hipótesis de coste; regresión: baseline, lineal y una mejora (interacciones o Lasso); métricas en euros.
- **Día 2 (7–8/11):** clasificación: baseline y logística (más un segundo modelo si queréis); curva ROC/PR, elección del umbral con validación cruzada; coste total en test.
- **Día 3 (9/11):** análisis de sensibilidad, informe con la recomendación, README, autoevaluación y coevaluación; **review + retrospectiva** (última hora).

Qué se enseña en la review (5 min por equipo): la tabla comparativa de métricas, el umbral elegido y su coste en euros frente a «no hacer nada», y una frase de recomendación para el gerente.

Preguntas de la retrospectiva: ¿qué hipótesis de coste discutimos más? ¿Cómo cambia la decisión si cambia el coste? ¿Qué habríamos necesitado saber del hotel para afinar?

Definition of Done

- [ ] Modelo de regresión con baseline y métricas en euros (MAE, RMSE) y R^2.
- [ ] Modelo de clasificación con baseline, matriz de confusión, AUC/AP y umbral justificado.
- [ ] Costes de FN y FP explicitados como hipótesis y análisis de sensibilidad.
- [ ] Recomendación de negocio con cifras y límites.
- [ ] Sin fuga de datos; test usado una sola vez.
- [ ] Notebook ejecutable de principio a fin y README con versiones.
- [ ] Subido a Git; autoevaluación y coevaluación rellenadas.

Recursos

- Documentación de scikit-learn: *Linear Models* (Ridge, Lasso, regresión logística).
- Documentación de scikit-learn: *Model evaluation: quantifying the quality of predictions* (ROC, PR, matriz de confusión).
- Guía de scikit-learn: *Tuning the decision threshold for class prediction*.
- Notebook `S07_03` (umbral y coste): reutiliza `coste_total` como punto de partida.
- Tu tabla de defectos y el pipeline del reto del Sprint 6.