

Sprint 7 · ML supervisado: regresión y clasificación

¿PODEMOS PREDECIR EL PRECIO O LA CANCELACIÓN?

5-9 DE NOVIEMBRE

12 H TOTALES (4 H TEORÍA · 5 H PRÁCTICA · 3 H PBL)

Bienvenidos al **Sprint 7**, dedicado al modelado predictivo supervisado mediante técnicas de regresión y clasificación. En este sprint trabajaréis con datos reales de **TurisData Canarias** para dar respuesta a dos retos de negocio esenciales: predecir la tarifa de referencia por noche y estimar el riesgo de cancelación de las reservas para gestionar el *overbooking*, traduciendo siempre las métricas técnicas a impacto económico real en euros.

4 h Teoría

Regresión lineal, polinómica, Ridge, Lasso, regresión logística, k-NN y Naive Bayes

5 h Práctica

5 notebooks guiados: regresión, regularización, logística, ROC/PR y comparativa de modelos

3 h Reto PBL

Reto «Precio y cancelación»: modelos, costes, umbral óptimo y recomendación de negocio

¿Qué aprenderás?

- 1

Regresión lineal y coeficientes

Ajustar una regresión lineal y polinómica e interpretar los coeficientes directamente en euros.
- 2

Ridge y Lasso

Usar Ridge y Lasso para controlar el sobreajuste y realizar selección efectiva de variables.
- 3

Regresión logística y umbrales

Entrenar una regresión logística, interpretar odds ratios, la matriz de confusión y elegir el umbral óptimo.
- 4

ROC, precisión–recall y balanceo

Evaluar con curvas ROC y precisión–recall, aprendiendo a tratar adecuadamente clases desbalanceadas.
- 5

k-NN, Naive Bayes y traducción a euros

Comparar k-NN y Naive Bayes con la logística y traducir las métricas técnicas a euros para el cliente.

⚠

Requisitos previos: Sprint 6: pipelines (ColumnTransformer + Pipeline), baseline, validación cruzada y fuga de datos. Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`; descarga automática si falta).

Prácticas del sprint

Notebook	Tema	Tiempo
S07_01_regresion_lineal_polinomica	Regresión lineal, coeficientes, residuos, interacciones y polinomios	60 min
S07_02_ridge_lasso	Regularización: Ridge, Lasso y elección de alpha	50 min
S07_03_regresion_logistica	Regresión logística, odds ratios, umbral, matriz de confusión y coste	70 min
S07_04_roc_pr_desbalance	ROC, precisión–recall y clases desbalanceadas	60 min
S07_05_knn_naive_bayes	k-NN y Naive Bayes; comparativa de modelos	55 min

Ficha del reto · «Precio y cancelación»

TURISDATA CANARIAS

3 H, EN EQUIPO

Contexto del cliente: TurisData Canarias quiere dos cosas: (1) una **tarifa de referencia** que le diga cuánto debería costar una noche según el tipo de habitación y la época, y (2) un **aviso de riesgo de cancelación** para decidir cuándo vender por encima de su capacidad (*overbooking*). El gerente no quiere oír hablar de "AUC": quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro.

Qué se entrega

Tres entregables por equipo (plantilla en [guias/S07/informe_modelado_plantilla.md](#)):

1 · informe_modelado.md

2–3 páginas (.md o PDF) con métricas de ambos modelos y recomendación de negocio en euros.

2 · reto_S07.ipynb

Modelo de regresión (`precio_noche`) y de clasificación (`cancelada`), con baselines, validación y métricas.

3 · README.md

Instrucciones completas para reproducir los resultados (semilla fija y versiones de librerías).

Pregunta clave

¿Qué cuesta más: cancelación no prevista o falsa alarma? Hipótesis de coste, umbral óptimo y sensibilidad.

Restricciones del reto

• Sin fuga de datos

Solo variables conocidas al reservar; cancelada no predice precio.

• Partición y umbral

Umbral elegido con CV en train; test usado una sola vez.


• Entorno

Solo librerías del curso y semilla fija (`SEMILLA = 42`).

• Límite de modelos

Máximo 3 modelos por problema (baseline incluido).

Pasos sugeridos por día



❗ La pregunta clave del informe: ¿Qué cuesta más, una cancelación no prevista (habitación vacía) o una falsa alarma (*overbooking* sin sitio)?

Qué se enseña en la review (5 min por equipo)

- La **tabla comparativa de métricas** de los modelos de regresión y clasificación.
- El **umbral elegido** y su coste total en euros frente a la opción de «no hacer nada».
- Una **frase clara de recomendación** de negocio directamente para el gerente de TurisData.

Criterios de evaluación

RÚBRICA DE EQUIPO

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica de retos del curso. La evaluación es de equipo: los modelos, la formulación de costes y la recomendación al cliente cuentan de forma integral. A continuación se detalla la descripción de cada nivel para que podáis autoevaluaros antes de la review final.

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Errores que invalidan el resultado	Correcto con fallos menores	Correcto y bien justificado	Correcto, justificado y con alternativas comparadas
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda	Se ejecuta desde el README	Además incluye datos o script y versiones fijas
Análisis y comunicación	Solo código o cifras sin interpretar	Interpretación básica	Conclusiones claras para el cliente	Recomendación accionable con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos identificados	Medidas aplicadas y evaluadas

Pista de IA responsable y claves de excelencia

El nivel Excelente requiere conectar el modelado técnico con el impacto ético y de negocio. Analizad quién asume el coste de los errores, justificad cada hipótesis económica y acompañad vuestra propuesta con recomendaciones accionables y límites claros.



Impacto de los falsos positivos

¿Quién sufre el error si el modelo predice cancelación y el huésped aparece? Un cliente reubicado daña gravemente la reputación del hotel.



Exigencia de depósitos selectivos

Evaluad las implicaciones éticas y comerciales de exigir depósitos previos o prepagos solo a reservas clasificadas como sospechosas.



Sesgos por país o canal

Comprobad si el modelo penaliza sistemáticamente a clientes de ciertos países o canales de venta antes de aplicar decisiones automáticas.



Sensibilidad y límites del modelo

Mostrad qué sucede si los costes unitarios de FN y FP varían, explicitando con transparencia hasta dónde puede llegar la automatización.

Definition of Done y cierre del sprint

CHECKLIST FINAL

RETROSPECTIVA

RECURSOS

Antes de dar por cerrado el Sprint 7, cada equipo debe repasar la siguiente Definition of Done. Si algún punto no está completado, aún estáis a tiempo de resolverlo antes de la review y entrega final del reto.

Checklist Definition of Done

- ☐ Modelo de regresión con baseline y métricas en euros (MAE, RMSE) y R^2
- ☐ Modelo de clasificación con baseline, matriz de confusión, AUC/AP y umbral justificado
- ☐ Costes de FN y FP explicitados como hipótesis y análisis de sensibilidad
- ☐ Recomendación de negocio con cifras y límites
- ☐ Sin fuga de datos; test usado una sola vez
- ☐ Notebook ejecutable de principio a fin y README con versiones
- ☐ Subido a Git; autoevaluación y coevaluación rellenas

Preguntas de retrospectiva

Dedicad los últimos minutos del sprint a reflexionar en equipo sobre el proceso de modelado y la toma de decisiones:

- ¿Qué hipótesis de coste discutimos más?
- ¿Cómo cambia la decisión si cambia el coste?
- ¿Qué habríamos necesitado saber del hotel para afinar?

Recursos recomendados

Todos los recursos siguientes son gratuitos y están disponibles en español o en inglés. No es necesario leerlos enteros antes del sprint: usadlos como referencia cuando tengáis una duda concreta.

1

Modelos lineales · scikit-learn

Documentación oficial sobre modelos lineales: Ridge, Lasso y regresión logística.

2

Evaluación de modelos · scikit-learn

Guía de métricas de calidad de predicción: ROC, curvas PR y matriz de confusión.

3

Ajuste de umbrales de decisión

Guía de scikit-learn sobre *Tuning the decision threshold for class prediction*.

4

Notebook S07_03 (umbral y coste)

Reutiliza la función `coste_total` como base de cálculo económico en el reto.

5

Pipeline y defectos del Sprint 6

Reutiliza tu tabla de defectos previa y la estructura de pipelines del reto anterior.

⚠ Recordad llegar a la review con el notebook validado, el informe listo y la recomendación económica clara para el cliente.