README Sprint S07 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
10–11 de noviembre

HORAS
9 h (2 h teoría · 4 h práctica · 3 h PBL)

PARA IMPRIMIR
todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

Sigue el orden de arriba abajo y abre solo lo que pone en cada fila. Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Si el tiempo aprieta, haz solo los ejercicios marcados «en clase»: el resto es para casa.

Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

Día 1 · Martes 10/11

Qué haces	Abre	Min
Ceremonia · Planning del reto «Precio y cancelación» y reparto de roles	—	10
Teoría · Regresión lineal y polinómica: coeficientes, residuos e interacciones	Presentación S07_01	15
Práctica · Regresión lineal y polinómica (los ejercicios marcados «en clase»)	Cuaderno S07_01	40
Teoría · Regularización: Ridge y Lasso	Presentación S07_02	10
Práctica · Ridge y Lasso (los ejercicios marcados «en clase»)	Cuaderno S07_02	35
Teoría · Regresión logística: probabilidades, odds y umbral	Presentación S07_03	20
Práctica · Regresión logística (los ejercicios marcados «en clase»)	Cuaderno S07_03	45
Reto · Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2)	Reto en una página	25

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

- ☐ Sé entrenar una regresión y una regresión logística con scikit-learn.
- ☐ Sé leer un coeficiente.

Día 2 · Miércoles 11/11

Qué haces	Abre	Min
Práctica · ROC, PR y datos desbalanceados (los ejercicios marcados «en clase»)	Cuaderno S07_04 · Presentación S07_04	15
Teoría · k-NN y Naive Bayes: dos algoritmos más	Presentación S07_05	10
Reto · Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5)	Reto en una página	40
Test · **Test de M3 (parte 1)**	Abrir	25

Qué haces	Abre	Min
Ceremonia · Entrega en `sprint-07/` y autoevaluación del Sprint 7 (la coevaluación, la review y la retro se hacen el jueves, junto con las del Sprint 8)	—	15
En casa · k vecinos (k-NN) y Naive Bayes (cuaderno completo)	Cuaderno S07_05 · Presentación S07_05	40 (casa)

En clase: 1 h 45 min.

Al acabar el día, deberías poder decir:

- ☐ Sé interpretar en euros los coeficientes de una regresión.
- ☐ Sé leer una matriz de confusión y elegir un umbral según lo que cuesta equivocarse.
- ☐ Sé traducir las métricas de mis modelos a euros para el cliente.

El reto en pocas palabras

Qué os pide el cliente. El gerente de TurisData quiere **dos herramientas**:

1. Una **tarifa de referencia**: cuánto debería costar una noche según el tipo de habitación y la época (predecir un **número**: `precio_noche`).
2. Un **aviso de riesgo de cancelación**, para decidir cuándo vender por encima de su capacidad (*overbooking*: aceptar más reservas que habitaciones, apostando a que algunas se cancelarán) (predecir una **categoría**: `cancelada`, sí o no).

Qué vais a entregar: `informe_modelado.md` (o PDF), el cuaderno `reto_S07.ipynb` y un `README.md`.

Núcleo y extra. Núcleo: regresión del precio y clasificación de la cancelación con las hipótesis de coste. Extra: análisis de sensibilidad completo.

Antes de empezar, probad la demo interactiva (muestra lo que tendréis al final). Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

Definition of Done · antes de cerrar el sprint (Definition of Done)

Archivos subidos en el repositorio del equipo, carpeta `sprint-07/` (marca cada uno cuando lo veas en GitHub):

- ☐ `reto_S07.ipynb` · lo creáis
- ☐ `informe_modelado.md` · lo creáis a partir de una plantilla
- ☐ `README.md` · lo modificáis
- ☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

Total en `sprint-07/`: 3 ficheros del equipo + 1 hoja por persona (un equipo de 3 sube 6). Aparte: reservas_turisdata.csv en `data/` si aún no está; Segundo modelo de clasificación (extra); los extras solo si los hacéis. La *review* y la *retro* no se suben.

Comprobaciones antes de dar el sprint por cerrado:

- ☐ Test de conocimientos hecho el mié 11/11
- ☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
- ☐ Regresión (MAE, RMSE, R^2) y clasificación (matriz de confusión, AUC/AP) con *baseline*
- ☐ Costes de error explicitados, umbral justificado y recomendación con cifras
- ☐ Sin fuga de datos; test usado una sola vez
- ☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

En casa (cuando puedas)

- Los ejercicios de cada cuaderno que **no** se hacen en clase. Se autocorrigen, y debajo llevan una «Solución de referencia» plegada por si te quedas atascado.
- Si quieres repasar la teoría con calma: apuntes del sprint.

Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Mira el código explicado del cuaderno en el que estás.
3. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

Carpeta	Qué hay
`1_Teoria/`	Las presentaciones del sprint y los apuntes para repasar
`2_Practica/`	Los cuadernos (Colab) y su explicación línea a línea en `codigo_explicado/`
`3_Reto/`	`1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado)
`4_Referencia/`	Infografías del sprint

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

Temario oficial de este sprint

Unidad	Conceptos que entran
UD 3.3	Regresión lineal y polinómica; regularización Ridge/Lasso
UD 3.4	Regresión logística y clasificación
UD 3.5	k-NN y Naive Bayes

Y ahora: Sprint 8 · Árboles, ensembles y SVM (miércoles 11/11).

9 h (2 h teoría · 4 h práctica · 3 h PBL).