Sprint 7 · Reto «Precio y cancelación»

Ficha completa del reto, para consultar. Para trabajar, el reto en una página. Qué se sube y cómo se evalúa: entrega y rúbrica.

- Volver al README del sprint.
- Si es vuestro primer reto: Cómo se trabaja un reto.

RETO Ficha del reto

1 Qué os pide el cliente

Qué os pide el cliente. El gerente de TurisData quiere **dos herramientas**. La primera es una **tarifa de referencia**: cuánto debería costar una noche según el tipo de habitación y la época (predecir un **número**: `precio_noche`). La segunda es un **aviso de riesgo de cancelación**, para decidir cuándo vender por encima de su capacidad (*overbooking*: aceptar más reservas que habitaciones, apostando a que algunas se cancelarán), que predice una **categoría**: `cancelada`, sí o no. Hay un detalle importante: **el gerente no quiere oír hablar de «AUC»**. Quiere saber **cuánto dinero se juega** si el modelo se equivoca en un sentido o en otro. Vuestro trabajo es **traducir las métricas a euros**: escribir cuánto cuesta cada tipo de error, elegir el umbral que menos cuesta, comprobar qué pasa si esos costes cambian y recomendar una acción con cifras.

Cómo se trabaja. No hace falta experiencia previa: los cuadernos del sprint (`S07_01` a `S07_04`) tienen casi todo el código que necesitáis, y vuestro trabajo es **reutilizarlo en un cuaderno nuevo** y **decidir** con él. Las hipótesis de coste son vuestras: la IA no las elige por vosotros. En clase tenéis 10 minutos de planning y **25 minutos de reto el día 1** (hipótesis de coste y precio), **30 el día 2** (cancelación, sensibilidad e informe) y **15 de entrega**; lo que no quepa va a casa o a la 6.ª hora. El equipo decide hasta dónde llega: mínimo, estándar o extra.

2 · Recursos del reto

Recurso	Para qué lo usaréis	Dónde está
Google Colab (Python con `pandas`, `numpy`, `scikit-learn` y `matplotlib`, las librerías del curso)	Crear y ejecutar `reto_S07.ipynb`	colab.research.google.com → *Nuevo cuaderno*
El CSV `reservas_turisdata.csv`	6000 reservas **sintéticas**; objetivos `precio_noche` y `cancelada`	Los cuadernos lo descargan solos con la función `dato()`; también en el botón *Download raw file*
Cuadernos del sprint: `S07_01` (regresión lineal) y `S07_02` (Ridge y Lasso)	Las celdas para el modelo de **precio**	Colab; su código explicado
Cuadernos del sprint: `S07_03` (logística, umbral y coste) y `S07_04` (ROC, PR y desbalance)	Las celdas para la **cancelación**; `S07_03` trae `coste_total`, el punto de partida para el coste	Colab
Cuaderno `S07_05` (k-NN y Naive Bayes)	Solo para el segundo modelo del nivel extra	Colab
La plantilla del informe `informe_modelado_plantilla.md`	Los apartados del informe, con huecos	En GitHub: copiad el texto con el botón *Raw*

Recurso	Para qué lo usaréis	Dónde está
Matriz de confusión en sencillo	Repasar FN, FP y por qué los errores no cuestan igual	Explicación sencilla y lámina de la matriz
Cómo entregar en GitHub	Subir la carpeta `sprint-07/` desde el navegador	Guía de entrega (apartado 6: subir un cuaderno de Colab)
Autoevaluación y coevaluación	Cada persona rellena su hoja	Hoja del sprint
Un asistente de IA (opcional)	Entender errores y métricas	Con las reglas de la «Ayuda 1» del paso a paso

3 · Guía paso a paso

Son cinco pasos, de **55 minutos en total** (25 el día 1 y 30 el día 2), más 15 minutos de entrega. Cada uno dice **qué hacéis** (la lista corta), **cómo se hace** con el detalle, **qué deberíais ver** y **cuándo está hecho**. Las ayudas (IA, errores, atascos) están al final. Si el tiempo aprieta, completad el nivel mínimo y dejad lo demás para casa. Antes del paso 1 ya habéis hecho el *planning* de 10 minutos (roles del sprint y tareas en el tablero).

Paso 1 · Acordar las hipótesis de coste y abrir el cuaderno (día 1, 5 minutos)

1. Abrir un cuaderno nuevo en Colab con el nombre `reto_S07`.
2. Responder la pregunta central: ¿qué cuesta más, una cancelación no prevista o una falsa alarma?
3. Escribir una hipótesis de coste para cada error, con una frase de razón.

Cómo se hace

- **Abrir el cuaderno.** En Colab, *Nuevo cuaderno*, y ponedle `reto_S07`. En la primera celda copiad la celda «Preparación» de `S07_01` (la función `dato()` que descarga el CSV) y escribid `SEMILLA = 42`.
- **La pregunta central del informe.** Una **cancelación no prevista** es un falso negativo (FN): el modelo dice «no se cancelará», sí se cancela y la habitación queda vacía. Una **falsa alarma** es un falso positivo (FP): el modelo dice «se cancelará», no se cancela y el cliente llega y no hay sitio.
- **Hipótesis de coste.** Proponed una cifra en euros para cada error y **una frase de razón**. Ejemplos del enunciado: una cancelación no prevista cuesta **la mitad de una noche**, porque solo se revende la mitad de esas noches; una falsa alarma cuesta **una noche de compensación** (alojamiento en otro hotel y una disculpa). Para pasar «una noche» a euros, mirad el precio medio de `precio_noche` en los datos.
- **Escribidlas como variables**, con su razón en un comentario, para poder cambiarlas luego: `COSTE_FN = … # razón` y `COSTE_FP = … # razón`.

Qué deberíais ver. Una celda con `SEMILLA`, `COSTE_FN` y `COSTE_FP`, cada coste con su razón al lado, y el CSV cargado en un `DataFrame`.

Hecho cuando: el cuaderno abre y carga los datos, y las dos hipótesis de coste están escritas con su razón.

Paso 2 · Regresión del precio (día 1, 20 minutos)

1. Elegir las variables que **se conocen al reservar**; `cancelada` queda fuera.
2. Separar train y test, y medir el modelo de referencia (precio medio).
3. Ajustar la regresión lineal y comparar.
4. Probar una mejora y decidir si compensa. Contar el resultado en euros.

Cómo se hace

- **Variables sin fuga.** Haced una lista de las columnas del CSV y marcad cuáles se conocen **en el momento de reservar** (por ejemplo, tipo de habitación, mes de llegada, antelación, canal). **`cancelada` no se puede usar para predecir el precio**: es fuga, porque no se sabe hasta después. Apuntad la lista de usadas y excluidas: va en el informe.

- **Separar y medir la referencia.** Como en `S07_01`: `train_test_split` con 20 % de test y `random_state=SEMILLA`. El modelo de referencia (*baseline*) predice siempre la media del precio de entrenamiento (`DummyRegressor`). Medid MAE y RMSE sobre test.
- **Regresión lineal.** La de `S07_01` (`LinearRegression`), con las variables elegidas. Medid MAE, RMSE y R^2. ¿Mejora a la referencia?
- **Una mejora.** Interacciones o polinomio (`S07_01`) o regularización Ridge o Lasso (`S07_02`). Si apenas mejora, quedaos con el modelo sencillo y decidlo en el informe.
- **En euros.** Escribid una frase del tipo «nos equivocamos de media en X € por noche».

Qué deberíais ver. Una tabla con una fila por modelo (referencia, lineal y mejora) y las columnas MAE, RMSE y R^2. La lineal mejora a la referencia. Como orientación: en `S07_01`, con tipo de habitación y temporada, el cuaderno espera un R^2 por encima de 0,85 y un MAE de entre 5 y 15 €. Si el vuestro está muy lejos, mirad la «Ayuda 2».

Hecho cuando: la tabla de precio está en el cuaderno, sin `cancelada` entre las variables, y tenéis la frase del error medio en euros.

Paso 3 · Clasificación de la cancelación y elección del umbral (día 2, 15 minutos)

1. Separar train y test, y **no tocar el test** hasta el final.
2. Medir la referencia (siempre «no cancela») y la regresión logística; dibujar la matriz de confusión y las curvas ROC y PR.
3. Elegir el umbral que minimiza el coste con validación cruzada sobre train.
4. Usar el test **una sola vez**, al final, para dar el coste esperado.

Cómo se hace

- **Partir y modelos.** Como en `S07_03`: partición train/test y regresión logística. La referencia es un `DummyClassifier` que siempre dice «no cancela». Máximo 3 modelos por problema, referencia incluida.
- **Matriz y curvas.** Matriz de confusión en test (`S07_03`), y curvas ROC y PR con AUC y AP (`S07_04`: `roc_auc_score`, `average_precision_score`). Para el nivel mínimo basta la matriz.
- **El umbral.** El umbral es la probabilidad a partir de la cual decimos «se cancelará». Con `cross_val_predict` sobre train (como en `S07_03`) obtenéis las probabilidades; probad muchos umbrales (`np.arange(0.05, 0.96, 0.05)`) y calculad el coste de cada uno: `coste = FN × COSTE_FN + FP × COSTE_FP`. **Cuidado:** `coste_total` de `S07_03` trae por defecto FN = 3 y FP = 1; pasadle **vuestros** costes. El mejor umbral es el que **minimiza el coste**; no se lo dejéis elegir a la IA.
- **El test, una vez.** Con el umbral ya elegido, calculad el coste en test de tres formas: **sin modelo** (la referencia, que nunca avisa), con el umbral 0,5 y con el umbral elegido.

Qué deberíais ver. La matriz de confusión, una tabla o curva de coste por umbral con un mínimo claro y tres cifras de coste en test (sin modelo, umbral 0,5 y umbral elegido). El umbral elegido cuesta menos que el 0,5.

Hecho cuando: hay umbral elegido con vuestros costes, el coste en test está calculado una sola vez y nadie ha mirado el test para elegir el umbral.

Paso 4 · Análisis de sensibilidad (día 2, 5 minutos)

1. Cambiar los costes: ¿y si una noche vacía costara el doble? ¿y si la compensación costara la mitad?
2. Calcular el umbral óptimo y el coste total de cada combinación.
3. Resumir en una tabla y una frase.

Cómo se hace

- **Repetid la búsqueda del paso 3** dentro de un bucle: para cada pareja de costes, buscad el umbral de menor coste y guardad el resultado. Usad al menos tres combinaciones: la vuestra, FN el doble y FP la mitad.
- **Tabla.** Con las columnas `COSTE_FN`, `COSTE_FP`, umbral óptimo y coste total; un gráfico del umbral óptimo también vale.
- **La conclusión** es del tipo: «con estos costes recomendamos un umbral de X; si el coste de una falsa alarma sube al doble, el umbral sube a Y». Las cifras serán las de vuestro cuaderno.

Qué deberíais ver. Una tabla con al menos tres filas y cómo se mueve el umbral óptimo. Si FN se encarece, el umbral baja (se avisa más); si se encarece FP, sube.

Hecho cuando: la tabla (o el gráfico) está en el cuaderno y tenéis la frase de conclusión escrita.

Paso 5 · Informe y README (día 2, 10 minutos)

1. Copiar la plantilla como `informe_modelado.md` y rellenarla con las cifras del cuaderno.
2. Escribir el README: semilla, versiones, cómo ejecutar y uso de la IA.
3. Preparar la entrega: revisión con la rúbrica, subida y autoevaluación (los 15 minutos siguientes).

Cómo se hace

- **El informe.** Abrid `informe_modelado_plantilla.md`, pulsad *Raw*, copiad el texto y pegadlo en un archivo nuevo `informe_modelado.md`. Para el **nivel mínimo** bastan estas, en pocas líneas:

Apartado de la plantilla	Qué escribís
1 · Resumen para el gerente	Cinco líneas con euros: qué recomendáis, qué cuesta cada error y cuánto ahorráis frente a no hacer nada
3 · Regresión	La tabla de MAE, RMSE y R^2 y la frase del error medio en euros
4 · Clasificación	La tabla de métricas y la matriz de confusión con el umbral elegido
5 · De las métricas a los euros	`COSTE_FN` y `COSTE_FP` con su razón, el umbral y el coste en test

Para el **nivel estándar**, completad también el 2 (variables usadas y excluidas), la sensibilidad del 5, el 6 (recomendación con cifras y límites) y el 7 (riesgos de IA responsable).

- **El README.** Cuatro cosas: `SEMILLA = 42`; las versiones (`!python --version` y `import sklearn; print(sklearn.__version__)` en una celda); cómo ejecutar (*abrir en Colab y ejecutar de arriba abajo*); y el uso de la IA (qué pedisteis y qué revisasteis). Añadid quién hizo qué.
- **La revisión con la rúbrica (5 minutos, al empezar la entrega).** Quien revisa sigue los cinco pasos de «Cómo se revisa» de entrega y rúbrica y rellena la sección «Revisión con la rúbrica» del final de `informe_modelado.md`: un nivel de 1 a 4 por criterio y **una frase de prueba**.
- **Subir los ficheros (la vía del curso, desde el navegador).** Seguid Cómo entregar en GitHub: (1) en Colab, *Entorno de ejecución → Reiniciar y ejecutar todo* y después *Archivo → Descargar → Descargar .ipynb*; (2) abrid el repositorio del equipo y **entrad primero en la carpeta `sprint-07`**; (3) *Add file → Upload files* y arrastrad los ficheros; (4) escribid un mensaje corto y pulsad **Commit changes**. Cada subida es un *commit* con el nombre de quien la hace. Un reparto posible: la persona A sube `reto_S07.ipynb` («Añado cuaderno del reto»), la B sube `informe_modelado.md` («Añado informe»), la C edita `README.md` («Completo README»). Los nombres de archivo, **en minúsculas y sin espacios**. El CSV va a `data/` del repositorio solo si aún no está.

Qué deberíais ver. En la carpeta `sprint-07` del repositorio, los tres ficheros del equipo y una hoja de autoevaluación por persona (**3 + N**); y en el historial (el icono del reloj), commits de personas distintas.

Hecho cuando: otra persona podría ejecutar el cuaderno siguiendo solo el README, la sección «Revisión con la rúbrica» del informe está rellena y todo está subido a `sprint-07/`.

Después, 15 minutos de entrega: cada persona rellena y sube su autoevaluación y coevaluación a `sprint-07/` (la parte de coevaluación se completa en la *review* del jueves 12/11, en el mismo fichero). En la *review* (5 minutos por equipo) enseñaréis la tabla comparativa de métricas, el umbral elegido y su coste en euros frente a «no hacer nada», y una frase de recomendación para el gerente. En la retrospectiva, pensad: ¿qué hipótesis de coste discutimos más? ¿Cómo cambia la decisión si cambia el coste? ¿Qué habríamos necesitado saber del hotel para afinar?

Ayuda 1 · Cómo usar la IA en este reto

La IA puede ahorrar tiempo, pero **da código que parece funcionar y no se entiende**, y también **cifras que parecen razonables y no lo son**. Reglas:

- **Las hipótesis de coste son vuestras.** Si la IA os da cifras, preguntaos de dónde salen y justificadlas. No sirve «la IA dijo 200 €».
- **No dejéis que la IA elija el umbral por vosotros:** debe salir del cálculo con vuestros costes.
- **Todo lo que dé, lo ejecutáis y lo entendéis.** Si el docente pregunta por una línea, tenéis que saber explicarla.
- **Declaradlo** en el README: qué pedisteis y qué revisasteis.
- **Nada de datos personales ni claves** en una IA.

Para qué	Ejemplo de petición	Qué comprobáis
Entender una métrica	«Explícame la diferencia entre MAE y RMSE con un ejemplo de precios de hotel»	Que podéis explicar cuándo conviene cada una
Entender falsos positivos y negativos	«Dame un ejemplo en un hotel de falso positivo y falso negativo de un modelo de cancelaciones»	Que los asociáis a **vuestros** costes
Depurar código	«Este código de scikit-learn da este error: *[error]*. ¿Qué lo causa?»	Que lo entendéis y lo arregláis vosotros
Revisar la recomendación	«Lee esta recomendación al gerente y dime si hay algo ambiguo o demasiado técnico»	Que no cambie las cifras

Pista de IA responsable: ¿quién sufre los falsos positivos (un cliente reubicado)? ¿Se penaliza a algún país o canal? ¿Qué pasa si el modelo se usa para pedir depósitos solo a ciertos clientes? Respondedlo en el informe.

Ayuda 2 · Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Usar `cancelada` o información posterior para predecir el precio	No se piensa en el momento de la reserva	Hacer una lista de variables y marcar cuáles se conocen **al reservar**
Elegir el umbral mirando el test	«Queda mejor»	El umbral sale de validación cruzada sobre train; el test, **una sola vez**
Costes sin justificar, o los de la IA	Parece un detalle	Cada coste lleva una frase de razón y es del equipo
Dejar los costes por defecto de `coste_total` (3 y 1)	Se copia la celda de `S07_03` sin cambiarla	Pasar `COSTE_FN` y `COSTE_FP` a la función
Informe solo con AUC	Es lo que muestra el cuaderno	Traducir a euros: «el modelo ahorra X € frente a no hacer nada»
Probar 10 modelos	«Más es mejor»	Máximo **3 modelos por problema**, referencia incluida
Olvidar el análisis de sensibilidad	Parece opcional	Es lo que da robustez a la recomendación
El cuaderno da errores de dimensiones	La variable objetivo sigue dentro de `X`, o `X` e `y` no coinciden	Comprobar `X.shape` y `y.shape` y que `precio_noche` o `cancelada` no están en `X`

Ayuda 3 · Si os atascáis

1. **No sabemos qué costes poner:** pensad en una noche de un alojamiento de TurisData, razonad con una frase y luego **variad** los costes en la sensibilidad.

2. **No entendemos el umbral:** pensad en un semáforo. Con el umbral muy bajo avisamos casi siempre (muchas falsas alarmas); muy alto, casi nunca (muchas cancelaciones sin detectar).
3. Repasad el cuaderno de esa parte (`S07_01` a `S07_04`) y su código explicado. Después preguntad al equipo y, por último, al docente.