

Regresión lineal, polinómica y regularización

El gerente de TurisData quiere una tarifa de referencia: cuánto debería costar una noche según el tipo de habitación y la época. Predecir un número es regresión.

SPRINT 7 · MODELOS DE REGRESIÓN Y CLASIFICACIÓN · S07.1

La idea: una suma ponderada

precio ≈ base + (efecto suite)·es_suite + (efecto temporada alta)·temporada_alta + …

- Cada coeficiente dice cuántos euros cambia el precio al subir esa variable en una unidad.
- Las categóricas se pasan a 0/1 con drop_first=True: se quita una categoría (estandar) que hace de referencia.
- Se lee: «una suite cuesta X € más que una estándar».

```
modelo_lin = LinearRegression().fit(X_train, y_train)      # Ejercicio 1
coefs = pd.Series(modelo_lin.coef_, index=X.columns)       # Ejercicio 2
```

Interpretar y revisar: coeficientes y residuos

- extra_suite y efecto_temporada_alta (≈ 22 €) salen directamente de coefs.
- Residuo = real – predicho. Un modelo bien planteado deja residuos sin patrón alrededor de 0.
- Curvas o un embudo en los residuos indican que falta algo: interacciones, transformar el objetivo (logaritmo)…

```
con_interacciones.fit(X_train, y_train)                # Ejercicio 3
mejora_mae = mae_test - mean_absolute_error(y_test, pred_inter)
```

El coeficiente de temporada_alta no es el mismo «extra» para una estándar que para una suite: eso es una interacción.

Polinomios: captar curvas… y su peligro

El precio sube en invierno y verano y baja en primavera y otoño: relación con curvas respecto a mes_llegada.

```
make_pipeline(PolynomialFeatures(2), LinearRegression())        # grado 2
cross_val_score(modelo, X, y, cv=5, scoring="r2").mean()        # Ejercicio 4
```

Opción	Idea
Polinomio de grado alto	imita la curva, pero es frágil y difícil de explicar
temporada_alta (variable pensada)	simple, explicable y suele ganar

Pensar bien las variables (feature engineering) casi siempre supera a añadir complejidad al modelo.

Muchas variables, pocos datos (cuaderno S07_02)

Variables originales más todas sus combinaciones de grado 2: cientos de columnas para solo 120 filas. Solo unas pocas influyen de verdad.

```
r2_train_ols = ols.score(X_train, y_train)      # Ejercicio 1
r2_test_ols  = ols.score(X_test, y_test)
brecha_ols = r2_train_ols - r2_test_ols         # ¿es una brecha sana?
```

Una brecha grande entre entrenamiento y prueba es sobreajuste. La solución: penalizar los coeficientes grandes.

Ridge (L2) y Lasso (L1)

Ridge

Penaliza alpha · Σ coef². Encoge todos los coeficientes; reparte el peso entre variables parecidas. Rara vez deja alguno en cero.

Lasso

Penaliza alpha · Σ |coef|. Lleva a cero las variables poco útiles: modelo disperso y selección de variables.

ElasticNet

Mezcla ambas: útil con variables muy correlacionadas.

```
ridge = modelo_con(RidgeCV(alphas=np.logspace(-1, 4, 30))).fit(X_train, y_train)   # Ejercicio 2
lasso[-1].coef_                                                                    # Ejercicio 3
```

Elegir alpha y cuántos datos hacen falta

- RidgeCV y LassoCV prueban una lista de alpha con validación cruzada dentro de train; el test no se toca hasta el final.
- Escalar antes de penalizar: si no, las variables con números grandes quedan castigadas injustamente.
- Lasso gana cuando pocas variables lo explican casi todo (nuestro caso) y es fácil de explicar al cliente («las 5 cosas que más influyen en el precio»).
- Mini-reto: curva con el R^2 en test de ols y lasso para tamanos = [60, 120, 300, 1000]. Con muchos datos, regularizar importa menos.

S07 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S07_01_regresion_lineal_polinomica — 40 min

Regresión lineal y polinómica (los ejercicios marcados «en clase»)

sprints/S07/notebooks/S07_01_regresion_lineal_polinomica.ipynb

CUADERNO

S07_02_ridge_lasso — 35 min

Ridge y Lasso (los ejercicios marcados «en clase»)

sprints/S07/notebooks/S07_02_ridge_lasso.ipynb