

7.2 · Regresión Logística y Clasificación

De la predicción de valores continuos a la toma de decisiones discretas. En esta unidad exploraremos cómo la regresión logística transforma el problema de clasificación en una estimación de probabilidades, dotando a los modelos de una interpretabilidad intuitiva y una base matemática sólida.

APRENDIZAJE SUPERVISADO

CLASIFICACIÓN

PROBABILIDAD

$$E = mc^2$$

$$F = G(m_1 m_2) r^2$$

$$\int e^{-x^2} dx = \sqrt{\frac{\pi}{2}}$$

$$a^2 + b^2 = c^2$$

$$\frac{dy}{dx} = \lim_{h \rightarrow 0} [f(x+h) - f(x)] h$$

$$\sum_{n=h}^x \text{from } n = \frac{to}{to} \infty \frac{1^2}{n} = \frac{\pi^2}{6}$$

Contenidos de la Unidad

Un recorrido estructurado por los conceptos clave de la regresión logística, desde sus fundamentos hasta su aplicación práctica en problemas reales.

01

De regresión a clasificación

El salto conceptual del espacio continuo al discreto.

02

Función sigmoide y probabilidad

La clave para obtener salidas interpretables como probabilidades.

03

Frontera de decisión

Cómo el modelo separa las clases en el espacio de características.

04

Función de coste y optimización

Log-loss, regularización y el equilibrio precisión/recall.

05

Casos avanzados

Clasificación multiclase, datos desbalanceados y caso práctico.

1. De Regresión a Clasificación

La **regresión lineal** predice valores continuos (*¿cuánto?*), mientras que la **clasificación** asigna una etiqueta discreta a cada observación (*¿cuál?*). Aunque podría usarse regresión lineal aplicando un umbral, los resultados son sensibles a valores atípicos y las salidas no están acotadas. La **regresión logística** resuelve esto modelando directamente $P(y=1 \mid \mathbf{x})$, la probabilidad de pertenecer a una clase, garantizando una salida en $[0, 1]$.



Regresión Lineal

Salida: valor real en $(-\infty, +\infty)$

- Predice cantidades continuas
- Sensible a outliers
- No adecuada para probabilidades

Regresión Logística

Salida: probabilidad en $[0, 1]$

- Predice membresía a una clase
- Robusta e interpretable
- Base para clasificación binaria

❏ La diferencia clave no es el nombre, sino la función de activación aplicada a la salida lineal.

2. La Función Sigmoide

La función sigmoide $\sigma(\mathbf{z})$ transforma cualquier valor real en un número entre 0 y 1, interpretable como probabilidad. Se define como:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \text{donde} \quad z = \mathbf{w}^T \mathbf{x} + b$$

Propiedades clave

- $\sigma(0) = 0.5 \rightarrow$ punto de incertidumbre máxima
- $\sigma(z) \rightarrow 1$ cuando $z \rightarrow +\infty$
- $\sigma(z) \rightarrow 0$ cuando $z \rightarrow -\infty$
- Derivada: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Interpretación probabilística

Si el modelo devuelve $\sigma(\mathbf{z}) = 0.82$, significa que estima una probabilidad del 82 % de que la observación pertenezca a la clase positiva. Esto facilita la calibración de decisiones según el contexto.

3. Frontera de Decisión

La **frontera de decisión** es la superficie en el espacio de características donde el modelo asigna probabilidad 0.5 a ambas clases, es decir, donde $z = \mathbf{w}^T \mathbf{x} + b = 0$. A un lado, el modelo predice clase 0; al otro, clase 1.

Frontera Lineal

Si las características son originales, la frontera es una línea recta (2D) o un hiperplano (nD). Ejemplo: separar correos spam de legítimos.

Frontera No Lineal

Añadiendo características polinómicas (x^2 , x_1x_2) se obtienen fronteras curvas. La complejidad aumenta la capacidad expresiva del modelo.

Importancia de los Pesos

Los pesos $\mathbf{w}$ determinan la orientación de la frontera; el sesgo b controla su desplazamiento. Interpretar los pesos aporta explicabilidad.



4. Función de Coste: Log-Loss

El error cuadrático medio no es adecuado para clasificación. En su lugar usamos la **entropía cruzada binaria** (log-loss), que penaliza fuertemente las predicciones confiadas pero erróneas:

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log \hat{p}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$

Esta función es **convexa**, lo que garantiza que el descenso de gradiente converge a un único mínimo global, a diferencia del error cuadrático con sigmoide.

Log-Loss: Intuición Visual

Cuando $y = 1$ (clase positiva)

El coste es $-\log(\hat{p})$. Si el modelo predice $\hat{p} = 0.99$, el coste es casi 0. Si predice $\hat{p} = 0.01$, el coste se dispara a valores muy altos. El modelo aprende a ser confiado en los positivos.

Cuando $y = 0$ (clase negativa)

El coste es $-\log(1 - \hat{p})$. Si el modelo predice $\hat{p} = 0.01$, el coste es mínimo. Si predice $\hat{p} = 0.99$, el coste es muy elevado. El modelo aprende a ser confiado también en los negativos.

- ❏ Regla nemotécnica: log-loss castiga el error proporcional a tu confianza equivocada. Cuanto más seguro estás de algo incorrecto, mayor es la penalización.

5. Umbral y Equilibrio Precisión/Recall

Por defecto, el umbral de clasificación es 0.5: si $\hat{p} \geq 0.5$, se predice clase 1. Pero este valor es ajustable y tiene un impacto crítico en el rendimiento real del modelo.

Precisión (Precision)

De todas las predicciones positivas del modelo, ¿cuántas son realmente positivas? $P = \frac{TP}{TP+FP}$. Relevante cuando los falsos positivos son costosos (p. ej., diagnósticos médicos innecesarios).

Exhaustividad (Recall)

De todos los casos realmente positivos, ¿cuántos detecta el modelo? $R = \frac{TP}{TP+FN}$. Relevante cuando los falsos negativos son peligrosos (p. ej., detección de fraudes o tumores).

F1-Score

Media armónica entre precisión y recall: $F_1 = 2 \cdot \frac{P \cdot R}{P+R}$. Es la métrica de equilibrio cuando ambas dimensiones importan por igual.

La Curva ROC y el Umbral Óptimo

¿Cómo elegir el umbral?

Al variar el umbral entre 0 y 1, se barre la curva **ROC** (Receiver Operating Characteristic), que representa la tasa de verdaderos positivos frente a la de falsos positivos. El área bajo la curva (**AUC-ROC**) mide la capacidad discriminativa global del modelo.

- $AUC = 1.0 \rightarrow$ clasificador perfecto
- $AUC = 0.5 \rightarrow$ clasificador aleatorio
- El umbral óptimo depende del coste relativo de FP y FN en cada negocio


Reglas prácticas

Umbral bajo

Mayor recall, menor precisión. Útil en detección de enfermedades.

Umbral alto

Mayor precisión, menor recall. Útil en sistemas de recomendación.



6. Clasificación Multiclase

La regresión logística se extiende de forma natural más allá de la clasificación binaria para manejar problemas con **K clases distintas**. Existen dos estrategias principales:

1

One-vs-Rest (OvR)

Se entrena un clasificador binario por cada clase, comparando esa clase contra todas las demás. Se asigna la clase con mayor probabilidad predicha.

2

One-vs-One (OvO)

Se entrenan clasificadores para cada par de clases posible. Con K clases, se generan $K(K-1)/2$ modelos. La clase más votada gana.

3

Softmax (Multinomial)

Generalización directa: una única función softmax produce probabilidades para todas las clases simultáneamente, garantizando que sumen 1.

La Función Softmax

La función softmax es la generalización de la sigmoide para K clases. Para la clase k en un problema con K clases:

$$P(y = k \mid \mathbf{x}) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad \text{donde} \quad z_k = \mathbf{w}_k^T \mathbf{x} + b_k$$

Propiedades de Softmax

- Las probabilidades de todas las clases suman exactamente 1
- Amplifica diferencias entre logits (exponencial)
- La clase con mayor logit recibe la mayor probabilidad
- Usada como capa final en redes neuronales multiclase

Ejemplo

Clasificar una flor en 3 especies: Setosa, Versicolor, Virginica.
Softmax devuelve **[0.70, 0.25, 0.05]**: el modelo predice Setosa con 70 % de confianza.

7. Regularización en Regresión Logística

Sin regularización, el modelo puede ajustarse en exceso a los datos de entrenamiento (**overfitting**), especialmente con muchas características o datos escasos. La regularización añade una penalización a los pesos grandes para forzar un modelo más simple y generalizable.

Regularización L2 (Ridge)

Penaliza la suma de los cuadrados de los pesos: $\lambda \sum w_j^2$. Reduce todos los pesos proporcionalmente pero raramente los anula por completo. Es la más habitual en regresión logística.

Regularización L1 (Lasso)

Penaliza la suma de los valores absolutos: $\lambda \sum |w_j|$. Tiene la propiedad de generar **sparsity**: anula los pesos de características irrelevantes, actuando como selección automática de variables.

Elastic Net

Combinación lineal de L1 y L2: $\lambda_1 \sum |w_j| + \lambda_2 \sum w_j^2$. Combina la selección de variables de Lasso con la estabilidad numérica de Ridge.

El Hiperparámetro C y la Regularización

¿Qué controla C?

En scikit-learn, la fuerza de regularización se controla con el parámetro $C = 1/\lambda$:

- **C pequeño** → regularización fuerte → modelo simple
- **C grande** → regularización débil → modelo complejo

El valor por defecto es $C = 1.0$. Se selecciona mediante validación cruzada.

Función de coste regularizada

$$J = -\frac{1}{m} \sum \text{log-loss} + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

El término de regularización solo penaliza los pesos $\mathbf{w}$, nunca el sesgo $\mathbf{b}$, ya que este no contribuye al sobreajuste de la misma manera.

8. Datos Desbalanceados

En muchos problemas reales —detección de fraude, diagnóstico médico, cancelaciones de reservas— una clase es mucho más frecuente que la otra. Un modelo entrenado ingenuamente aprenderá a predecir siempre la clase mayoritaria, obteniendo una alta exactitud (accuracy) pero un recall casi nulo para la clase minoritaria.



Resampling

Oversampling (SMOTE): genera ejemplos sintéticos de la clase minoritaria. **Undersampling**: elimina ejemplos de la mayoría. Ambas técnicas equilibran el conjunto de entrenamiento.



Class Weights

Asignar un peso mayor a los errores en la clase minoritaria mediante **class_weight='balanced'** en scikit-learn. El modelo penaliza más fuertemente los fallos en clases raras.



Métricas Adecuadas

Nunca usar accuracy como única métrica. Preferir **F1-score**, **AUC-ROC**, o la **matriz de confusión** para evaluar el rendimiento real sobre ambas clases.

SMOTE: Generación de Ejemplos Sintéticos

¿Cómo funciona SMOTE?

SMOTE (*Synthetic Minority Over-sampling Technique*) crea nuevos ejemplos de la clase minoritaria interpolando entre ejemplos existentes y sus vecinos más cercanos en el espacio de características. A diferencia de la duplicación simple, genera variabilidad real.

- Selecciona un ejemplo minoritario
- Encuentra sus k vecinos más cercanos de la misma clase
- Crea un punto aleatorio en el segmento entre ambos

Advertencias de uso



Solo en
entrenamiento

SMOTE debe aplicarse únicamente al conjunto de entrenamiento, nunca al de validación o test.




Riesgo de
sobreajuste


Un oversampling excesivo puede hacer que el modelo aprenda los ejemplos sintéticos en lugar de patrones reales.

9. Caso Práctico: Cancelación de Reservas de Hotel

La predicción de cancelaciones es un problema de clasificación binaria con impacto directo en los ingresos de un hotel. Los datos incluyen características como el tipo de habitación, días de antelación, número de cambios en la reserva, o el historial del cliente. El modelo debe predecir si una reserva será cancelada ($y=1$) o no ($y=0$).



Modelado del Caso de Cancelaciones



Cada etapa del pipeline tiene decisiones de diseño críticas. El umbral final no es 0.5 por defecto: el negocio decide cuántas cancelaciones perdidas tolera frente al coste de molestar a clientes que no cancelarán.

Resultados e Interpretación del Modelo

Variables más influyentes

Días de antelación

Cuanto mayor la antelación, mayor probabilidad de cancelación. El modelo asigna un peso positivo alto a esta variable.

Número de cambios

Más cambios en la reserva correlacionan fuertemente con cancelación. Señal de indecisión del cliente.

Tipo de depósito

Reservas sin depósito cancelan más. Las que requieren depósito no reembolsable rara vez cancelan.

Decisión de negocio

Con un umbral calibrado al 0.35, el modelo captura el **78 % de las cancelaciones reales** con una precisión del 65 %. El hotel puede activar políticas preventivas (overbooking controlado, comunicación proactiva) para cada reserva de alto riesgo.

❏ La interpretabilidad de la regresión logística es una ventaja competitiva: el equipo de operaciones puede entender y confiar en las predicciones del modelo.

Resumen de la Unidad

La regresión logística es mucho más que un clasificador simple: es una herramienta interpretable, eficiente y con sólidos fundamentos probabilísticos.



Sigmoide → Probabilidad

Transforma la combinación lineal en una estimación de probabilidad bien calibrada.



Log-Loss

Función de coste convexa que garantiza la convergencia del descenso de gradiente.



Umbral Ajustable

El umbral de decisión se calibra según el contexto de negocio y el coste de los errores.



Regularización

L1 y L2 previenen el sobreajuste y mejoran la generalización del modelo.



Datos Desbalanceados

SMOTE, class weights y métricas adecuadas son esenciales en problemas reales.