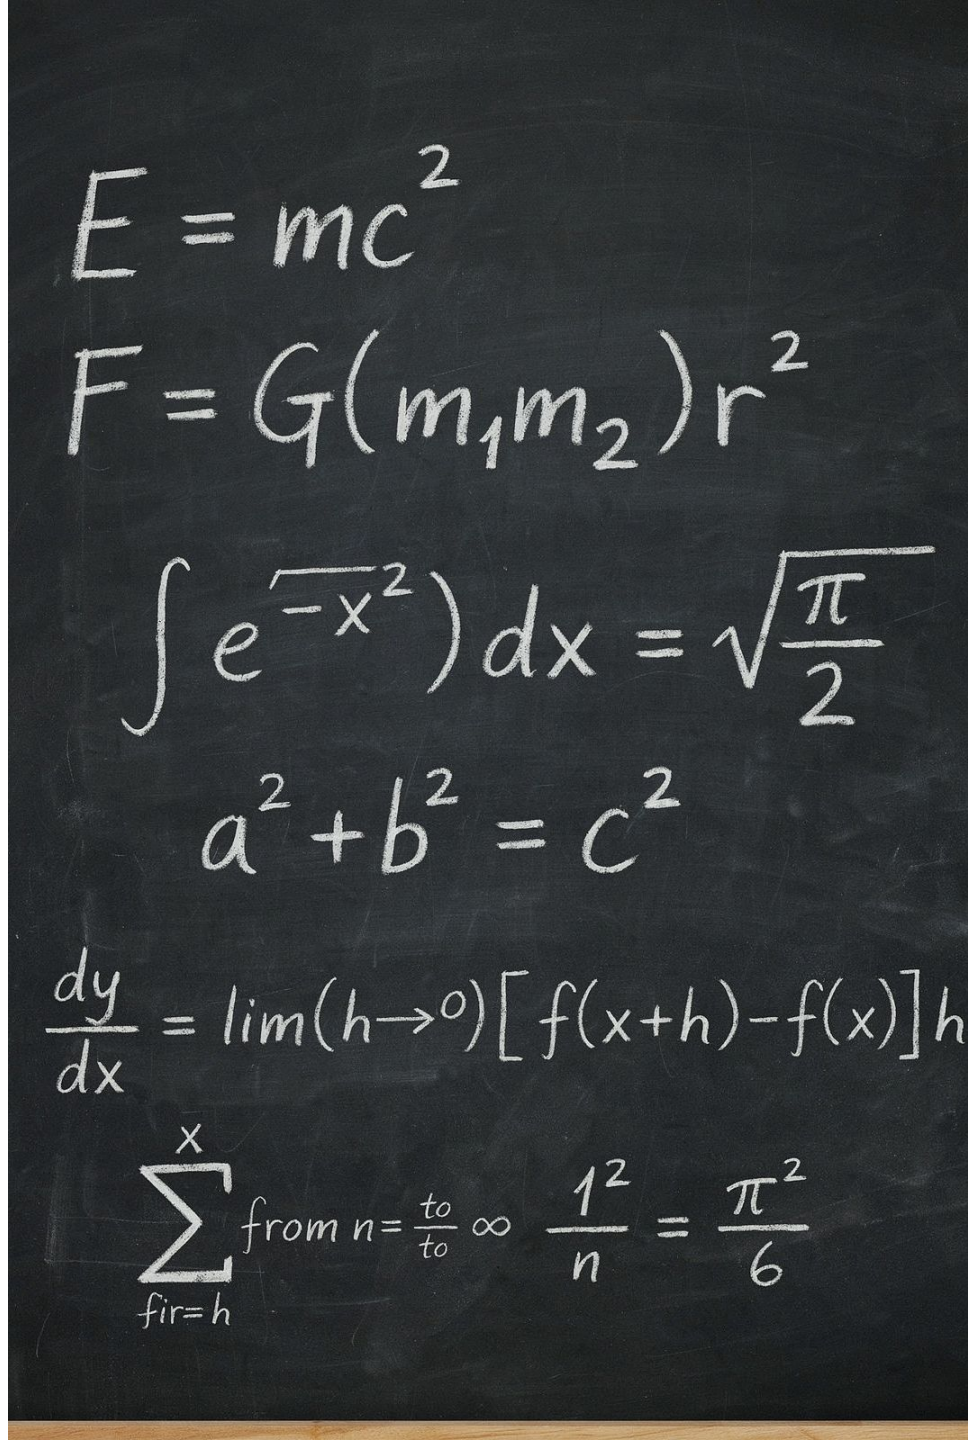
7.2 · Regresión Logística y Clasificación

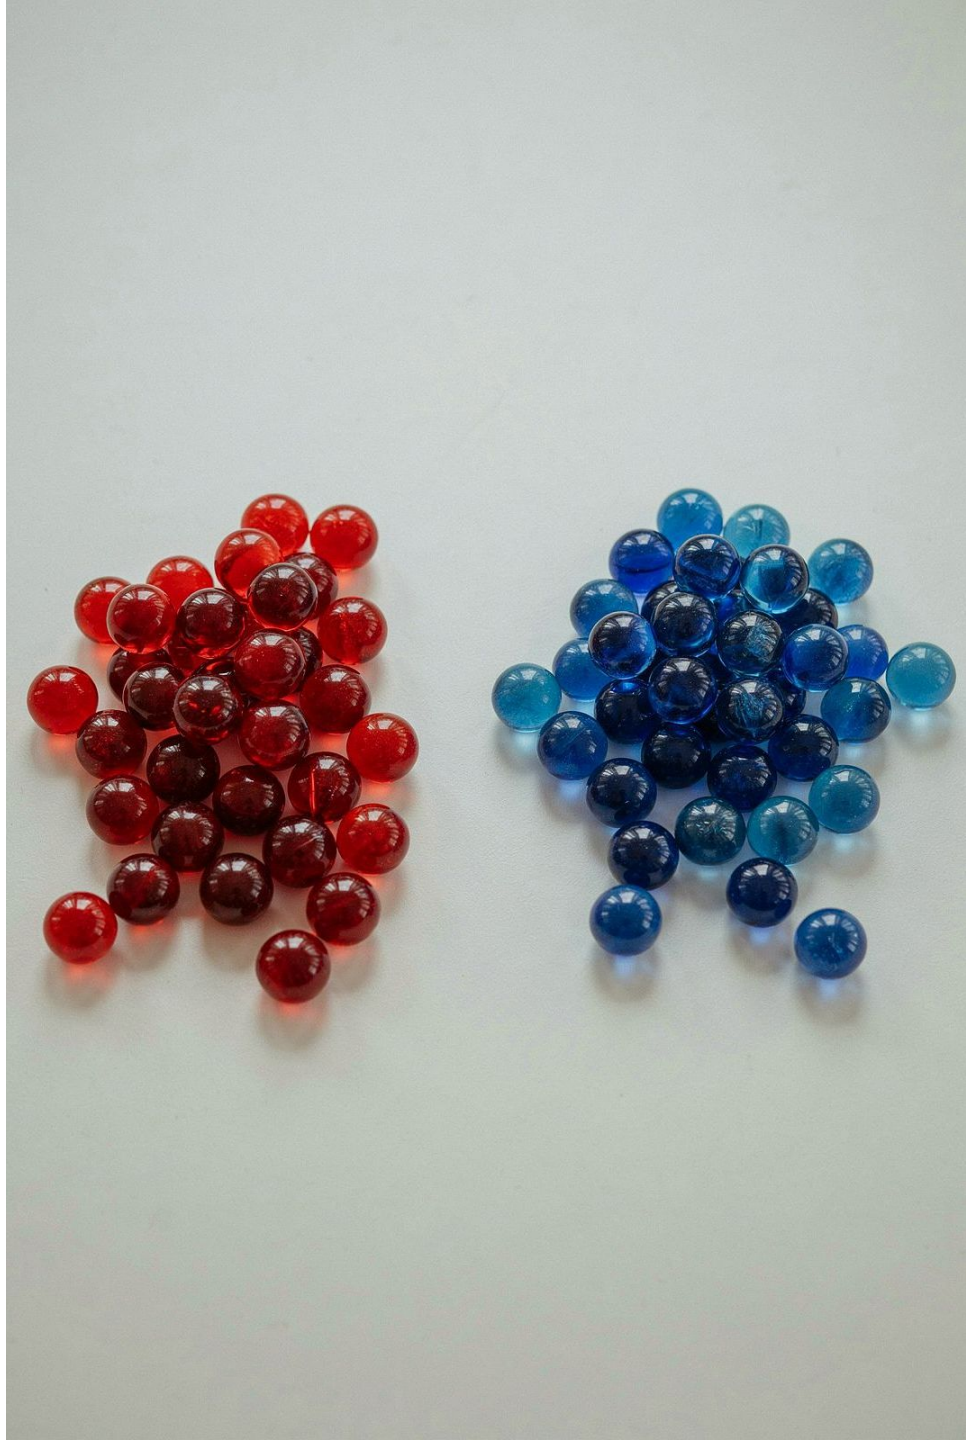
De la predicción de valores continuos a la toma de decisiones discretas. En esta unidad exploraremos cómo la regresión logística transforma el problema de clasificación en una estimación de probabilidades, dotando a los modelos de una interpretabilidad intuitiva y una base matemática sólida.

APRENDIZAJE SUPERVISADO | CLASIFICACIÓN | PROBABILIDAD



1. De Regresión a Clasificación

La **regresión lineal** predice valores continuos (*¿cuánto?*), mientras que la **clasificación** asigna una etiqueta discreta a cada observación (*¿cuál?*). Aunque podría usarse regresión lineal aplicando un umbral, los resultados son sensibles a valores atípicos y las salidas no están acotadas. La **regresión logística** resuelve esto modelando directamente **P(y=1 | x)**, la probabilidad de pertenecer a una clase, garantizando una salida en [0, 1].



2. La Función Sigmoide

La función sigmoide **σ(z)** transforma cualquier valor real en un número entre 0 y 1, interpretable como probabilidad. Se define como:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \text{donde} \quad z = \mathbf{w}^T \mathbf{x} + b$$

Propiedades clave

- σ(0) = 0.5 → punto de incertidumbre máxima
- σ(z) → 1 cuando z → +∞
- σ(z) → 0 cuando z → –∞
- Derivada: σ'(z) = σ(z)(1 – σ(z))

Interpretación probabilística

Si el modelo devuelve **σ(z) = 0.82**, significa que estima una probabilidad del 82 % de que la observación pertenezca a la clase positiva. Esto facilita la calibración de decisiones según el contexto.

3. Frontera de Decisión

La **frontera de decisión** es la superficie en el espacio de características donde el modelo asigna probabilidad 0.5 a ambas clases, es decir, donde $z = \mathbf{w}^T\mathbf{x} + b = 0$. A un lado, el modelo predice clase 0; al otro, clase 1.

Frontera Lineal

Si las características son originales, la frontera es una línea recta (2D) o un hiperplano (nD). Ejemplo: separar correos spam de legítimos.

Frontera No Lineal

Añadiendo características polinómicas (x^2, x_1x_2) se obtienen fronteras curvas. La complejidad aumenta la capacidad expresiva del modelo.

Importancia de los Pesos

Los pesos **w** determinan la orientación de la frontera; el sesgo **b** controla su desplazamiento. Interpretar los pesos aporta explicabilidad.



4. Función de Coste: Log-Loss

El error cuadrático medio no es adecuado para clasificación. En su lugar usamos la **entropía cruzada binaria** (log-loss), que penaliza fuertemente las predicciones confiadas pero erróneas:

$$J(\mathbf{w}) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log\hat{p}^{(i)} + (1-y^{(i)})\log(1-\hat{p}^{(i)})\right]$$

Esta función es **convexa**, lo que garantiza que el descenso de gradiente converge a un único mínimo global, a diferencia del error cuadrático con sigmoide.

5. Umbral y Equilibrio Precisión/Recall

Por defecto, el umbral de clasificación es 0.5: si $\hat{p} \geq 0.5$, se predice clase 1. Pero este valor es ajustable y tiene un impacto crítico en el rendimiento real del modelo.

Precisión (Precision)

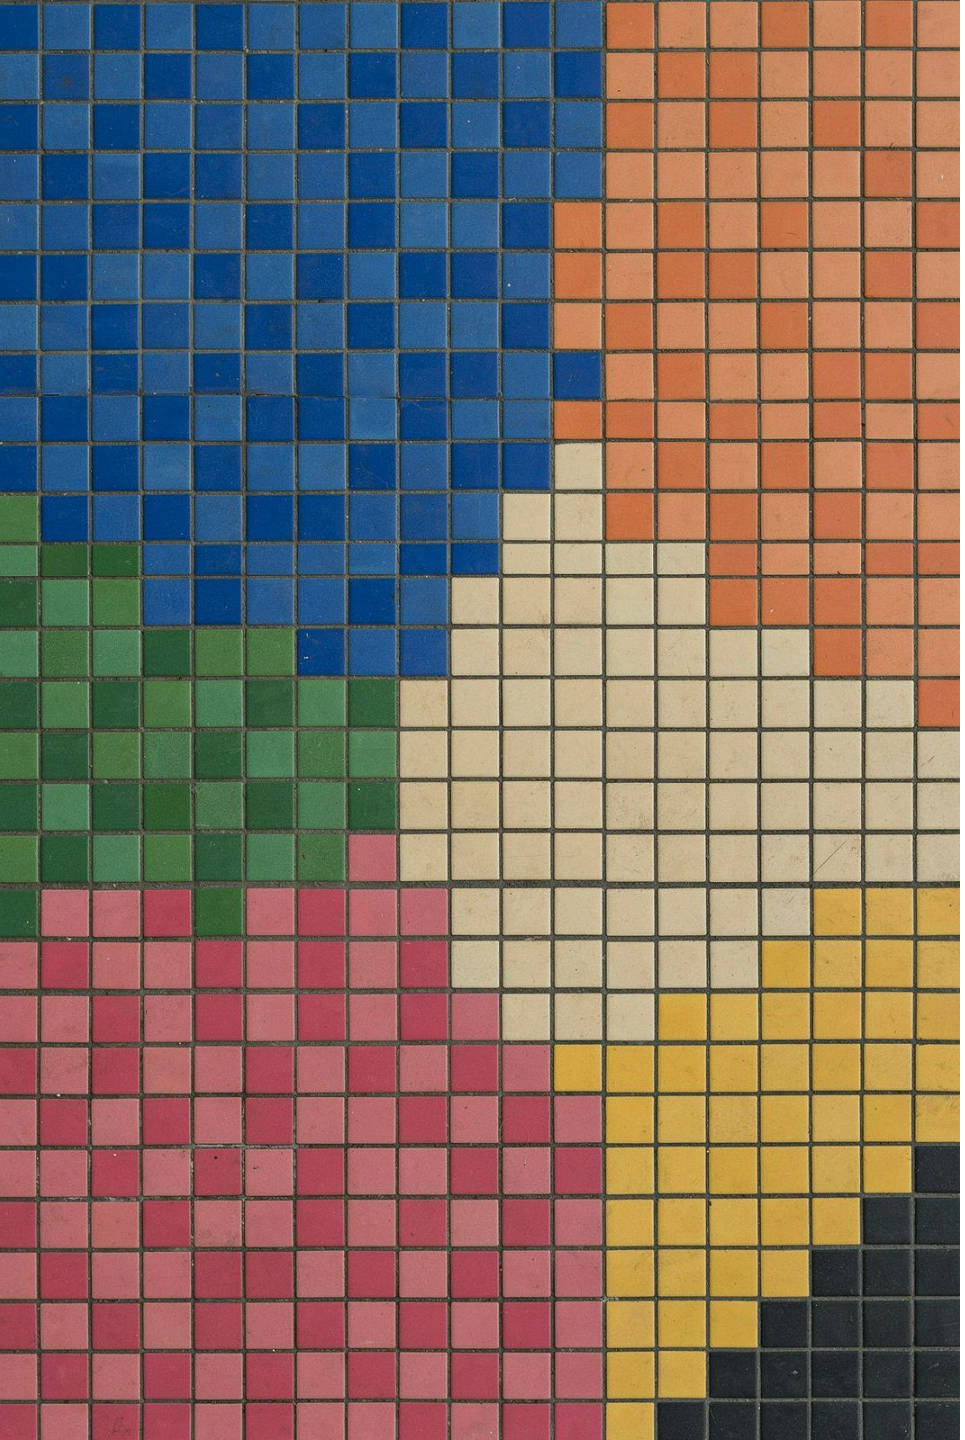
De todas las predicciones positivas del modelo, ¿cuántas son realmente positivas? $P = \frac{TP}{TP+FP}$. Relevante cuando los falsos positivos son costosos (p. ej., diagnósticos médicos innecesarios).

Exhaustividad (Recall)

De todos los casos realmente positivos, ¿cuántos detecta el modelo? $R = \frac{TP}{TP+FN}$. Relevante cuando los falsos negativos son peligrosos (p. ej., detección de fraudes o tumores).

F1-Score

Media armónica entre precisión y recall: $F_1 = 2 \cdot \frac{P \cdot R}{P+R}$. Es la métrica de equilibrio cuando ambas dimensiones importan por igual.



6. Clasificación Multiclase

La regresión logística se extiende de forma natural más allá de la clasificación binaria para manejar problemas con **K clases distintas**. Existen dos estrategias principales:

1

One-vs-Rest (OvR)

Se entrena un clasificador binario por cada clase, comparando esa clase contra todas las demás. Se asigna la clase con mayor probabilidad predicha.

2

One-vs-One (OvO)

Se entrenan clasificadores para cada par de clases posible. Con K clases, se generan K(K−1)/2 modelos. La clase más votada gana.

3

Softmax (Multinomial)

Generalización directa: una única función softmax produce probabilidades para todas las clases simultáneamente, garantizando que sumen 1.

7. Regularización en Regresión Logística

Sin regularización, el modelo puede ajustarse en exceso a los datos de entrenamiento (**overfitting**), especialmente con muchas características o datos escasos. La regularización añade una penalización a los pesos grandes para forzar un modelo más simple y generalizable.

Regularización L2 (Ridge)

Penaliza la suma de los cuadrados de los pesos: $\lambda \sum w_j^2$. Reduce todos los pesos proporcionalmente pero raramente los anula por completo. Es la más habitual en regresión logística.

Regularización L1 (Lasso)

Penaliza la suma de los valores absolutos: $\lambda \sum |w_j|$. Tiene la propiedad de generar **sparsity**: anula los pesos de características irrelevantes, actuando como selección automática de variables.

Elastic Net

Combinación lineal de L1 y L2: $\lambda_1 \sum |w_j| + \lambda_2 \sum w_j^2$. Combina la selección de variables de Lasso con la estabilidad numérica de Ridge.

8. Datos Desbalanceados

En muchos problemas reales —detección de fraude, diagnóstico médico, cancelaciones de reservas— una clase es mucho más frecuente que la otra. Un modelo entrenado ingenuamente aprenderá a predecir siempre la clase mayoritaria, obteniendo una alta exactitud (accuracy) pero un recall casi nulo para la clase minoritaria.



Resampling

Oversampling (SMOTE): genera ejemplos sintéticos de la clase minoritaria. **Undersampling**: elimina ejemplos de la mayoría. Ambas técnicas equilibran el conjunto de entrenamiento.



Class Weights

Asignar un peso mayor a los errores en la clase minoritaria mediante **class_weight='balanced'** en scikit-learn. El modelo penaliza más fuertemente los fallos en clases raras.

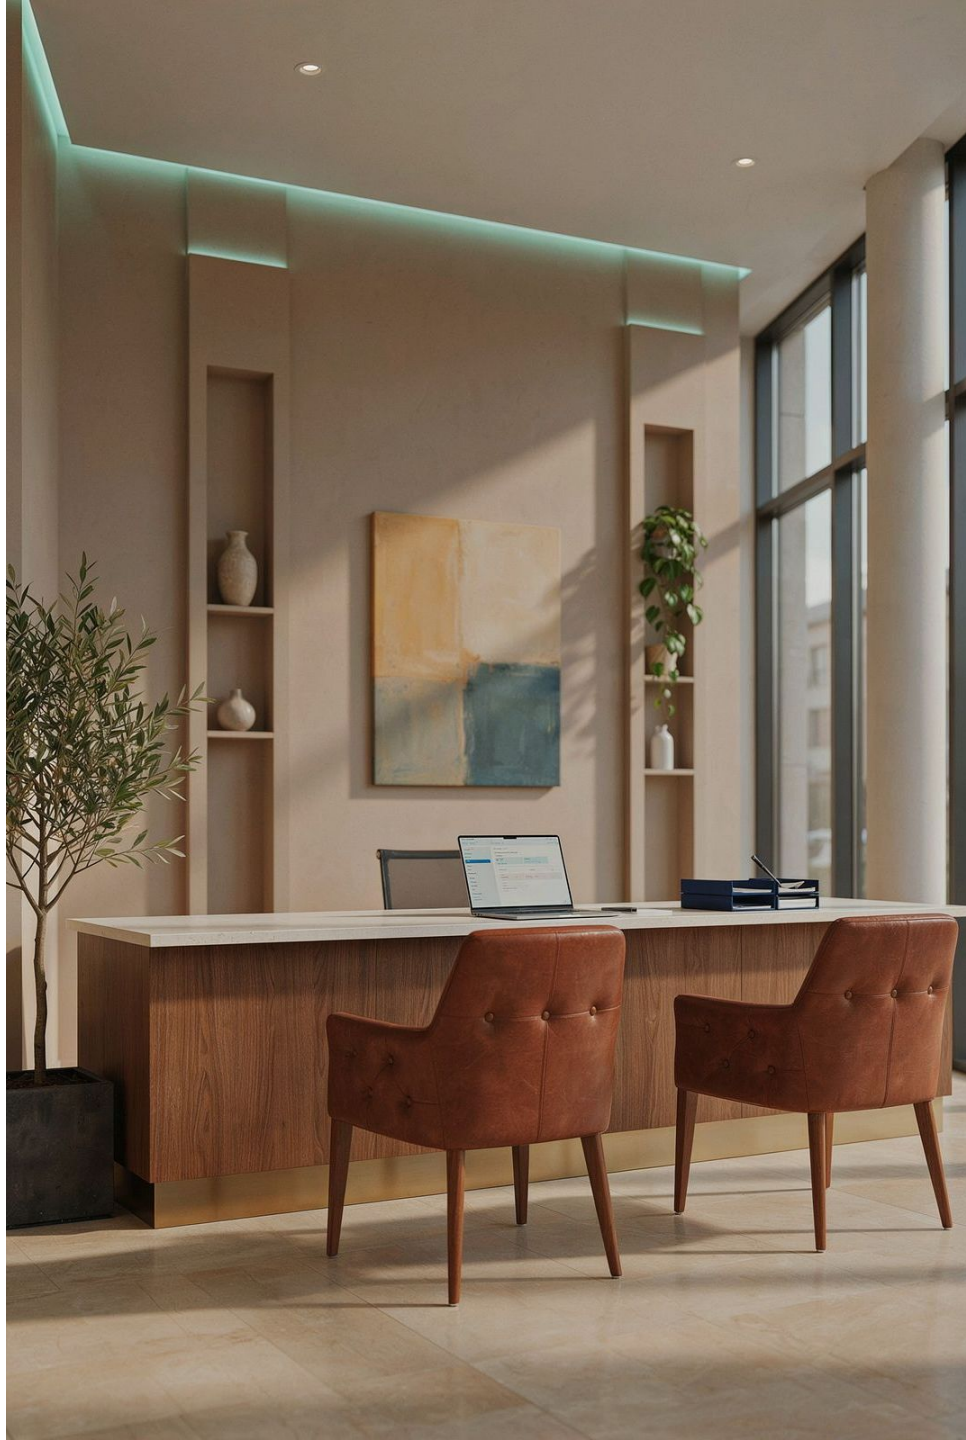


Métricas Adecuadas

Nunca usar accuracy como única métrica. Preferir **F1-score**, **AUC-ROC**, o la **matriz de confusión** para evaluar el rendimiento real sobre ambas clases.

9. Caso Práctico: Cancelación de Reservas de Hotel

La predicción de cancelaciones es un problema de clasificación binaria con impacto directo en los ingresos de un hotel. Los datos incluyen características como el tipo de habitación, días de antelación, número de cambios en la reserva, o el historial del cliente. El modelo debe predecir si una reserva será cancelada (**y=1**) o no (**y=0**).



Resultados e Interpretación del Modelo

Variables más influyentes

Días de antelación

Cuanto mayor la antelación, mayor probabilidad de cancelación. El modelo asigna un peso positivo alto a esta variable.

Número de cambios

Más cambios en la reserva correlacionan fuertemente con cancelación. Señal de indecisión del cliente.

Tipo de depósito

Reservas sin depósito cancelan más. Las que requieren depósito no reembolsable rara vez cancelan.

Decisión de negocio

Con un umbral calibrado al 0.35, el modelo captura el **78 % de las cancelaciones reales** con una precisión del 65 %. El hotel puede activar políticas preventivas (overbooking controlado, comunicación proactiva) para cada reserva de alto riesgo.

La interpretabilidad de la regresión logística es una ventaja competitiva: el equipo de operaciones puede entender y confiar en las predicciones del modelo.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S07_03_regresion_logistica — 55 min

Regresión logística

sprints/S07/notebooks/S07_03_regresion_logistica.ipynb