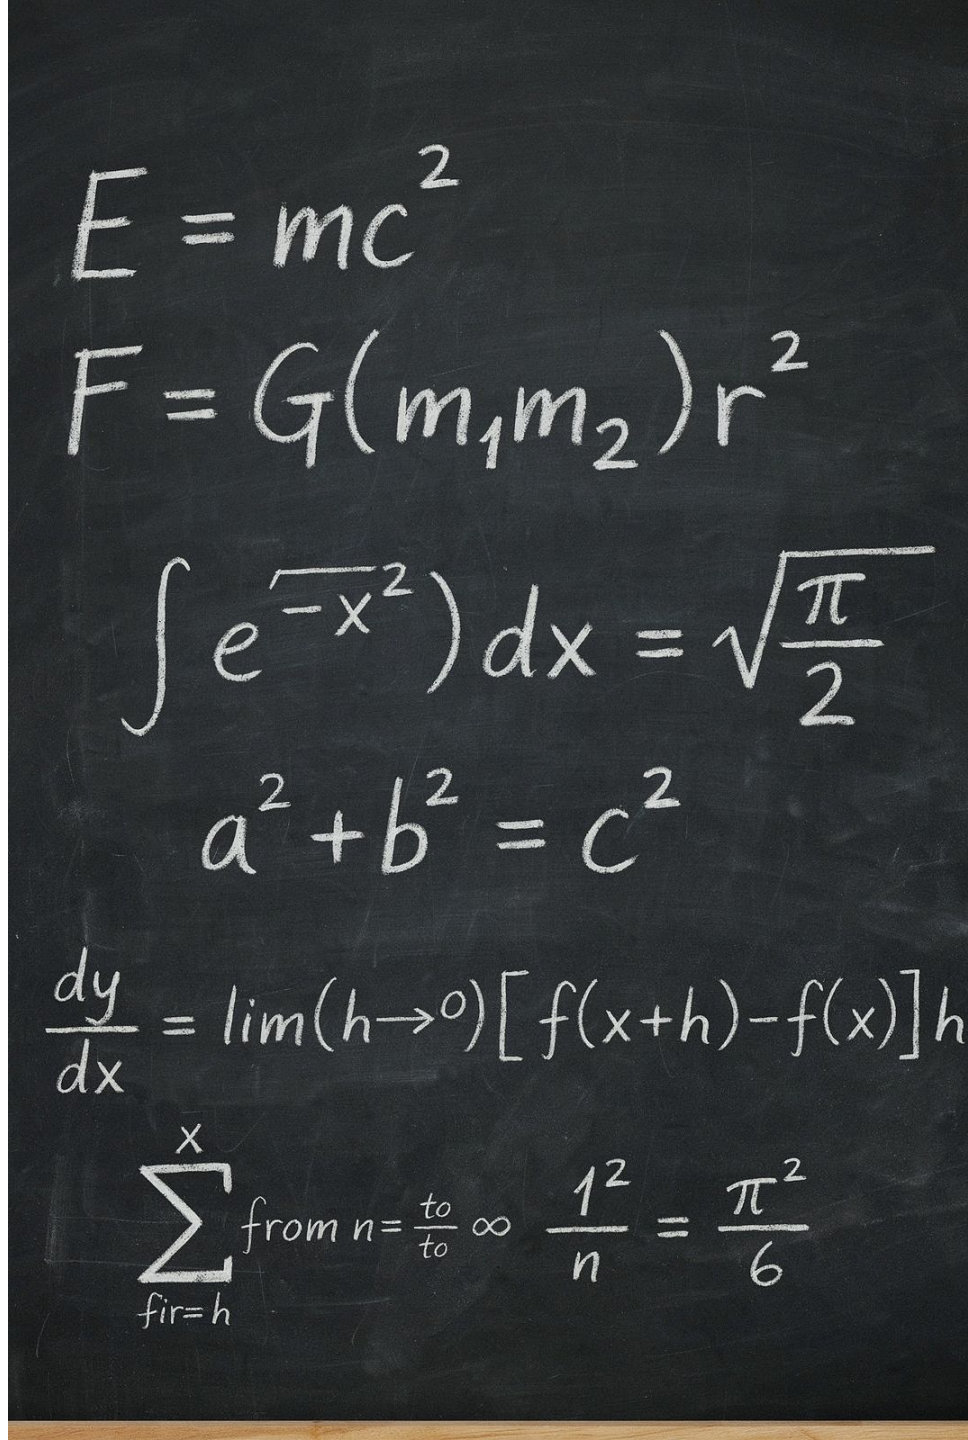
SPRINT 7 · MODELOS DE REGRESIÓN Y CLASIFICACIÓN · S07.2

Regresión logística y clasificación

Segunda herramienta para el gerente: un aviso de riesgo de cancelación para decidir cuándo vender por encima de la capacidad (overbooking). Predecir una categoría.



De una suma ponderada a una probabilidad

> probabilidad = 1 / (1 + e^(−z)): la sigmoide comprime la suma ponderada z entre 0 y 1.

```
logit = Pipeline([("prep", prep), ("clf", LogisticRegression(max_iter=1000))])   # Ejercicio 1
logit.fit(X_train, y_train)
proba_test = logit.predict_proba(X_test)[:, 1]
```

- predict_proba da la probabilidad; predict aplica un umbral de 0,5 por defecto.
- Todo el preprocesado va dentro del Pipeline (como en el Sprint 6).

Interpretar: odds ratios

- Odds = P(cancela) / P(no cancela). exp(coeficiente) = odds ratio: cuánto se multiplican los odds.
- > 1 aumenta el riesgo; < 1 lo reduce.

```
odds = pd.Series(np.exp(coefs), index=nombres)              # Ejercicio 2
or_no_reembolsable = odds["cat__tarifa_no_reembolsable"]
or_deposito_total  = odds["cat__deposito_total"]
mas_riesgo = odds.idxmax()
```

> Ojo: que la tarifa no reembolsable tenga un odds ratio < 1 no significa que cause menos cancelaciones; puede ser que quien la elige ya es más seguro.

El umbral y la matriz de confusión

	Predicho: se mantiene	Predicho: cancela
Real: se mantiene	Verdadero negativo	Falsa alarma (FP)
Real: cancela	Cancelación no prevista (FN)	Verdadero positivo

- El modelo da una probabilidad; nosotros decidimos desde qué valor hablamos de «riesgo».
- Ejercicio 3: con metricas_umbral(y_test, proba_test, umbral), compara 0,5 y 0,3: sube el recall (sube_recall) y baja la precisión (baja_precision).

Elegir el umbral según el coste

- FN: habitación vacía que podíamos haber vendido. FP: molestamos a un cliente que iba a venir o hacemos overbooking sin necesidad.
- Si un FN cuesta el triple que un FP, conviene ser más «alarmista».

```
umbrales = np.arange(0.05, 0.96, 0.05)
costes = [coste_total(y_train, proba_cv, u) for u in umbrales]   # FN = 3, FP = 1  (Ejercicio 4)
mejor_umbral = umbrales[int(np.argmin(costes))]
```

Mini-reto: tabla_umbrales con 0,5, 0,3 y mejor_umbral (recall, precisión y coste en test) y una recomendacion con al menos una cifra. El gerente no quiere oír «AUC»: quiere euros.

Datos desbalanceados (cuaderno S07_04)

```
tonto = DummyClassifier(strategy="most_frequent").fit(X_train, y_train)   # Ejercicio 1
acc_tonto, recall_tonto = tonto.score(X_test, y_test), recall_score(y_test, tonto.predict(X_test))
```

> La paradoja de la exactitud: un modelo que nunca avisa de una cancelación acierta mucho… y tiene recall 0.

Tres remedios: pesos por clase (class_weight="balanced"), submuestreo de la clase mayoritaria y ajustar el umbral.

ROC frente a PR

Curva ROC y AUC

TPR (recall) frente a FPR para cada umbral. Diagonal = modelo inútil.

roc_curve, roc_auc_score (Ejercicio 2).

Curva PR y AP

Precisión frente a recall, solo con la clase que importa. Más honesta con clases raras.

average_precision_score (Ejercicio 3).

- Con clases raras la ROC puede parecer excelente aunque la mayoría de las alarmas sean falsas.
- La línea de referencia de la PR es la prevalencia: veces_mejor_que_azar = ap_base / prevalencia.

Remedios y umbral con restricción

```
nuevo_modelo(class_weight="balanced").fit(X_train, y_train)      # Ejercicio 4
resample(negativas, replace=False, n_samples=2 * len(positivas),
         random_state=SEMILLA)                                   # Ejercicio 5 (solo en train)

prec, rec, umbrales = precision_recall_curve(y_train, proba_cv)    # Ejercicio 6
umbral_70 = umbrales[rec[:-1] >= 0.70].max()                       # detectar ≥ 70 %
```

- Remuestrear solo el entrenamiento; el test se deja como es en la realidad.
- Mini-reto: comparativa de "base", "pesos" y "submuestreo" con AUC, AP, recall y precisión en test.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

Tipo	Recurso	Tiempo
CUADERNO	Regresión logística (sprints/S07/notebooks/S07_03_regresion_logistica)	55 min
RETO	Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2) (sprints/S07/Reto_S07/Reto_Sprint_07.md)	30 min
CUADERNO	ROC, PR y datos desbalanceados (sprints/S07/notebooks/S07_04_roc_pr_desbalance)	40 min