SPRINT 7 · MODELOS DE REGRESIÓN Y CLASIFICACIÓN · S07.3

k-NN y Naive Bayes

Dos modelos sencillos más para la caja de herramientas, con una pregunta práctica: ¿cuál le conviene al equipo de reservas?

k-NN: predecir mirando a los vecinos

1. Calcula la **distancia** de la reserva nueva a todas las conocidas.
2. Quédate con las **k más cercanas**.
3. La clase es la **más frecuente** entre ellas (la probabilidad, la proporción).

- No hay entrenamiento real: guarda los datos y consulta. Por eso **predecir es lento** con muchos datos.
- Mide **distancias** → hay que **escalar**: sin escalar, `antelacion_dias` aportaría casi toda la distancia (Ejercicio 1: `pct_antelacion_sin_escalar` frente a `pct_antelacion_escalada`).

Elegir `k`

k pequeño (1, 3)

Copia el ruido de los vecinos: alta varianza, sobreajuste.

k grande

Promedia demasiado: alto sesgo, suaviza en exceso.

```
auc_por_k = [cross_val_score(knn(k), X_train, y_train, cv=cv,
                             scoring="roc_auc").mean() for k in ks]     # Ejercicio 2
mejor_k = ks[int(np.argmax(auc_por_k))]
```

Se elige con **validación cruzada** y se evalúa con AUC.

Naive Bayes: probabilidades multiplicadas

Teorema de Bayes (Sprint 5) + una simplificación «ingenua»: las variables son **independientes** entre sí dado el resultado → basta **multiplicar** probabilidades.

```
nb_gauss = Pipeline([("prep", prep_onehot()), ("nb", GaussianNB())])        # Ejercicio 3

nb_cat = Pipeline([("prep", ColumnTransformer([                              # Ejercicio 4
            ("num", [imputar mediana, KBinsDiscretizer(n_bins=5, encode="ordinal")], num),
            ("cat", [imputar moda, OrdinalEncoder()], cat)])),
        ("nb", CategoricalNB(min_categories=5))])
```

- Muy rápido y con pocos datos; la suposición de independencia casi nunca es cierta, pero a menudo funciona.

¿Qué modelo para el equipo de reservas?

Modelo	Ventaja	Pega
Regresión logística	Explicable (odds ratio), rápida	Solo fronteras lineales
k-NN	Sin supuestos, simple	Lento al predecir; necesita escalado
Naive Bayes	Muy rápido, pocos datos	Independencia poco realista

Mini-reto: `tabla` con `auc_cv`, `segundos_ajuste` y `segundos_predecir` (con `time.perf_counter()`) de `"logistica"`, `"knn"`, `"nb_gauss"` y `"nb_cat"`. El mejor modelo no es solo el de mayor AUC: cuenta el **tiempo** y la **explicabilidad**.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S07_05_knn_naive_bayes — 25 min

k-NN y Naive Bayes

sprints/S07/notebooks/S07_05_knn_naive_bayes.ipynb

RETO

Reto del sprint — 40 min

Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5)

sprints/S07/guia/Reto_Sprint_07.md