SPRINT 7 · MODELOS DE REGRESIÓN Y CLASIFICACIÓN · S07.3

k-NN y Naive Bayes

Dos modelos sencillos más para la caja de herramientas, con una pregunta práctica: ¿cuál le conviene al equipo de reservas?



k-NN: predecir mirando a los vecinos

1. Calcula la distancia de la reserva nueva a todas las conocidas.
2. Quédate con las k más cercanas.
3. La clase es la más frecuente entre ellas (la probabilidad, la proporción).

- No hay entrenamiento real: guarda los datos y consulta. Por eso predecir es lento con muchos datos.
- Mide distancias → hay que escalar: sin escalar, antelacion_dias aportaría casi toda la distancia (Ejercicio 1: pct_antelacion_sin_escalar frente a pct_antelacion_escalada).

Elegir k

k pequeño (1, 3)

Copia el ruido de los vecinos: alta varianza, sobreajuste.

k grande

Promedia demasiado: alto sesgo, suaviza en exceso.

```
auc_por_k = [cross_val_score(knn(k), X_train, y_train, cv=cv,
                             scoring="roc_auc").mean() for k in ks]     # Ejercicio 2
mejor_k = ks[int(np.argmax(auc_por_k))]
```

Se elige con validación cruzada y se evalúa con AUC.

Naive Bayes: probabilidades multiplicadas

Teorema de Bayes (Sprint 5)

$$P(C \mid x) = \frac{P(x \mid C) \cdot P(C)}{P(x)}$$

Simplificación «ingenua»: las variables son independientes entre sí dado el resultado → basta multiplicar probabilidades.

```
nb_gauss = Pipeline([("prep", prep_onehot()), ("nb", GaussianNB())])      # Ejercicio 3

nb_cat = Pipeline([("prep", ColumnTransformer([                           # Ejercicio 4
        ("num", [imputar mediana, KBinsDiscretizer(n_bins=5, encode="ordinal")], num),
        ("cat", [imputar moda, OrdinalEncoder()], cat)])),
    ("nb", CategoricalNB(min_categories=5))])
```

- Muy rápido y con pocos datos; la suposición de independencia casi nunca es cierta, pero a menudo funciona.

¿Qué modelo para el equipo de reservas?

Modelo	Ventaja	Pega
Regresión logística	Explicable (odds ratio), rápida	Solo fronteras lineales
k-NN	Sin supuestos, simple	Lento al predecir; necesita escalado
Naive Bayes	Muy rápido, pocos datos	Independencia poco realista

Mini-reto: tabla con auc_cv, segundos_ajuste y segundos_predecir (con time.perf_counter()) de "logistica", "knn", "nb_gauss" y "nb_cat". El mejor modelo no es solo el de mayor AUC: cuenta el tiempo y la explicabilidad.

S07 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

RETO

Reto del sprint — 30 min

Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5)

sprints/S07/Reto_S07/Reto_Sprint_07.md