IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 7 DE 17

# README Sprint S07 · ML supervisado: regresión y clasificación

*¿podemos predecir el precio o la cancelación?*

**FECHAS**
6 y 9 de noviembre

**HORAS**
12 h (4 h teoría · 5 h práctica guiada · 3 h PBL)

**ESTE README EN PDF**
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

## Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

## Requisitos previos

- Sprint 6: pipelines (`ColumnTransformer` + `Pipeline`), baseline, validación cruzada y fuga de datos.
- Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`). Los notebooks lo descargan solos si no lo encuentran.

## Materiales del sprint

**Documentos del curso** (PDF y .md; las actividades van en la tabla siguiente)

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Guía del sprint (PDF) · ecofriendly | Resumen del sprint: qué aprenderás, temario, material, reto y conclusión | 2 páginas | Antes de empezar |
| Reto completo, paso a paso (.md) · PDF · ecofriendly | Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes | — | Antes del planning y durante el reto |
| Resumen del sprint en una página | Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso | — | Antes del planning |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Esquema del contenido y su relación con el reto | Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después | — | Antes del planning y como guía durante el reto |
| Infografías del reto | 5 láminas ilustradas del reto | — | Reto |
| Atlas de algoritmos | Atlas de algoritmos del sprint: regresión lineal, Ridge/Lasso, logística, k-NN y Naive Bayes | — | Teoría y práctica; consulta cuando elijas modelo |
| Cómo se trabaja un reto | El método de trabajo de todos los retos | — | Antes del primer reto |
| `S07.1_Regresion_lineal_polinomica_y_regularizacion.pdf` | Regresión lineal, polinómica y regularización (Ridge y Lasso) | 25 min | Teoría · viernes 6/11 |
| `S07.2_Regresion_logistica_y_clasificacion.pdf` | Regresión logística y clasificación | 15 min | Teoría · viernes 6/11 |
| Explicación sencilla: matriz de confusión (VN, FP, FN, VP) · `.html` | Las cuatro casillas, cómo leer las siglas, por qué los errores no cuestan igual y mini-test | 10 min | Antes del ejercicio interactivo |
| Lámina: la matriz de confusión | Una página con las cuatro casillas, las métricas y el efecto del umbral (para tener a mano) | — | Consulta (junto al ejercicio) |
| Ejercicio interactivo: matriz de confusión · `.html` | Construye la matriz a mano, calcula métricas, mueve el umbral y elige con el coste (datos ficticios) | 25–30 min | Antes del cuaderno S07_03 (refuerzo) |
| `S07.3_k_NN_y_Naive_Bayes.pdf` | k-NN y Naive Bayes | 10 min | Teoría · lunes 9/11 |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Test de conocimientos | Test de M3 · parte 1 · 10 preguntas · individual, en el navegador, sin penalización por fallo.1 a 3.4 (preprocesado, métricas, regresión y clasificación). | 20 min | Solo se abre el lun 9/11 (hora de Canarias) |

**Material de las actividades**

| Notebook | Tema | Tiempo | Colab |
|---|---|---|---|
| `S07_01_regresion_lineal_polinomica` | Regresión lineal, coeficientes, residuos, interacciones y polinomios | 40 min | Abrir en Colab |
| `S07_02_ridge_lasso` | Regularización: Ridge, Lasso y elección de `alpha` | 35 min | Abrir en Colab |
| `S07_03_regresion_logistica` | Regresión logística, *odds ratios*, umbral, matriz de confusión y coste | 55 min | Abrir en Colab |
| `S07_04_roc_pr_desbalance` | ROC, precisión–recall y clases desbalanceadas | 40 min | Abrir en Colab |
| `S07_05_knn_naive_bayes` | k-NN y Naive Bayes; comparativa de modelos | 25 min | Abrir en Colab |

Los ejercicios se autocorrigen con `assert`. Los datos (`reservas_turisdata.csv`) se descargan solos.

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

**Viernes 6/11**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 1 | Ceremonia | Planning del reto «Precio y cancelación» y reparto de roles | 10 min |
| 2 | Teoría | Regresión lineal, polinómica y regularización (Ridge y Lasso) | 25 min |
| 3 | Práctica | Regresión lineal y polinómica | 40 min |
| 4 | Práctica | Ridge y Lasso | 35 min |
| 5 | Teoría | Regresión logística y clasificación | 15 min |
| 6 | Práctica | Regresión logística | 55 min |
| 7 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 20 min |

**Lunes 9/11**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 8 | Reto | Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2) | 30 min |
| 9 | Práctica | ROC, PR y datos desbalanceados | 40 min |
| 10 | Teoría | k-NN y Naive Bayes | 10 min |
| 11 | Práctica | k-NN y Naive Bayes | 25 min |
| 12 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 10 min |
| 13 | Reto | Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5) | 40 min |
| 14 | Test | **Test de M3 (parte 1)**, solo se abre hoy | 25 min |
| 15 | Ceremonia | Entrega en `sprint-07/`, autoevaluación y coevaluación, review y retrospectiva | 20 min |

## RETO Reto · «Precio y cancelación»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

**Ver el reto completo, explicado paso a paso** (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData Canarias quiere una tarifa de referencia por noche y un aviso de riesgo de cancelación para decidir el *overbooking*. El gerente no quiere oír hablar de «AUC»: quiere saber cuánto dinero se juega si el modelo falla.

**Entregáis** (carpeta `sprint-07/` del repositorio del equipo):

- `informe_modelado.md` (2–3 páginas) con comparativa de métricas y recomendación de negocio en euros. Plantilla: `informe_modelado_plantilla.md`.
- `reto_S07.ipynb`: regresión para `precio_noche` y clasificación para `cancelada`, cada una con *baseline*.
- Hipótesis de coste de cada error, umbral elegido y análisis de sensibilidad.
- `README.md` para reproducirlo (semilla, versiones).

**Reglas:**

- Unas 3 h en equipo; máx. 3 modelos por problema (*baseline* incluido); `SEMILLA = 42`.
- Solo variables conocidas al reservar (sin fuga). El umbral se elige con validación cruzada y el test se usa una sola vez.
- Nunca claves ni datos personales.

**Se valora:** corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿se penaliza a algún país o canal?), más costes razonados y sensibilidad.

## Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el lun 9/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Regresión (MAE, RMSE, $R^2$) y clasificación (matriz de confusión, AUC/AP) con *baseline*
- [ ] Costes de error explicitados, umbral justificado y recomendación con cifras
- [ ] Sin fuga de datos; test usado una sola vez

- [ ] Entregable subido a la carpeta `sprint-07/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas