Sprint 7 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
5–9 de noviembre

HORAS
12 h (4 h teoría · 5 h práctica guiada · 3 h PBL)

Reto de este sprint: «Precio y cancelación». Ver el reto completo, explicado paso a paso · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

Material del sprint

- **Guía del sprint (PDF):** `Guia_Sprint_07.pdf` · versión ecofriendly para imprimir
- **Reto completo, paso a paso:** `Reto_Sprint_07.md`
- **S07.1 · Regresion lineal polinomica y regularizacion:** `S07.1_Regresion_lineal_polinomica_y_regularizacion.pdf`
- **S07.2 · Regresion logistica y clasificacion:** `S07.2_Regresion_logistica_y_clasificacion.pdf`
- **S07.3 · k NN y Naive Bayes:** `S07.3_k_NN_y_Naive_Bayes.pdf`

Contenidos: M3 UD 3.3 (regresión lineal, polinómica, Ridge y Lasso), UD 3.4 (regresión logística y clasificación) y UD 3.5 (k-NN y Naive Bayes).

En esta carpeta: `guia/` PDF de la guía (normal y para imprimir) y el reto explicado paso a paso · `presentaciones/` diapositivas de cada sesión · `notebooks/` prácticas para abrir en Colab · `plantillas/` plantillas para el reto · `tests/` test de conocimientos

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Teoría = diapositivas · Práctica = cuaderno de Colab o actividad · Reto = trabajo en equipo · Ceremonia = momento de Scrum

Sesión 1

1. **Ceremonia**: Planning del reto y reparto de roles · *30 min*
2. **Teoría**: Regresión lineal, polinómica y regularización (Ridge y Lasso) · *2 h*
3. **Práctica**: Regresión lineal y polinómica · *60 min*
4. **Práctica**: Ridge y Lasso · *50 min*

Sesión 2

5. **Teoría**: Regresión logística y clasificación · *1 h*
6. **Práctica**: Regresión logística · *70 min*
7. **Práctica**: ROC, PR y datos desbalanceados · *60 min*
8. **Reto**: Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2) · *1 h*

Sesión 3 (última)

9. **Teoría**: k-NN y Naive Bayes · *1 h*
10. **Práctica**: k-NN y Naive Bayes · *55 min*
11. **Reto**: Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5) · *2 h*
12. **Ceremonia**: Review y retrospectiva · *última hora*

Qué aprenderás

- Ajustar regresiones lineales y polinómicas e **interpretar los coeficientes** en euros.
- Usar **Ridge y Lasso** contra el sobreajuste y entrenar una regresión logística (umbral, matriz de confusión).
- Evaluar con **ROC y precisión–recall** y comparar con k-NN y Naive Bayes.
- Hace falta lo del Sprint 6: *pipelines*, *baseline* y validación cruzada.

Prácticas

Notebook	Tema	Tiempo
`S07_01_regresion_lineal_polinomica`	Regresión lineal, coeficientes, residuos, interacciones y polinomios	60 min
`S07_02_ridge_lasso`	Regularización: Ridge, Lasso y elección de `alpha`	50 min

Notebook	Tema	Tiempo
`S07_03_regresion_logistica`	Regresión logística, *odds ratios*, umbral, matriz de confusión y coste	70 min
`S07_04_roc_pr_desbalance`	ROC, precisión–recall y clases desbalanceadas	60 min
`S07_05_knn_naive_bayes`	k-NN y Naive Bayes; comparativa de modelos	55 min

Los ejercicios se autocorrigen con `assert`. Los datos (`reservas_turisdata.csv`) se descargan solos.

RETO Reto · «Precio y cancelación»

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias quiere una tarifa de referencia por noche y un aviso de riesgo de cancelación para decidir el *overbooking*. El gerente no quiere oír hablar de «AUC»: quiere saber cuánto dinero se juega si el modelo falla.

Entregáis (carpeta `sprint-07/` del repositorio del equipo):

- `informe_modelado.md` (2–3 páginas) con comparativa de métricas y recomendación de negocio en euros. Plantilla: `informe_modelado_plantilla.md`.
- `reto_S07.ipynb`: regresión para `precio_noche` y clasificación para `cancelada`, cada una con *baseline*.
- Hipótesis de coste de cada error, umbral elegido y análisis de sensibilidad.
- `README.md` para reproducirlo (semilla, versiones).

Reglas:

- 3 h en equipo; máx. 3 modelos por problema (*baseline* incluido); `SEMILLA = 42`.
- Solo variables conocidas al reservar (sin fuga). El umbral se elige con validación cruzada y el test se usa una sola vez.
- Nunca claves ni datos personales.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿se penaliza a algún país o canal?), más costes razonados y sensibilidad.

Test de conocimientos · lun 9/11

Test de M3 · parte 1 · 10 preguntas · unos 20 min · individual, en el navegador, sin penalización por fallo. Cubre M3, UD 3.1 a 3.4 (preprocesado, métricas, regresión y clasificación).

Abrir el test (`https://ccoolboox.github.io/IFCD107-alumnado/sprints/S07/tests/test_M3_parte1.html`)

Solo se abre el día lun 9/11 (hora de Canarias). Al terminar, copia tu resultado y envíaselo al docente. Cuenta para el 30 % de «tests de conocimientos».

Definition of Done · antes de cerrar el sprint

- ☐ Test de conocimientos hecho el lun 9/11
- ☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
- ☐ Regresión (MAE, RMSE, R^2) y clasificación (matriz de confusión, AUC/AP) con *baseline*
- ☐ Costes de error explicitados, umbral justificado y recomendación con cifras
- ☐ Sin fuga de datos; test usado una sola vez
- ☐ Entregable subido a la carpeta `sprint-07/` del repositorio del equipo
- ☐ Autoevaluación y coevaluación rellenadas