README Sprint S07 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
6 y 9 de noviembre

HORAS
12 h (4 h teoría · 5 h práctica guiada · 3 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

Requisitos previos

- Sprint 6: pipelines (`ColumnTransformer` + `Pipeline`), baseline, validación cruzada y fuga de datos.
- Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`). Los notebooks lo descargan solos si no lo encuentran.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta del cliente, los pasos, lo que se entrega y lo que se aprende	—	Antes del planning
Esquema del contenido y su relación con el reto	Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después	—	Antes del planning y como guía durante el reto
Infografías del reto	6 láminas ilustradas del reto	—	Reto
Atlas de algoritmos	Atlas de algoritmos del sprint: regresión lineal, Ridge/Lasso, logística, k-NN y Naive Bayes	—	Teoría y práctica; consulta cuando elijas modelo

Material	Tema	Tiempo	Cuándo
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S07.1_Regresion_lineal_polinomica_y_regularizacion.pdf`	Regresión lineal, polinómica y regularización (Ridge y Lasso)	25 min	Teoría · viernes 6/11
`S07.2_Regresion_logistica_y_clasificacion.pdf`	Regresión logística y clasificación	15 min	Teoría · viernes 6/11
Explicación sencilla: matriz de confusión (VN, FP, FN, VP) · `.html`	Las cuatro casillas, cómo leer las siglas, por qué los errores no cuestan igual y mini-test	10 min	Antes del ejercicio interactivo
Lámina: la matriz de confusión	Una página con las cuatro casillas, las métricas y el efecto del umbral (para tener a mano)	—	Consulta (junto al ejercicio)
Ejercicio interactivo: matriz de confusión · `.html`	Construye la matriz a mano, calcula métricas, mueve el umbral y elige con el coste (datos ficticios)	25–30 min	Antes del cuaderno S07_03 (refuerzo)
`S07.3_k_NN_y_Naive_Bayes.pdf`	k-NN y Naive Bayes	10 min	Teoría · lunes 9/11
Test de conocimientos	Test de M3 · parte 1 · 10 preguntas · individual, en el navegador, sin penalización por fallo.1 a 3.4 (preprocesado, métricas, regresión y clasificación).	20 min	Solo se abre el lun 9/11 (hora de Canarias)

Material de las actividades

Notebook	Tema	Tiempo
`S07_01_regresion_lineal_polinomica`	Regresión lineal, coeficientes, residuos, interacciones y polinomios	40 min
`S07_02_ridge_lasso`	Regularización: Ridge, Lasso y elección de `alpha`	35 min
`S07_03_regresion_logistica`	Regresión logística, *odds ratios*, umbral, matriz de confusión y coste	55 min
`S07_04_roc_pr_desbalance`	ROC, precisión–recall y clases desbalanceadas	40 min
`S07_05_knn_naive_bayes`	k-NN y Naive Bayes; comparativa de modelos	25 min

Los ejercicios se autocorrigen con `assert`. Los datos (`reservas_turisdata.csv`) se descargan solos.

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Viernes 6/11

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Precio y cancelación» y reparto de roles	10 min
2	Teoría	Regresión lineal, polinómica y regularización (Ridge y Lasso)	25 min
3	Práctica	Regresión lineal y polinómica	40 min
4	Práctica	Ridge y Lasso	35 min
5	Teoría	Regresión logística y clasificación	15 min
6	Práctica	Regresión logística	55 min
7	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	20 min

Lunes 9/11

Nº	Tipo	Qué se hace	Tiempo
8	Reto	Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2)	30 min
9	Práctica	ROC, PR y datos desbalanceados	40 min
10	Teoría	k-NN y Naive Bayes	10 min
11	Práctica	k-NN y Naive Bayes	25 min
12	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	10 min
13	Reto	Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5)	40 min
14	Test	**Test de M3 (parte 1)**, solo se abre hoy	25 min
15	Ceremonia	Entrega en `sprint-07/`, autoevaluación y coevaluación, review y retrospectiva	20 min

RETO Reto · «Precio y cancelación»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias quiere una tarifa de referencia por noche y un aviso de riesgo de cancelación para decidir el *overbooking*. El gerente no quiere oír hablar de «AUC»: quiere saber cuánto dinero se juega si el modelo falla.

Entregáis (carpeta `sprint-07/` del repositorio del equipo):

- `informe_modelado.md` (2–3 páginas) con comparativa de métricas y recomendación de negocio en euros. Plantilla: `informe_modelado_plantilla.md`.
- `reto_S07.ipynb`: regresión para `precio_noche` y clasificación para `cancelada`, cada una con *baseline*.
- Hipótesis de coste de cada error, umbral elegido y análisis de sensibilidad.
- `README.md` para reproducirlo (semilla, versiones).

Reglas:

- Unas 3 h en equipo; máx. 3 modelos por problema (*baseline* incluido); `SEMILLA = 42`.
- Solo variables conocidas al reservar (sin fuga). El umbral se elige con validación cruzada y el test se usa una sola vez.
- Nunca claves ni datos personales.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿se penaliza a algún país o canal?), más costes razonados y sensibilidad.

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el lun 9/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Regresión (MAE, RMSE, R^2) y clasificación (matriz de confusión, AUC/AP) con *baseline*
- [ ] Costes de error explicitados, umbral justificado y recomendación con cifras
- [ ] Sin fuga de datos; test usado una sola vez
- [ ] Entregable subido a la carpeta `sprint-07/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas