README Sprint S07 · ML supervisado: regresión y clasificación

¿podemos predecir el precio o la cancelación?

FECHAS
10–11 de noviembre

HORAS
9 h (2 h teoría · 4 h práctica · 3 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. Ajustar una regresión lineal y polinómica e **interpretar los coeficientes** en euros.
2. Usar **Ridge y Lasso** para controlar el sobreajuste y seleccionar variables.
3. Entrenar una regresión logística, leer *odds ratios*, la **matriz de confusión** y elegir un **umbral**.
4. Evaluar con **ROC, precisión–recall** y tratar clases desbalanceadas.
5. Comparar k-NN y Naive Bayes con la logística y **traducir las métricas a euros** para el cliente.

Requisitos previos

- Sprint 6: pipelines (`ColumnTransformer` + `Pipeline`), baseline, validación cruzada y fuga de datos.
- Datos: `datos/reservas_turisdata.csv` (6000 reservas; objetivos `precio_noche` y `cancelada`). Los notebooks lo descargan solos si no lo encuentran.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Carpeta del reto: `Reto_S07/`	Todo el material del reto junto: ficha (.md y PDF), plantillas y material de apoyo, hoja de autoevaluación y coevaluación y láminas del reto	—	Antes del planning y durante el reto
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso	—	Antes del planning

Material	Tema	Tiempo	Cuándo
El reto paso a paso · PDF con enlaces	Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA	—	Durante el reto
Esquema del contenido y su relación con el reto	Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después	—	Antes del planning y como guía durante el reto
Infografías del sprint	4 láminas ilustradas	—	Antes del planning y durante el reto
Atlas de algoritmos	Atlas de algoritmos del sprint: regresión lineal, Ridge/Lasso, logística, k-NN y Naive Bayes	—	Teoría y práctica; consulta cuando elijas modelo
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S07.1_Regresion_lineal_polinomica_y_regularizacion.pdf`	Regresión lineal, polinómica y regularización (Ridge y Lasso)	25 min	Teoría · día 1 del S07
`S07.2_Regresion_logistica_y_clasificacion.pdf`	Regresión logística y clasificación	15 min	Teoría · día 1 del S07
Explicación sencilla: matriz de confusión (VN, FP, FN, VP) · `.html`	Las cuatro casillas, cómo leer las siglas, por qué los errores no cuestan igual y mini-test	10 min	Antes del ejercicio interactivo
Lámina: la matriz de confusión	Una página con las cuatro casillas, las métricas y el efecto del umbral (para tener a mano)	—	Consulta (junto al ejercicio)
Ejercicio interactivo: matriz de confusión · `.html`	Construye la matriz a mano, calcula métricas, mueve el umbral y elige con el coste (datos ficticios)	25–30 min	Antes del cuaderno S07_03 (refuerzo)
`S07.3_k_NN_y_Naive_Bayes.pdf`	k-NN y Naive Bayes	10 min	Teoría · día 2 del S07

Material	Tema	Tiempo	Cuándo
Test de conocimientos	Test de M3 · parte 1 · 10 preguntas · individual, en el navegador, sin penalización por fallo.1 a 3.4 (preprocesado, métricas, regresión y clasificación).	20 min	Solo se abre el lun 9/11 (hora de Canarias)

Material de las actividades

Notebook	Tema	Tiempo
`apuntes_regresion_y_clasificacion.md` · PDF · ecofriendly	**Apuntes que complementan las diapositivas**: regresión lineal y polinómica, Ridge y Lasso, regresión logística, umbral por coste, ROC y PR, k-NN y Naive Bayes explicados con ejemplos que puedes comprobar a mano	—
`S07_01_regresion_lineal_polinomica`	Regresión lineal, coeficientes, residuos, interacciones y polinomios	40 min
`S07_02_ridge_lasso`	Regularización: Ridge, Lasso y elección de `alpha`	35 min
`S07_03_regresion_logistica`	Regresión logística, *odds ratios*, umbral, matriz de confusión y coste	55 min
`S07_04_roc_pr_desbalance`	ROC, precisión–recall y clases desbalanceadas	40 min
`S07_05_knn_naive_bayes`	k-NN y Naive Bayes; comparativa de modelos	25 min

Los ejercicios se autocorrigen con `assert`. Los datos (`reservas_turisdata.csv`) se descargan solos.

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Día 1 del S07

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Precio y cancelación» y reparto de roles	10 min
2	Teoría	Regresión lineal, polinómica y regularización (Ridge y Lasso)	25 min
3	Práctica	Regresión lineal y polinómica (los ejercicios marcados «en clase»)	40 min
4	Práctica	Ridge y Lasso (los ejercicios marcados «en clase»)	35 min
5	Teoría	Regresión logística y clasificación	20 min
6	Práctica	Regresión logística (los ejercicios marcados «en clase»)	45 min
7	Reto	Acordar las hipótesis de coste y hacer la regresión del precio (pasos 1–2)	25 min

Día 2 del S07

Nº	Tipo	Qué se hace	Tiempo
8	Práctica	ROC, PR y datos desbalanceados (los ejercicios marcados «en clase»)	25 min
9	Teoría	k-NN y Naive Bayes	10 min
10	Reto	Clasificación de la cancelación, análisis de sensibilidad, informe y README (pasos 3–5)	30 min

Nº	Tipo	Qué se hace	Tiempo
11	Test	**Test de M3 (parte 1)**, solo se abre hoy	25 min
12	Ceremonia	Entrega en `sprint-07/` y autoevaluación y coevaluación del Sprint 7 (la review y la retro se hacen junto con las del Sprint 8)	15 min

RETO Reto · «Precio y cancelación»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias quiere una tarifa de referencia por noche y un aviso de riesgo de cancelación para decidir el *overbooking*. El gerente no quiere oír hablar de «AUC»: quiere saber cuánto dinero se juega si el modelo falla.

Entregáis (carpeta `sprint-07/` del repositorio del equipo):

- `informe_modelado.md` (2–3 páginas) con comparativa de métricas y recomendación de negocio en euros. Plantilla: `informe_modelado_plantilla.md`.
- `reto_S07.ipynb`: regresión para `precio_noche` y clasificación para `cancelada`, cada una con *baseline*.
- Hipótesis de coste de cada error, umbral elegido y análisis de sensibilidad.
- `README.md` para reproducirlo (semilla, versiones).

Reglas:

- Unas 1 h 40 min en equipo (planning, reto y entrega); máx. 3 modelos por problema (*baseline* incluido); `SEMILLA = 42`.
- Solo variables conocidas al reservar (sin fuga). El umbral se elige con validación cruzada y el test se usa una sola vez.
- Nunca claves ni datos personales.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (¿se penaliza a algún país o canal?), más costes razonados y sensibilidad.

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 11/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Regresión (MAE, RMSE, R^2) y clasificación (matriz de confusión, AUC/AP) con *baseline*
- [ ] Costes de error explicitados, umbral justificado y recomendación con cifras
- [ ] Sin fuga de datos; test usado una sola vez
- [ ] Entregable subido a la carpeta `sprint-07/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas