IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Árboles, bosques y SVM un recorrido

Modelos que aprenden preguntas · cómo juntar muchos · cómo ajustar sus botones

Sprint 8 · recorrido global de los cuadernos S08_01 a S08_05

DÓNDE ESTAMOS

Mismo problema, mismo marcador, modelos nuevos

Lo que no cambia

El problema: **¿cancelará esta reserva?** (sí o no).

El marcador: el **AUC** (0,5 = azar, 1 = perfecto).

La regla de oro: el **test se mira una sola vez**.

Lo que cambia

Antes (S07): modelos que **suman** efectos o miran **vecinos**.

Ahora (S08): modelos que **aprenden preguntas** y se **combinan**.

Y una forma nueva de separar: la **calle más ancha**.

Seguimos en aprendizaje supervisado: ejemplos con la respuesta conocida. Solo cambia el tipo de modelo.

Todo lo de hoy vale para regresión y clasificación; en las diapositivas usamos la clasificación (cancela / no cancela).

LOS MODELOS DE HOY

Cuatro ideas, cuatro familias

Modelo	La idea en una frase	Cuaderno
Árbol de decisión	Una cadena de **preguntas de sí o no**	S08_01
Random Forest	Muchos árboles distintos **votan**	S08_02
Boosting (XGBoost, LightGBM)	Árboles **en serie**: cada uno corrige al anterior	S08_03
SVM	La **calle más ancha** entre dos grupos	S08_04

Y una pregunta común a todos: ¿cómo ajusto sus botones sin hacer trampa? Búsqueda de hiperparámetros: S08_05.

Recorrido: 1 · Árbol → 2 · Bosque → 3 · Boosting → 4 · SVM → 5 · Ajustar los botones.

1 · EL ÁRBOL DE DECISIÓN

Un árbol es una cadena de preguntas de sí o no



Rojo = canceló · gris = se quedó. Las cajas del final son las **hojas**: ahí el árbol decide.

Se lee de arriba abajo, respuesta a respuesta, hasta una hoja. Son reglas: un gerente las entiende sin ser matemático.

1 · EL ÁRBOL DE DECISIÓN

¿Qué pregunta hacer primero? La que menos mezcla

Sin preguntar nada



Mezcla (Gini)

0,50

Tras «¿antelación ≤ 115?» (los que sí)



Mezcla (Gini)

0,28

Tras «¿antelación ≤ 115?» (los que no)



Mezcla (Gini)

0

0 = todas iguales (grupo puro) · **0,5** = mitad y mitad. La mejor pregunta es la que deja los grupos **menos mezclados**.

Cómo se lee

El árbol prueba **todas las preguntas posibles** con todas las variables.

Se queda con la que deja los grupos **más puros** (menos mezclados).

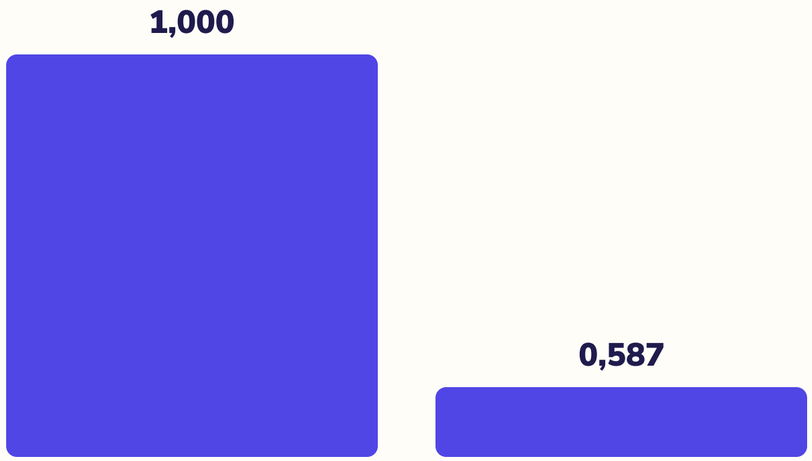
El número

Gini 0 = todas las reservas del grupo son iguales.

Gini 0,5 = mitad y mitad: no sabemos nada.

1 · EL ÁRBOL DE DECISIÓN

Un árbol sin límites se aprende los datos de memoria



Cómo se lee

Barras medidas desde 0,5 (el azar).

En entrenamiento **no falla ni una vez**: 1,000.

En prueba casi **no supera al azar**: 0,587.

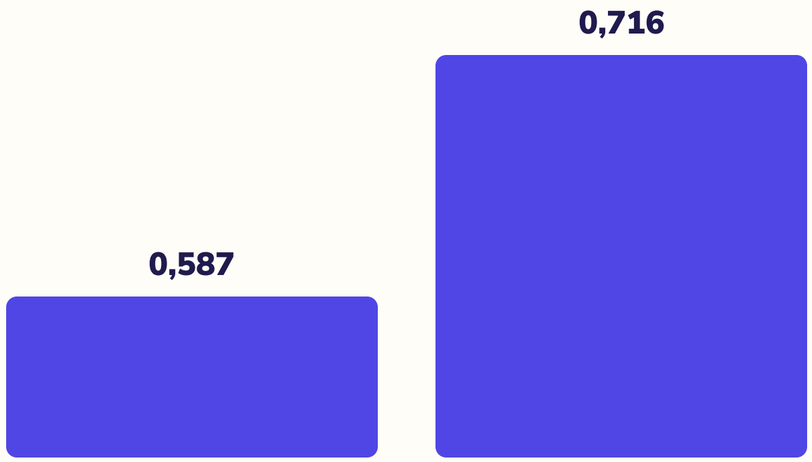
Por qué

Tiene **1 206 hojas** para 4 800 reservas: casi **una hoja por reserva**.

Es el mismo problema de S07: **memoriza**.

Un árbol puede hacer preguntas hasta separar cada reserva. Eso no es aprender: es memorizar.

Podar: ponerle un límite al árbol



Cómo se poda

Se exige un **mínimo de reservas por hoja**: no se pregunta más si el grupo es pequeño.

Se elige el mínimo con **validación cruzada**, nunca con el test.

En tu cuaderno

Mejor valor: **80 reservas por hoja**.

De **1 206 a 46 hojas** y AUC en prueba **de 0,587 a 0,716**.

Barras: **AUC en prueba**, medido desde 0,5. Un árbol más pequeño es **mejor y más fácil de leer**.

1 · EL ÁRBOL DE DECISIÓN

Qué mira el árbol, y su punto débil

Qué variables usa

Las tres que más pesan: **antelación**, **sin depósito** y **canal directo**.

Entre las tres suman el **70 %** de la importancia.

Se reconoce el mismo patrón de S07: reservar con mucha antelación y sin depósito eleva el riesgo.

Su punto débil

Inestable: con unos pocos datos distintos puede salir **otro árbol**.

Un solo árbol es fácil de leer… pero poco fiable.

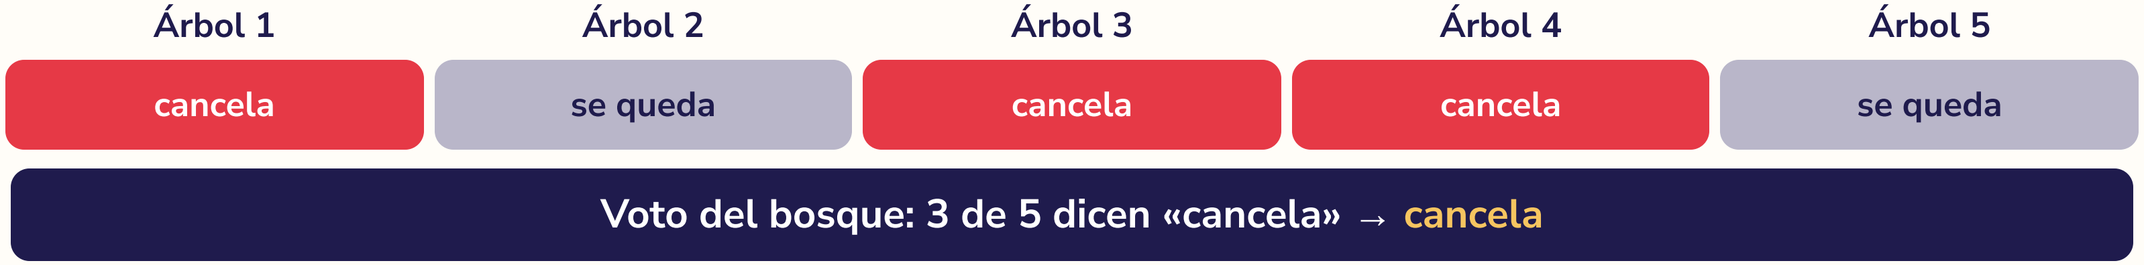
¿Y si en vez de fiarnos de un árbol juntamos muchos? Es la idea de los bosques.

Un árbol **no necesita escalar** las variables: solo compara «mayor o menor que».

2 · RANDOM FOREST

Un árbol opina; un bosque vota

Una **misma reserva** nueva, vista por 5 árboles distintos:



En el cuaderno el bosque tiene **300 árboles**; el voto es el mismo, solo que con más voces.

Cómo se lee

Cada árbol da **su propia respuesta** para la misma reserva.

El bosque cuenta los votos: **gana la mayoría**.

Por qué funciona

Los árboles **se equivocan en cosas distintas**, y los errores se **compensan**.

Es la «sabiduría de la multitud».

¿Cómo conseguir árboles distintos?

Datos originales: 10 reservas numeradas del 1 al 10. Cada árbol **saca 10 con repetición**:

Árbol 1	1	1	3	4	4	6	8	8	8	10	no salen:	2	5	7	9
Árbol 2	2	3	3	5	6	7	7	9	10	10	no salen:	1	4	8	
Árbol 3	1	2	2	4	5	5	6	9	9	9	no salen:	3	7	8	10

Algunas reservas se repiten y otras no salen. **Las que no salen** (amarillo) son un **examen gratis**: el árbol no las ha visto.

1 · Muestras distintas

Cada árbol se entrena con una **muestra con repetición** de los datos (*bagging*).

Las reservas que **no salen** sirven de examen: es el **OOB**.

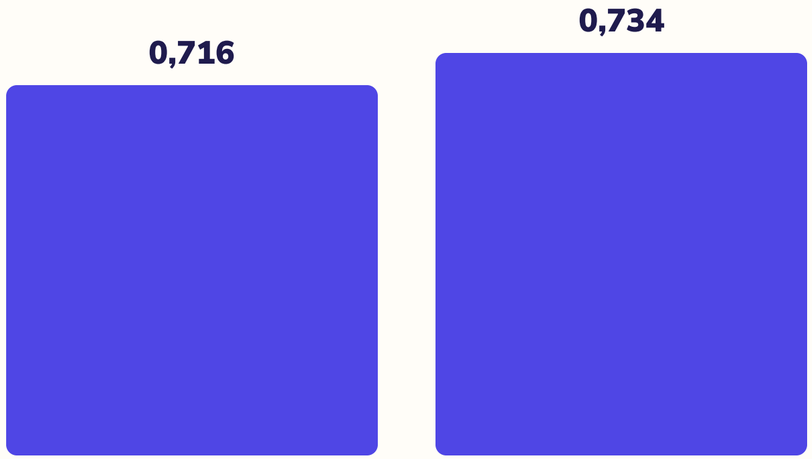
2 · Columnas distintas

En **cada pregunta**, el árbol solo puede mirar **algunas columnas** al azar.

Así no copian todos la misma variable estrella.

2 · RANDOM FOREST

¿Compensa un bosque? Más árboles ayudan… hasta que se estabiliza



Cuánto mejora

El bosque de 300 árboles saca **0,734** de AUC frente a **0,716** del árbol podado.

Es más fiable, aunque ya **no se lee** como reglas.

¿Cuántos árboles?

De **5 a 400** árboles: **+0,103** de AUC.

De **100 a 400**: solo **+0,005**: rendimientos decrecientes.

Barras: **AUC en prueba**, medido desde 0,5. Pasado cierto punto, más árboles solo cuestan **más tiempo**.

2 · RANDOM FOREST

¿Qué mira un bosque? Barajar una columna y ver cuánto empeora

1 · Mide

Se mide el **AUC** del modelo ya entrenado.

2 · Baraja

Se **desordena al azar una columna**: su relación con la cancelación desaparece.

3 · Compara

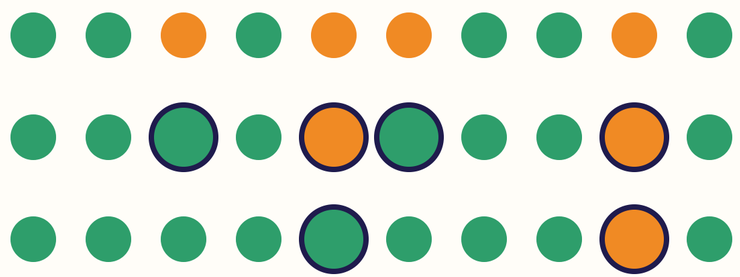
Se vuelve a medir el AUC. **Cuanto más cae, más importante era** esa columna.

En tu cuaderno: antelación, depósito, canal y tarifa son las que importan; 6 variables casi no aportan nada.

Es la **importancia por permutación**: sirve con **cualquier modelo**, no solo con bosques.

3 · BOOSTING

Cada árbol repasa los fallos del anterior



Todas pesan igual
4 fallos

Los fallos de antes **pesan más** (grandes)
2 fallos

Los fallos de antes **pesan más** (grandes)
1 fallo

Ejemplo ilustrativo con 10 reservas. Verde = acierta · naranja = falla. Cada árbol nuevo **se centra en lo que los anteriores hicieron mal**.

Cómo se lee

El primer árbol es sencillo y **falla** en algunas reservas.

El siguiente se centra en **esos fallos** (pesan más) y así en cadena.

El resultado

El modelo final **suma** todos los árboles pequeños.

XGBoost y LightGBM son dos **implementaciones** muy usadas de esta idea.

Dos formas de juntar árboles

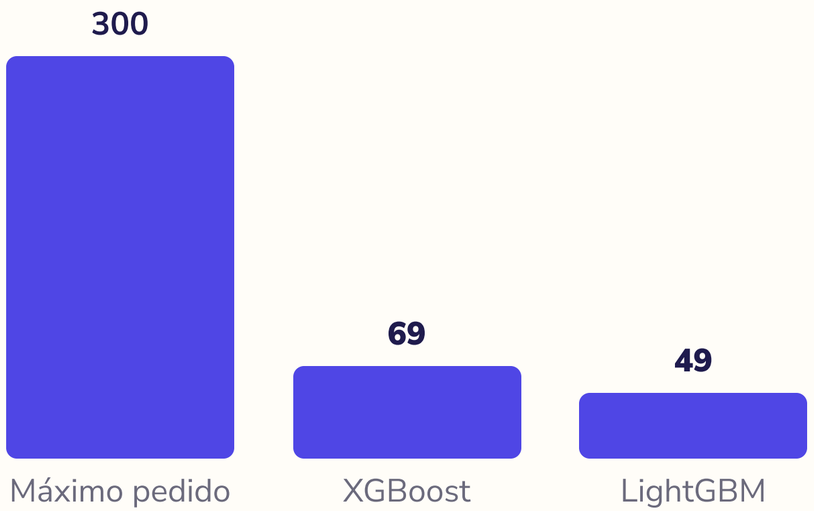
	Bosque (bagging)	Boosting
Cómo se juntan	En **paralelo**, a la vez	En **serie**, uno tras otro
Qué hace cada árbol	Es **independiente** y complejo	Es **pequeño** y corrige al anterior
Decisión final	**Votan**	Se **suman**
Riesgo	Poco: es muy estable	**Memorizar** si se añaden demasiados

El bosque reduce errores promediando; el boosting los va corrigiendo uno a uno.

Por eso el boosting **necesita un límite**: la siguiente diapositiva.

3 · BOOSTING

Parada temprana: que pare cuando deja de mejorar



El problema

Con más árboles el AUC en entrenamiento **sube sin parar**… y el de validación **baja**.

En el cuaderno, seguir hasta **300** árboles pierde **0,039** de AUC respecto al mejor punto (12 árboles).

La solución

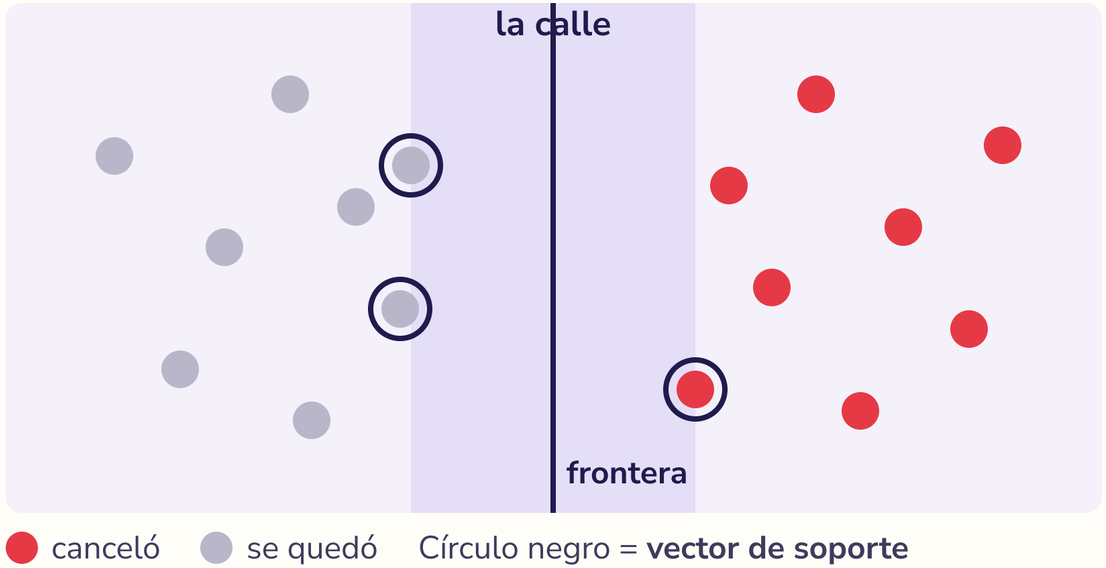
Parada temprana: se pide un máximo alto y el modelo **para solo** cuando la validación deja de mejorar.

Ambos acaban en **AUC 0,745** en prueba.

Barras: **número de árboles** con el que para cada modelo. Da igual cuál uses: **la implementación importa menos que los datos**.

4 · SVM

La calle más ancha entre dos grupos



Cómo se lee

La SVM busca la **frontera** que deja **la calle más ancha** entre los dos grupos.

Cuanto más ancha, **más margen** ante reservas nuevas.

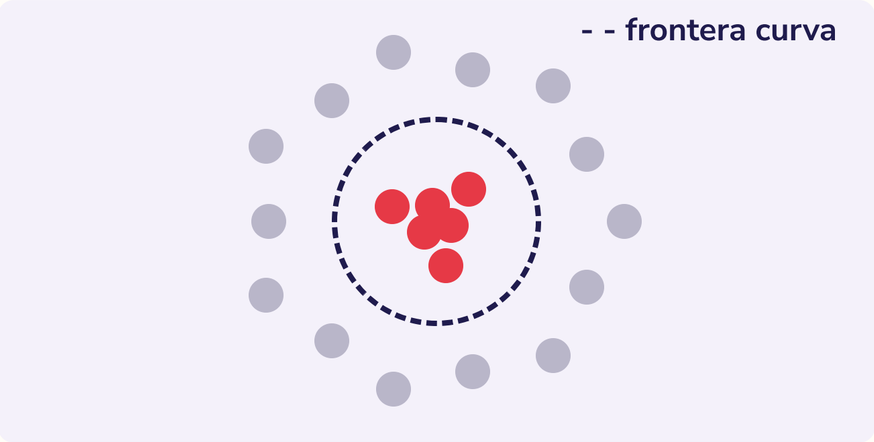
Vectores de soporte

Solo mandan las reservas que **tocan los bordes** de la calle (círculos negros).

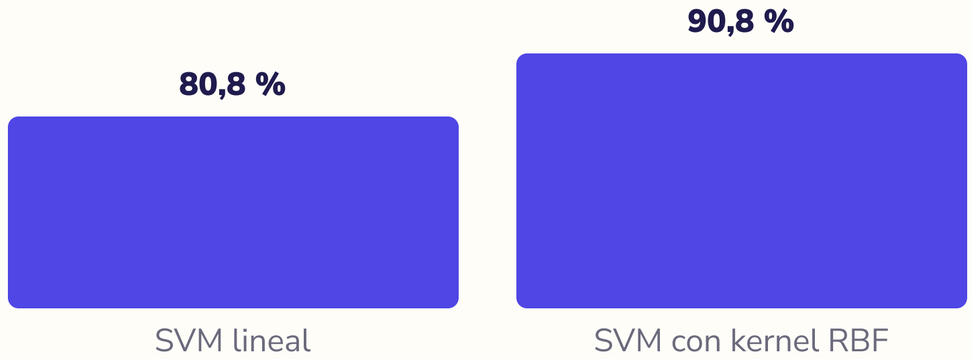
Si quitas las demás, **la frontera no cambia**.

Es otra manera de separar: no pregunta ni suma, **busca el mayor margen**.

Cuando una recta no basta: el kernel



Ninguna **recta** separa el rojo del gris. El **kernel** permite una frontera curva.



Cómo se lee

Con grupos «uno dentro de otro», una recta no sirve.

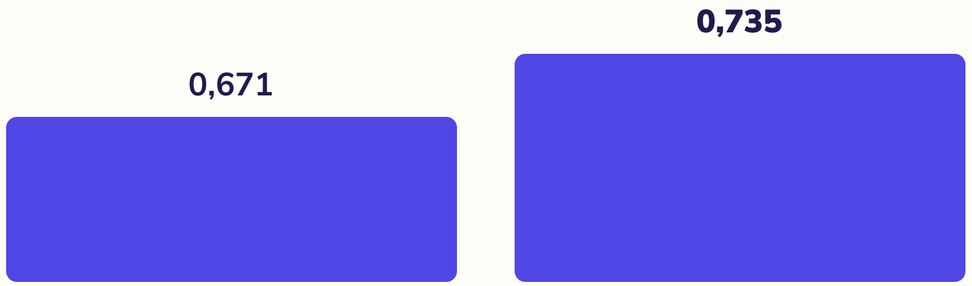
El **kernel** curva la frontera: **90,8 %** frente a **80,8 %**, con **91** vectores de soporte.

Barras: **exactitud** en datos curvos (altura desde 0,5). **C** = cuánto cuesta equivocarse · **gamma** = hasta dónde llega cada punto.

4 · SVM

Dos cuidados: escalar y vigilar el tiempo

AUC según escalado (barras desde 0,5)



Tiempo al cuadruplicar las filas



Escalar es obligatorio

La SVM **mide distancias**: sin escalar, las variables con números grandes mandan.

AUC **0,735** escalando frente a **0,671** sin escalar.

Con muchas filas, se hace lenta

4 veces más filas → **16,9 veces más tiempo** (de 0,05 s a 0,84 s).

Buena con **pocos o medianos datos**; con muchos, el boosting suele ser mejor.

5 · AJUSTAR LOS BOTONES

Parámetros frente a hiperparámetros

Parámetros: los aprende el modelo

Salen **de los datos** al entrenar.

Ejemplos: las **preguntas** de un árbol, los **pesos** de la logística.

Hiperparámetros: los pones tú

Se fijan **antes** de entrenar: son los **botones** del modelo.

Ejemplos: **mínimo de reservas por hoja**, **nº de árboles**, **C**, **gamma**.

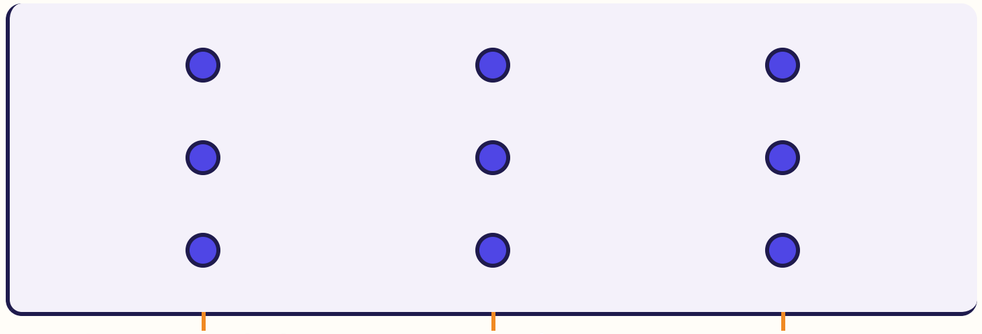
Como una receta: los ingredientes salen de los datos; la temperatura del horno la eliges tú.

Los hiperparámetros se eligen con **validación cruzada**, nunca mirando el test.

5 · AJUSTAR LOS BOTONES

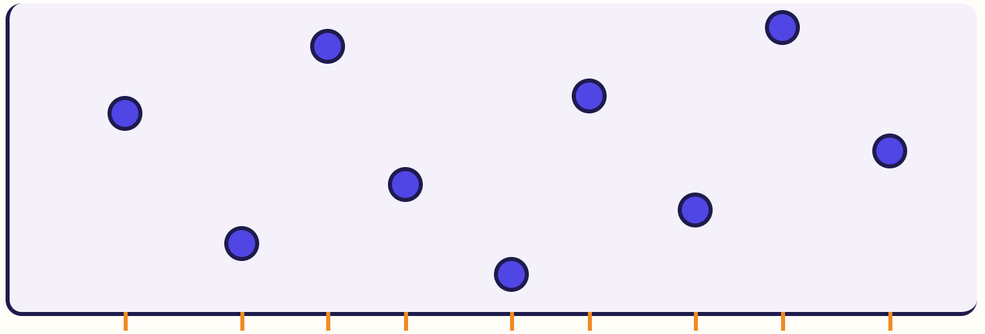
Un buscador gira los botones por ti: rejilla o azar

Rejilla · 9 pruebas



Solo **3 valores distintos** de cada botón

Al azar · 9 pruebas



9 valores distintos de cada botón

Cada punto = una combinación de dos hiperparámetros. Marcas naranjas = valores del eje horizontal que se llegan a probar.

Rejilla

Prueba **todas las combinaciones** de una lista corta.

Con 9 pruebas, solo **3 valores** de cada botón.

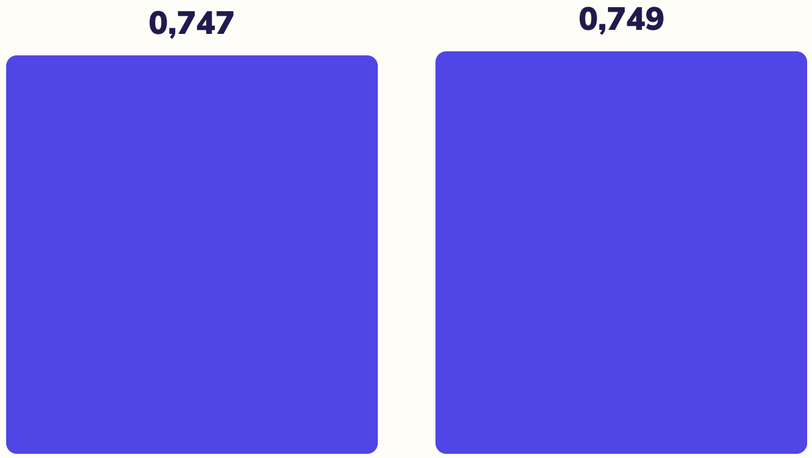
Al azar

Con las mismas 9 pruebas, **9 valores** de cada botón.

Suele **explorar mejor** con muchos botones.

5 · AJUSTAR LOS BOTONES

Da igual cómo busques: el AUC ronda 0,75



Barras: **AUC en validación cruzada**, medido desde 0,5.

Muchos empates

13 de 25 configuraciones quedan a menos de un error estándar de la mejor.

Entre empates, **elige la más sencilla** (la de 4 hojas).

La nota engaña un poco

La mejor nota de validación es **en parte suerte**.

Con datos de prueba: **0,747** → **0,734** y **0,749** → **0,740**: siempre sale algo peor.

QUÉ MODELO ELIJO

El mejor modelo depende de lo que necesites

Modelo	AUC	Se puede explicar	Cuándo
Regresión logística (S07)	**0,755** (validación)	**Sí**: odds ratio	Punto de partida y reto
Árbol podado	0,716 (prueba)	**Sí**: reglas	Explicar a un gerente
Random Forest	0,734 (prueba)	Algo: importancias	Fiable sin mucho ajuste
XGBoost / LightGBM	0,745 (prueba)	Algo: importancias	Muchos datos y tablas
SVM	0,752 (validación)	Poco	Pocos o medianos datos

En el reto, la regresión logística gana: casi el mejor AUC y la más explicable. Más complejo no es mejor.

Cada cifra viene de su cuaderno: unas son en **prueba** y otras en **validación**, no se comparan al milímetro.

MAPA FINAL

Familia, botón y límite

Familia	La idea	El botón que se ajusta	Para no memorizar
Árbol	Preguntas de sí/no encadenadas	Mínimo de reservas por hoja	**Podar**
Bosque	Muchos árboles distintos **votan**	Nº de árboles · columnas por pregunta	**Promediar muchos**
Boosting	Árboles **en serie**: cada uno corrige al anterior	Nº de árboles · **learning_rate**	**Parada temprana**
SVM	La **calle más ancha** entre dos grupos	**C** · **gamma** · kernel	**Escalar y elegir C**

Todos los modelos pueden memorizar; cada familia tiene su botón para limitarlo. Y siempre se ajusta con validación cruzada, no con el test.

PARA LLEVARSE

Lo que tienes que poder decir

Árbol

Preguntas de sí o no. Sin límites **memoriza**; **podar** lo arregla.

Bosque y boosting

Bosque: muchos árboles **votan**. Boosting: cada uno **corrige al anterior** (y hay que **parar a tiempo**).

SVM

La **calle más ancha**. Hay que **escalar**; con muchos datos, lenta.

Botones

Se ajustan con **validación cruzada**. Más complejo **no** es siempre mejor.

Los detalles, en las presentaciones S08_01 a S08_05 y en los cuadernos.