IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Un árbol de preguntas de sí o no

Teoría, práctica y, al final, material de consulta

Sprint 8 · S08_01 · teoría breve, 35 min de práctica y material de consulta

PARTES DE UN ÁRBOL

Preguntas de sí o no encadenadas

Raíz · ¿antelación ≤ 115 días?

Las 10 reservas: 5 cancelan y 5 no.

Sí → rama · ¿va sin depósito?

6 reservas: 1 cancela.

No → hoja: cancela

4 reservas: las 4 cancelan.

No → hoja: no cancela

3 reservas con depósito: ninguna cancela.

Sí → hoja: no cancela

3 reservas sin depósito: 1 cancela.

Cada **hoja** predice la clase **mayoritaria** de las reservas que caen en ella.

CÓMO ELIGE LA PREGUNTA

La mejor pregunta es la que más purifica

Gini mide cuánto se mezclan las clases en un grupo: **0** = todas iguales (hoja pura), **0,5** = mitad y mitad. Con 6 reservas y 1 cancelada: $1 - (1/6)^2 - (5/6)^2 = 1 - 0{,}03 - 0{,}69 = \mathbf{0{,}28}$.

Pregunta	Grupo «sí»	Grupo «no»	Gini ponderado
Sin preguntar	10 reservas · 5 cancelan	—	0,50
¿Antelación ≤ 115 días?	6 reservas · 1 cancela · 0,28	4 reservas · 4 cancelan · 0,00	**0,17**
¿Va sin depósito?	6 reservas · 4 cancelan · 0,44	4 reservas · 1 cancela · 0,38	0,42

Gana la pregunta que deja el menor Gini ponderado: la de la antelación, 0,17 frente a 0,42.

Ponderado = cada grupo cuenta según su tamaño: $(6 \times 0{,}28 + 4 \times 0{,}00) / 10 = 0{,}17$.

LEER EL ÁRBOL

Cada línea es una pregunta; cada class, una hoja

Texto del árbol	Qué significa
|--- antelacion <= 115	Pregunta de la raíz: ¿antelación de 115 días o menos? **Sí** → rama de dentro
| |--- sin_deposito <= 0.50	Segunda pregunta. Tras el one-hot, **<= 0.50** = **no** y **> 0.50** = **sí**
| | |--- class: 0	Hoja: predice «no cancela»
|--- antelacion > 115	La otra rama: **no** a la pregunta de la raíz
| |--- class: 1	Hoja: predice «cancela»

Sangría = profundidad

Lo que cuelga de una pregunta es su respuesta: **<=** sí, **>** no.

Las hojas

class: 0 = «no cancela» · **class: 1** = «cancela».

SOBREAJUSTE

El árbol libre memoriza

Sin límites, el árbol sigue preguntando hasta que **cada hoja es pura**. Es como aprenderse de memoria los exámenes de otros años: un 10 en esos… y un suspenso en el nuevo.

69

hojas

para 200 reservas de entrenamiento

100 %

de aciertos en train

las memoriza todas, ruido incluido

67 %

de aciertos en test

reservas que no había visto

Señal de alarma: nota perfecta en train y mucho peor en test.

PODA

Podar: frenar el crecimiento

max_depth

Profundidad máxima: **cuántas preguntas seguidas**.

min_samples_leaf

Mínimo de reservas por hoja: evita hojas «de 2 casos».

ccp_alpha

Poda **a posteriori**: se recortan las ramas que no compensan su complejidad.

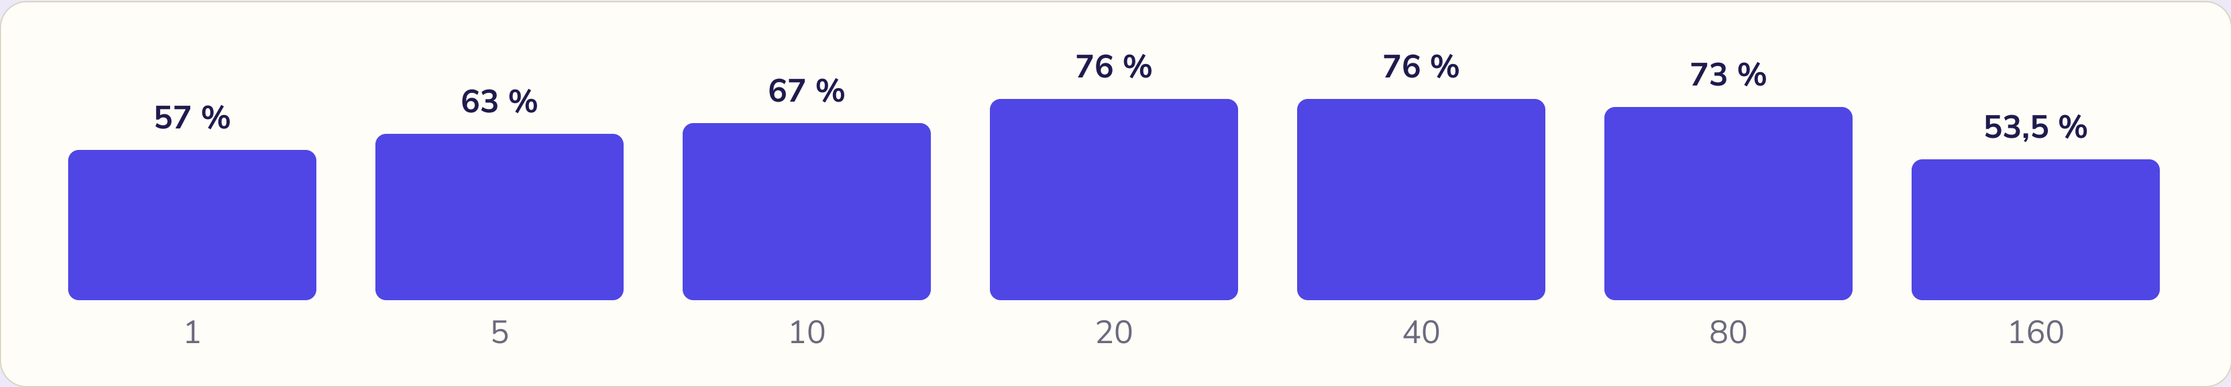
Mismo conjunto de datos	Hojas	Acierto en train	Acierto en test
Árbol libre	69	100 %	67 %
min_samples_leaf = 5	26	81 %	70 %
min_samples_leaf = 20	7	76,5 %	74,5 %
max_depth = 2	4	77 %	74,5 %

Como podar un rosal: se quita lo que sobra para que la planta crezca mejor. Menos hojas, **menos distancia** entre train y test.

ELEGIR LA PODA

Se elige con validación cruzada, nunca con test

Acierto en validación cruzada según **min_samples_leaf** (ejemplo de 200 reservas):



Demasiada poda (160) deja el árbol corto. El test se mira una sola vez, al final, con el árbol ya elegido.

PUNTOS FUERTES

Un árbol no necesita escalar

Mismo árbol, dos unidades	Antelación en días	Antelación en semanas (días ÷ 7)
Pregunta de la raíz	¿antelación ≤ 115?	¿antelación ≤ 16,4?
Reservas en cada grupo	6 y 4	6 y 4
Predicciones de las 10 reservas	las mismas	las mismas

Por qué

Un árbol solo **compara con un umbral**. Cambiar la unidad mueve el umbral, pero no el orden de las reservas.

Ojo

Con k-NN o la regresión logística, escalar **sí** importaba. Con árboles, solo hace falta imputar nulos y codificar categorías.

Fuerte

Explicable: se lee como reglas.

Débil

Inestable y suele rendir menos que los ensembles.

IMPORTANCIA DE VARIABLES

Cuánto purifica cada variable en total

Pregunta del árbol	Impureza antes	Impureza después	Reducción
Raíz: antelación	10 × 0,50 = 5,00	6 × 0,28 + 4 × 0 = 1,67	3,33
Rama: sin depósito	6 × 0,28 = 1,67	3 × 0 + 3 × 0,44 = 1,33	0,33

Total = 3,67 → antelación **91 %** (3,33 / 3,67) y sin depósito **9 %** (0,33 / 3,67). La suma es 1.

No es causal

Dice qué **mira el modelo**, no qué causa la cancelación.

Infla numéricas

Favorece variables con **muchos valores** distintos.

Correlacionadas

Se reparte de forma algo **arbitraria**.

INESTABILIDAD

Pequeños cambios en los datos, otro árbol

5 árboles, cada uno con el 80 % de train	Árbol 1	Árbol 2	Árbol 3	Árbol 4	Árbol 5
Umbral de la raíz (días de antelación)	111,6	111,6	111,6	112,5	108,4
Hojas	12	13	12	13	14

Misma configuración, otros datos: en el 41 % de las 200 reservas de prueba, los 5 árboles no coinciden.

Lo arreglan los **ensembles**: bosques aleatorios (S08_02) y boosting (S08_03).

REGLAS PARA EL GERENTE

Del árbol a frases para el gerente

Ruta de la raíz a la hoja	Reservas	Cancelan	Frase para el gerente
antelación > 115	4	4 (100 %)	«Con más de 115 días de antelación, canceló el 100 % (4 de 4).»
antelación ≤ 115 y con depósito	3	0 (0 %)	«Con poca antelación y depósito, nadie canceló (0 de 3).»
antelación ≤ 115 y sin depósito	3	1 (33 %)	«Con poca antelación y sin depósito, canceló 1 de cada 3.»

Una regla es un camino de la raíz a una hoja. Añade siempre una cifra y escribe con palabras de negocio.

PRÁCTICA · CUADERNO S08_01

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación y ejemplos	Preparar los datos y dibujar un árbol pequeño con sus reglas	Clase
Ejercicio 1	Variable de la raíz y número de hojas	Clase
Ejercicio 2	El árbol libre: AUC en train y en test	Clase
Ejemplo	Cómo cambia el AUC al podar con **min_samples_leaf**	Clase
Ejercicio 3	Elegir la poda y medirla en test	Clase
Ejercicio 4	Las tres variables más importantes	Casa
Ejemplo	Cinco árboles, cinco submuestras: ¿coinciden?	Casa
Mini-reto	Tres reglas para el gerente	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 4 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Raíz y hojas	14 y 15
2	El árbol libre	16 y 17
3	Elegir la poda	18 y 19
4 (casa)	Importancia de variables	20 y 21
Mini-reto (casa)	Reglas para el gerente	22 y 23

CONSULTA · EJERCICIO 1

Raíz y hojas del árbol (ejercicio 1)

```
variable_raiz = nombres[arbol_peq.tree_.feature[0]]    # 'num__antelacion_dias'
n_hojas = arbol_peq.get_n_leaves()                     # 8
```

antelación

variable de la raíz

8

hojas (2^3)

Cada pregunta duplica las ramas: profundidad 3 → 2 × 2 × 2 = 8 hojas como máximo.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer la raíz y las hojas (ejercicio 1)

tree_.feature[0]

Es el **índice** de la variable del nodo 0, la raíz; **nombres[...]** lo convierte en **nombre**.

get_n_leaves()

Cuenta las **hojas** del árbol: los nodos donde ya no se pregunta nada.

Por qué 8

Cada pregunta duplica las ramas: 2 × 2 × 2 = **$2^3 = 8$**, el máximo con **max_depth=3**.

Por qué la antelación

De todas las preguntas posibles, es la que **mejor separa** canceladas y no canceladas (menor Gini).

CONSULTA · EJERCICIO 2

El árbol libre memoriza (ejercicio 2)

```
arbol_libre = DecisionTreeClassifier(random_state=SEMILLA).fit(Xtr, y_train)
auc_train_libre = roc_auc_score(y_train, arbol_libre.predict_proba(Xtr)[:, 1])    # 1.000
auc_test_libre = roc_auc_score(y_test, arbol_libre.predict_proba(Xte)[:, 1])      # 0.587
hojas_libre = arbol_libre.get_n_leaves()                                          # 1206
```

1,000
AUC en train

0,587
AUC en test

1206 hojas para 4800 reservas: casi una hoja por cada 4. Sobreajuste.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer el árbol libre (ejercicio 2)

DecisionTreeClassifier(random_state=…)

Sin **max_depth** ni **min_samples_leaf**: **sin límites**. La semilla fija los empates.

predict_proba(…)[:, 1]

El AUC se mide con **probabilidades**, no con **predict**; la columna 1 es «cancela».

AUC 1,000 frente a 0,587

Una diferencia tan grande es **sobreajuste**: aprende el ruido y en test casi no supera al azar (0,5).

1206 hojas

Para 4800 reservas: **una hoja por cada 4**. Ha memorizado el entrenamiento.

CONSULTA · EJERCICIO 3

Elegir la poda y medirla en test (ejercicio 3)

```
mejor_min_hoja = hojas_min[int(np.argmax(auc_cv_hojas))]                    # 80
arbol_podado = DecisionTreeClassifier(min_samples_leaf=mejor_min_hoja, random_state=SEMILLA).fit(Xtr, y_train)
auc_test_podado = roc_auc_score(y_test, arbol_podado.predict_proba(Xte)[:, 1])    # 0.716
```

0,716

AUC en test del podado

46

hojas: de 1206 a

La poda sube el AUC en test de 0,587 a 0,716 (+0,13) con ≈ 26 veces menos hojas.

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer la poda (ejercicio 3)

np.argmax(auc_cv_hojas)

Da la **posición** del mayor AUC, no el AUC; **hojas_min[...]** la convierte en el valor de **min_samples_leaf**.

Validación cruzada, no test

El parámetro se elige **sin mirar el test**, que queda para medir el árbol final.

La curva es una colina

Con 1 hoja mínima, AUC 0,584; con **80**, 0,716 (con 160 casi igual); con 320 baja a 0,692: **subajuste**.

Qué ganas y qué pierdes

Ganas **generalización** y un árbol de 46 hojas; pierdes el ajuste perfecto en train, que era memorización.

CONSULTA · EJERCICIO 4

Las tres variables más importantes (ejercicio 4, casa)

```
top3 = list(importancias.head(3).index)          # los 3 nombres
suma_top3 = float(importancias.head(3).sum())    # 0.70
```

≈ 70 %

antelación (0,445) + depósito (0,163) + canal directo (0,092)

34

columnas tras el one-hot

Solo 3 columnas de 34 acumulan el 70 % de la importancia.

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer la importancia (ejercicio 4, casa)

head(3).index

Se queda con los **nombres** de las tres primeras (la Serie está ordenada); **head(3).sum()** suma sus **valores**.

Prefijos num__ y cat__

num__ = numérica; **cat__variable_valor** = categórica pasada a **one-hot** (1 = sí, 0 = no).

70 % con 3 de 34

El árbol se apoya en **muy pocas variables**: antelación, si hay depósito y si es canal directo.

No es causal

La importancia mide **cuánto usa el modelo** una variable, no que cause las cancelaciones.

CONSULTA · MINI-RETO

Tres reglas para el gerente (mini-reto, casa)

```
arbol_gerente = DecisionTreeClassifier(max_depth=3, random_state=SEMILLA).fit(Xtr, y_train)
auc_test_gerente = roc_auc_score(y_test, arbol_gerente.predict_proba(Xte)[:, 1])    # 0.692
print(export_text(arbol_gerente, feature_names=list(nombres)))                      # 8 hojas
```

0,692

AUC en test del árbol del gerente

8

hojas: se pueden leer todas

Peor que el podado (0,716, 46 hojas), pero cabe en 8 reglas que el gerente puede leer.

CONSULTA · ACLARACIONES · MINI-RETO

Leer las reglas (mini-reto, casa)

export_text(...)

Imprime el árbol como texto; **cada camino** de la raíz a una hoja es una regla.

reglas = [...]

Exactamente **3 frases** de más de 20 caracteres, con una cifra y palabras de negocio.

AUC 0,692 frente a 0,716

Es más simple: **8 hojas** frente a 46, y capta menos matices.

Qué gana el gerente

Puede leerlo y explicarlo: 8 reglas con las variables que importan, sin matemáticas.