IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Muchos árboles votan mejor que uno

Bagging, variables al azar, validación out-of-bag, importancia y coste

Sprint 8 · S08_02 · cuaderno: 30 min en clase (ejercicios 1 y 2)

LA IDEA

Un árbol opina; un bosque vota

Como pedir opinión a cinco compañeros en lugar de a uno: si cada uno mira cosas distintas, **los fallos de unos los tapan los otros**.

reserva nueva	árbol 1	árbol 2	árbol 3	árbol 4	árbol 5	votos «cancela»	bosque
A · 10 días, con depósito	0	0	0	0	0	0 de 5	0,0
B · 22 días, sin depósito	1	1	1	1	0	4 de 5	0,8
C · 38 días, con depósito	0	1	0	1	1	3 de 5	0,6
D · 80 días, sin depósito	1	1	1	1	1	5 de 5	1,0

```
bosque = RandomForestClassifier(
    n_estimators=5, random_state=5)
bosque.fit(X, y)                        # 16 reservas de ejemplo
bosque.predict_proba(nuevas)[:, 1]      # 0.0 0.8 0.6 1.0
```

Probabilidad = proporción de votos

Cada árbol dice 1 (cancela) o 0 (no cancela). El bosque promedia: **3 votos de 5 = 0,6**.

AZAR Nº 1 · BAGGING

Cada árbol ve una muestra distinta

Se sortean reservas **con reemplazo**: se saca una, se anota y se devuelve a la bolsa. Así unas salen repetidas y otras no salen. Ejemplo con 8 reservas, A a H:

árbol	muestra de 8 reservas (con repetidas)	se queda fuera (OOB)
árbol 1	A · B · D · E · G · G · H · H	C y F
árbol 2	B · C · C · C · D · D · G · G	A, E, F y H
árbol 3	A · A · E · E · F · G · G · G	B, C, D y H

≈ 37 %

Fuera de cada muestra queda en torno al **37 %**: con 8 reservas de media el 34,4 %, con 100 el 36,6 % y, al crecer, tiende a **36,8 %**.

OOB = out-of-bag («fuera de la bolsa»)

Las reservas que un árbol no vio son su **examen sorpresa**. La G entró en los tres árboles: ninguno la tiene como examen.

AZAR Nº 2 · VARIABLES, Y LOS MANDOS DEL BOSQUE

Cada pregunta mira solo algunas columnas

Si todos los árboles pudieran elegir entre todas las columnas, casi todos preguntarían primero por la misma y saldrían **casi iguales**. Con **max_features**, cada pregunta ve solo un grupo al azar.

Mando	Qué controla	En el cuaderno
n_estimators	Número de árboles. Más árboles casi nunca perjudica: solo cuesta tiempo	300
min_samples_leaf	Mínimo de reservas en cada hoja: frena el sobreajuste de cada árbol	5
max_depth	Profundidad máxima de cada árbol	sin límite
max_features	Columnas que ve cada pregunta (por defecto, la raíz cuadrada del total)	5 de 34

Tras el one-hot hay 34 columnas: la raíz cuadrada de 34 es 5,8 y cada pregunta elige entre 5.

VALIDACIÓN GRATIS · OOB

Cada árbol tiene un examen que no ha visto

La valoración OOB de una reserva sale **solo de los árboles que no la vieron**: una nota honesta sin separar datos.

```
b = RandomForestClassifier(n_estimators=100, min_samples_leaf=5,
        oob_score=True, random_state=42).fit(Xtr, y_train)
b.oob_decision_function_[:, 1]    # probabilidad OOB de cada reserva
```

Árboles del bosque	Reservas de train sin valoración OOB	AUC out-of-bag
5	487 de 4800 (10,1 %)	0,637
10	58 de 4800 (1,2 %)	0,676
25	0	0,718

Con pocos árboles, algunas reservas nunca quedan fuera: no tienen examen y la nota baja.

EJERCICIO 1 · CUADERNO (CLASE)

Un árbol podado frente a un bosque de 300

```
bosque = RandomForestClassifier(n_estimators=300, min_samples_leaf=5,
                                random_state=SEMILLA, n_jobs=2)
bosque.fit(Xtr, y_train)
p = bosque.predict_proba(Xte)[:, 1]    # prob. de cancelar
auc_test_bosque = roc_auc_score(y_test, p)
```

Modelo	AUC en test (1200 reservas)
Árbol podado (**min_samples_leaf=80**)	0,716
Bosque de 300 árboles	0,734

n_jobs=2

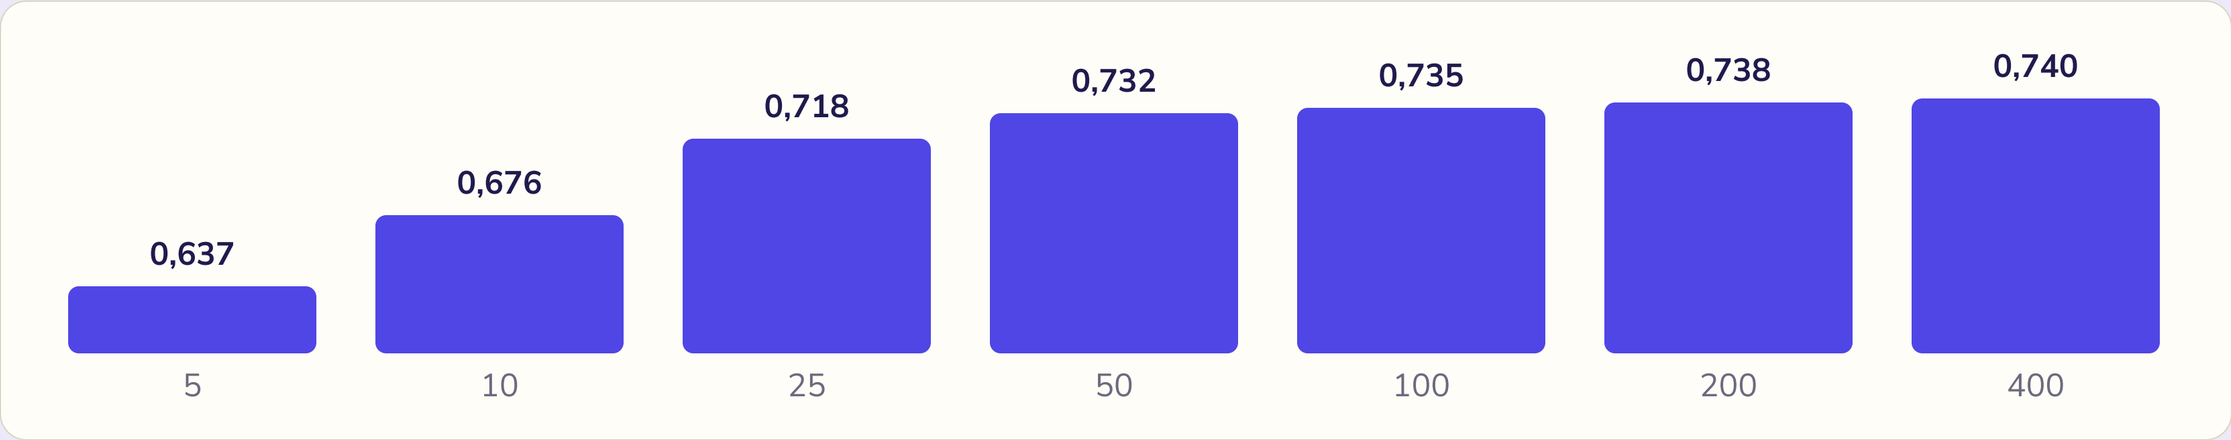
Entrena con **2 núcleos** a la vez.

El bosque gana, pero poco

Sube unas **2 centésimas** de AUC: ¿compensa su coste?

CUÁNTOS ÁRBOLES · EJERCICIO 2 · CUADERNO (CLASE)

Más árboles ayudan, hasta que se estabiliza



AUC out-of-bag según el número de árboles. Las barras parten de 0,60 para apreciar la diferencia.

```
mejora_5_a_400 = oob_auc[-1] - oob_auc[0]
mejora_100_a_400 = (oob_auc[-1]
    - oob_auc[n_arboles.index(100)])
```

+0,103
de 5 a 400 árboles

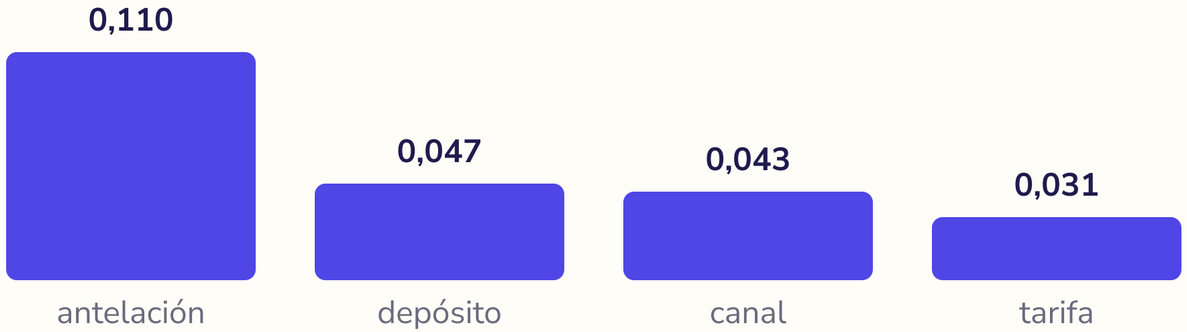
+0,005
de 100 a 400 árboles

IMPORTANCIA DE VARIABLES · EJERCICIO 3 (CASA)

Baraja una columna y mira cuánto empeora

Ejemplo: 600 reservas inventadas	Importancia de impureza (train)	Caída del AUC al barajar (test)
antelacion_dias (sí influye)	0,815	0,345
dia_del_mes (puro ruido)	0,185	–0,012

La impureza da un 18 % de importancia a una columna de ruido; la permutación la deja en cero.



En TurisData (cuaderno)

Variable principal: **antelacion_dias**.

6 de 15 columnas tienen importancia menor de 0,002.

COSTE Y DUELO · MINI-RETO (CASA)

¿Compensa el bosque frente a la logística?

Modelo (validación cruzada, 5 folds)	AUC medio	Desviación
Árbol podado	0,716	0,016
Bosque de 300 árboles	0,741	0,014
Regresión logística	0,758	0,012

12 ms → 1,6 s

árbol → bosque de 300 en nuestra prueba (≈ 137 veces). En tu ordenador saldrán otras cifras.

Explicabilidad

300 árboles no se leen. La logística da odds ratios y se explica al cliente.

Más complejo no siempre es mejor: aquí los datos siguen una relación casi logística.

HOY HAS APRENDIDO

Muchos árboles distintos, un solo voto

Dos azares

Muestras con reemplazo y pocas columnas por pregunta hacen **distintos** a los árboles

OOB y nº de árboles

El examen sorpresa da una nota gratis; más árboles, rendimientos decrecientes

Permutación y coste

Importancia más fiable; el bosque pierde explicabilidad y cuesta tiempo

Siguiente: S08_03 · boosting (árboles en cadena)