IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 8 DE 17

# Sprint 8 · Árboles, ensembles y SVM

*¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?*

**FECHAS**
10–11 de noviembre

**HORAS**
12 h (3 h teoría · 4 h práctica guiada · 5 h PBL)

**CONTENIDOS**
M3 UD 3.6 (árboles de decisión), UD 3.7 (Random Forest, Gradient Boosting, XGBoost y LightGBM) y UD 3.8 (SVM), más ajuste de hiperparámetros (`GridSearchCV`, `RandomizedSearchCV`).

**EVALUACIÓN**
test de M3 (primera parte) y reto PBL «Duelo de modelos».

## Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C`, `gamma`, kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

## Requisitos previos

- Sprint 6 y 7: pipelines, validación cruzada, métricas de clasificación (AUC, precisión, recall), umbral y regresión logística como referencia.
- Datos: `datos/reservas_turisdata.csv` (objetivo `cancelada`). Los notebooks lo descargan solos si no lo encuentran.
- Librerías: scikit-learn, xgboost y lightgbm (vienen instaladas en Colab; en local: `pip install xgboost lightgbm`).

## Prácticas

| Notebook | Tema | Tiempo | Colab |
|---|---|---|---|
| `S08_01_arboles_decision` | Árbol de decisión: reglas, sobreajuste, poda, importancia | 35 min | Abrir en Colab |
| `S08_02_random_forest` | Random Forest: bagging, OOB, importancia por permutación | 40 min | Abrir en Colab |
| `S08_03_boosting_xgboost_lightgbm` | Gradient Boosting, XGBoost, LightGBM y parada temprana | 45 min | Abrir en Colab |
| `S08_04_svm` | SVM: margen, kernels, `C`, `gamma`, escalado y coste | 30 min | Abrir en Colab |
| `S08_05_busqueda_hiperparametros` | `GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final | 30 min | Abrir en Colab |
| `S08_06_leaderboard_plantilla` | **Herramienta del reto**: leaderboard para rellenar | dentro del reto | Abrir en Colab |

Las cinco primeras son las prácticas guiadas; la sexta es la plantilla que usaréis en el reto. Los ejercicios se autocorrigen con `assert`.

## RETO Reto PBL · «Duelo de modelos»

**Qué os pide el cliente.** TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: *«¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?»*. Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

**Qué vais a entregar:** `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

**Cuánto tiempo:** unas 2 horas y 15 minutos en equipo entre el planning, el reto y la entrega (10 y 11/11).

**Núcleo y extra.** Núcleo: *leaderboard* con tres familias de modelos, pesos de los criterios, test una sola vez y ficha del modelo. Extra: más familias y búsqueda de hiperparámetros en varias.

**Ficha completa del reto** (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_08.md · **Qué hacemos cada día:** Guía día a día