Sprint 8 · Árboles, ensembles y SVM

¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?

FECHAS
10–11 de noviembre

HORAS
12 h (3 h teoría · 4 h práctica guiada · 5 h PBL)

CONTENIDOS
M3 UD 3.6 (árboles de decisión), UD 3.7 (Random Forest, Gradient Boosting, XGBoost y LightGBM) y UD 3.8 (SVM), más ajuste de hiperparámetros (`GridSearchCV`, `RandomizedSearchCV`).

EVALUACIÓN
test de M3 (primera parte) y reto PBL «Duelo de modelos».

Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C`, `gamma`, kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

Requisitos previos

- Sprint 6 y 7: pipelines, validación cruzada, métricas de clasificación (AUC, precisión, recall), umbral y regresión logística como referencia.
- Datos: `datos/reservas_turisdata.csv` (objetivo `cancelada`). Los notebooks lo descargan solos si no lo encuentran.
- Librerías: scikit-learn, xgboost y lightgbm (vienen instaladas en Colab; en local: `pip install xgboost lightgbm`).

Prácticas

Notebook	Tema	Tiempo
`S08_01_arboles_decision`	Árbol de decisión: reglas, sobreajuste, poda, importancia	35 min
`S08_02_random_forest`	Random Forest: bagging, OOB, importancia por permutación	40 min
`S08_03_boosting_xgboost_lightgbm`	Gradient Boosting, XGBoost, LightGBM y parada temprana	45 min
`S08_04_svm`	SVM: margen, kernels, `C`, `gamma`, escalado y coste	30 min
`S08_05_busqueda_hiperparametros`	`GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final	30 min
`S08_06_leaderboard_plantilla`	**Herramienta del reto**: leaderboard para rellenar	dentro del reto

Las cinco primeras son las prácticas guiadas; la sexta es la plantilla que usaréis en el reto. Los ejercicios se autocorrigen con `assert`.

RETO Reto PBL · «Duelo de modelos»

Qué os pide el cliente. TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: *«¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?»*. Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

Qué vais a entregar: `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

Cuánto tiempo: unas 2 horas y 15 minutos en equipo entre el planning, el reto y la entrega (10 y 11/11).

Núcleo y extra. Núcleo: *leaderboard* con tres familias de modelos, pesos de los criterios, test una sola vez y ficha del modelo. Extra: más familias y búsqueda de hiperparámetros en varias.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_08.md · **Qué hacemos cada día:** Guía día a día