Guía Sprint S08 · Árboles, ensembles y SVM

¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?

FECHAS
11–12 de noviembre

HORAS
9 h (2 h teoría · 3 h práctica · 4 h PBL)

Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C`, `gamma`, kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

Temario

Los conceptos que entran en este sprint (temario oficial del curso):

Unidad	Conceptos que entran
UD 3.6	Árboles de decisión
UD 3.7	Ensembles: Random Forest, Gradient Boosting, XGBoost
UD 3.8	Máquinas de vectores de soporte (SVM)

Material del sprint

Presentaciones

Presentación	Tema	Tiempo
S08.1	Árboles de decisión	25 min
S08.2	Ensembles: Random Forest y *boosting*	25 min
S08.3	Máquinas de vectores de soporte (SVM), versión corta	10 min

Actividades

Actividad	Tiempo
Árbol de decisión: reglas, poda e importancia (los ejercicios marcados «en clase»)	30 min
Random Forest: bagging, OOB e importancia por permutación (los ejercicios marcados «en clase»)	30 min
Gradient Boosting, XGBoost y LightGBM (los ejercicios marcados «en clase»)	30 min

RETO **Reto PBL · «Duelo de modelos»**

Qué os pide el cliente. TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: *«¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?»*. Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

Qué vais a entregar: `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

Cuánto tiempo: unas 2 horas y 15 minutos en equipo entre el planning, el reto y la entrega (días 1 y 2).

Núcleo y extra. Núcleo: *leaderboard* con tres familias de modelos, pesos de los criterios, test una sola vez y ficha del modelo. Extra: más familias y búsqueda de hiperparámetros en varias.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_08.md · **Qué hacemos cada día:** Guía día a día

Conclusión del Sprint 8

Al acabar este sprint...

- Mi equipo ha acordado los pesos de rendimiento, explicabilidad y coste.
- Sé cómo decide un árbol y para qué sirve un ensemble.
- Leaderboard y ficha del modelo en `sprint-08/`.
- El test lo he usado una sola vez.
- Test de M3 (parte 2) hecho y autoevaluación/coevaluación rellenadas.

Y ahora: Sprint 9 · Segmentar, recomendar y aprender por refuerzo (viernes 13/11).