README Sprint S08 · Árboles, ensembles y SVM

Pregunta guía: ¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?
Fechas: 11–12 de noviembre · **Horas:** 9 h (2 h teoría · 3 h práctica · 4 h PBL)

📄 **Para imprimir:** todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

> **Sigue el orden de arriba abajo y abre solo lo que pone en cada fila.** Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Si el tiempo aprieta, haz solo lo que está por encima de la línea «🏠 A partir de aquí, en casa» de cada cuaderno: lo demás es para casa.

Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C`, `gamma`, kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

Día 1 · Miércoles 11/11

☐	Qué haces	Abre	Min
☐	🔔 Ceremonia · Planning del reto «Duelo de modelos» y pesos de los criterios (la «voz del cliente»)	—	10
☐	📖 Teoría · Árboles de decisión	Presentación S08.1	25
☐	💻 Práctica · Árbol de decisión: reglas, poda e importancia (hasta la línea 🏠 del cuaderno)	Cuaderno S08_01	35
☐	📖 Teoría · Ensembles: Random Forest y *boosting*	Presentación S08.2	25
☐	🏠 **En casa** · Buscar hiperparámetros con `GridSearchCV` y `RandomizedSearchCV`: **esta tarde**, para el paso 3 del reto de mañana (bastan sus secciones 2 y 3)	Cuaderno S08_05	40 (casa)

En clase: 1 h 35 min.

Al acabar el día, deberías poder decir:

☐ Mi equipo ha acordado los pesos de rendimiento, explicabilidad y coste.
☐ Sé cómo decide un árbol y para qué sirve un ensemble.
☐ En casa, esta tarde: la práctica `S08_05` (≈ 40 min), la guía del paso 3 del reto de mañana.

Día 2 · Jueves 12/11

☐	Qué haces	Abre	Min
☐	📖 Teoría · Máquinas de vectores de soporte (SVM), versión corta	Presentación S08.3	10
☐	💻 Práctica · Random Forest: bagging, OOB e importancia por permutación (hasta la línea 🏠 del cuaderno)	Cuaderno S08_02	30
☐	💻 Práctica · Gradient Boosting, XGBoost y LightGBM (hasta la línea 🏠 del cuaderno)	Cuaderno S08_03	25
☐	🎯 Reto · *Leaderboard* (*baseline*, logística, árbol y bosque), búsqueda de hiperparámetros en dos familias, sensibilidad de los pesos, campeón, test **una sola vez**, ficha del modelo y README (pasos 2–5; lo que falte, en la consolidación y la 6.ª hora)	Cuaderno S08_06	75
☐	📝 Test · **Test de M3 (parte 2)**, solo se abre hoy	Abrir	25
☐	🔔 Ceremonia · Entrega en `sprint-08/`, autoevaluación y coevaluación, y review y retrospectiva de los Sprints 7 y 8	—	35
☐	🏠 **En casa** · Máquinas de vectores de soporte, SVM (cuaderno completo)	Cuaderno S08_04	40 (casa)

En clase: 3 h 20 min.

Al acabar el día, deberías poder decir:

☐ Sé buscar hiperparámetros sin engañarme con la nota de validación.
☐ Sé elegir un modelo campeón justificando rendimiento, explicabilidad y coste.
☐ Sé usar el test una sola vez y documentar el modelo en una ficha (*model card*).

El reto en pocas palabras

Qué os pide el cliente. TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: «*¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?*». Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

Qué vais a entregar: `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

Núcleo y extra. Núcleo: *leaderboard* con tres familias de modelos, pesos de los criterios, test una sola vez y ficha del modelo. Extra: más familias y búsqueda de hiperparámetros en varias.

Antes de empezar, probad la demo interactiva (muestra lo que tendréis al final). Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

✅ Antes de cerrar el sprint (Definition of Done)

Archivos subidos en el repositorio del equipo, carpeta `sprint-08/` (marca cada uno cuando lo veas en GitHub): ☐ `leaderboard_S08.csv` · lo genera
☐ `reto_S08.ipynb` · lo modificáis
☐ `model_card.md` · lo creáis a partir de una plantilla
☐ `README.md` · lo creáis
☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

Total en `sprint-08/`: 4 ficheros del equipo + 1 hoja por persona (un equipo de 3 sube 7). Los extras solo si los hacéis. La *review* y la *retro* no se suben.

Comprobaciones antes de dar el sprint por cerrado: ☐ Test de conocimientos hecho el jue 12/11
☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
☐ Leaderboard con ≥ 6 modelos de al menos 4 familias
☐ Hiperparámetros buscados con validación cruzada en train para dos familias
☐ AUC de test calculado una sola vez y `model_card.md` completa
☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

En casa (cuando puedas)

- Los ejercicios de cada cuaderno que **no** se hacen en clase. Se autocorrigen, y debajo llevan una «Solución de referencia» plegada por si te quedas atascado.
- Si quieres repasar la teoría con calma: apuntes del sprint.

Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Mira el código explicado del cuaderno en el que estás.
3. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

Carpeta	Qué hay
`1_Teoria/`	Las presentaciones del sprint y los apuntes para repasar
`2_Practica/`	Los cuadernos (Colab) y su explicación línea a línea en `codigo_explicado/`
`3_Reto/`	`1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado)
`4_Referencia/`	Infografías del sprint

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

Temario oficial de este sprint

Unidad	Conceptos que entran
UD 3.6	Árboles de decisión
UD 3.7	Ensembles: Random Forest, Gradient Boosting, XGBoost
UD 3.8	Máquinas de vectores de soporte (SVM)

Y ahora: Sprint 9 · Segmentar, recomendar y aprender por refuerzo (viernes 13/11).

9 h (2 h teoría · 3 h práctica · 4 h PBL).