# README Sprint S08 · Árboles, ensembles y SVM

**Pregunta guía:** ¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?
**Fechas:** 11–12 de noviembre · **Horas:** 9 h (2 h teoría · 3 h práctica · 4 h PBL)

📄 **Para imprimir:** todos los documentos del sprint en PDF, a color y ecofriendly, están juntos en la carpeta `pdf/` (descárgalos para que funcionen los enlaces).

> **Sigue el orden de arriba abajo y abre solo lo que pone en cada fila.** Los demás documentos del sprint son para consultar si te atascas (apartado «Si te atascas»). Si el tiempo aprieta, haz solo los ejercicios marcados «en clase»: el resto es para casa.

## Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C`, `gamma`, kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

## Día 1 · Miércoles 11/11

| ☐ | Qué haces | Abre | Min |
|---|---|---|---|
| ☐ | 🔔 Ceremonia · Planning del reto «Duelo de modelos» y pesos de los criterios (la «voz del cliente») | — | 10 |
| ☐ | 📖 Teoría · Árboles de decisión: reglas, sobreajuste y poda | Presentación S08_01 | 25 |
| ☐ | 💻 Práctica · Árbol de decisión: reglas, poda e importancia (los ejercicios marcados «en clase») | Cuaderno S08_01 | 35 |
| ☐ | 📖 Teoría · Random Forest: muchos árboles votan | Presentación S08_02 | 15 |
| ☐ | 📖 Teoría · *Boosting*: corregir los errores paso a paso | Presentación S08_03 | 10 |
| ☐ | 🏠 **En casa** · Buscar hiperparámetros con `GridSearchCV` y `RandomizedSearchCV`: **esta tarde**, para el paso 3 del reto de mañana (bastan sus secciones 2 y 3) | Cuaderno S08_05 · Presentación S08_05 | 40 (casa) |

**En clase: 1 h 35 min.**

**Al acabar el día, deberías poder decir:**

☐ Mi equipo ha acordado los pesos de rendimiento, explicabilidad y coste.
☐ Sé cómo decide un árbol y para qué sirve un ensemble.
☐ En casa, esta tarde: la práctica `S08_05` (≈ 40 min), la guía del paso 3 del reto de mañana.

**Día 2 · Jueves 12/11**

| ☐ | Qué haces | Abre | Min |
|---|---|---|---|
| ☐ | 📖 Teoría · Máquinas de vectores de soporte (SVM), versión corta | Presentación S08_04 | 10 |
| ☐ | 💻 Práctica · Random Forest: bagging, OOB e importancia por permutación (los ejercicios marcados «en clase») | Cuaderno S08_02 · Presentación S08_02 | 30 |
| ☐ | 💻 Práctica · Gradient Boosting, XGBoost y LightGBM (los ejercicios marcados «en clase») | Cuaderno S08_03 · Presentación S08_03 | 25 |
| ☐ | 🎯 Reto · *Leaderboard* (*baseline*, logística, árbol y bosque), búsqueda de hiperparámetros en dos familias, sensibilidad de los pesos, campeón, test **una sola vez**, ficha del modelo y README (pasos 4–5; los pasos 2–3 van dentro de las prácticas; lo que falte, en la consolidación y la 6.ª hora) | Cuaderno S08_06 | 75 |
| ☐ | 📝 Test · **Test de M3 (parte 2)** | Abrir | 25 |
| ☐ | 🔔 Ceremonia · Entrega en `sprint-08/`, autoevaluación y coevaluación, y review y retrospectiva de los Sprints 7 y 8 | — | 35 |
| ☐ | 🏠 **En casa** · Máquinas de vectores de soporte, SVM (cuaderno completo) | Cuaderno S08_04 · Presentación S08_04 | 40 (casa) |

**En clase: 3 h 20 min.**

**Al acabar el día, deberías poder decir:**

☐ Sé buscar hiperparámetros sin engañarme con la nota de validación.
☐ Sé elegir un modelo campeón justificando rendimiento, explicabilidad y coste.
☐ Sé usar el test una sola vez y documentar el modelo en una ficha (*model card*).

## El reto en pocas palabras

**Qué os pide el cliente.** TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: «*¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?*». Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

**Qué vais a entregar:** `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

**Núcleo y extra.** Núcleo: *leaderboard* con 6 modelos de al menos 4 familias, pesos de los criterios, test una sola vez y ficha del modelo. Estándar: búsqueda de hiperparámetros en dos familias y análisis de sensibilidad de los pesos. Extra: más familias y búsqueda en varias.

Antes de empezar, probad la demo interactiva (muestra lo que tendréis al final). Para trabajar: reto en una página. Para entregar: qué se sube y rúbrica. Para consultar: ficha del reto (qué pide el cliente, ayudas y errores frecuentes) y cada paso explicado.

## ✅ Antes de cerrar el sprint (Definition of Done)

**Archivos subidos en el repositorio del equipo, carpeta `sprint-08/`** (marca cada uno cuando lo veas en GitHub): ☐ `leaderboard_S08.csv` · lo genera
☐ `reto_S08.ipynb` · lo modificáis
☐ `model_card.md` · lo creáis a partir de una plantilla
☐ `README.md` · lo modificáis
☐ `autoevaluacion_nombre.md` · **uno por persona** (la coevaluación va dentro del mismo fichero): plantilla

**Total en `sprint-08/`: 4 ficheros del equipo + 1 hoja por persona** (un equipo de 3 sube 7). Los extras solo si los hacéis. La *review* y la *retro* no se suben.

**Comprobaciones antes de dar el sprint por cerrado:** ☐ Test de conocimientos hecho el jue 12/11
☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
☐ Leaderboard con ≥ 6 modelos de al menos 4 familias
☐ Hiperparámetros buscados con validación cruzada en train para dos familias
☐ AUC de test calculado una sola vez y `model_card.md` completa
☐ Alguien que **no escribió esa parte** ha revisado el entregable con la rúbrica y lo ha anotado en el propio entregable

## En casa (cuando puedas)

- Los ejercicios de cada cuaderno que **no** se hacen en clase. Se autocorrigen, y debajo llevan una «Solución de referencia» plegada por si te quedas atascado.
- Si quieres repasar la teoría con calma: apuntes del sprint.

## Si te atascas

1. Lee primero la parte «Si os atascáis» de la ficha completa del reto.
2. Mira el código explicado del cuaderno en el que estás.
3. Pregunta a tu equipo y, después, al docente. Si usas IA, cuenta en el README qué te dijo y qué comprobaste.

## Todo el material, por carpetas

Las carpetas están **numeradas en el orden en que las usas**. Cada documento está en `.md`.

| Carpeta | Qué hay |
|---|---|
| `1_Teoria/` | Las presentaciones del sprint y los apuntes para repasar |
| `2_Practica/` | Los cuadernos (Colab) y su explicación línea a línea en `codigo_explicado/` |
| `3_Reto/` | `1_Trabajar` (reto en una página, plantillas y datos) · `2_Entregar` (qué se sube, rúbrica y autoevaluación) · `3_Consultar` (ficha del reto y cada paso explicado) |
| `4_Referencia/` | Infografías del sprint |

Cómo se trabaja un reto, en todos los sprints: método de trabajo.

## Temario oficial de este sprint

| Unidad | Conceptos que entran |
|---|---|
| UD 3.6 | Árboles de decisión |
| UD 3.7 | Ensembles: Random Forest, Gradient Boosting, XGBoost |
| UD 3.8 | Máquinas de vectores de soporte (SVM) |

**Y ahora:** Sprint 9 · Segmentar, recomendar y aprender por refuerzo (viernes 13/11).

*9 h (2 h teoría · 3 h práctica · 4 h PBL).*