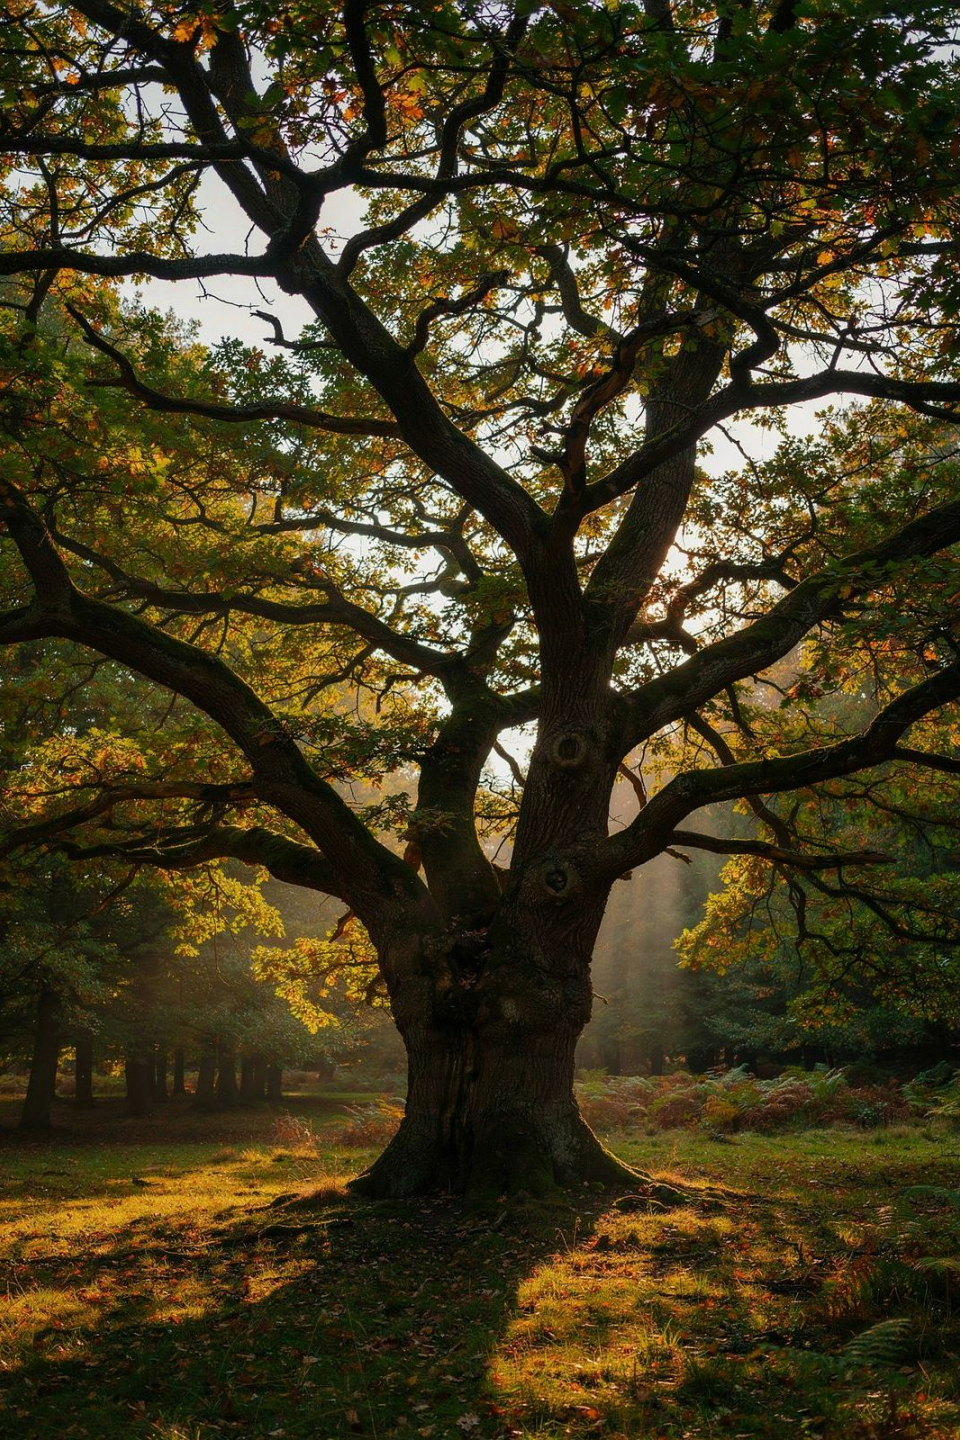


Árboles de Decisión

Un recorrido profundo por uno de los algoritmos más intuitivos e interpretables del aprendizaje automático: desde la idea fundamental hasta sus ventajas, límites y aplicaciones prácticas.

TEMA 8.1 MACHINE LEARNING



La idea del árbol

Un árbol de decisión imita el proceso de razonamiento humano: **se formulan preguntas sucesivas sobre los atributos de los datos** hasta llegar a una conclusión. Cada nodo interno representa una pregunta (p. ej., «¿edad > 30?»), cada rama es una respuesta posible y cada hoja contiene la predicción final.

Nodo raíz

Primera pregunta, sobre el atributo más informativo del conjunto de datos.

Nodos internos

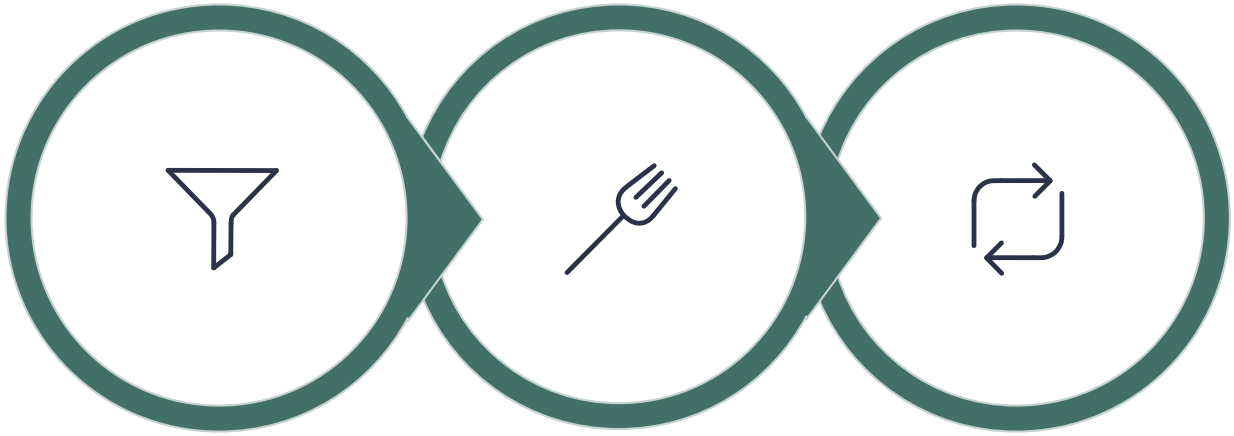
Preguntas sucesivas que van particionando el espacio de características.

Hojas

Decisión final: clase mayoritaria (clasificación) o valor medio (regresión).

¿Cómo aprende un árbol?

El algoritmo de entrenamiento más habitual es **CART** (*Classification and Regression Trees*). En cada nodo busca la partición binaria que maximiza la **pureza** de los subconjuntos resultantes. El proceso es codicioso (*greedy*): toma la mejor decisión local sin garantizar el óptimo global.



El proceso se repite recursivamente en cada nodo hijo hasta que se alcanza un criterio de parada: profundidad máxima, mínimo de muestras por hoja o pureza perfecta.

Criterios de división: Gini y Entropía

Para elegir **qué atributo usar** en cada nodo y con qué umbral, se necesita medir la *impureza* de un conjunto. Los dos criterios más utilizados son el **índice de Gini** y la **entropía de Shannon**.

Índice de Gini

$$Gini = 1 - \sum_{k} p_k^2$$

Mide la probabilidad de etiquetar incorrectamente un elemento elegido al azar. Vale **0** cuando el nodo es puro y alcanza su máximo cuando las clases están uniformemente distribuidas.

Entropía de Shannon

$$H = -\sum_{k} p_k \log_2 p_k$$

Cuantifica la *incertidumbre* de la distribución de clases. La **ganancia de información** es la reducción de entropía tras una partición. Más costosa computacionalmente, pero equivalente en resultados prácticos.

Profundidad y sobreajuste

Sin restricciones, un árbol de decisión crece hasta memorizar perfectamente el conjunto de entrenamiento: **cada hoja contiene exactamente una muestra**. Esto se denomina *sobreajuste* (*overfitting*): el modelo capta el ruido de los datos en lugar de sus patrones generales, y falla al generalizar a datos nuevos.

Profundidad 1–3

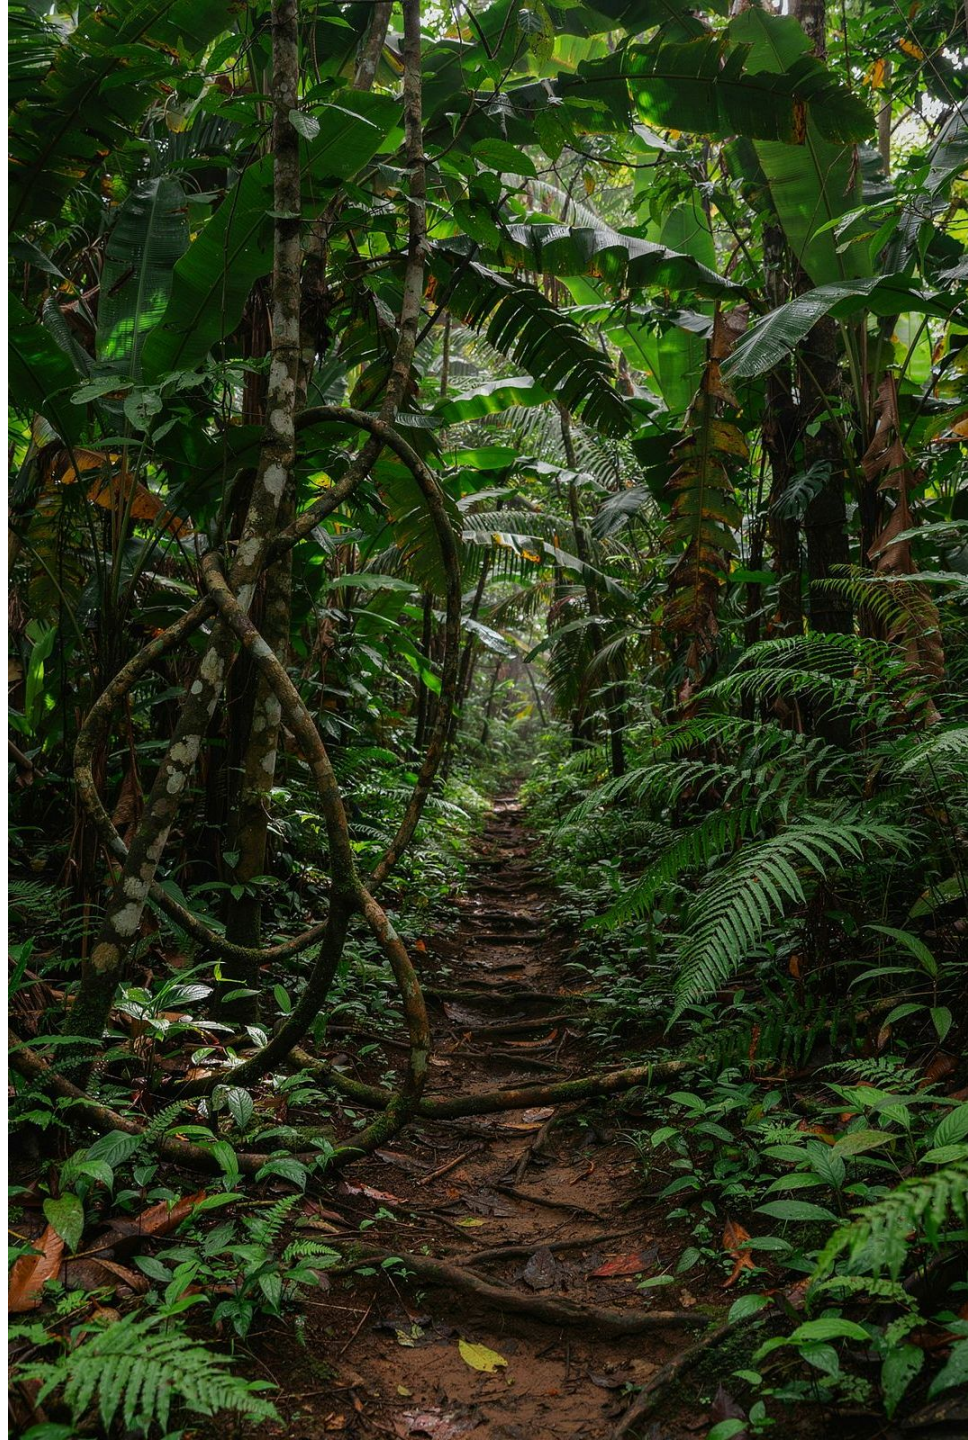
Modelo simple, posible subajuste. Alta sesgo, baja varianza.

Profundidad 5–8

Balance razonable entre sesgo y varianza para muchos problemas reales.

Profundidad ilimitada

Memorización completa del entrenamiento. Baja sesgo, altísima varianza.



Parámetros de regularización

Para controlar la complejidad del árbol se actúa sobre varios hiperparámetros antes o durante el entrenamiento. Ajustarlos correctamente mediante **validación cruzada** es clave para un buen rendimiento.



max_depth

Profundidad máxima del árbol. Limita el número de niveles de preguntas y es el parámetro más intuitivo para controlar la complejidad.



min_samples_split

Número mínimo de muestras que debe tener un nodo para poder dividirse. Valores altos producen árboles más conservadores.



min_samples_leaf

Número mínimo de muestras en cada hoja. Evita hojas con muy pocos ejemplos que podrían representar ruido estadístico.

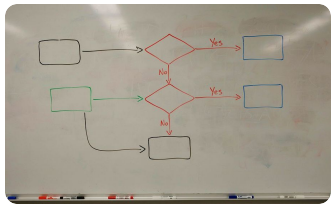


max_features

Número de atributos considerados en cada división. Reducirlo introduce aleatoriedad y es la base de los *Random Forests*.

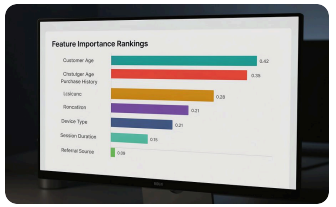
Interpretabilidad y visualización

Una de las mayores fortalezas de los árboles de decisión es su **transparencia**: el proceso de decisión puede representarse gráficamente y explicarse en lenguaje natural. Esto los convierte en la opción preferida cuando la interpretabilidad es un requisito del proyecto.



Visualización del árbol

Con `plot_tree` de scikit-learn o la librería `graphviz` se puede representar el árbol completo, mostrando en cada nodo el criterio de división, la impureza y el número de muestras.



Importancia de variables

El atributo `feature_importances_` indica cuánto contribuye cada variable a reducir la impureza total. Es una herramienta muy útil para la selección de características.

Ventajas y límites

✅ Ventajas

- **Interpretabilidad**: fáciles de explicar a no expertos.
- **Sin preprocesamiento**: no requieren normalización ni codificación de variables categóricas.
- **Tolerancia a outliers** y a valores faltantes.
- **Captura de no linealidades** e interacciones sin configuración explícita.
- **Velocidad** de entrenamiento e inferencia.

⚠️ Límites

- **Alta varianza**: pequeños cambios en los datos pueden producir árboles muy diferentes.
- **Sobreajuste** si no se regulariza adecuadamente.
- **Fronteras de decisión ortogonales**: dificultad con relaciones diagonales.
- **Predicciones constantes** en regresión, sin extrapolación.
- Superados en rendimiento por **métodos ensemble** como Random Forests o Gradient Boosting.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S08_01_arboles_decision — 35 min

Árbol de decisión: reglas, poda e importancia

sprints/S08/notebooks/S08_01_arboles_decision.ipynb