SPRINT 8 · DUELO DE MODELOS · S08.2

Ensembles: Random Forest y boosting

Un solo árbol es inestable. Muchos árboles juntos son más precisos y más estables, a cambio de explicabilidad y coste.

Dos estrategias para juntar árboles

Bagging → Random Forest

Muchos árboles **independientes**, cada uno con una muestra con reemplazo y variables al azar; se **promedian**.

Boosting

Árboles pequeños **en cadena**: cada uno corrige los errores del anterior, sumado con un paso pequeño (`learning_rate`).

Si todos los árboles fueran iguales, promediar no serviría: por eso se introduce **aleatoriedad** (muestras y variables).

Random Forest (cuaderno S08_02)

```
bosque = RandomForestClassifier(n_estimators=300, min_samples_leaf=5,
                                random_state=SEMILLA, n_jobs=2).fit(Xtr, y_train)
auc_test_bosque = roc_auc_score(y_test, bosque.predict_proba(Xte)[:, 1])   # Ejercicio 1
```

- `n_estimators`: **más árboles casi nunca perjudica**; se estabiliza (de 100 a 400 árboles la mejora es mínima: Ejercicio 2).
- `min_samples_leaf` y `max_depth` controlan el sobreajuste de cada árbol; `max_features` = variables por pregunta.
- La puntuación **OOB** (las reservas que cada árbol no vio) da una validación gratis.

Importancia: impureza frente a permutación

	Impureza (`feature_importances_`)	Permutación
Cómo	lo que reduce Gini en el entrenamiento	se **baraja una columna del test** y se mide cuánto cae el AUC
Pega	sesgada a numéricas con muchos valores; calculada sobre train	más lenta
Ventaja	rápida	mide el efecto real sobre la predicción

Ejercicio 3: `variable_top` y `n_irrelevantes` (importancia < 0,002).

El bosque **gana rendimiento y pierde explicabilidad**: 300 árboles no se leen. Además cuesta más tiempo y memoria. Lo medimos frente al árbol y la logística en el mini-reto (`duelo`).

Boosting y el peligro de pasarse (cuaderno S08_03)

1. Un primer árbol muy pequeño predice.
2. El siguiente se entrena para **predecir los errores** (residuos).
3. Se suma multiplicado por `learning_rate`. Se repite cientos de veces.

```
mejor_n_arboles = int(np.argmax(auc_val_por_arbol)) + 1        # Ejercicio 1
caida_final = max(auc_val_por_arbol) - auc_val_por_arbol[-1]
```

Con demasiados árboles, el AUC de **validación** sube y luego **baja**: sobreajuste. Solución: **parada temprana** (máximo alto de árboles y se detiene si la validación no mejora N rondas), con tasa baja (0,03–0,1).

XGBoost y LightGBM

	XGBoost	LightGBM
Crecimiento	por niveles (`max_depth`)	**por hojas** (`num_leaves`)
Control de hojas	`min_child_weight`	`min_child_samples`
Parada temprana	`early_stopping_rounds` + `eval_set`	`callbacks` + `eval_set`
Importancias	por ganancia	por ganancia

```
modelo_xgb.fit(Xfit, yfit, eval_set=[(Xval, yval)], verbose=False)
modelo_lgb.fit(Xfit, yfit, eval_set=[(Xval, yval)], eval_metric="auc", callbacks=[...])
```

Mini-reto: `tabla` con `auc_test`, `arboles` y `segundos_ajuste` de `sklearn_gb`, `xgboost` y `lightgbm`.

Primeros modelos en el *leaderboard* (S08_06)

```
registrar(evaluar_modelo("baseline", "referencia",
                         hacer_pipe(DummyClassifier(strategy="prior")), 5, notas))   # Ejercicio 1
registrar(evaluar_modelo("random_forest", "ensemble_bagging", hacer_pipe(...), 2, notas))
```

- `evaluar_modelo` mide **AUC y AP** (validación cruzada), **tiempo de ajuste**, **tiempo de predicción** por 1000 reservas y **tamaño** en KB; la **explicabilidad** (1–5) la pones tú.
- Hoy: baseline, logística, árbol y bosque (pasos 1–2 del reto). SVM y búsqueda, en la siguiente sesión.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO **S08_02_random_forest** — 40 min
Random Forest: bagging, OOB e importancia por permutación
sprints/S08/notebooks/S08_02_random_forest.ipynb

CUADERNO **S08_03_boosting_xgboost_lightgbm** — 45 min
Gradient Boosting, XGBoost y LightGBM
sprints/S08/notebooks/S08_03_boosting_xgboost_lightgbm.ipynb

CUADERNO **S08_06_leaderboard_plantilla** — 25 min
Primeros modelos en el *leaderboard* (*baseline*, logística, árbol y bosque; pasos 1–2)
sprints/S08/notebooks/S08_06_leaderboard_plantilla.ipynb