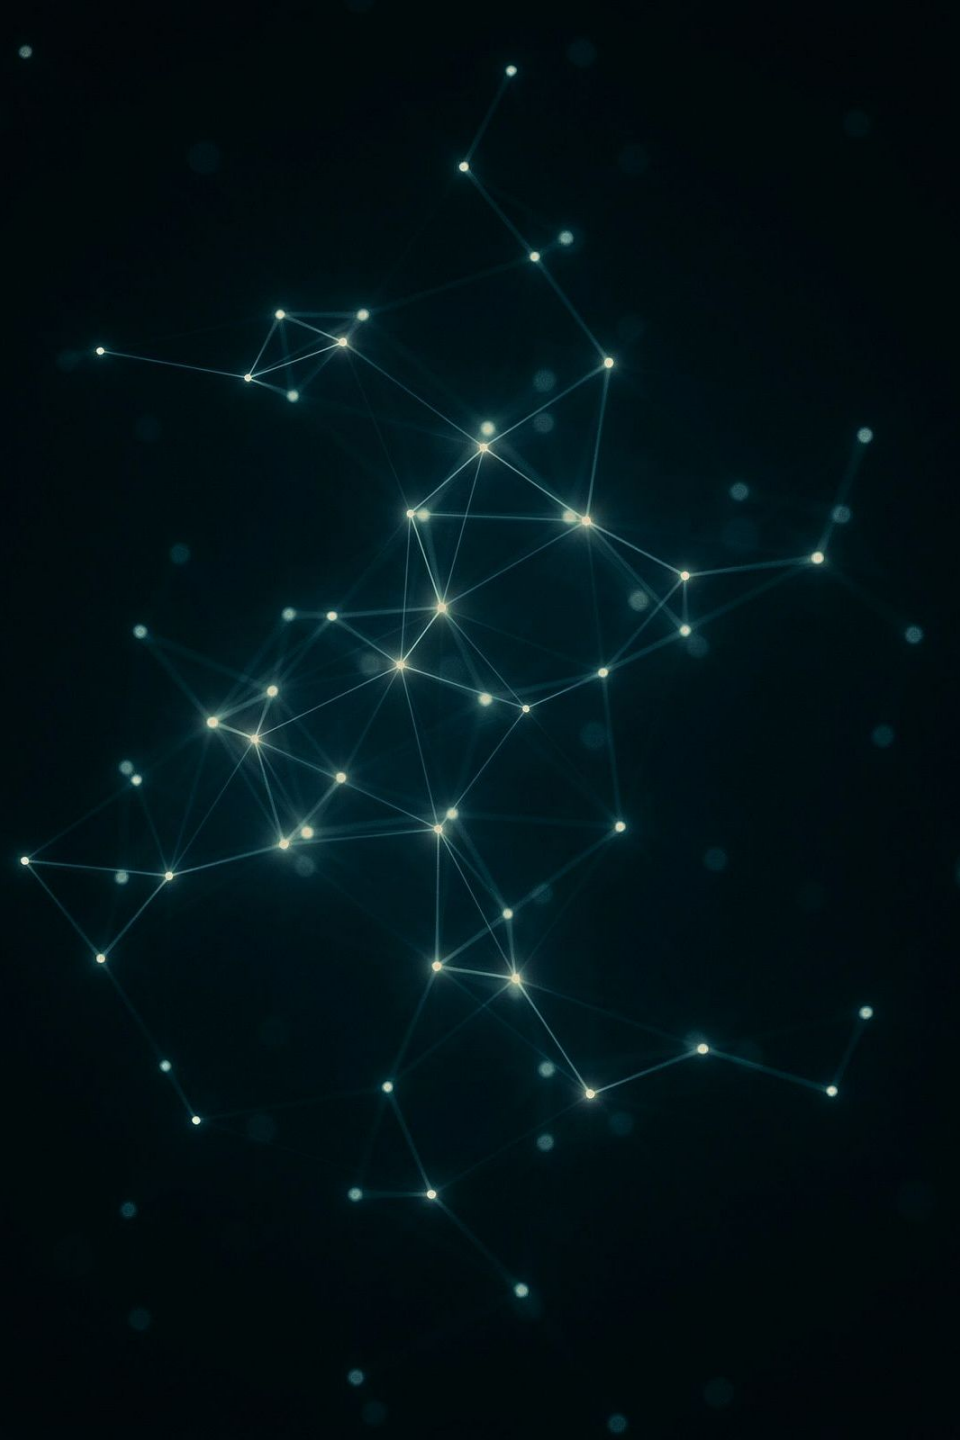


# Máquinas de Vectores de Soporte

## Sección 8.3 · Aprendizaje Automático

Las máquinas de vectores de soporte (SVM) son uno de los algoritmos de clasificación más potentes y elegantes del aprendizaje automático. Basadas en principios geométricos sólidos, ofrecen garantías teóricas únicas sobre la capacidad de generalización. En esta sección exploraremos los cuatro pilares fundamentales: el margen máximo, el truco del kernel, los parámetros de regularización y cuándo conviene —o no— aplicar SVM.

8.3 · SVM

# 1. El Margen Máximo

El objetivo central de una SVM es encontrar el **hiperplano de separación óptimo**: aquel que maximiza la distancia entre las clases. Esta distancia se denomina **margen**.

### Hiperplano separador

En un espacio de $n$ dimensiones, el hiperplano tiene dimensión $n–1$. En 2D es una recta; en 3D, un plano.

### Vectores de soporte

Son los puntos de entrenamiento más cercanos al hiperplano. Solo estos puntos **determinan completamente** la frontera de decisión.

### Maximización del margen

Maximizar el margen equivale a resolver un problema de optimización cuadrática convexa, con solución única y global garantizada.

### ¿Por qué importa el margen?

Un margen mayor implica mayor robustez frente a perturbaciones en los datos nuevos. La teoría de Vapnik-Chervonenkis demuestra que maximizar el margen minimiza el riesgo de sobreajuste.

# 2. El Truco del *Kernel*

Muchos problemas reales **no son linealmente separables** en su espacio original. El truco del *kernel* permite operar en espacios de alta dimensión sin calcular explícitamente las nuevas coordenadas.




## Kernels más habituales

### Lineal

$K(x,y) = x^T y$

Para datos ya separables linealmente.

### Polinomial

$K(x,y) = (x^T y + c)^d$

Captura interacciones entre características.

### RBF / Gaussiano

$K(x,y) = \exp(-\gamma \| x-y \|^2)$

El más versátil; fronteras no lineales complejas.

La clave del truco: la SVM solo necesita productos escalares entre puntos, que el kernel calcula directamente sin proyectar explícitamente al espacio de alta dimensión.

# 3. Parámetros C y Gamma

Ajustar correctamente estos dos hiperparámetros es crucial para obtener un modelo que generalice bien. Ambos controlan el equilibrio entre sesgo y varianza.



## Parámetro C (Regularización)

Controla la **penalización por errores de clasificación**. Un valor **C alto** penaliza mucho los errores → margen estrecho, posible sobreajuste. Un valor **C bajo** permite más errores → margen amplio, mayor generalización.



## Parámetro Gamma (kernel RBF)

Define el **alcance de influencia** de cada punto de entrenamiento. Un **gamma alto** → influencia local, fronteras muy complejas → sobreajuste. Un **gamma bajo** → influencia amplia, fronteras suaves → infraajuste.



## Búsqueda de hiperparámetros

La combinación óptima de C y gamma se determina mediante **validación cruzada** (k-fold CV) y búsqueda en rejilla (*grid search*) o búsqueda aleatoria, evaluando el rendimiento en el conjunto de validación.

# 4. ¿Cuándo Usar SVM?

Las SVM brillan en contextos específicos. Conocer sus puntos fuertes y sus limitaciones es esencial para elegirlas con criterio.

## ✓ Situaciones favorables

### → Espacios de alta dimensión

Clasificación de texto, datos genómicos o señales donde el número de características supera al de muestras.

### → Conjuntos de datos pequeños o medianos

Con pocos miles de muestras, la SVM supera con frecuencia a redes neuronales profundas sin necesitar grandes recursos.

### → Fronteras complejas no lineales

Con el kernel RBF, la SVM puede modelar separaciones muy intrincadas que escapan a modelos lineales.

## ✗ Limitaciones a considerar

### → Escalabilidad

El entrenamiento tiene complejidad $O(n^2)$ a $O(n^3)$. Con millones de muestras, el coste computacional se vuelve prohibitivo.

### → Elección del kernel

Seleccionar el kernel inadecuado puede degradar severamente el rendimiento. Requiere conocimiento del dominio o experimentación sistemática.

### → Interpretabilidad

A diferencia de los árboles de decisión, los modelos SVM con kernels no lineales son difíciles de interpretar y explicar a audiencias no técnicas.

S08 · EN EL REPOSITORIO DEL CURSO

# Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

## S08_04_svm

30 min

SVM: margen, kernels, C y gamma

sprints/S08/notebooks/S08_04_svm.ipynb

CUADERNO

## S08_05_busqueda_hiperparametros

30 min

GridSearchCV y RandomizedSearchCV

sprints/S08/notebooks/S08_05_busqueda_hiperparametros.ipynb

RETO

## Reto del sprint

25 min

Búsqueda de hiperparámetros para una familia, la que elijáis (paso 3)

sprints/S08/guia/Reto_Sprint_08.md

RETO

## Reto del sprint (sigue)

40 min

Sensibilidad de los pesos, elegir el campeón, test una sola vez, ficha del modelo y README (pasos 4–5)

sprints/S08/guia/Reto_Sprint_08.md