



Máquinas de Vectores de Soporte

Sección 8.3 · Aprendizaje Automático

Las máquinas de vectores de soporte (SVM) son uno de los algoritmos de clasificación más potentes y elegantes del aprendizaje automático. Basadas en principios geométricos sólidos, ofrecen garantías teóricas únicas sobre la capacidad de generalización. En esta sección exploraremos los cuatro pilares fundamentales: el margen máximo, el truco del kernel, los parámetros de regularización y cuándo conviene —o no— aplicar SVM.

8.3 · SVM

1. El Margen Máximo

El objetivo central de una SVM es encontrar el **hiperplano de separación óptimo**: aquel que maximiza la distancia entre las clases. Esta distancia se denomina **margen**.

Hiperplano separador

En un espacio de n dimensiones, el hiperplano tiene dimensión $n-1$. En 2D es una recta; en 3D, un plano.

Vectores de soporte

Son los puntos de entrenamiento más cercanos al hiperplano. Solo estos puntos **determinan completamente** la frontera de decisión.

Maximización del margen

Maximizar el margen equivale a resolver un problema de optimización cuadrática convexa, con solución única y global garantizada.

¿Por qué importa el margen?

Un margen mayor implica mayor robustez frente a perturbaciones en los datos nuevos. La teoría de Vapnik-Chervonenkis demuestra que maximizar el margen minimiza el riesgo de sobreajuste.

2. El Truco del *Kernel*

Muchos problemas reales **no son linealmente separables** en su espacio original. El truco del *kernel* permite operar en espacios de alta dimensión sin calcular explícitamente las nuevas coordenadas.



Kernels más habituales

Lineal

$$K(x,y) = x^T y$$

Para datos ya separables linealmente.

Polinomial

$$K(x,y) = (x^T y + c)^d$$

Captura interacciones entre características.

RBF / Gaussiano

$$K(x,y) = \exp(-\gamma \|x-y\|^2)$$

El más versátil; fronteras no lineales complejas.

❏ La clave del truco: la SVM solo necesita productos escalares entre puntos, que el kernel calcula directamente sin proyectar explícitamente al espacio de alta dimensión.

3. Parámetros C y Gamma

Ajustar correctamente estos dos hiperparámetros es crucial para obtener un modelo que generalice bien. Ambos controlan el equilibrio entre sesgo y varianza.



Parámetro C (Regularización)

Controla la **penalización por errores de clasificación**. Un valor **C alto** penaliza mucho los errores → margen estrecho, posible sobreajuste. Un valor **C bajo** permite más errores → margen amplio, mayor generalización.



Parámetro Gamma (kernel RBF)

Define el **alcance de influencia** de cada punto de entrenamiento. Un **gamma alto** → influencia local, fronteras muy complejas → sobreajuste. Un **gamma bajo** → influencia amplia, fronteras suaves → infraajuste.



Búsqueda de hiperparámetros

La combinación óptima de C y gamma se determina mediante **validación cruzada** (k-fold CV) y búsqueda en rejilla (*grid search*) o búsqueda aleatoria, evaluando el rendimiento en el conjunto de validación.

4. ¿Cuándo Usar SVM?

Las SVM brillan en contextos específicos. Conocer sus puntos fuertes y sus limitaciones es esencial para elegir las con criterio.

✓ Situaciones favorables

→ Espacios de alta dimensión

Clasificación de texto, datos genómicos o señales donde el número de características supera al de muestras.

→ Conjuntos de datos pequeños o medianos

Con pocos miles de muestras, la SVM supera con frecuencia a redes neuronales profundas sin necesitar grandes recursos.

→ Fronteras complejas no lineales

Con el kernel RBF, la SVM puede modelar separaciones muy intrincadas que escapan a modelos lineales.

✗ Limitaciones a considerar

→ Escalabilidad

El entrenamiento tiene complejidad $O(n^2)$ a $O(n^3)$. Con millones de muestras, el coste computacional se vuelve prohibitivo.

→ Elección del kernel

Seleccionar el kernel inadecuado puede degradar severamente el rendimiento. Requiere conocimiento del dominio o experimentación sistemática.

→ Interpretabilidad

A diferencia de los árboles de decisión, los modelos SVM con kernels no lineales son difíciles de interpretar y explicar a audiencias no técnicas.

SVM frente a Otros Algoritmos

Elegir el algoritmo correcto depende del contexto. Esta tabla compara las SVM con alternativas habituales en las dimensiones más relevantes.

Criterio	SVM	Regresión logística	Random Forest	Red neuronal
Datos pequeños	★★★★	★★	★★	★
Alta dimensión	★★★★	★★	★	★★
Grandes volúmenes	★	★★★★	★★	★★★★
Interpretabilidad	★	★★★★	★★	★
No linealidad	★★★★	★	★★★★	★★★★

Resumen y Conclusiones

Las SVM combinan elegancia matemática con potencia práctica. Estos son los conceptos clave que debes consolidar:



Margen máximo

La SVM busca el hiperplano que maximiza la distancia a ambas clases. Solo los **vectores de soporte** definen la frontera; el resto de puntos son irrelevantes para el modelo final.



Parámetros C y gamma

C regula la tolerancia al error; **gamma** controla el alcance del kernel. Ambos se ajustan con validación cruzada para evitar sobreajuste e infraajuste.



Truco del kernel

Permite clasificar datos no linealmente separables proyectándolos implícitamente a espacios de mayor dimensión. El kernel RBF es la elección más común y versátil.



Cuándo usar SVM

Ideales para datos de **alta dimensión y conjuntos pequeños**. Evítalas si tienes millones de muestras o necesitas modelos fácilmente interpretables.

📌 Próximo paso: practica ajustando C y gamma en un conjunto de datos real usando `sklearn.svm.SVC` con `GridSearchCV` para consolidar estos conceptos.