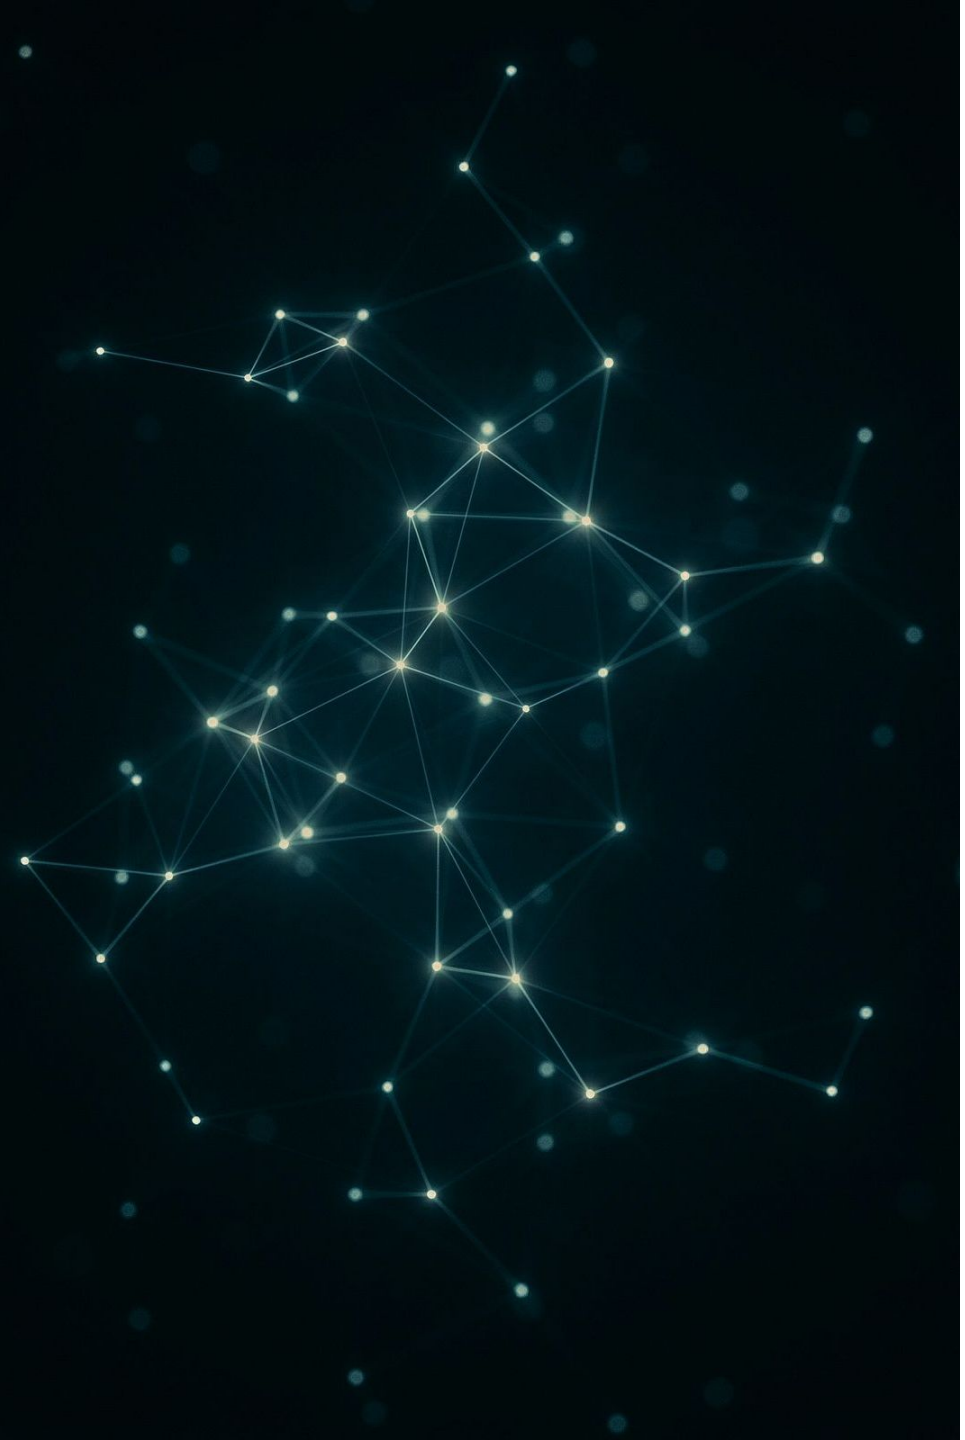


SVM y búsqueda de hiperparámetros

Sprint 8 · Duelo de modelos · S08.3

Última familia del duelo con las reservas de TurisData, y cómo ajustar los modelos sin hacer trampas.

SVM: la idea en dos dimensiones

Imagina cada reserva como un punto en un plano (por ejemplo antelacion_dias y precio_noche).

- Una SVM traza la recta que separa las dos clases dejando el pasillo (margen) más ancho posible.
- Los puntos que tocan el borde del pasillo son los vectores de soporte.
- Solo ellos definen la frontera: el resto podría desaparecer y la recta no cambiaría.

Dos botones: C y el kernel

C

Cuánto castigamos un punto mal clasificado — C grande → margen estrecho, ajusta mucho (riesgo de sobreajuste). C pequeño → margen ancho, más tolerancia a errores.

Kernel

¿Y si una recta no basta? — "linear": frontera recta. "rbf": «curva» el espacio y dibuja fronteras curvas.

gamma (solo RBF)

Cuánto influye cada punto. Alto → islotes alrededor de cada punto; bajo → casi una recta.

Cuaderno S08_04 · Ejercicio 1: las dos lunas

Datos de juguete (make_moons, 400 puntos): dos grupos con forma de luna que una recta no separa.

```
svm_lineal = SVC(kernel="linear", C=1)
svm_rbf    = SVC(kernel="rbf", C=1, gamma=1)
```

- El kernel RBF supera al lineal: la frontera se curva (acc_lineal frente a acc_rbf).
- Con gamma = 0.05 / 1 / 50 verás infraajuste → ajuste razonable → sobreajuste.
- Compara también el número de vectores de soporte (n_support_).

Con las reservas de TurisData: hay que escalar

Una SVM mide distancias: si precio_noche va de 40 a 400 y peticiones_especiales de 0 a 3, la primera lo domina todo.

```
Pipeline([("prep", prep_escalado()),      # StandardScaler + OneHotEncoder
          ("svm", SVC(kernel="rbf", C=1))])
```

- Evaluamos con el AUC usando decision_function (la distancia a la frontera ordena las reservas por riesgo).
- Ejercicio 2: compara auc_con_escalado y auc_sin_escalado. Escalar mejora claramente el AUC.

El precio de una SVM y cuándo usarla

Sí	No
Pocas filas y muchas variables	Muchas filas (millones): el tiempo crece más que linealmente
Fronteras curvas que una recta no capta	Hay que explicar cada decisión al cliente
Variables ya escaladas y limpias	Necesitas probabilidades rápidas (probability=True entrena ~5 veces más despacio)

En el duelo de TurisData, la SVM lineal rinde casi igual que la RBF y es más sencilla.

Hiperparámetros: los botones que fijamos nosotros (S08_05)

	Parámetros	Hiperparámetros
Quién los fija	El modelo, al entrenar	Nosotros, antes de entrenar
Ejemplos	coeficientes, umbrales de un árbol	max_depth, learning_rate, C, k, alpha

```
rejilla = {"rf__n_estimators": [100, 200], "rf__max_depth": [4, 8],
           "rf__min_samples_leaf": [10, 40]}                    # Ejercicio 1
busqueda_grid = GridSearchCV(pipe_rf, rejilla, cv=5, scoring="roc_auc")
```

El prefijo del paso (rf__) indica a qué parte del Pipeline pertenece.

RandomizedSearchCV y leer los resultados

```
distribuciones = {"lgb__learning_rate": loguniform(0.01, 0.3),
                  "lgb__num_leaves": randint(3, 40),
                  "lgb__min_child_samples": randint(10, 200)}          # Ejercicio 2
busqueda_rand = RandomizedSearchCV(pipe_lgb, distribuciones, n_iter=25, cv=5, scoring="roc_auc")
```

- Rejilla: todas las combinaciones (8 entrenamientos × 5 folds). Aleatoria: 25 combinaciones al azar; explora más valores distintos.
- cv_results_: suele haber muchas configuraciones empatadas. Regla del 1 error estándar: entre las empatadas, elige la más sencilla.
- La nota de la búsqueda es optimista («maldición del ganador»): el resultado honesto es el del test, una sola vez.

Cierre del duelo: campeón, test y model card

1. Registra SVM y los modelos que falten en el leaderboard (S08_06, Ejercicio 2).
2. Define tus pesos de rendimiento, explicabilidad y coste (suman 1) y calcula lb_pond (Ejercicio 3).
3. Reconstruye el campeón con catalogocampeon y evalúalo en test una sola vez (Ejercicio 4).
4. Rellena model_card.md: para qué sirve, con qué datos, cómo rinde y qué no debe usarse.

¿Cambia el campeón si varían los pesos?

Esa es la pregunta que el gerente querrá ver respondida.

S08 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO **S08_02_random_forest** — 30 min

Random Forest: bagging, OOB e importancia por permutación (los ejercicios marcados «en clase»)

sprints/S08/notebooks/S08_02_random_forest.ipynb

CUADERNO **S08_03_boosting_xgboost_lightgbm** — 25 min

Gradient Boosting, XGBoost y LightGBM (los ejercicios marcados «en clase»)

sprints/S08/notebooks/S08_03_boosting_xgboost_lightgbm.ipynb

CUADERNO **S08_06_leaderboard_plantilla** — 75 min

Leaderboard (*baseline*, logística, árbol y bosque), búsqueda de hiperparámetros para una familia, sensibilidad de…

sprints/S08/notebooks/S08_06_leaderboard_plantilla.ipynb