SPRINT 8 · DUELO DE MODELOS · S08.3

SVM y búsqueda de hiperparámetros

Última familia del duelo con las reservas de TurisData, y cómo ajustar los modelos sin hacer trampas.

SVM: la idea en dos dimensiones

Imagina cada reserva como un punto en un plano (por ejemplo `antelacion_dias` y `precio_noche`).

- Una SVM traza la recta que separa las dos clases dejando **el pasillo (margen) más ancho posible**.
- Los puntos que tocan el borde del pasillo son los **vectores de soporte**.
- **Solo ellos definen la frontera:** el resto podría desaparecer y la recta no cambiaría.

Dos botones: `C` y el kernel

`C`: cuánto castigamos un punto mal clasificado

`C` grande → margen estrecho, ajusta mucho (riesgo de sobreajuste). `C` pequeño → margen ancho, más tolerancia a errores.

Kernel: ¿y si una recta no basta?

`"linear"`: frontera recta. `"rbf"`: «curva» el espacio y dibuja fronteras curvas.

`gamma` (solo RBF)

Cuánto influye cada punto. Alto → islotes alrededor de cada punto; bajo → casi una recta.

Cuaderno S08_04 · Ejercicio 1: las dos lunas

Datos de juguete (`make_moons`, 400 puntos): dos grupos con forma de luna que una recta no separa.

```
svm_lineal = SVC(kernel="linear", C=1)
svm_rbf    = SVC(kernel="rbf", C=1, gamma=1)
```

- El kernel **RBF** supera al lineal: la frontera se curva (`acc_lineal` frente a `acc_rbf`).
- Con `gamma` = 0.05 / 1 / 50 verás **infraajuste → ajuste razonable → sobreajuste**.
- Compara también el número de vectores de soporte (`n_support_`).

Con las reservas de TurisData: hay que escalar

Una SVM mide **distancias**: si `precio_noche` va de 40 a 400 y `peticiones_especiales` de 0 a 3, la primera lo domina todo.

```
Pipeline([("prep", prep_escalado()),      # StandardScaler + OneHotEncoder
          ("svm", SVC(kernel="rbf", C=1))])
```

- Evaluamos con el **AUC** usando `decision_function` (la distancia a la frontera ordena las reservas por riesgo).
- Ejercicio 2: compara `auc_con_escalado` y `auc_sin_escalado`. Escalar mejora claramente el AUC.

El precio de una SVM y cuándo usarla

Sí	No
Pocas filas y muchas variables	Muchas filas (millones): el tiempo crece más que linealmente
Fronteras curvas que una recta no capta	Hay que explicar cada decisión al cliente
Variables ya escaladas y limpias	Necesitas probabilidades rápidas (`probability=True` entrena ~5 veces más despacio)

En el duelo de TurisData, la SVM **lineal** rinde casi igual que la RBF y es más sencilla.

Hiperparámetros: los botones que fijamos nosotros (S08_05)

	Parámetros	Hiperparámetros
Quién los fija	El **modelo**, al entrenar	**Nosotros**, antes de entrenar
Ejemplos	coeficientes, umbrales de un árbol	`max_depth`, `learning_rate`, `C`, `k`, `alpha`

```
rejilla = {"rf__n_estimators": [100, 200], "rf__max_depth": [4, 8],
           "rf__min_samples_leaf": [10, 40]}                          # Ejercicio 1
busqueda_grid = GridSearchCV(pipe_rf, rejilla, cv=5, scoring="roc_auc")
```

El prefijo del paso (`rf__`) indica a qué parte del `Pipeline` pertenece.

`RandomizedSearchCV` y leer los resultados

```
distribuciones = {"lgb__learning_rate": loguniform(0.01, 0.3),
                  "lgb__num_leaves": randint(3, 40),
                  "lgb__min_child_samples": randint(10, 200)}            # Ejercicio 2
busqueda_rand = RandomizedSearchCV(pipe_lgb, distribuciones, n_iter=25, cv=5, scoring="roc_auc")
```

- **Rejilla**: todas las combinaciones (8 entrenamientos × 5 folds). **Aleatoria**: 25 combinaciones al azar; explora más valores distintos.
- `cv_results_`: suele haber **muchas configuraciones empatadas**. Regla del **1 error estándar**: entre las empatadas, elige la **más sencilla**.
- **La nota de la búsqueda es optimista** («maldición del ganador»): el resultado honesto es el del **test, una sola vez**.

Cierre del duelo: campeón, test y model card

1. Registra SVM y los modelos que falten en el leaderboard (`S08_06`, Ejercicio 2).
2. Define tus `pesos` de rendimiento, explicabilidad y coste (suman 1) y calcula `lb_pond` (Ejercicio 3).
3. Reconstruye el campeón con `catalogo[campeon]()` y evalúalo en test **una sola vez** (Ejercicio 4).
4. Rellena `model_card.md`: para qué sirve, con qué datos, cómo rinde y **qué no debe usarse**.

> ¿Cambia el campeón si varían los pesos? Esa es la pregunta que el gerente querrá ver respondida.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S08_04_svm

30 min

SVM: margen, kernels, C y gamma

sprints/S08/notebooks/S08_04_svm.ipynb

CUADERNO

S08_05_busqueda_hiperparametros

30 min

GridSearchCV y RandomizedSearchCV

sprints/S08/notebooks/S08_05_busqueda_hiperparametros.ipynb

RETO

Reto del sprint

65 min

Búsqueda de hiperparámetros para una familia, la que elijáis (paso 3)

sprints/S08/guia/Reto_Sprint_08.md