ETAPA B · CONSTRUIR · SPRINT 8 DE 17

README Sprint S08 · Árboles, ensembles y SVM

¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?

FECHAS
10–11 de noviembre

HORAS
12 h (3 h teoría · 4 h práctica guiada · 5 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C` , `gamma` , kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con `GridSearchCV` y `RandomizedSearchCV` sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

Requisitos previos

- Sprint 6 y 7: pipelines, validación cruzada, métricas de clasificación (AUC, precisión, recall), umbral y regresión logística como referencia.
- Datos: `datos/reservas_turisdata.csv` (objetivo `cancelada`). Los notebooks lo descargan solos si no lo encuentran.
- Librerías: scikit-learn, xgboost y lightgbm (vienen instaladas en Colab; en local: `pip install xgboost lightgbm`).

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta del cliente, los pasos, lo que se entrega y lo que se aprende	—	Antes del planning
Infografías del reto	4 láminas ilustradas del reto	—	Reto
Atlas de algoritmos	Atlas de algoritmos del sprint: árbol, Random Forest, boosting, SVM y ajuste de hiperparámetros	—	Teoría y práctica; consulta cuando elijas modelo
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S08.1_Arboles_de_decision.pdf`	Árboles de decisión	15 min	Teoría · martes 10/11
`S08.2_Ensembles_Random_Forest_y_Boosting.pdf`	Ensembles: Random Forest y *boosting*	20 min	Teoría · martes 10/11

Material	Tema	Tiempo	Cuándo
`S08.3 Maquinas de vectores de soporte.pdf`	Máquinas de vectores de soporte (SVM)	15 min	Teoría · miércoles 11/11
Test de conocimientos	Test de M3 · parte 2 · 10 preguntas · individual, en el navegador, sin penalización por fallo.5 a 3.8 (k-NN y Naive Bayes, árboles, ensembles y SVM).	20 min	Solo se abre el mié 11/11 (hora de Canarias)

Material de las actividades

Notebook	Tema	Tiempo	Colab
`S08_01_arboles_decision`	Árbol de decisión: reglas, sobreajuste, poda, importancia	35 min	Abrir en Colab
`S08_02_random_forest`	Random Forest: bagging, OOB, importancia por permutación	40 min	Abrir en Colab
`S08_03_boosting_xgboost_lightgbm`	Gradient Boosting, XGBoost, LightGBM y parada temprana	45 min	Abrir en Colab
`S08_04_svm`	SVM: margen, kernels, `C`, `gamma`, escalado y coste	30 min	Abrir en Colab
`S08_05_busqueda_hiperparametros`	`GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final	30 min	Abrir en Colab
`S08_06_leaderboard_plantilla`	**Herramienta del reto**: leaderboard para rellenar	dentro del reto	Abrir en Colab

Las cinco primeras son prácticas guiadas; la sexta es la plantilla del reto. Los ejercicios se autocorrigen con `assert`.

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Martes 10/11

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Duelo de modelos» y pesos de los criterios (la «voz del cliente»)	10 min
2	Teoría	Árboles de decisión	15 min
3	Práctica	Árbol de decisión: reglas, poda e importancia	35 min
4	Teoría	Ensembles: Random Forest y *boosting*	20 min
5	Práctica	Random Forest: bagging, OOB e importancia por permutación	40 min
6	Práctica	Gradient Boosting, XGBoost y LightGBM	45 min
7	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	10 min
8	Reto	Primeros modelos en el *leaderboard* (*baseline*, logística, árbol y bosque; pasos 1–2)	25 min

Miércoles 11/11

Nº	Tipo	Qué se hace	Tiempo
9	Teoría	Máquinas de vectores de soporte (SVM)	15 min
10	Práctica	SVM: margen, kernels, `C` y `gamma`	30 min
11	Práctica	`GridSearchCV` y `RandomizedSearchCV`	30 min

Nº	Tipo	Qué se hace	Tiempo
12	Reto	Búsqueda de hiperparámetros para una familia, la que elijáis (paso 3)	25 min
13	Reto	Sensibilidad de los pesos, elegir el campeón, test **una sola vez**, ficha del modelo y README (pasos 4–5)	40 min
14	Test	**Test de M3 (parte 2)**, solo se abre hoy	25 min
15	Ceremonia	Entrega en `sprint-08/`, autoevaluación y coevaluación, review y retrospectiva	35 min

RETO Reto · «Duelo de modelos»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData ya sabe predecir cancelaciones y ahora quiere saber qué modelo poner en producción: ¿el más preciso, el más comprensible o el más barato de mantener? Enfrentáis árboles, bosques, *boosting* y SVM y elegís un campeón con argumentos.

Entregáis (carpeta `sprint-08/` del repositorio del equipo):

- `leaderboard_S08.csv` con ≥ 6 modelos (*baseline* y logística incluidos). Plantilla: `leaderboard_plantilla.csv`.
- `model_card.md` del campeón (1–2 páginas). Plantilla: `model_card_plantilla.md`.
- `reto_S08.ipynb` con la comparación y la búsqueda de hiperparámetros de al menos dos familias.
- `README.md` (versiones, semilla, orden de ejecución).

Reglas:

- Unas 4 h en equipo; máx. 8 modelos; cada búsqueda, 5 min como máximo en Colab; `SEMILLA = 42`.
- Búsqueda solo sobre train; el test se usa una vez, solo con el campeón.
- Nunca claves ni datos personales. Review: 5 min por equipo.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (usos no previstos, deriva, país de origen), más campeón justificado con rendimiento, explicabilidad y coste.

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 11/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Leaderboard con ≥ 6 modelos de al menos 4 familias
- [ ] Hiperparámetros buscados con validación cruzada en train para dos familias
- [ ] AUC de test calculado una sola vez y `model_card.md` completa
- [ ] Entregable subido a la carpeta `sprint-08/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas