ETAPA B · CONSTRUIR · SPRINT 8 DE 17

# README Sprint S08 · Árboles, ensembles y SVM

*¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?*

**FECHAS**
10–11 de noviembre

**HORAS**
12 h (3 h teoría · 4 h práctica guiada · 5 h PBL)

**ESTE README EN PDF**
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

## Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** ( `C` , `gamma` , kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con **`GridSearchCV`** y **`RandomizedSearchCV`** sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

## Requisitos previos

- Sprint 6 y 7: pipelines, validación cruzada, métricas de clasificación (AUC, precisión, recall), umbral y regresión logística como referencia.
- Datos: `datos/reservas_turisdata.csv` (objetivo `cancelada` ). Los notebooks lo descargan solos si no lo encuentran.
- Librerías: scikit-learn, xgboost y lightgbm (vienen instaladas en Colab; en local: `pip install xgboost lightgbm` ).

## Materiales del sprint

**Documentos del curso** (PDF y .md; las actividades van en la tabla siguiente)

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Guía del sprint (PDF) · ecofriendly | Resumen del sprint: qué aprenderás, temario, material, reto y conclusión | 2 páginas | Antes de empezar |
| **Carpeta del reto: `Reto_S08/`** | Todo el material del reto junto: ficha (.md y PDF), plantillas y material de apoyo, hoja de autoevaluación y coevaluación y láminas del reto | — | Antes del planning y durante el reto |
| Reto completo, paso a paso (.md) · PDF · ecofriendly | Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes | — | Antes del planning y durante el reto |
| Resumen del sprint en una página | Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso | — | Antes del planning |
| El reto paso a paso · PDF con enlaces | Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA | — | Durante el reto |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Esquema del contenido y su relación con el reto | Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después | — | Antes del planning y como guía durante el reto |
| Infografías del sprint | 3 láminas ilustradas | — | Antes del planning y durante el reto |
| Atlas de algoritmos | Atlas de algoritmos del sprint: árbol, Random Forest, boosting, SVM y ajuste de hiperparámetros | — | Teoría y práctica; consulta cuando elijas modelo |
| Cómo se trabaja un reto | El método de trabajo de todos los retos | — | Antes del primer reto |
| `S08.1_Arboles_de_decision.pdf` | Árboles de decisión | 15 min | Teoría · día 1 del S08 |
| `S08.2_Ensembles_Random_Forest_y_Boosting.pdf` | Ensembles: Random Forest y *boosting* | 20 min | Teoría · día 1 del S08 |
| `S08.3_Maquinas_de_vectores_de_soporte.pdf` | Máquinas de vectores de soporte (SVM) | 15 min | Teoría · día 2 del S08 |
| Test de conocimientos | Test de M3 · parte 2 · 10 preguntas · individual, en el navegador, sin penalización por fallo.5 a 3.8 (k-NN y Naive Bayes, árboles, ensembles y SVM). | 20 min | Solo se abre el mié 11/11 (hora de Canarias) |

**Material de las actividades**

| Notebook | Tema | Tiempo | Colab |
|---|---|---|---|
| `apuntes_arboles_ensembles_y_svm.md` · PDF · ecofriendly | **Apuntes que complementan las diapositivas**: árboles de decisión, Random Forest, boosting, SVM, hiperparámetros y cómo elegir un campeón (rendimiento, explicabilidad y coste) explicados con ejemplos que puedes calcular a mano | — | Antes del sprint y cuando tengas dudas |
| `S08_01_arboles_decision` | Árbol de decisión: reglas, sobreajuste, poda, importancia | 35 min | Abrir en Colab |
| `S08_02_random_forest` | Random Forest: bagging, OOB, importancia por permutación | 40 min | Abrir en Colab |
| `S08_03_boosting_xgboost_lightgbm` | Gradient Boosting, XGBoost, LightGBM y parada temprana | 45 min | Abrir en Colab |
| `S08_04_svm` | SVM: margen, kernels, `C`, `gamma`, escalado y coste | 30 min | Abrir en Colab |
| `S08_05_busqueda_hiperparametros` | `GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final | 30 min | Abrir en Colab |
| `S08_06_leaderboard_plantilla` | **Herramienta del reto**: leaderboard para rellenar | dentro del reto | Abrir en Colab |

Las cinco primeras son prácticas guiadas; la sexta es la plantilla del reto. Los ejercicios se autocorrigen con `assert`.

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

**Día 1 del S08**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 1 | Ceremonia | Planning del reto «Duelo de modelos» y pesos de los criterios (la «voz del cliente») | 10 min |
| 2 | Teoría | Árboles de decisión | 15 min |
| 3 | Práctica | Árbol de decisión: reglas, poda e importancia | 35 min |
| 4 | Teoría | Ensembles: Random Forest y *boosting* | 20 min |
| 5 | Práctica | Random Forest: bagging, OOB e importancia por permutación | 40 min |
| 6 | Práctica | Gradient Boosting, XGBoost y LightGBM | 45 min |
| 7 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 10 min |
| 8 | Reto | Primeros modelos en el *leaderboard* (*baseline*, logística, árbol y bosque; pasos 1–2) | 25 min |

**Día 2 del S08**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 9 | Teoría | Máquinas de vectores de soporte (SVM) | 15 min |
| 10 | Práctica | SVM: margen, kernels, `C` y `gamma` | 30 min |
| 11 | Práctica | `GridSearchCV` y `RandomizedSearchCV` | 30 min |
| 12 | Reto | Búsqueda de hiperparámetros para una familia, la que elijáis (paso 3) | 25 min |
| 13 | Reto | Sensibilidad de los pesos, elegir el campeón, test **una sola vez**, ficha del modelo y README (pasos 4–5) | 40 min |
| 14 | Test | **Test de M3 (parte 2)**, solo se abre hoy | 25 min |
| 15 | Ceremonia | Entrega en `sprint-08/`, autoevaluación y coevaluación, review y retrospectiva | 35 min |

### RETO Reto · «Duelo de modelos»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

**Ver el reto completo, explicado paso a paso** (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData ya sabe predecir cancelaciones y ahora quiere saber qué modelo poner en producción: ¿el más preciso, el más comprensible o el más barato de mantener? Enfrentáis árboles, bosques, *boosting* y SVM y elegís un campeón con argumentos.

**Entregáis** (carpeta `sprint-08/` del repositorio del equipo):

- `leaderboard_S08.csv` con ≥ 6 modelos (*baseline* y logística incluidos). Plantilla: `leaderboard_plantilla.csv`.
- `model_card.md` del campeón (1–2 páginas). Plantilla: `model_card_plantilla.md`.
- `reto_S08.ipynb` con la comparación y la búsqueda de hiperparámetros de al menos dos familias.
- `README.md` (versiones, semilla, orden de ejecución).

**Reglas:**

- Unas 4 h en equipo; máx. 8 modelos; cada búsqueda, 5 min como máximo en Colab; `SEMILLA = 42`.
- Búsqueda solo sobre train; el test se usa una vez, solo con el campeón.
- Nunca claves ni datos personales. Review: 5 min por equipo.

**Se valora:** corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (usos no previstos, deriva, país de origen), más campeón justificado con rendimiento, explicabilidad y coste.

## Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 11/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Leaderboard con ≥ 6 modelos de al menos 4 familias
- [ ] Hiperparámetros buscados con validación cruzada en train para dos familias
- [ ] AUC de test calculado una sola vez y `model_card.md` completa
- [ ] Entregable subido a la carpeta `sprint-08/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas