ETAPA B · CONSTRUIR · SPRINT 8 DE 17

README Sprint S08 · Árboles, ensembles y SVM

¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?

FECHAS
10–11 de noviembre

HORAS
12 h (3 h teoría · 4 h práctica guiada · 5 h PBL)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. Entrenar un **árbol de decisión**, detectar su sobreajuste, podarlo y leer sus reglas y su importancia de variables.
2. Explicar la diferencia entre **bosque aleatorio** (promediar árboles) y **boosting** (corregir errores en cadena), y usar XGBoost y LightGBM con parada temprana.
3. Ajustar una **SVM** (`C` , `gamma` , kernel) y saber cuándo su coste la descarta.
4. Buscar hiperparámetros con `GridSearchCV` y `RandomizedSearchCV` sin engañarte con la nota de validación.
5. **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste, y documentarlo en una *model card*.

Requisitos previos

- Sprint 6 y 7: pipelines, validación cruzada, métricas de clasificación (AUC, precisión, recall), umbral y regresión logística como referencia.
- Datos: `datos/reservas_turisdata.csv` (objetivo `cancelada`). Los notebooks lo descargan solos si no lo encuentran.
- Librerías: scikit-learn, xgboost y lightgbm (vienen instaladas en Colab; en local: `pip install xgboost lightgbm`).

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta del cliente, los pasos, lo que se entrega y lo que se aprende	—	Antes del planning
Esquema del contenido y su relación con el reto	Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después	—	Antes del planning y como guía durante el reto
Infografías del reto	5 láminas ilustradas del reto	—	Reto
Atlas de algoritmos	Atlas de algoritmos del sprint: árbol, Random Forest, boosting, SVM y ajuste de hiperparámetros	—	Teoría y práctica; consulta cuando elijas modelo
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto

Material	Tema	Tiempo	Cuándo
`S08.1 Arboles de decision.pdf`	Árboles de decisión	15 min	Teoría · martes 10/11
`S08.2_Ensembles_Random_Forest_y_Boosting.pdf`	Ensembles: Random Forest y *boosting*	20 min	Teoría · martes 10/11
`S08.3_Maquinas_de_vectores_de_soporte.pdf`	Máquinas de vectores de soporte (SVM)	15 min	Teoría · miércoles 11/11
Test de conocimientos	Test de M3 · parte 2 · 10 preguntas · individual, en el navegador, sin penalización por fallo.5 a 3.8 (k-NN y Naive Bayes, árboles, ensembles y SVM).	20 min	Solo se abre el mié 11/11 (hora de Canarias)

Material de las actividades

Notebook	Tema	Tiempo	Colab
`S08_01_arboles_decision`	Árbol de decisión: reglas, sobreajuste, poda, importancia	35 min	Abrir en Colab
`S08_02_random_forest`	Random Forest: bagging, OOB, importancia por permutación	40 min	Abrir en Colab
`S08_03_boosting_xgboost_lightgbm`	Gradient Boosting, XGBoost, LightGBM y parada temprana	45 min	Abrir en Colab
`S08_04_svm`	SVM: margen, kernels, `C`, `gamma`, escalado y coste	30 min	Abrir en Colab
`S08_05_busqueda_hiperparametros`	`GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final	30 min	Abrir en Colab
`S08_06_leaderboard_plantilla`	**Herramienta del reto**: leaderboard para rellenar	dentro del reto	Abrir en Colab

Las cinco primeras son prácticas guiadas; la sexta es la plantilla del reto. Los ejercicios se autocorrigen con `assert`.

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Martes 10/11

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Duelo de modelos» y pesos de los criterios (la «voz del cliente»)	10 min
2	Teoría	Árboles de decisión	15 min
3	Práctica	Árbol de decisión: reglas, poda e importancia	35 min
4	Teoría	Ensembles: Random Forest y *boosting*	20 min
5	Práctica	Random Forest: bagging, OOB e importancia por permutación	40 min
6	Práctica	Gradient Boosting, XGBoost y LightGBM	45 min
7	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	10 min
8	Reto	Primeros modelos en el *leaderboard* (*baseline*, logística, árbol y bosque; pasos 1–2)	25 min

Miércoles 11/11

Nº	Tipo	Qué se hace	Tiempo
9	Teoría	Máquinas de vectores de soporte (SVM)	15 min
10	Práctica	SVM: margen, kernels, `C` y `gamma`	30 min
11	Práctica	`GridSearchCV` y `RandomizedSearchCV`	30 min
12	Reto	Búsqueda de hiperparámetros para una familia, la que elijáis (paso 3)	25 min
13	Reto	Sensibilidad de los pesos, elegir el campeón, test **una sola vez**, ficha del modelo y README (pasos 4–5)	40 min
14	Test	**Test de M3 (parte 2)**, solo se abre hoy	25 min
15	Ceremonia	Entrega en `sprint-08/`, autoevaluación y coevaluación, review y retrospectiva	35 min

RETO Reto · «Duelo de modelos»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData ya sabe predecir cancelaciones y ahora quiere saber qué modelo poner en producción: ¿el más preciso, el más comprensible o el más barato de mantener? Enfrentáis árboles, bosques, *boosting* y SVM y elegís un campeón con argumentos.

Entregáis (carpeta `sprint-08/` del repositorio del equipo):

- `leaderboard_S08.csv` con ≥ 6 modelos (*baseline* y logística incluidos). Plantilla: `leaderboard_plantilla.csv`.
- `model_card.md` del campeón (1–2 páginas). Plantilla: `model_card_plantilla.md`.
- `reto_S08.ipynb` con la comparación y la búsqueda de hiperparámetros de al menos dos familias.
- `README.md` (versiones, semilla, orden de ejecución).

Reglas:

- Unas 4 h en equipo; máx. 8 modelos; cada búsqueda, 5 min como máximo en Colab; `SEMILLA = 42`.
- Búsqueda solo sobre train; el test se usa una vez, solo con el campeón.
- Nunca claves ni datos personales. Review: 5 min por equipo.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (usos no previstos, deriva, país de origen), más campeón justificado con rendimiento, explicabilidad y coste.

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 11/11
- [ ] Notebook ejecutable de principio a fin (`Restart & Run all`)
- [ ] Leaderboard con ≥ 6 modelos de al menos 4 familias
- [ ] Hiperparámetros buscados con validación cruzada en train para dos familias
- [ ] AUC de test calculado una sola vez y `model_card.md` completa
- [ ] Entregable subido a la carpeta `sprint-08/` del repositorio del equipo
- [ ] Autoevaluación y coevaluación rellenadas