Sprint 8 · Árboles, ensembles y SVM

¿cuál es el mejor modelo y cuánto nos cuesta mantenerlo?

FECHAS
9–11 de noviembre

HORAS
11 h (3 h teoría · 5 h práctica guiada · 3 h PBL)

Reto de este sprint: «Duelo de modelos». Ver el reto completo, explicado paso a paso · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

Material del sprint

- **Guía del sprint (PDF):** `Guia_Sprint_08.pdf` · versión ecofriendly para imprimir
- **Reto completo, paso a paso:** `Reto_Sprint_08.md`
- **S08.1 · Arboles de decision:** `S08.1_Arboles_de_decision.pdf`
- **S08.2 · Ensembles Random Forest y Boosting:** `S08.2_Ensembles_Random_Forest_y_Boosting.pdf`
- **S08.3 · Maquinas de vectores de soporte:** `S08.3_Maquinas_de_vectores_de_soporte.pdf`

Contenidos: M3 UD 3.6 (árboles de decisión), UD 3.7 (Random Forest, Gradient Boosting, XGBoost y LightGBM) y UD 3.8 (SVM), más ajuste de hiperparámetros (`GridSearchCV`, `RandomizedSearchCV`). **Evaluación:** test de M3 (parte 2, el 11/11) y reto PBL «Duelo de modelos».

En esta carpeta: `guia/` PDF de la guía (normal y para imprimir) y el reto explicado paso a paso · `presentaciones/` diapositivas de cada sesión · `notebooks/` prácticas para abrir en Colab · `plantillas/` plantillas para el reto · `tests/` test de conocimientos

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Teoría = diapositivas · Práctica = cuaderno de Colab o actividad · Reto = trabajo en equipo · Ceremonia = momento de Scrum

Sesión 1

1. **Ceremonia**: Planning del reto y pesos de los criterios (la «voz del cliente») · *30 min*
2. **Teoría**: Árboles de decisión · *45 min*
3. **Teoría**: Ensembles: Random Forest (primera parte) · *45 min*
4. **Práctica**: Árbol de decisión: reglas, poda e importancia · *55 min*
5. **Práctica**: Random Forest: bagging, OOB e importancia por permutación · *55 min*
6. **Reto**: Primeros modelos en el *leaderboard* (*baseline*, logística, árbol y bosque; pasos 1–2) · *resto de la sesión*

Sesión 2

7. **Teoría**: Ensembles: *boosting* · *45 min*
8. **Teoría**: Máquinas de vectores de soporte (SVM) · *45 min*
9. **Práctica**: Gradient Boosting, XGBoost y LightGBM · *65 min*
10. **Práctica**: SVM: margen, kernels, C y `gamma` · *55 min*
11. **Práctica**: `GridSearchCV` y `RandomizedSearchCV` · *60 min*
12. **Reto**: Búsqueda de hiperparámetros para dos familias (paso 3) · *resto de la sesión*

Sesión 3

13. **Reto**: Sensibilidad de los pesos, elegir el campeón, test **una sola vez**, ficha del modelo y README (pasos 4–5) · *2 h*
14. **Ceremonia**: Review y retrospectiva · *última hora*

Qué aprenderás

- Entrenar y podar un **árbol de decisión**; entender bosques aleatorios y *boosting* (XGBoost, LightGBM).
- Ajustar una **SVM** y buscar hiperparámetros con `GridSearchCV` y `RandomizedSearchCV`.
- **Elegir un modelo campeón** justificando rendimiento, explicabilidad y coste.
- Hace falta lo de los Sprints 6 y 7; en local: `pip install xgboost lightgbm`.

Prácticas

Notebook	Tema	Tiempo
`S08_01_arboles_decision`	Árbol de decisión: reglas, sobreajuste, poda, importancia	55 min
`S08_02_random_forest`	Random Forest: bagging, OOB, importancia por permutación	55 min
`S08_03_boosting_xgboost_lightgbm`	Gradient Boosting, XGBoost, LightGBM y parada temprana	65 min
`S08_04_svm`	SVM: margen, kernels, `C`, `gamma`, escalado y coste	55 min
`S08_05_busqueda_hiperparametros`	`GridSearchCV`, `RandomizedSearchCV`, `cv_results_`, test final	60 min
`S08_06_leaderboard_plantilla`	**Herramienta del reto**: leaderboard para rellenar	45 min

Las cinco primeras son prácticas guiadas; la sexta es la plantilla del reto. Los ejercicios se autocorrigen con `assert`.

RETO Reto · «Duelo de modelos»

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData ya sabe predecir cancelaciones y ahora quiere saber qué modelo poner en producción: ¿el más preciso, el más comprensible o el más barato de mantener? Enfrentáis árboles, bosques, *boosting* y SVM y elegís un campeón con argumentos.

Entregáis (carpeta `sprint-08/` del repositorio del equipo):

- `leaderboard_S08.csv` con ≥ 6 modelos (*baseline* y logística incluidos). Plantilla: `leaderboard_plantilla.csv`.
- `model_card.md` del campeón (1–2 páginas). Plantilla: `model_card_plantilla.md`.
- `reto_S08.ipynb` con la comparación y la búsqueda de hiperparámetros de al menos dos familias.
- `README.md` (versiones, semilla, orden de ejecución).

Reglas:

- 3 h en equipo; máx. 8 modelos; cada búsqueda, 5 min como máximo en Colab; `SEMILLA = 42`.
- Búsqueda solo sobre train; el test se usa una vez, solo con el campeón.
- Nunca claves ni datos personales. Review: 5 min por equipo.

Se valora: corrección técnica, reproducibilidad, comunicación al cliente e IA responsable (usos no previstos, deriva, país de origen), más campeón justificado con rendimiento, explicabilidad y coste.

Test de conocimientos · mié 11/11

Test de M3 · parte 2 · 10 preguntas · unos 20 min · individual, en el navegador, sin penalización por fallo. Cubre M3, UD 3.5 a 3.8 (k-NN y Naive Bayes, árboles, ensembles y SVM).

Abrir el test (`https://ccoolboox.github.io/IFCD107-alumnado/sprints/S08/tests/test_M3_parte2.html`)

Solo se abre el día mié 11/11 (hora de Canarias). Al terminar, copia tu resultado y envíaselo al docente. Cuenta para el 30 % de «tests de conocimientos».

Definition of Done · antes de cerrar el sprint

- ☐ Test de conocimientos hecho el mié 11/11
- ☐ Notebook ejecutable de principio a fin (`Restart & Run all`)
- ☐ Leaderboard con ≥ 6 modelos de al menos 4 familias
- ☐ Hiperparámetros buscados con validación cruzada en train para dos familias
- ☐ AUC de test calculado una sola vez y `model_card.md` completa
- ☐ Entregable subido a la carpeta `sprint-08/` del repositorio del equipo
- ☐ Autoevaluación y coevaluación rellenadas