# Sprint 8 · Reto «Duelo de modelos»

**Esta es la ficha completa del reto, explicada paso a paso** para quien nunca ha trabajado con esta metodología ni con IA. Léela entera **antes de empezar** y vuelve a ella cuando tengas dudas.

- Si es tu primer reto, lee antes Cómo se trabaja un reto.
- Volver al README del sprint · Guía del sprint en PDF · versión ecofriendly para imprimir.
- **Este reto en PDF:** a color · ecofriendly, para imprimir.

## RETO Ficha del reto

### En pocas palabras (léelo primero)

**Qué os pide el cliente.** TurisData ya sabe que se pueden predecir las cancelaciones (lo visteis en el Sprint 7). Ahora la pregunta es: **¿qué modelo ponemos en producción?** El gerente duda: *«¿el más preciso? ¿el que yo pueda entender? ¿el más barato de mantener?»*. Vuestro equipo tiene que **enfrentar varios modelos** (árboles, bosques, boosting y SVM), compararlos con las mismas reglas y **elegir un campeón con argumentos**.

**La idea clave:** en la vida real **el modelo más preciso no siempre es el mejor**. Un modelo un poco peor, pero que se entiende y se mantiene fácilmente, puede ser la mejor decisión. Aprenderéis a decidir con **tres criterios**: rendimiento, explicabilidad y coste.

**Qué vais a hacer, en seis pasos:**

1. **Acordar los pesos** de los tres criterios con la «voz del cliente» (¿qué importa más?).
2. **Entrenar y registrar** al menos 6 modelos en el *leaderboard* (tabla de resultados), todos medidos igual.
3. **Buscar los mejores ajustes** (hiperparámetros) para al menos dos familias de modelos.
4. **Elegir el campeón** y comprobar si la elección cambia al variar los pesos.
5. **Evaluar el campeón en el test, una sola vez.**
6. **Escribir la *model card*** (la «ficha técnica» del modelo) y el README.

**Qué vais a entregar:** `leaderboard_S08.csv` (plantilla), `model_card.md` (plantilla), el cuaderno `reto_S08.ipynb` y `README.md`.

**Qué vais a aprender haciéndolo:** a comparar modelos de forma **justa**, a **ajustar hiperparámetros sin hacer trampas**, y a **documentar un modelo** como se hace en las empresas.

**Cuánto tiempo:** unas 2 horas y 15 minutos en equipo entre el planning, el reto y la entrega (días 1 y 2).

**Núcleo y extra.** Núcleo: *leaderboard* con tres familias de modelos, pesos de los criterios, test una sola vez y ficha del modelo. Extra: más familias y búsqueda de hiperparámetros en varias.

### Palabras que van a aparecer en este reto

| Palabra | Qué significa, en sencillo |
|---|---|
| **Leaderboard** | Tabla de clasificación de los modelos, con sus resultados |
| **Árbol de decisión** | Modelo que decide con una cadena de preguntas sí/no. Fácil de explicar |
| **Bosque aleatorio (random forest)** | Muchos árboles que «votan». Más preciso, menos fácil de explicar |
| **Boosting** | Árboles que se construyen uno tras otro, corrigiendo los errores del anterior. Muy potente |
| **SVM** | Modelo que busca la mejor «frontera» entre las clases |
| **Hiperparámetro** | Un ajuste que hacéis vosotros **antes** de entrenar (profundidad del árbol, número de árboles…) |
| **Búsqueda en rejilla / aleatoria** | Probar combinaciones de hiperparámetros de forma ordenada o al azar |
| **Validación cruzada (CV)** | Evaluar varias veces con particiones distintas para tener una medida fiable |
| **Folds** | Los trozos en que se divide el train en la validación cruzada |
| **AUC con incertidumbre** | El AUC acompañado de cuánto varía de un fold a otro (media ± desviación) |
| **Explicabilidad** | Poder decir **por qué** el modelo toma una decisión |
| **Model card** | Documento de 1–2 páginas que describe un modelo: usos, datos, métricas, límites, riesgos |

| Palabra | Qué significa, en sencillo |
|---|---|
| **Deriva (drift)** | Cuando el comportamiento de los clientes cambia con el tiempo y el modelo deja de funcionar bien |

**Contexto del cliente.** TurisData ya sabe que puede predecir cancelaciones (Sprint 7). Ahora quiere saber **qué modelo poner en producción**. El gerente pregunta: «¿el más preciso? ¿el que puedo entender? ¿el más barato de mantener?». Vuestro equipo compite consigo mismo: tenéis que enfrentar **árboles, bosques, boosting y SVM**, y **elegir un campeón** con argumentos.

**Qué se entrega.**

1. **Leaderboard**: `leaderboard_S08.csv` con al menos **6 modelos** (baseline y logística incluidos) medidos igual. Se rellena con el notebook `S08_06_leaderboard_plantilla` (plantilla del CSV: `Reto_S08/leaderboard_plantilla.csv`).
2. **Model card** del campeón: `model_card.md` siguiendo `Reto_S08/model_card_plantilla.md` (1–2 páginas).
3. `reto_S08.ipynb` con la comparación reproducible y la búsqueda de hiperparámetros de, al menos, **dos** familias.
4. `README.md` para reproducirlo (versiones, semilla, orden de ejecución).

**Restricciones.**

- Mismos datos, mismos folds y misma métrica para todos los modelos (ya lo garantiza la plantilla).
- La búsqueda de hiperparámetros se hace **solo sobre train**. **El test se usa una vez**, únicamente con el campeón.
- Máximo 8 modelos en el leaderboard; tiempo máximo de cada búsqueda: 5 minutos en Colab.
- Solo librerías del curso. Semilla fija (`SEMILLA = 42`).
- El campeón se justifica con **tres** criterios: **rendimiento** (AUC con incertidumbre), **explicabilidad** (¿puede el gerente entender por qué?) y **coste** (tiempo, tamaño, mantenimiento).

**Criterios de evaluación** (0–4 cada uno; misma rúbrica de todos los retos):

| Criterio | 1 · Insuficiente | 2 · Suficiente | 3 · Bueno | 4 · Excelente |
|---|---|---|---|---|
| Corrección técnica | Errores que invalidan el resultado | Correcto con fallos menores | Correcto y bien justificado | Correcto, justificado y con alternativas comparadas |
| Reproducibilidad | No se puede volver a ejecutar | Se ejecuta con ayuda | Se ejecuta desde el README | Además incluye datos o script y versiones fijas |
| Análisis y comunicación al cliente | Solo código o cifras sin interpretar | Interpretación básica | Conclusiones claras para el cliente | Recomendación accionable con límites explicados |
| IA responsable | No se considera | Menciones genéricas | Riesgos específicos identificados | Medidas aplicadas y evaluadas |

*Pistas de IA responsable (en la model card):* usos previstos y **no** previstos, qué variables sensibles hay (país de origen), qué pasa si el comportamiento de los clientes cambia (deriva), cómo se vigilará el modelo y quién revisa las decisiones.

**Pasos sugeridos.**

- **Día 1:** *planning* (25 min); acordar los **pesos** de rendimiento/explicabilidad/coste con la «voz del cliente»; registrar baseline, logística, árbol podado y bosque en el leaderboard (40 min).
- **Día 2, por la mañana:** boosting y SVM en las prácticas; después, búsqueda de hiperparámetros (rejilla o aleatoria) para las dos familias más prometedoras y actualización del leaderboard (35 min).
- **Cierre del miércoles:** sensibilidad de los pesos, elección del campeón, evaluación en test **una vez**, *model card* y README (105 min); autoevaluación y coevaluación; **review + retrospectiva** (última hora).

### Guía paso a paso para principiantes

#### *Paso 1 · Planning y pesos de los criterios (día 1, 20 minutos)*

1. Roles y tareas en el tablero.
2. **Decidid los pesos** de los tres criterios, con una justificación («el gerente necesita entender por qué se avisa»):

| Criterio | Qué mide | Peso (ejemplo) |
|---|---|---|
| **Rendimiento** | AUC con incertidumbre (media ± desviación en la CV) | 50 % |
| **Explicabilidad** | ¿Puede el gerente entender por qué? (Alta, media o baja) | 30 % |
| **Coste** | Tiempo de entrenamiento, tamaño, mantenimiento | 20 % |

Los pesos son vuestros; lo importante es que estén **justificados** y que luego probéis cómo cambia la decisión si cambian.

***Paso 2 · Primeros modelos en el leaderboard (día 1, 30 minutos)***

1. Abrid `S08_06_leaderboard_plantilla` (el cuaderno ya garantiza **mismos datos, mismos folds y misma métrica** para todos).
2. Registrad el **modelo de referencia (baseline)**, la **regresión logística**, un **árbol podado** y un **bosque**.
3. Cada fila del leaderboard: modelo, familia, AUC medio ± desviación, tiempo de entrenamiento y nota de explicabilidad.

***Paso 3 · Boosting, SVM y búsqueda de hiperparámetros (día 2, 25 minutos; los modelos salen de las prácticas)***

1. Añadid **boosting** y **SVM**.
2. Para las **dos familias más prometedoras**, haced una búsqueda de hiperparámetros (rejilla o aleatoria) **solo sobre train**, con validación cruzada. Cada búsqueda no debe pasar de **5 minutos en Colab**.
3. Actualizad el leaderboard con los mejores modelos. Máximo **8 modelos** en total.

***Paso 4 · Elegir el campeón (día 2, 45 minutos)***

1. Calculad la **puntuación ponderada** de cada modelo con los pesos del paso 1.
2. **Análisis de sensibilidad:** cambiad los pesos (por ejemplo, 30/50/20 o 70/10/20) y mirad si **cambia el campeón**. Si cambia fácilmente, decidlo en el informe: la decisión depende de lo que el cliente valore.
3. **Evaluad el campeón en el test, una sola vez.** Ese número va en la model card. No se evalúan los demás modelos en test.

***Paso 5 · Model card y README (día 2, 30 minutos)***

Seguid `model_card_plantilla.md`. Incluye:

1. **Usos previstos y no previstos.**
2. **Datos** de entrenamiento y sus límites (sintéticos).
3. **Métricas** (con incertidumbre) y rendimiento en test.
4. **Limitaciones** y variables sensibles (país de origen).
5. **Deriva y mantenimiento:** qué mediríais en producción para saber que el modelo se degrada.
6. **IA responsable:** quién revisa las decisiones del modelo.

README: versiones, `SEMILLA = 42` y orden de ejecución.

**Cómo usar la IA en este reto**

| Para qué | Ejemplo de petición | Qué tenéis que comprobar |
|---|---|---|
| Entender un modelo | «Explícame cómo funciona un bosque aleatorio con una analogía de votación de expertos, sin fórmulas» | Que podáis explicarlo al gerente |
| Entender un hiperparámetro | «¿Qué hace `max_depth` en un árbol? ¿Qué pasa si es muy grande?» | Que probáis valores y vea lo que ocurre (sobreajuste) |
| Redactar la model card | «Ayúdame a redactar la sección de limitaciones. Estos son los datos: *[resumen]*» | Que **todo** lo que escriba coincide con vuestros resultados |
| Preparar la defensa | «Hazme 5 preguntas difíciles que un gerente podría hacer sobre mi elección de campeón» | Que preparéis la respuesta con **vuestros** datos |

**Reglas del reto:**

- **El test se usa una sola vez**, con el campeón. Probar varios modelos en el test y quedarse con el mejor es hacer trampa.
- **La IA no decide el campeón:** lo decide el cálculo con vuestros pesos.
- Declarad dónde habéis usado IA en el README.

**Errores frecuentes (y cómo evitarlos)**

| Error | Por qué ocurre | Cómo evitarlo |
|---|---|---|
| Comparar modelos con particiones distintas | Cada uno prueba «por su lado» | Usad el cuaderno plantilla: mismos folds para todos |
| Ajustar hiperparámetros mirando el test | «Para ver si mejora» | Solo con **train y validación cruzada** |
| Elegir el modelo por el AUC más alto sin ver la desviación | «0,81 > 0,80» | Si los intervalos se solapan, la diferencia puede ser ruido |
| Model card genérica | Se copia el modelo de ejemplo | Cada apartado con **vuestros** datos y riesgos |

| Error | Por qué ocurre | Cómo evitarlo |
|---|---|---|
| Olvidar la explicabilidad y el coste | Solo se mira la precisión | Puntuadlos y ponderadlos |
| Búsquedas de horas | «Más combinaciones» | Máximo 5 minutos por búsqueda |

**Un buen resultado se parece a...**

> *«Campeón: bosque aleatorio de 200 árboles (AUC 0,78 ± 0,02). No ganó el boosting (AUC 0,79 ± 0,02) porque la diferencia es menor que la incertidumbre, entrena 6 veces más lento y es más difícil de explicar. Si el cliente valorara solo el rendimiento, elegiríamos el boosting.»* (Cifras de ejemplo.)

Fijaos en que se explica **por qué no ganó otro** y **qué cambiaría la elección**.

**Antes de entregar: autoevaluación rápida**

Repasad estas preguntas y rellenad después la hoja autoevaluacion_y_coevaluacion.md (cada persona sube la suya con su entrega).

| Pregunta | Sí / No |
|---|---|
| ¿El leaderboard tiene ≥ 6 modelos de al menos 4 familias? | |
| ¿Hay búsqueda de hiperparámetros con CV sobre train para al menos dos familias? | |
| ¿El campeón se justifica con los tres criterios y se probó la sensibilidad de los pesos? | |
| ¿El AUC de test se calculó una sola vez, solo para el campeón? | |
| ¿La model card está completa (usos, datos, métricas, limitaciones, IA responsable, mantenimiento)? | |
| ¿El cuaderno se ejecuta entero y el README tiene versiones? | |
| ¿Está subido a Git, con autoevaluación y coevaluación? | |

**Si os atascáis**

- **No sabemos qué peso poner:** pensad en lo que diría el gerente. Si prioriza entender, sube la explicabilidad.
- **La búsqueda tarda demasiado:** reducid el número de combinaciones o usad búsqueda aleatoria con pocas iteraciones.
- **Dos modelos empatan:** es un resultado válido. Elegid el más simple y explicadlo.
- Más ayuda: Cómo se trabaja un reto.

**Qué se enseña en la review** (5 min por equipo): el leaderboard (tabla o gráfico), el campeón y **por qué no ganó otro**, y una frase sobre qué cambiaría la elección si el cliente valorara otra cosa.

**Preguntas de la retrospectiva:** ¿nos sorprendió que un modelo sencillo compitiera con uno complejo? ¿Qué criterio pesó más en nuestra decisión? ¿Qué mediríamos en producción para saber que el modelo se degrada?

## Definition of Done (lista de comprobación)

Si queda una casilla sin marcar, **el reto no está terminado**.

- [ ] `leaderboard_S08.csv` con ≥ 6 modelos de al menos 4 familias (árbol, ensemble, SVM y lineal/baseline).
- [ ] Búsqueda de hiperparámetros con validación cruzada sobre train para al menos dos familias.
- [ ] Campeón elegido con los tres criterios y análisis de sensibilidad de los pesos.
- [ ] AUC de test calculado **una sola vez**, solo para el campeón.
- [ ] `model_card.md` completa (usos, datos, métricas, limitaciones, IA responsable, mantenimiento).
- [ ] Notebook ejecutable de principio a fin y README con versiones.
- [ ] Subido a Git; autoevaluación y coevaluación rellenadas.